

全国高等院校计算数学教材

现代数值计算方法

主编 肖筱南

编著 肖筱南 赵来军
党林立

北京大学出版社

· 北 京 ·

图书在版编目(CIP)数据

现代数值计算方法/肖筱南主编. —北京: 北京大学出版社, 2003. 7

ISBN 7-301-06332-6

. 现... . 肖... . 数值计算-计算方法-高等学校-教材
. 0241

中国版本图书馆 CIP 数据核字(2003)第 034468 号

书 名: 现代数值计算方法

著作责任者: 肖筱南 赵来军 党林立

责任编辑: 刘 勇

标准书号: ISBN 7-301-06332-6/O · 0566

出版发行: 北京大学出版社

地 址: 北京市海淀区中关村 北京大学校内 100871

网 址: <http://cbs.pku.edu.cn> 电子信箱: zpup@pup.pku.edu.cn

电 话: 邮购部 62752015 发行部 62750672 理科编辑部 62752021

排 版 者: 北京高新特打字服务社 51736661

印 刷 者: 北京大学印刷厂

经 销 者: 新华书店

850×1168 32 开本 8.5 印张 220 千字

2003 年 7 月第 1 版 2003 年 7 月第 1 次印刷

印 数: 0001- 6000 册

定 价: 15.00 元

未经许可, 不得以任何方式复制或抄袭本书之部分或全部内容。

版权所有, 翻版必究

内 容 简 介

本书是为理工科院校各专业本科生、研究生开设的“数值计算方法”课程而编写的教材。全书系统地介绍了现代科学与工程计算中常用的数值分析理论、方法及有关应用,内容包括误差分析、线性方程组的直接解法与迭代解法、非线性方程的数值解法、矩阵的特征值与特征向量的计算、插值法与曲线拟合、数值积分与数值微分、常微分方程初值问题的数值解法等。本书取材新颖、阐述严谨、内容丰富、重点突出、推导详尽、思路清晰、深入浅出、富有启发性,便于教学与自学。为了加强对学生基本知识的训练与综合能力的培养,每章末都配备了小结并精选了相当数量的算法与 C 语言程序设计上机实例、复习思考题及综合练习题,以便读者巩固、复习、应用所学知识。书末附有习题答案与提示,可供教师与学生参考。

本书可作为理工科院校各专业本科生、研究生“数值计算方法”课程的教材或教学参考书,也可供从事数值计算的科技工作者学习参考。

前 言

随着科学技术的不断发展与计算机技术的广泛应用,数值计算越来越显示出其重要作用,科学计算的重要性被愈来愈多的人所认识.而对于当今信息社会的大学生而言,则更应当具备这方面的知识与能力.事实上,在众多科技与工程领域中,如果没有科学计算,就不可能产生一流的研究成果.由此可见科学计算在科技发展中的重要性.正因如此,许多理工科大学都已将“计算方法”列为了大学生与硕士研究生的必修课程,以便学生将来能为众多的科学与工程技术问题提供准确、有效、可靠、科学的数值计算方法.

为了进一步提高数值计算方法的教学质量,更好地满足新世纪对高等理工科院校培养复合型高素质人才的要求,我们在紧扣教育部最新颁布的工科院校“计算方法”教学大纲的前提下,结合多年的教学研究与实践,博采众家之长并针对理工科院校学生学习计算方法的实际需要,几经易稿编写了本书.在编写过程中,我们既充分考虑到现代科学技术发展的需要,系统地介绍了现代科学与工程计算中常用的数值计算方法、理论及其应用,又充分考虑到理工科院校开设“计算方法”课程的教学特点和需要,在遵循本学科科学性与系统性、基础性与实用性并重的前提下,尽量注意贯彻由浅入深、循序渐进、融会贯通的教学原则与直观形象的教学方法,既注意现代数值计算方法基本概念、基本理论和方法的阐述,又注意对学生基本计算、编程能力的训练和分析问题、解决问题能力的培养,以达到使学生真正掌握好这门课程之目的.此外,本书每章末还都配备了

小结、算法及 C 语言程序设计实例、复习思考题和综合练习题,以供读者巩固、复习、应用所学知识.书末附有习题答案与提示,可供教师与学生参考.

本书可作为高等理工科院校本科生、研究生“计算方法”课的教材或教学参考书.全书共分八章,内容包括:数值计算中的误差分析,线性方程组的数值解法,非线性方程的数值解法,矩阵的特征值及特征向量的计算,插值法,最小二乘法与曲线拟合,数值微积分,常微分方程的数值解法等.本书结构严谨、逻辑清晰、深入浅出、分析深刻、富有新意,便于教学与阅读.书中内容包括了现代科学与工程计算中常用的数值分析理论及方法,本书各章内容具有一定的独立性.讲授全书约需 72 学时,但根据实际情况与专业需要,删去部分内容,也可适用于 40~60 学时的教学需要.

本书由肖筱南教授主编,编著者为肖筱南教授、赵来军博士与党林立博士.在本书的编写过程中,得到了北京大学出版社的大力支持与帮助,责任编辑刘勇副编审为本书的出版付出了辛勤劳动,在此一并表示诚挚的谢意.

我们谨将本书奉献给读者,希望它能成为每位读者学习数值计算方法的良师益友.限于编者水平,书中难免有不妥之处,恳请读者指正.

编 者

2003 年 5 月

目 录

第一章 数值计算中的误差分析.....	(1)
§ 1 数值计算的对象、任务与特点	(1)
§ 2 误差与数值计算的误差估计	(2)
一、误差的来源与分类	(2)
二、误差与有效数字	(4)
三、数值计算的误差估计	(8)
§ 3 选用和设计算法时应遵循的原则	(11)
一、选用数值稳定的计算公式,控制舍入误差的传播	(11)
二、尽量简化计算步骤以便减少运算次数	(13)
三、尽量避免两个相近的数相减.....	(13)
四、绝对值太小的数不宜作除数.....	(14)
五、合理安排运算顺序,防止大数“吃掉”小数	(15)
本章小结	(15)
算法与程序设计实例	(16)
思考题	(19)
习题一	(19)
第二章 线性方程组的数值解法	(21)
§ 1 线性方程组的直接解法	(22)
一、高斯(Gauss) 列主元消去法	(22)
二、高斯全主元消去法	(27)
三、选主元素消去法的应用	(28)
四、矩阵的三角分解	(30)
五、平方根法及改进的平方根法.....	(37)
六、追赶法	(43)

七、列主元三角分解法	(45)
§ 2 线性方程组的迭代解法	(50)
一、雅可比(Jacobi)迭代法	(50)
二、高斯-塞德尔(Gauss-Seidel)迭代法	(53)
三、逐次超松弛(SOR)迭代法	(54)
§ 3 迭代法的收敛性	(57)
一、向量范数与矩阵范数	(58)
二、迭代法的收敛性	(60)
本章小结	(67)
算法与程序设计实例	(68)
思考题	(73)
习题二	(74)
第三章 非线性方程的数值解法	(78)
§ 1 根的搜索与二分法	(78)
一、根的搜索	(78)
二、二分法	(80)
§ 2 迭代法及其迭代收敛的加速方法	(83)
一、迭代法	(84)
二、迭代收敛的加速方法	(93)
§ 3 牛顿(Newton)迭代法	(96)
一、牛顿迭代法	(96)
二、迭代法的收敛阶	(104)
§ 4 弦截法	(105)
本章小结	(108)
算法与程序设计实例	(109)
思考题	(111)
习题三	(112)
*第四章 矩阵的特征值及特征向量的计算	(114)
*§ 1 幂法与反幂法	(114)

一、幂法	(115)
二、反幂法	(120)
*§ 2 雅可比方法	(122)
一、古典雅可比方法	(123)
二、雅可比过关法	(128)
本章小结	(130)
算法与程序设计实例	(131)
思考题	(134)
习题四	(135)
第五章 插值法.....	(137)
§ 1 拉格朗日(Lagrange)插值	(138)
一、代数插值问题	(138)
二、插值多项式的存在与惟一性	(139)
三、线性插值	(139)
四、抛物线插值	(142)
五、拉格朗日插值多项式	(143)
§ 2 分段低次插值	(146)
一、分段线性插值	(148)
二、分段抛物线插值	(149)
§ 3 差商与牛顿插值多项式	(150)
一、差商的定义及性质	(151)
二、牛顿插值多项式及其余项	(153)
§ 4 差分与等距节点插值公式	(157)
一、差分的定义及性质	(157)
二、等距节点插值多项式及其余项	(159)
*§ 5 埃尔米特(Hermite)插值	(163)
一、一般情形的埃尔米特插值问题	(163)
二、特殊情形的埃尔米特插值问题	(166)
*§ 6 三次样条插值	(167)

一、三次样条插值函数的定义	(168)
二、三次样条插值函数的构造	(169)
本章小结	(177)
算法与程序设计实例	(178)
思考题	(181)
习题五	(182)
第六章 最小二乘法与曲线拟合	(186)
§ 1 用最小二乘法求解矛盾方程组	(186)
一、最小二乘原理	(186)
二、用最小二乘法求解矛盾方程组	(187)
§ 2 用多项式作最小二乘曲线拟合	(190)
本章小结	(195)
算法与程序设计实例	(196)
思考题	(200)
习题六	(200)
第七章 数值微积分	(203)
§ 1 牛顿-柯特斯(Newton-Cotes) 公式	(204)
一、数值求积的基本思想	(204)
二、插值型求积公式	(205)
三、牛顿-柯特斯公式	(206)
§ 2 龙贝格(Romberg) 求积公式	(209)
一、复化求积公式	(209)
二、变步长求积公式	(211)
三、龙贝格求积公式	(212)
*§ 3 高斯型求积公式	(214)
一、代数精确度	(214)
二、高斯型求积公式	(216)
三、勒让德(Legendre) 多项式	(219)
§ 4 数值微分	(219)

一、差商型求导公式	(219)
二、插值型求导公式	(220)
本章小结	(222)
算法与程序设计实例	(223)
思考题	(225)
习题七	(226)
第八章 常微分方程的数值解法.....	(228)
§ 1 欧拉(Euler)方法	(229)
一、欧拉公式	(229)
二、欧拉预估-校正方法	(230)
三、欧拉方法的误差估计	(232)
§ 2 龙格-库塔(Runge-Kutta)方法	(233)
一、龙格-库塔方法的基本思想	(233)
二、二阶龙格-库塔公式	(234)
三、高阶龙格-库塔公式	(235)
§ 3 线性多步方法	(237)
一、线性多步方法的基本思想	(237)
二、阿达姆斯(Adams)外插公式及其误差	(238)
三、阿达姆斯内插公式	(240)
§ 4 一阶微分方程组和高阶微分方程的数值解法	(241)
一、一阶微分方程组的数值解法	(241)
二、高阶微分方程的数值解法	(242)
本章小结	(243)
算法与程序设计实例	(243)
思考题	(246)
习题八	(246)
习题答案与提示.....	(248)
参考书目.....	(253)

第一章 数值计算中的误差分析

§ 1 数值计算的对象、任务与特点

随着电子计算机的普及与发展,数值计算已成为科学研究与工程设计中必不可少的重要手段.在科学技术高速发展的今天,学习、掌握数值计算方法并会用电子计算机来解决科研与工程实际中的数值计算问题,已成为广大科技与工程技术人员迫切需要.因此,在理工科高等院校的本科生与研究生的教育中,很多专业都将数值计算方法列为必修课程.

数值计算方法(也称计算方法,数值方法)是研究科学与工程数学问题的数值解及其理论的一个数学分支,它的涉及面很广,如涉及代数、微积分、微分方程的数值解等问题.自电子计算机成为数值计算的主要工具以来,数值计算方法的主要任务就是研究适合于在计算机上使用的数值计算方法及与此相关的理论,如方法的收敛性、稳定性以及误差分析等,此外,还要根据计算机的特点研究计算时间最短、需要计算机内存最少等计算方法问题.我们从计算机解决科学计算问题时经历的几个过程:实际问题
数学模型 提出数学问题 设计高效、可靠的数值计算方法
程序设计 上机计算求出结果,可以看出,由实际问题的提出到上机求得问题解答,整个过程的关键是如何根据数学模型提出求解的数值计算方法直到编出程序上机算出结果,这一过程既是计算数学的任务,也是数值计算方法的研究对象.可见,数值计算方法不同于纯数学的是,它既具有数学的抽象性与严格性,又具有应用的广泛性与实际试验的技术性,它是一门与计算机紧密结合的实用性很强的有着自身研究方法 with 理论系统的计算数学课程.

具体而言,数值计算方法的特点可概括为:应提供能让计算机直接处理的,包括加减乘除运算和逻辑运算及具有完整解题步骤的,切实可行的有效算法与程序,它可用框图、算法语言、数学语言或自然语言来描述,并有可靠的理论分析,能任意逼近且达到精度要求,对近似算法应保证收敛性和数值稳定性、进行必要的误差分析.此外,还要注意算法能否在计算机上实现,应避免因数值方法选用不当、程序设计不合理而导致超过计算机的存贮能力,或导致计算结果精度不高等.

根据“数值计算”的特点,学习本课程时,我们应首先注意掌握数值计算方法的基本原理和思想,注意方法处理的技巧及其与计算机的密切结合,重视误差分析、收敛性及稳定性的基本理论;其次还要注意方法的使用条件,通过各种方法的比较,了解各种方法的异同及优缺点;为了学好这门课程,我们还应通过一定数量的理论与计算练习,培养与提高我们使用各种数值计算方法解决实际计算问题的能力.

§ 2 误差与数值计算的误差估计

一、误差的来源与分类

在数值计算过程中,估计计算结果的精确度是十分重要的工作,而影响精确度的因素是各种各样的误差,它们可分为两大类:一类称为“过失误差”,它一般是由人为造成的,这是可以避免的,故在“数值计算”中我们不讨论它;而另一类称为“非过失误差”,这在“数值计算”中往往是无法避免的,也是我们要研究的.按照它们的来源,误差可分为以下四种:

1. 模型误差

用数值计算方法解决实际问题时,首先必须建立数学模型.由于实际问题的复杂性,在对实际问题进行抽象与简化时,往往为了

抓住主要因素而忽略了一些次要因素, 这样就会使得建立起来的数学模型只是复杂客观现象的一种近似描述, 它与实际问题之间总会存在一定的误差. 我们把数学模型与实际问题之间出现的这种误差称为模型误差.

2. 观测误差

在数学模型中往往包含一些由观测或实验得来的物理量, 由于测量工具精度和测量手段的限制, 它们与实际量大小之间必然存在误差, 这种误差称为观测误差.

3. 截断误差

由实际问题建立起来的数学模型, 在很多情况下要得到准确解是困难的, 通常要用数值方法求出它的近似解. 例如常用有限过程逼近无限过程, 用能计算的问题代替不能计算的问题. 这种数学模型的精确解与由数值方法求出的近似解之间的误差称为截断误差, 由于截断误差是数值计算方法固有的, 故又称为方法误差.

例如用函数 $f(x)$ 的泰勒(Taylor)展开式的部分和 $S_n(x)$ 去近似代替 $f(x)$, 其余项 R_n 就是真值 $f(x)$ 的截断误差.

4. 舍入误差

用计算机进行数值计算时, 由于计算机的位数有限, 计算时只能对超过位数的数字进行四舍五入, 由此产生的误差称为舍入误差. 例如用 2.71828 作为无理数 e 的近似值产生的误差就是舍入误差. 应请读者注意的是, 虽然少量的舍入误差是微不足道的, 但在计算机上完成了千百万次运算之后, 舍入误差的积累却可能是十分惊人的.

综上所述, 数值计算中除了可以完全避免的过失误差外, 还存在难以回避的模型误差、观测误差、截断误差和舍入误差. 而在这四种误差来源的分析中, 前两种误差是客观存在的, 后两种误差是由计算方法所引起的. 因此, 后两种误差将是数值计算方法的主要研究对象, 讨论它们在计算过程中的传播和对计算结果的影响, 并找出误差的界, 对研究误差的渐近特性和改进算法的近似程度具

有重大的实际意义.

二、误差与有效数字

1. 绝对误差与绝对误差限

设某一量的精确值为 x , 其近似值为 x^* , 则称

$$E(x) = x - x^*$$

为近似值 x^* 的绝对误差, 简称误差.

当 $E(x) > 0$ 时, 称 x^* 为弱近似值或亏近似值, 当 $E(x) < 0$ 时, 称 x^* 为强近似值或盈近似值.

一般地, 某一量的精确值 x 是不知道的, 因而 $E(x)$ 也无法求出, 但往往可以估计出 $E(x)$ 的上界, 即存在 $\delta > 0$, 使得

$$E(x) = x - x^* \leq \delta,$$

此时, 称 δ 为近似值 x^* 的绝对误差限, 简称误差限或精度. δ 越小, 表示近似值 x^* 的精度越高. 显然有

$$x^* - \delta \leq x \leq x^* + \delta.$$

有时也用

$$x = x^* \pm \delta$$

来表示近似值 x^* 的精度或精确值 x 的所在范围. 绝对误差是有量纲的.

例如, 用毫米刻度的直尺去测量一长度为 x 的物体, 测得其近似值为 $x^* = 84 \text{ mm}$, 由于直尺以毫米为刻度, 所以其误差不超过 0.5 mm , 即

$$x - 84 \leq 0.5(\text{mm}).$$

这样, 虽然不能得出准确值 x 的长度是多少, 但从这个不等式可以知道 x 的范围是

$$83.5 \text{ mm} \leq x \leq 84.5 \text{ mm},$$

即说明 x 必在 $[83.5 \text{ mm}, 84.5 \text{ mm}]$ 内.

2. 相对误差与相对误差限

用绝对误差来刻画一个近似值的精确程度是有局限性的, 在

很多场合中它无法显示出近似值的准确程度. 如测量 100 m 和 10 m 两个长度, 若它们的绝对误差都是 1 cm, 显然前者的测量结果比后者的准确. 由此可见, 决定一个量的近似值的精确度, 除了要看绝对误差的大小外, 还必须考虑该量本身的大小, 为此引入相对误差的概念.

绝对误差与精确值之比, 即称

$$E_r(x) = \frac{E(x)}{x} = \frac{x - x^*}{x}$$

为近似值 x^* 的相对误差. 在实际中, 由于精确值 x 一般无法知道, 因此往往取

$$E_r^*(x) = \frac{x - x^*}{x^*}$$

作为近似值 x^* 的相对误差.

类似于绝对误差的情况, 若存在 $\delta > 0$, 使得

$$E_r(x) = \left| \frac{x - x^*}{x^*} \right| < \delta,$$

则称 δ 为近似值 x^* 的相对误差限. 相对误差是无量纲的数, 通常用百分比表示, 称为百分误差.

根据上述定义可知, 当 $x - x^* = 1 \text{ cm}$ 时, 测量 100 m 物体时的相对误差

$$E_r(x) = \frac{1}{10000} = 0.01\%,$$

测量 10 m 物体时的相对误差

$$E_r(x) = \frac{1}{1000} = 0.1\%.$$

可见前者的测量结果要比后者精确. 所以, 在分析误差时, 相对误差更能刻画误差的特性.

3. 有效数字

为了能给出一种数的表示法, 使之既能表示其大小, 又能表示其精确程度, 于是需要引进有效数字的概念. 在实际计算中, 当准

确值 x 有很多位数时, 我们常按四舍五入的原则得到 x 的近似值 x^* . 例如无理数

$$e = 2.718281828\dots,$$

若按四舍五入原则分别取三位和六位小数时, 则得

$$e \approx 2.72, \quad e \approx 2.71828.$$

不管取几位小数得到的近似数, 其绝对误差都不超过末位数的半个单位, 即

$$e - 2.72 \leq \frac{1}{2} \times 10^{-2},$$

$$e - 2.71828 \leq \frac{1}{2} \times 10^{-5}.$$

下面我们将四舍五入抽象成数学语言, 进而引进“有效数字”的概念.

若近似值 x^* 的绝对误差限是某一位的半个单位, 就称其“准确”到这一位, 且从该位直到 x^* 的第一位非零数字共有 n 位, 则称近似数 x^* 有 n 位有效数字.

引入有效数字概念后, 我们规定所写出的数都应该是有效数字, 且在同一计算问题中, 参加运算的数, 都应该有相同的有效数字.

例如, 下列各数 358.467, 0.00427511, 8.000034, 8.000034 $\times 10^3$ 的具有 5 位有效数字的近似值分别是 358.47, 0.0042751, 8.0000, 8000.0.

注意: 8.000034 的 5 位有效数字是 8.0000, 而不是 8, 因为 8 只有 1 位有效数字. 前者精确到 0.0001, 而后者仅精确到 1, 两者相差是很大的. 显然, 前者远较后者精确, 由此可见, 有效数字尾部的零不能随意省去, 以免损失精度.

一般地, 任何一个实数 x 经四舍五入后得到的近似值 x^* 都可写成如下标准形式

$$x^* = \pm (a_1 \times 10^{-1} + a_2 \times 10^{-2} + \dots + a_n \times 10^{-n}) \times 10^m. \quad (1.2.1)$$

所以,当其绝对误差限满足

$$x - x^* \leq \frac{1}{2} \times 10^{m-n} \quad (1.2.2)$$

时,则称近似值 x^* 具有 n 位有效数字,其中 m 为整数, a_1 是 1 到 9 中的一个数字, a_2, a_3, \dots, a_n 是 0 到 9 中的数字.

根据上述有效数字的定义,不难验证 e 的近似值 2.71828 具有 6 位有效数字.事实上,

$$2.71828 = (2 \times 10^{-1} + 7 \times 10^{-2} + 1 \times 10^{-3} + 8 \times 10^{-4} + 2 \times 10^{-5} + 8 \times 10^{-6}) \times 10.$$

这里 $m=1, n=6$. 因为

$$e - 2.71828 = 0.000001828... < \frac{1}{2} \times 10^{-5},$$

所以它具有 6 位有效数字.

有效数字不但给出了近似值的大小,而且还给出了它的绝对误差限.例如有效数字 3567.82, 0.423×10^{-2} , 0.4230×10^{-2} 的绝对误差限分别为 $\frac{1}{2} \times 10^{-2}$, $\frac{1}{2} \times 10^{-5}$, $\frac{1}{2} \times 10^{-6}$. 必须注意,在有效数字的记法中, 0.423×10^{-2} 与 0.4230×10^{-2} 是有区别的,前者只有 3 位有效数字,而后者则具有 4 位有效数字.

还需指出的是,一个准确数字的有效数字的位数,应当说有无穷多位,例如 $1/8 = 0.125$ 不能说只有 3 位有效数字.

有效数字与绝对误差、相对误差有如下关系:

(1) 若某数 x 的近似值 x^* 有 n 位有效数字,则此近似值 x^* 的绝对误差限为

$$x - x^* \leq \frac{1}{2} \times 10^{m-n}.$$

由此可见,当 m 一定时,有效数字位数 n 越多,其绝对误差限越小.

(2) 若用(1.2.1)式表示的近似数 x^* 具有 n 位有效数字,则其相对误差限为

$$E_r^*(x) = \frac{1}{2 \times 10^{m-1}} \times 10^{-(n-1)}. \quad (1.2.3)$$

反之,若 x^* 的相对误差限满足

$$E_r^*(x) = \frac{1}{2(\times 10^{m-1} + 1)} \times 10^{-(n-1)}, \quad (1.2.4)$$

则 x^* 至少具有 n 位有效数字.

事实上,由(1.2.1)式可知

$$\times 10^{m-1} - x^* = (\times 10^{m-1} + 1) \times 10^{m-1},$$

所以

$$E_r^*(x) = \frac{x - x^*}{x^*} = \frac{\times 10^{m-1}}{\times 10^{m-1} + 1} \times \frac{1}{2 \times 10^{m-1}} \times 10^{-(n-1)}.$$

反之,由

$$\begin{aligned} x - x^* &= x^* \cdot E_r^*(x) \\ &= (\times 10^{m-1} + 1) \times 10^{m-1} \times \frac{1}{2(\times 10^{m-1} + 1)} \times 10^{-(n-1)} \\ &= \frac{1}{2} \times 10^{m-n} \end{aligned}$$

知, x^* 至少具有 n 位有效数字.

可见有效数字的位数越多,相对误差限就越小,即近似数的有效位数越多,用这个近似数去近似代替准确值的精度就越高.

例1 为使 $\sqrt{20}$ 的近似值的相对误差小于1%,问至少应取几位有效数字?

解 $\sqrt{20}$ 的近似值的首位非零数字是 $\times 10^1 = 4$,由(1.2.3)式有

$$E_r^*(x) = \frac{1}{2 \times 4 \times 10^{m-1}} \times 10^{-(n-1)} < 1\%,$$

解之得 $n > 2$,故取 $n = 3$ 即可满足要求.也就是说只要 $\sqrt{20}$ 的近似值具有3位有效数字,就能保证 $\sqrt{20} \approx 4.47$ 的相对误差小于1%.

三、数值计算的误差估计

数值计算中误差产生与传播的情况非常复杂,参与运算的数

据往往都是些近似数, 它们都带有误差. 而这些数据的误差在多次运算中又会进行传播, 使计算结果产生一定的误差, 这就是误差的传播问题. 以下介绍利用函数的 Taylor 公式来估计误差的一种常用方法.

设可微函数 $y = f(x_1, x_2, \dots, x_n)$ 中的自变量 x_1, x_2, \dots, x_n 相互独立, 又 $x_1^*, x_2^*, \dots, x_n^*$ 依次是 x_1, x_2, \dots, x_n 的近似值, 则 y 的近似值 $y^* = f(x_1^*, x_2^*, \dots, x_n^*)$.

将函数 $f(x_1, x_2, \dots, x_n)$ 在点 $(x_1^*, x_2^*, \dots, x_n^*)$ 处作泰勒展开, 并略去其中的高阶小量等项, 即可得到 y 的近似值 y^* 的绝对误差和相对误差的估计式为

$$\begin{aligned} E(y^*) &= y - y^* = f(x_1, x_2, \dots, x_n) - f(x_1^*, x_2^*, \dots, x_n^*) \\ &= \sum_{i=1}^n \frac{f(x_1^*, x_2^*, \dots, x_n^*)}{x_i} (x_i - x_i^*) \\ &= \sum_{i=1}^n \frac{f(x_1^*, x_2^*, \dots, x_n^*)}{x_i} \cdot E(x_i^*), \end{aligned} \quad (1.2.5)$$

$$\begin{aligned} E_r(y^*) &= \frac{E(y^*)}{y^*} = \sum_{i=1}^n \frac{f(x_1^*, x_2^*, \dots, x_n^*)}{x_i} \frac{x_i^*}{y^*} \frac{E(x_i^*)}{x_i^*} \\ &= \sum_{i=1}^n \frac{x_i^*}{y^*} \frac{f(x_1^*, x_2^*, \dots, x_n^*)}{x_i} \cdot E_r(x_i^*). \end{aligned} \quad (1.2.6)$$

以上两式中的各项

$$\frac{f(x_1^*, x_2^*, \dots, x_n^*)}{x_i} \quad \text{和} \quad \frac{x_i^*}{y^*} \frac{f(x_1^*, x_2^*, \dots, x_n^*)}{x_i} \quad (i = 1, 2, 3, \dots, n)$$

分别为各个 x_i^* ($i = 1, 2, 3, \dots, n$) 对 y^* 的绝对误差和相对误差的增长因子, 它们分别表示绝对误差 $E(x_i^*)$ 和相对误差 $E_r(x_i^*)$ 经过传播后增大或缩小的倍数.

利用(1.2.5)式或(1.2.6)式, 还可得到两数和、差、积、商的误差估计.

例 2 试估计 $y = f(x_1, x_2, \dots, x_n) = x_1 + x_2 + \dots + x_n$ 的绝对误差与相对误差.

解 因为 $\frac{f}{x_i} = 1$, 所以由(1.2.5)式知

$$E(y^*) = \sum_{i=1}^n E(x_i^*), \quad E_r(y^*) = \sum_{i=1}^n E_r(x_i^*),$$

即和的绝对误差不超过各加数的绝对误差之和.

为了估计和式 y 的相对误差, 考虑到误差源 $E(x_i^*)$ 同号这一最坏情况, 不妨假设 $x_i^* > 0$ ($i = 1, 2, \dots, n$), 于是可得

$$E_r(y^*) = \max_{1 \leq i \leq n} E_r(x_i^*),$$

即和的相对误差不超过相加各项中最不准确的一项的相对误差.

例 3 测得某桌面的长 a 的近似值为 $a^* = 120$ cm, 宽 b 的近似值 $b^* = 60$ cm, 若已知 $a - a^* = 0.2$ cm, $b - b^* = 0.1$ cm, 试求近似面积 $S^* = a^* b^*$ 的绝对误差限与相对误差限.

解 因为 $S = ab$, $\frac{S}{a} = b$, $\frac{S}{b} = a$, 则由(1.2.5)式得

$$\begin{aligned} E(S^*) &= \frac{S^*}{a^*} E(a^*) + \frac{S^*}{b^*} E(b^*) \\ &= b^* E(a^*) + a^* E(b^*). \end{aligned}$$

所以

$$E(S^*) = 60 \times 0.2 + 120 \times 0.1 = 24 \text{ cm}^2.$$

而相对误差限为

$$E_r(S^*) = \left| \frac{E(S^*)}{S^*} \right| = \frac{E(S^*)}{a^* b^*} = \frac{24}{7200} = 0.33\%.$$

最后指出, 在由误差估计式得出绝对误差限和相对误差限的估计时, 由于取了绝对值并用三角不等式放大, 因此是按最坏的情形得出的, 所以由此得出的结果是保守的. 事实上, 出现最坏情形的可能性是很小的. 因此近年来出现了一系列关于误差的概率估计. 一般来说, 为了保证运算结果的精确度, 只要根据运算量的大小, 比结果中所要求的有效数字的位数多取 1 位或 2 位进行计算就可以了.

§ 3 选用和设计算法时应遵循的原则

利用电子计算机来求数学模型的数值解时, 必须首先设计算法, 而算法的好坏, 将会直接影响到计算机的使用效率, 也会影响到数值计算结果的精确度与真实性. 为了选用到计算量小、精确度高的有效算法, 选用算法时一般应遵循以下原则: 算法是否稳定; 算法的逻辑结构是否简单; 算法的运算次数和算法的存储量是否尽量少等等. 同时, 为了让计算机能更好地解决实际问题, 我们除了要首先建立正确的数学模型外, 还应针对具体问题适当地选择与改造算法, 熟悉算法的设计原理与计算过程, 精心设计与编写计算机程序, 才能获得满意的计算效果. 下面, 通过对误差传播规律与算法优劣的分析, 指出选用和设计算法时应注意的几个问题.

一、选用数值稳定的计算公式, 控制舍入误差的传播

一个算法是否稳定, 这是十分重要的. 如果算法不稳定, 则数值计算的结果就会严重背离数学模型的真实结果. 因此, 在选择数值计算公式来进行近似计算时, 我们应特别注意选用那些在数值计算过程中不会导致误差迅速增长的计算公式.

例如计算定积分

$$I_n = \int_0^1 e^{-x} x^n dx, \quad n = 0, 1, 2, \dots \quad (1.3.1)$$

利用分部积分法不难求得 I_n 的递推关系式为

$$\begin{cases} I_n = 1 - nI_{n-1}, \\ I_0 = 1 - e^{-1} = 0.6321. \end{cases} \quad (1.3.2)$$

由(1.3.2)可依次算得结果如下:

$$\begin{aligned} I_0 &= 0.6321, & I_1 &= 0.3680, & I_2 &= 0.2640, \\ I_3 &= 0.2080, & I_4 &= 0.1680, & I_5 &= 0.1600, \\ I_6 &= 0.0400, & I_7 &= 0.7200, & I_8 &= -0.7280. \end{aligned}$$

由于

$$0 < I_n < e^{-1} \max_{0 \leq x \leq 1} (e^x) \cdot \int_0^1 x^n dx = \frac{1}{n+1}, \quad (1.3.3)$$

则由以上 I_n 的不等式可看出

$$I_7 < \frac{1}{8} = 0.1250.$$

可见按递推关系式(1.3.2)算出的 I_7, I_8 的结果是错误的. 错误产生的原因是因为 I_0 本身有不超过 $(1/2) \times 10^{-4}$ 的舍入误差, 此误差在运算中传播、积累很快, 传播到 I_7 与 I_8 时, 该误差已放大了 7 与 8 倍, 从而使得 I_7, I_8 的结果面目全非.

但若将(1.3.2)式改写为

$$I_{n-1} = \frac{1}{n} (1 - I_n), \quad (1.3.4)$$

因为

$$I_n > e^{-1} \min_{0 \leq x \leq 1} (e^x) \cdot \int_0^1 x^n dx = \frac{e^{-1}}{n+1},$$

则结合(1.3.3)式可得

$$\frac{e^{-1}}{n+1} < I_n < \frac{1}{n+1}.$$

当 $n=7$ 时, 由上面的估计式可取 $I_7 = 0.1124$ 作初始值, 依算式(1.3.4)计算, 有如下结果:

$$I_7 = 0.1124, \quad I_6 = 0.1269, \quad I_5 = 0.1455,$$

$$I_4 = 0.1708, \quad I_3 = 0.2073, \quad I_2 = 0.2643,$$

$$I_1 = 0.3680, \quad I_0 = 0.6320.$$

此时, 由于因 I_7 引起的初始误差在以后的计算过程中逐渐减小, 最后便得到了与 $I_0 = 1 - e^{-1} = 0.6321$ 相差无几的精确结果.

在数值计算中, 我们将在计算过程中误差不会增长的计算公式称为是数值稳定的, 否则就是不稳定的. 为了不影响数值计算结果的精确度与真实性, 在实际应用中, 我们应选用数值稳定的计算公式, 尽量避免使用数值不稳定的公式.

二、尽量简化计算步骤以便减少运算次数

同样一个计算问题,若能选用更为简单的计算公式,减少运算次数,不但可以节省计算量,提高计算速度,还能简化逻辑结构,减少误差积累,这也是数值计算必须遵循的原则与计算方法研究的一项主要内容.

例如,计算多项式

$$P_n(x) = a_n x^n + a_{n-1} x^{n-1} + \dots + a_1 x + a_0$$

的值,若采用逐项计算然后相加的算法,计算 $a_k x^k$ 要做 k 次乘法,而 $P_n(x)$ 共有 $n+1$ 项,所以需做

$$1 + 2 + \dots + (n-1) + n = \frac{1}{2}n(n+1)$$

次乘法和 n 次加法.但若采用递推算法(又称秦九韶算法):

$$\begin{cases} u_0 = a_0, \\ u_k = u_{k-1} \cdot x + a_{n-k}, \end{cases} \quad (1.3.5)$$

对 $k=1, 2, \dots, n$ 反复执行算式(1.3.5),则只需 n 次乘法和 n 次加法,即可算出 $P_n(x)$ 的值.

又如计算和式

$$\sum_{n=1}^{1000} \frac{1}{n(n+1)}$$

的值,若直接逐项求和,则其运算次数不仅很多而且误差积累也不小,但若将该和式简化为

$$\sum_{n=1}^{1000} \frac{1}{n(n+1)} = \sum_{n=1}^{1000} \left[\frac{1}{n} - \frac{1}{n+1} \right] = 1 - \frac{1}{1001},$$

则整个计算就只需一次除法和一次减法.

三、尽量避免两个相近的数相减

在数值计算中,两个相近的数相减将会造成有效数字的严重损失.因此,遇到此种情况,应当多保留这两个数的有效数字,或尽

量避免减法运算, 改变计算方法, 根据不同情况对公式进行处理, 如可通过因式分解、分子分母有理化、三角函数恒等式、其他恒等式、Taylor 展开式等计算公式, 防止减法运算的出现.

例如, 当 $x = 1000$ 时, 计算

$$\sqrt{x+1} - \sqrt{x}$$

的值, 若取 4 位有效数字计算

$$\sqrt{x+1} - \sqrt{x} = \sqrt{1001} - \sqrt{1000} \quad 31.64 - 31.62 = 0.02.$$

这个结果只有一位有效数字, 损失了三位有效数字, 从而绝对误差和相对误差都变得很大, 严重影响了计算结果的精度. 但若将公式改变为

$$\sqrt{x+1} - \sqrt{x} = \frac{1}{\sqrt{x+1} + \sqrt{x}} \quad 0.01581.$$

它仍有四位有效数字, 可见改变计算公式可以避免两个相近数相减而引起的有效数字的损失, 从而可以得到比较精确的结果.

又如, 计算

$$A = 10^7(1 - \cos 2^\circ)$$

的值, 若将 $\cos 2^\circ = 0.9994$ (具有四位有效数字) 代入直接计算

$$A = 10^7(1 - 0.9994) = 6 \times 10^3,$$

这个结果只有一位有效数字, 但若利用公式

$$1 - \cos x = 2 \sin^2 \frac{x}{2},$$

则有

$$\begin{aligned} A &= 10^7(1 - \cos 2^\circ) = 2 \times (\sin 1^\circ)^2 \times 10^7 \\ &= 2 \times 0.01745^2 \times 10^7 = 6.09 \times 10^3. \end{aligned}$$

从而可得到具有三位有效数字的比较精确的结果.

四、绝对值太小的数不宜作除数

在数值计算中, 用绝对值很小的数作除数, 将会使商的数量级增加, 甚至会在计算机中造成“溢出”停机, 而且当很小的除数稍有

一点误差时,会对计算结果影响很大.

例如 $\frac{3.1416}{0.001} = 3141.6$, 当分母变为 0.0011, 即分母只有 0.0001 的变化时,

$$\frac{3.1416}{0.0011} = 2856.$$

商却引起了巨大变化. 因此, 在计算过程中, 不仅要避免两个相近的数相减, 还应特别注意避免再用这个差作除数.

五、合理安排运算顺序, 防止大数“吃掉”小数

在数值计算中, 参与运算的数有时数量级相差很大, 而计算机的位数是有限的, 在编制程序时, 如不注意运算次序, 就很可能出现小数加不到大数中而产生大数“吃掉”小数的现象, 因此, 两数相加时, 我们应尽量避免将小数加到大数中所引起的这种严重后果.

例如, 对 a, b, c 三数进行加法运算, 其中 $a = 10^{12}$, $b = 10$, $c = a$, 若按 $(a + b) + c$ 的顺序编制程序, 在八位的计算机上计算, 则 a “吃掉” b , 且 a 与 c 互相抵消, 其结果接近于零, 但若按 $(a + c) + b$ 的顺序编制程序, 则可得到接近于 10 的真实结果.

在实际计算中, 我们还要特别注意保护重要的物理参数, 防止一些重要的物理量在计算中被“吃掉”. 例如, 考察物体在阻尼介质中的运动时, 阻尼系数 k 是一个重要的物理参数, 若在动力学方程离散化过程中将 k 置于一个很大的数 a 的加减法运算中, 则 k 就会被数 a “吃掉”, 将会使计算结果严重失真. 因此, 为了避免大数“吃掉”小数, 我们必须事先分析计算方案的数量级, 在编制程序时加以合理安排, 这样, 一些重要的物理参数才不至于在计算中被“吃掉”, 以免造成有效数字不必要的损失.

本章小结

本章介绍了数值计算方法和误差的基本概念以及误差在近似

计算中的传播规律. 误差在数值计算中的危害是十分严重的, 若不控制误差的传播与积累, 则计算结果就会与真值有很大偏差, 甚至将会完全淹没真值. 因而误差的分析及其危害的防止是数值计算中的一个非常重要的问题, 应该引起读者的充分注意.

在实际计算以及在计算机上所进行的运算中, 参与运算的数都是有限位数, 因此有效数字的概念是非常重要的和有用的. 为了表示一个数的精确程度, 本章介绍了有效数字的概念以及有效数字与误差的关系, 并讨论了数值计算的误差估计问题, 其中利用函数的 Taylor 展开式估计误差是误差估计的一种基本方法.

最后, 本章还着重讨论了选用和设计算法时应遵循的若干原则, 这将对如何防止误差的传播和积累, 以及如何确定计算的稳定性与判别计算结果的可靠性等很有帮助.

算法与程序设计实例

对 $n = 0, 1, 2, \dots, 20$, 计算定积分 $y_n = \int_0^1 \frac{x^n}{x+5} dx$.

算法 1 利用递推公式

$$y_n = \frac{1}{n} - 5y_{n-1}, \quad n = 1, 2, \dots, 20.$$

取

$$y_0 = \int_0^1 \frac{1}{x+5} dx = \ln 6 - \ln 5 \approx 0.182322.$$

算法 2 利用递推公式

$$y_{n-1} = \frac{1}{5n} - \frac{1}{5}y_n, \quad n = 20, 19, \dots, 1.$$

注意到

$$\frac{1}{126} = \frac{1}{6} \int_0^1 x^{20} dx = \int_0^1 \frac{x^{20}}{6} dx = \frac{1}{5} \int_0^1 \frac{x^{20}}{6} dx = \frac{1}{105},$$

取

$$y_{20} = \frac{1}{2} \left[\frac{1}{105} + \frac{1}{126} \right] = 0.008730.$$

算法 1 的程序和输出结果

```
/* 数值不稳定算法 */
#include <stdio.h>
#include <conio.h>
#include <math.h>
main()
{
    float y_0= log( 6. 0) - log( 5. 0) , y_1;
    int n= 1;
    clrscr(); /* 清屏 */
    printf( y[ 0]= %- 20f , y_0);
    while( 1)
    {
        y_1= 1. 0/n- 5* y_0;
        printf( y[ %d]= %- 20f , n, y_1); /* 输出 */
        if(n>= 20) break;
        y_0= y_1;
        n++ ;
        if(n% 3== 0) printf("\n");
    }
    getch(); /* 保持用户屏幕 */
}
```

```
y[ 0]= 0. 182322,   y[ 1]= 0. 088392,   y[ 2]= 0. 058039,
y[ 3]= 0. 043138,   y[ 4]= 0. 034310,   y[ 5]= 0. 028448,
y[ 6]= 0. 024428,   y[ 7]= 0. 020719,   y[ 8]= 0. 021407,
```

y[9]= 0.004076,	y[10]= 0.079618,
y[11]= - 0.307181,	y[12]= 1.619237,
y[13]= - 8.019263,	y[14]= 40.167744,
y[15]= - 200.772049,	y[16]= 1003.922729,
y[17]= - 5019.554688,	y[18]= 25097.828125,
y[19]= - 125489.085938,	y[20]= 627445.500000.

算法 2 的程序和输出结果

```

/* 稳定算法 */
#include <stdio.h>
#include <conio.h>
#include <math.h>
main()
{
    float y_0= (1/105.0+ 1/126.0)/2, y_1;
    int n= 20;
    clrscr();
    printf( y[20]= %-20f , y_0);
    while(1)
    {
        y_1= 1/(5.0* n)- y_0/5.0;
        printf( y[%d]= %-20f , n-1, y_1);
        if(n<= 1)break;
        y_0= y_1;
        n- - ;
        if(n%3== 0)printf("\n");
    }
    getch();
}

```

$y[20] = 0.008730,$ $y[19] = 0.008254,$ $y[18] = 0.008876,$
 $y[17] = 0.009336,$ $y[16] = 0.009898,$ $y[15] = 0.010520,$
 $y[14] = 0.011229,$ $y[13] = 0.012040,$ $y[12] = 0.012977,$
 $y[11] = 0.014071,$ $y[10] = 0.015368,$ $y[9] = 0.016926,$
 $y[8] = 0.018837,$ $y[7] = 0.021233,$ $y[6] = 0.024325,$
 $y[5] = 0.028468,$ $y[4] = 0.034306,$ $y[3] = 0.043139,$
 $y[2] = 0.058039,$ $y[1] = 0.088392,$ $y[0] = 0.182322.$

说明：从计算结果可以看出，算法 1 是不稳定的，而算法 2 是稳定的。

思考题

1. 数值计算方法的主要研究对象、任务与特点是什么？
2. 误差为什么是不可避免的？用什么标准来衡量近似值是准确的？为减少计算误差，应当采取哪些措施？
3. 何谓绝对误差、相对误差、准确数字、有效数字？它们之间的关系如何？
4. 何谓数值稳定的计算公式？
5. 何谓算法？评判算法优劣的标准有哪些？选用与设计算法时应注意些什么？

习题一

1. 指出如下有效数的绝对误差限、相对误差限和有效数字位数：
 4×10^2 , 0.0490, 490.00.
2. 将 $22/7$ 作为 π 的近似值，它有几位有效数字？绝对误差限和相对误差限各为多少？
3. 要使 $\sqrt{101}$ 的相对误差不超过 $\frac{1}{2} \times 10^{-4}$ ，至少需要保留多

少位有效数字?

4. 设 x^* 为 x 的近似数, 证明 $\sqrt[n]{x^*}$ 的相对误差约为 x^* 的相对误差的 $\frac{1}{n}$ 倍.

5. 求 $\sqrt{20}$ 的近似有效数:

(1) 使绝对误差不超过 0.01;

(2) 使相对误差不超过 0.01.

6. 正方形的边长约为 10 cm, 问测量边长的误差界多大时才能保证面积的误差不超过 0.1 cm^2 ?

7. 设 x 的相对误差为 1%, 求 x^n 的相对误差.

8. 为使积分 $I = \int_0^1 e^{-x^2} dx$ 的近似值的相对误差不超过 1%, 问至少要取几位有效数字?

9. 设 $s = \frac{1}{2}gt^2$, 假定 g 是准确的, 而对 t 的测量有 ± 0.1 秒的误差, 试证当 t 增加时, s 的绝对误差增加, 而相对误差却减少.

10. 已知 $A = (\sqrt{2} - 1)^6$, 取 $\sqrt{2} = 1.4$, 利用下列各式计算 A , 问哪一个得到的计算结果最好?

(1) $\frac{1}{(\sqrt{\frac{1}{2}} + 1)^6}$; (2) $(3 - 2\sqrt{2})^3$;

(3) $\frac{1}{(3 + 2\sqrt{2})^3}$; (4) $99 - 70\sqrt{2}$.

11. 试改变下列表达式, 使计算结果比较精确:

(1) $\frac{1}{1+2x} - \frac{1-x}{1+x}$, $x \approx 1$;

(2) $\sqrt{x + \frac{1}{x}} - \sqrt{x - \frac{1}{x}}$, $x \approx 1$;

(3) $\frac{1 - \cos x}{x}$, $x \approx 1$ 且 $x > 0$.

12. 数列 x_n 满足递推公式 $x_n = 10x_{n-1} - 1$ ($n = 1, 2, \dots$). 若 $x_0 = \sqrt{2} = 1.41$ (三位有效数字), 问按上述递推公式, 从 x_0 到 x_{10} 时误差有多大? 这个计算过程稳定吗?

第二章 线性方程组的数值解法

在自然科学与工程技术中,很多问题的解决常常归结为解线性方程组,如电学中的网络问题,船体数学放样中建立三次样条函数问题,机械和建筑结构的设计和计算等.因此,如何利用电子计算机这一强有力的计算工具去求解线性方程组,这是一个非常重要的问题.对此,本章着重讨论了在电子计算机上求解系数行列式不为零的 n 阶非齐次线性方程组 $Ax = b$ 的两类主要解法——直接(解)法和迭代(解)法.

所谓直接法(也叫精确法),是指在没有舍入误差的假设下,经过有限步运算即可求得方程组的精确解的方法.但实际计算中由于舍入误差的存在和影响,这种方法也只能求得线性方程组的近似解.在本章中,将主要介绍这类算法中最基本的高斯消去法,平方根法,追赶法等.这类方法是解低阶稠密矩阵方程组及某些大型稀疏方程组(例如,大型带状方程组)的有效方法.

迭代法是用某种极限过程去逐步逼近线性方程组精确解的方法,即是从一个初始向量 $x^{(0)}$ 出发,按照一定的迭代格式产生一个向量序列 $\{x^{(k)}\}$,使其收敛到方程组 $Ax = b$ 的解.迭代法的优点是所需计算机存储单元少,程序设计简单,原始系数矩阵在计算过程中始终不变等.但迭代法存在收敛性及收敛速度问题.迭代法是解大型稀疏矩阵方程组(尤其是微分方程离散后得到的大型方程组)的重要方法.

本章分别讲述求解线性方程组的各种方法. § 1 讲述线性方程组的直接解法, § 2 讲述线性方程组的迭代解法, § 3 讨论迭代法的收敛性.本章内容是线性方程组数值解法的基础.

§ 1 线性方程组的直接解法

一、高斯(Gauss)列主元消去法

高斯列主元消去法是计算机上常用来求解线性方程组的一种直接解法,它是在高斯消去法的基础上的改进,下面先介绍高斯消去法.

1. 高斯消去法

高斯消去法(也称为顺序高斯消去法)是一种古老的求解线性方程组的方法.其基本思想是在逐步消元的过程中,把系数矩阵约化成上三角矩阵,从而将原方程组约化为容易求解的等价三角方程组,再通过回代过程即可逐一求出各未知数.下面以三元线性方程组为例来说明高斯消去法的基本思想.

设有线性方程组

$$\begin{cases} a_{11}^{(1)} x_1 + a_{12}^{(1)} x_2 + a_{13}^{(1)} x_3 = b_1^{(1)}, & (2.1.1) \\ a_{21}^{(1)} x_1 + a_{22}^{(1)} x_2 + a_{23}^{(1)} x_3 = b_2^{(1)}, & (2.1.2) \\ a_{31}^{(1)} x_1 + a_{32}^{(1)} x_2 + a_{33}^{(1)} x_3 = b_3^{(1)}, & (2.1.3) \end{cases}$$

若 $a_{11}^{(1)} \neq 0$, 则将方程(2.1.1)分别乘以 $-\frac{a_{21}^{(1)}}{a_{11}^{(1)}}$ 和 $-\frac{a_{31}^{(1)}}{a_{11}^{(1)}}$, 然后加到方程(2.1.2)和(2.1.3)中,消去这两个方程中的 x_1 , 得同解方程组

$$\begin{cases} a_{11}^{(1)} x_1 + a_{12}^{(1)} x_2 + a_{13}^{(1)} x_3 = b_1^{(1)}, & (2.1.1) \\ a_{22}^{(2)} x_2 + a_{23}^{(2)} x_3 = b_2^{(2)}, & (2.1.4) \\ a_{32}^{(2)} x_2 + a_{33}^{(2)} x_3 = b_3^{(2)}, & (2.1.5) \end{cases}$$

其中

$$a_{ij}^{(2)} = a_{ij}^{(1)} - \frac{a_{i1}^{(1)}}{a_{11}^{(1)}} a_{1j}^{(1)} \quad (i, j = 2, 3),$$

$$b_i^{(2)} = b_i^{(1)} - \frac{a_{i1}^{(1)}}{a_{11}^{(1)}} b_1^{(1)} \quad (i = 2, 3).$$

若 $a_{22}^{(2)} \neq 0$, 再将方程 (2. 1. 4) 乘以 $-\frac{a_{32}^{(2)}}{a_{22}^{(2)}}$ 并加到方程 (2. 1. 5) 中, 消去 x_2 , 得同解方程组

$$\begin{cases} a_{11}^{(1)} x_1 + a_{12}^{(1)} x_2 + a_{13}^{(1)} x_3 = b_1^{(1)}, & (2. 1. 1) \\ a_{22}^{(2)} x_2 + a_{23}^{(2)} x_3 = b_2^{(2)}, & (2. 1. 4) \\ a_{33}^{(3)} x_3 = b_3^{(3)}, & (2. 1. 6) \end{cases}$$

其中

$$a_{33}^{(3)} = a_{33}^{(2)} - \frac{a_{32}^{(2)}}{a_{22}^{(2)}} a_{23}^{(2)}, \quad b_3^{(3)} = b_3^{(2)} - \frac{a_{32}^{(2)}}{a_{22}^{(2)}} b_2^{(2)},$$

于是得到与原方程组等价的上三角方程组. 进而可由方程 (2. 1. 6) 求得 x_3 , 再将 x_3 的值代入方程 (2. 1. 4) 求出 x_2 , 最后将 x_2, x_3 的值代入方程 (2. 1. 1) 求出 x_1 . 这种通过逐步消元将原方程组化为上三角方程组求解的方法称为高斯消去法. 而将原方程组逐步化为同解的上三角方程组的过程称为消元过程, 按方程相反顺序逐步求解上三角方程组的过程称为回代过程.

上述方法可推广到一般情况:

设 n 元线性方程组

$$A^{(1)} X = b^{(1)},$$

其中

$$A^{(1)} = \begin{bmatrix} a_{11}^{(1)} & a_{12}^{(1)} & \dots & a_{1n}^{(1)} \\ a_{21}^{(1)} & a_{22}^{(1)} & \dots & a_{2n}^{(1)} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1}^{(1)} & a_{n2}^{(1)} & \dots & a_{nn}^{(1)} \end{bmatrix}, \quad X = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}, \quad b = \begin{bmatrix} b_1^{(1)} \\ b_2^{(1)} \\ \vdots \\ b_n^{(1)} \end{bmatrix}.$$

若约化的主元 $a_{kk}^{(k)} \neq 0$ ($k=1, 2, \dots, n$), 则可通过高斯消去法 (不进行行交换) 将方程组 $A^{(1)} X = b^{(1)}$ 约化为同解的三角形方程组

$$A^{(n)} X = b^{(n)},$$

即

$$\begin{bmatrix} a_{11}^{(1)} & a_{12}^{(1)} & \dots & a_{1n}^{(1)} \\ 0 & a_{22}^{(2)} & \dots & a_{2n}^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & a_{nn}^{(n)} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} b_1^{(1)} \\ b_2^{(2)} \\ \vdots \\ b_n^{(n)} \end{bmatrix},$$

并由回代公式

$$\begin{cases} x_n = \frac{b_n^{(n)}}{a_{nn}^{(n)}}, \\ x_i = \frac{b_i^{(i)} - \sum_{j=i+1}^n a_{ij}^{(i)} x_j}{a_{ii}^{(i)}} \quad (i = n-1, n-2, \dots, 1) \end{cases}$$

求得方程组的解.

易见, 高斯消去法的特点是每次都是按照系数矩阵的主对角线上元素的顺序依次消去对角线下方的元素, 若考虑高斯消去法的一种修正, 即消去对角线下方和上方的元素, 则这种方法称为高斯-若当 (Gauss-Jordan) 消去法, 而主对角线上的元素 $a_{kk}^{(k)}$ 称为主元. 在这种按顺序消元的过程中, 可能会出现两个问题:

(1) 一旦遇到某个主元 $a_{kk}^{(k)} = 0$, 则消元过程便无法继续进行;

(2) 即使主元素不为零, 但与该元素所在列的对角线以下的各元素相比, 它的绝对值很小 (称为小主元) 时, 尽管消去运算可以进行下去, 但用其做除数, 故其小小的舍入误差将会引起计算结果的严重扩散与失真. 例如下述方程组

$$\begin{cases} 0.00001x_1 + 2x_2 = 2, \\ x_1 + x_2 = 3, \end{cases}$$

其准确到小数点后第 9 位的解为 $x_1 = 2.000010000$, $x_2 = 0.999898999$. 但若依顺序高斯消去法并在计算机编程计算过程中用四位十进制浮点数求解 (随着计算机的飞速发展, 目前一般不使用定点表示而使用浮点表示法), 用第 1 个方程消去第 2 个方程的 x_1 , 得

$$\begin{cases} 10^{-4} \times 0.1000x_1 + 10 \times 0.2000x_2 = 10 \times 0.2000, \\ -10^6 \times 0.2000x_2 = -10^6 \times 0.2000. \end{cases}$$

回代后解得 $x_2 = 1, x_1 = 0$. 与精确解相比, 结果严重失真, 究其原因, 原因是用了“小”主元做除数, 致使舍入误差增大, 有效数字消失. 因此, 顺序高斯消去法并非实用的消元方法. 如果在消元前先交换两个方程的位置, 变为

$$\begin{cases} x_1 + x_2 = 3, \\ 0.00001x_1 + 2x_2 = 2, \end{cases}$$

对此方程消元得三角方程组

$$\begin{cases} x_1 + x_2 = 3, \\ 1.99999x_2 = 1.99997. \end{cases}$$

回代得解为 $x_2 = 0.99999, x_1 = 2.00001$, 结果与准确解非常接近. 可见, 第一种算法是不稳定的, 第二种算法是稳定的. 此例说明, 在消元过程中, 应避免选取绝对值较小的数作主元, 否则可能导致结果错误、计算失败. 根据主元素的选取范围不同, 通常又分为按列选主元和全面选主元两种方法.

2. 列主元消去法

列主元消去法能有效避免高斯消元过程中出现的两个问题, 它是直接法中最常用的一种方法. 在按列选主元的消元过程中, 每次选主元时, 仅依次按列选取绝对值最大的元素作为主元素, 它只进行行交换, 而不产生未知数次序的调换. 下面再通过具体例子加以说明.

例 1 求解线性方程组

$$\begin{cases} 2x_1 + x_2 + 2x_3 = 5, \\ 5x_1 - x_2 + x_3 = 8, \\ x_1 - 3x_2 - 4x_3 = -4. \end{cases}$$

解 方程组的增广矩阵为

$$\left[\begin{array}{ccc|c} 2 & 1 & 2 & 5 \\ 5 & -1 & 1 & 8 \\ 1 & -3 & -4 & -4 \end{array} \right].$$

在第一列中选取绝对值最大的元素 $a_{21} = 5$ 作为主元, 将第 2 行与

第 1 行交换, 得

$$\left[\begin{array}{cccc|c} 5 & - & 1 & 1 & 8 \\ 2 & & 1 & 2 & 5 \\ 1 & - & 3 & - & 4 \end{array} \right],$$

将第 1 行分别乘以 $-\frac{2}{5}$, $-\frac{1}{5}$ 加到第 2, 3 行, 得

$$\left[\begin{array}{cccc|c} 5 & - & 1 & 1 & 8 \\ 0 & & 1.4 & 1.6 & 1.8 \\ 0 & - & 2.8 & - & 4.2 \end{array} \right];$$

再在第 2 列的元素 $a_{22}=1.4$, $a_{32}=-2.8$ 中选取绝对值最大的元素作主元, 这里主元是 $a_{32}=-2.8$. 又将第 3 行与第 2 行交换, 得

$$\left[\begin{array}{cccc|c} 5 & - & 1 & 1 & 8 \\ 0 & - & 2.8 & - & 4.2 \\ 0 & & 1.4 & 1.6 & 1.8 \end{array} \right],$$

将第 2 行乘以 0.5 加到第 3 行, 得

$$\left[\begin{array}{cccc|c} 5 & - & 1 & 1 & 8 \\ 0 & - & 2.8 & - & 4.2 \\ 0 & & 0 & - & 0.5 \end{array} \right].$$

最后利用回代即可求得方程组的解为 $x_3=2$, $x_2=-1$, $x_1=1$.

由上例的求解过程可以看出, 高斯列主元消去法的特点是: 每次在系数矩阵中依次按列在主对角线及以下的元素中, 选取绝对值最大的元素作为主元, 将它调至主对角线上, 然后用它消去主对角线以下的元素, 最后变为同解的上三角形方程组去求解.

一般地, 设有 n 元线性方程组

$$A^{(1)}X = b^{(1)}, \quad (2.1.7)$$

其中

$$A^{(1)} = \begin{bmatrix} a_{11}^{(1)} & a_{12}^{(1)} & \dots & a_{1n}^{(1)} \\ a_{21}^{(1)} & a_{22}^{(1)} & \dots & a_{2n}^{(1)} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1}^{(1)} & a_{n2}^{(1)} & \dots & a_{nn}^{(1)} \end{bmatrix}, \quad X = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}, \quad b^{(1)} = \begin{bmatrix} b_1^{(1)} \\ b_2^{(1)} \\ \vdots \\ b_n^{(1)} \end{bmatrix}.$$

由线性代数知, 当 $A^{(1)}$ 为非奇异矩阵时, 方程组 (2.1.7) 有惟一解, 为此我们假定 $A^{(1)}$ 为非奇异矩阵. 此时, 高斯列主元消去法的消元过程为:

第一步 对方程组 (2.1.7) 确定 i_1 , 使 $a_{i_1 1}^{(1)} = \max_{1 \leq i \leq n} a_{i1}^{(1)}$, 于是选取 $a_{i_1 1}^{(1)}$ 作为第 1 个主元, 然后交换第 1 个和第 i_1 个方程, 仍记为 (2.1.7), 利用第 1 个方程将后 $n-1$ 个方程中的 x_1 消去, 仍记为 (2.1.7).

第二步 对方程组 (2.1.7) 确定 i_2 , 使 $a_{i_2 2}^{(2)} = \max_{2 \leq i \leq n} a_{i2}^{(2)}$, 则选取 $a_{i_2 2}^{(2)}$ 作为第 2 个主元, 然后交换第 2 个和第 i_2 个方程, 仍记为 (2.1.7), 又利用第 2 个方程将后 $n-2$ 个方程中的 x_2 消去. 依此类推, 进行 $n-1$ 步方程组就约化为上三角形方程组, 最后由回代过程即可求出方程组的解.

综上所述, 高斯列主元消去法的具体计算步骤为:

(1) 消元过程. 对 $k=1, 2, \dots, n-1$, 进行如下运算:

1) 选主元. 找行号 $i_k \in \{k, \dots, n\}$, 使 $a_{i_k k}^{(k)} = \max_{k \leq i \leq n} a_{ik}^{(k)}$;

2) 交换 $[A^{(k)}, b^{(k)}]$ 中的 k, i_k 两行;

3) 消元: 对 $i=k+1, \dots, n$, $l_{ik} = a_{ik}^{(k)} / a_{kk}^{(k)}$;

对 $j=k+1, \dots, n+1$, $a_{ij}^{(k+1)} = a_{ij}^{(k)} - l_{ik} a_{kj}^{(k)}$.

(2) 回代过程. 按下述公式

$$x_n = b_n^{(n)} / a_{nn}^{(n)},$$

$$x_i = \left[b_i^{(i)} - \sum_{j=i+1}^n a_{ij}^{(i)} x_j \right] / a_{ii}^{(i)}, \quad i = n-1, n-2, \dots, 1,$$

回代求解即可得到方程组 (2.1.7) 的解.

二、高斯全主元消去法

高斯全主元消去法选取主元的范围更大, 对增广矩阵 $[A^{(1)} | b^{(1)}]$ 来说, 第 1 步是在整个系数矩阵中选主元, 即将绝对值最大的元素经过行列交换使其置于 $a_{11}^{(1)}$ 元素的位置, 然后进行消

元过程;第 2 步是在 $[A^{(2)} \mid b^{(2)}]$ 中划掉第一行第一列后剩余的 $n-1$ 阶子系数矩阵

$$\begin{bmatrix} a_{22}^{(2)} & a_{23}^{(2)} & \cdots & a_{2n}^{(2)} \\ a_{32}^{(2)} & a_{33}^{(2)} & \cdots & a_{3n}^{(2)} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n2}^{(2)} & a_{n3}^{(2)} & \cdots & a_{nn}^{(2)} \end{bmatrix}$$

中选主元,并通过行、列交换置其于 $a_{22}^{(2)}$ 元素的位置,然后再进行消元过程;以后各步类似进行,最后得到与原方程组(2.1.7)等价的一个上三角形方程组,再由回代过程即可求得原方程组的解.

由于全主元消去法每步所选主元的绝对值不小于列主元消去法同一步所选主元的绝对值,因而全主元消去法的求解结果更加可靠,但由于选取主元的范围扩大,无疑需花费更多的时间进行比较,又由于对增广矩阵经过了行列交换后,未知量的次序改变了,这就使得算法的逻辑结构变得更复杂,需要占用的机时较多.而列主元消去法的计算结果已比较理想,而且它既简单,又能满足精度要求、达到较好的数值稳定性,故在实际计算中经常使用列主元消去法.

三、选主元素消去法的应用

1. 求逆矩阵

设 $A=(a_{ij})_{n \times n}$ 可逆, E 为 n 阶单位矩阵,对 $(A \mid E)$,即

$$\left[\begin{array}{cccc|cccc} a_{11} & a_{12} & \cdots & a_{1n} & 1 & & & \\ & a_{22} & \cdots & a_{2n} & & 1 & & 0 \\ & & \ddots & & & & \ddots & \\ & & & a_{nn} & 0 & & & 1 \end{array} \right]$$

按列选主元素后再用高斯-若当消去法将左边的矩阵 A 化为单位矩阵 E ,则可得如下矩阵

从而可得逆阵 $A^{-1} = (b_{ij})_{n \times n}$, 这是实用中求逆矩阵的可靠方法.

$$A = \begin{bmatrix} 11 & -3 & -2 \\ -23 & 11 & 1 \\ 1 & -2 & 2 \end{bmatrix}$$

解 用按列选主元素的高斯-若当方法.

$$\left[\begin{array}{cccc|ccc} 11 & - & 3 & - & 2 & 1 & 0 & 0 \\ - & 23 & & & 11 & 1 & 0 & 1 & 0 \\ 1 & - & 2 & & 2 & 0 & 0 & 1 \end{array} \right]$$

$$r_1 \setminus r_2 \begin{bmatrix} -23 & 11 & 1 & 0 & 1 & 0 \\ 11 & -3 & -2 & 1 & 0 & 0 \\ 1 & -2 & 2 & 0 & 0 & 1 \end{bmatrix}$$

$$\text{第 1 次消元} \left[\begin{array}{cccc|ccc} 1 & - & 0.478 & - & 0.044 & 0 & - & 0.044 & 0 \\ 0 & & \boxed{2.261} & - & 1.522 & 1 & & 0.478 & 0 \\ 0 & - & 1.522 & & 2.044 & 0 & & 0.044 & 1 \end{array} \right]$$

$$\text{第 2 次消元} \left[\begin{array}{cccc|ccc} 1 & 0 & - & 0.365 & 0.211 & 0.057 & 0 \\ 0 & 1 & - & 0.673 & 0.442 & 0.211 & 0 \\ 0 & 0 & & 1.019 & 0.673 & 0.365 & 1 \end{array} \right]$$

$$\text{第 3 次消元} \left[\begin{array}{ccc|ccc} 1 & 0 & 0 & 0.452 & 0.188 & 0.358 \\ 0 & 1 & 0 & 0.886 & 0.452 & 0.660 \\ 0 & 0 & 1 & 0.660 & 0.358 & 0.981 \end{array} \right],$$

所以 $A^{-1} = \begin{bmatrix} 0.452 & 0.188 & 0.358 \\ 0.886 & 0.452 & 0.660 \\ 0.660 & 0.358 & 0.981 \end{bmatrix}.$

2. 求行列式

设有矩阵

$$A = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{bmatrix},$$

用主元素消去法将其化为上三角矩阵, 并设对角元素为 $b_{11}, b_{22}, \dots, b_{nn}$, 故 A 的行列式为

$$\det(A) = (-1)^m b_{11} b_{22} \dots b_{nn},$$

其中 m 为所施行的行、列交换的次数. 这是实用中求行列式值的可靠方法.

四、矩阵的三角分解

由以上讨论我们看到, 高斯消去法的消去过程是将矩阵 $[A^{(1)} \mid b^{(1)}]$ 逐步变换成矩阵 $[A^{(n)} \mid b^{(n)}]$. 用矩阵的观点来看, 消去法的每一步相当于用一个初等下三角阵去左乘方程的两端. 以下我们将用矩阵的理论来分析高斯消去法, 从而建立矩阵的三角分解定理, 并可用它对特殊系数矩阵的方程组建立一些特殊解法. 下面仍以三元线性方程组为例加以说明.

设有线性方程组

$$\begin{cases} a_{11}^{(1)} x_1 + a_{12}^{(1)} x_2 + a_{13}^{(1)} x_3 = b_1^{(1)}, \\ a_{21}^{(1)} x_1 + a_{22}^{(1)} x_2 + a_{23}^{(1)} x_3 = b_2^{(1)}, \\ a_{31}^{(1)} x_1 + a_{32}^{(1)} x_2 + a_{33}^{(1)} x_3 = b_3^{(1)}, \end{cases}$$

记

$$A^{(1)} = \begin{bmatrix} a_{11}^{(1)} & a_{12}^{(1)} & a_{13}^{(1)} \\ a_{21}^{(1)} & a_{22}^{(1)} & a_{23}^{(1)} \\ a_{31}^{(1)} & a_{32}^{(1)} & a_{33}^{(1)} \end{bmatrix}, \quad x = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}, \quad b^{(1)} = \begin{bmatrix} b_1^{(1)} \\ b_2^{(1)} \\ b_3^{(1)} \end{bmatrix},$$

则上述方程组的矩阵形式为

$$A^{(1)}x = b^{(1)},$$

其增广矩阵为

$$[A^{(1)} \mid b^{(1)}].$$

不难验证, 高斯消去法的第一步是用下三角阵

$$L_1 = \begin{bmatrix} 1 & & & \\ & 1 & & \\ -l_{21} & & 1 & \\ -l_{31} & & 0 & 1 \end{bmatrix}$$

去左乘增广矩阵 $[A^{(1)} \mid b^{(1)}]$, 其中 $l_{i1} = a_{i1}^{(1)} / a_{11}^{(1)}, i = 2, 3$, 即

$$L_1[A^{(1)} \mid b^{(1)}] = [L_1A^{(1)} \mid L_1b^{(1)}] = \left[\begin{array}{ccc|c} a_{11}^{(1)} & a_{12}^{(1)} & a_{13}^{(1)} & b_1^{(1)} \\ 0 & a_{22}^{(2)} & a_{23}^{(2)} & b_2^{(2)} \\ 0 & a_{32}^{(2)} & a_{33}^{(2)} & b_3^{(2)} \end{array} \right].$$

记 $A^{(2)} = L_1A^{(1)}, b^{(2)} = L_1b^{(1)}$, 则

$$[L_1A^{(1)} \mid L_1b^{(1)}] = [A^{(2)} \mid b^{(2)}].$$

同理, 高斯消去法的第二步是用下三角阵

$$L_2 = \begin{bmatrix} 1 & & & \\ 0 & 1 & & \\ 0 & -l_{32} & 1 & \end{bmatrix}$$

去左乘增广矩阵 $[A^{(2)} \mid b^{(2)}]$, 其中 $l_{32} = a_{32}^{(2)} / a_{22}^{(2)}$, 即

$$L_2[A^{(2)} \mid b^{(2)}] = [L_2A^{(2)} \mid L_2b^{(2)}] = \left[\begin{array}{ccc|c} a_{11}^{(1)} & a_{12}^{(1)} & a_{13}^{(1)} & b_1^{(1)} \\ 0 & a_{22}^{(2)} & a_{23}^{(2)} & b_2^{(2)} \\ 0 & 0 & a_{33}^{(3)} & b_3^{(3)} \end{array} \right].$$

记 $A^{(3)} = L_2A^{(2)}, b^{(3)} = L_2b^{(2)}$, 且由上式可以看出, $A^{(3)}$ 为上三角阵.

由于矩阵 L_1 与 L_2 的行列式 $L_1 = L_2 = 1$, 所以 L_1^{-1} 与 L_2^{-1} 存

在,且

$$L_1^{-1} = \begin{bmatrix} 1 & & \\ l_{21} & 1 & \\ l_{31} & 0 & 1 \end{bmatrix},$$

$$L_2^{-1} = \begin{bmatrix} 1 & & \\ 0 & 1 & \\ 0 & l_{32} & 1 \end{bmatrix},$$

于是可得 $A^{(1)} = L_1^{-1} A^{(2)}$, $A^{(2)} = L_2^{-1} A^{(3)}$, 从而有 $A^{(1)} = L_1^{-1} L_2^{-1} A^{(3)}$. 因为

$$L_1^{-1} L_2^{-1} = \begin{bmatrix} 1 & & \\ l_{21} & 1 & \\ l_{31} & l_{32} & 1 \end{bmatrix},$$

记 $L = L_1^{-1} L_2^{-1}$, 则 L 是一个主对角线元素为 1 的下三角阵, 称为单位下三角阵. 又记 $A = A^{(1)}$, $U = A^{(3)}$, 于是有 $A = LU$.

上述分析说明: 当 $a_{11}^{(1)} \neq 0$, $a_{22}^{(2)} \neq 0$ 时, 通过高斯消去法, 可将方程组的系数矩阵 A 分解为一个单位下三角阵 L 与一个上三角阵 U 的乘积, 这种分解称为矩阵 A 的 LU 分解. 显然, 以上分析对 n 元线性方程组也是成立的.

对任意一个 n 阶方阵 A , 一般地说不一定都能作 LU 分解, 即使能作 LU 分解, 其分解式也不一定是惟一的. 为了确保分解的惟一性, 我们引入如下定义与 A 的 LU 分解的惟一性定理.

定义 1 如果 L 为单位下三角阵, U 为上三角阵, 则称 $A = LU$ 为杜里特尔(Doolittle)分解; 如果 L 为下三角阵, U 为单位上三角阵, 则称 $A = LU$ 为克劳特(Crout)分解.

定理 1 n 阶($n \geq 2$)矩阵 A 有惟一杜里特尔分解(或克劳特分解)的充要条件是 A 的前 $n-1$ 个顺序主子式都不为零.

证明 略.

如果对 n 个方程的 n 元线性方程组 $AX = b$ 的系数矩阵 A 能

作 LU 分解, 即 $A = LU$, 则方程组等价于

$$LUX = b. \quad (2.1.8)$$

若令 $UX = Y$, 则 $LY = b$. 从而原方程组的求解就转化为下述方程组

$$\begin{cases} LY = b, \\ UX = Y \end{cases} \quad (2.1.9)$$

$$(2.1.10)$$

的求解. 而三角方程组 (2.1.9) 和 (2.1.10) 很容易由回代公式求解.

将矩阵 A 作 LU 分解的重要性在于, 根据线性方程组系数矩阵 A 的具体性质, 可以作不同的 LU 分解, 从而可得到解线性方程组的不同的直接解法.

以下详细讨论系数矩阵 A 的三角分解, 这里以杜里特尔分解为例 (克劳特分解完全类似), 依定理 1, 若矩阵 A 的各阶顺序主子式都不为零, 则 A 可作惟一的 LU 分解. 设

$$A = \begin{bmatrix} 1 & & & \\ l_{21} & 1 & & \\ & & \ddots & \\ l_{n1} & l_{n2} & \dots & 1 \end{bmatrix} \begin{bmatrix} u_{11} & u_{12} & \dots & u_{1n} \\ & u_{22} & \dots & u_{2n} \\ & & \ddots & \\ & & & u_{nn} \end{bmatrix},$$

由矩阵乘法运算


$$a_{ij} = \sum_{k=1}^n l_{ik} u_{kj} \quad (i, j = 1, 2, \dots, n),$$

并注意: $l_{ii} = 1, l_{ij} = 0 (i < j), u_{ij} = 0 (i > j)$, 可得

$$u_{kj} = a_{kj} - \sum_{r=1}^{k-1} l_{kr} u_{rj} \quad (j = k, k+1, \dots, n), \quad (2.1.11)$$

$$l_{ik} = \left[a_{ik} - \sum_{r=1}^{k-1} l_{ir} u_{rk} \right] / u_{kk} \quad (i = k+1, k+2, \dots, n). \quad (2.1.12)$$

以上两式有如下计算特点: U 的元素按行求, L 的元素按列求; 先求 U 的第 r 行元素, 然后求 L 的第 r 列元素, U 和 L 一行一列交叉计算, 矩阵 A 的 LU 分解可按下图逐框计算:



由上图可见, 计算是按一框一框进行的. 由于以上计算是通过已知数和已经求出的数来求得 u_{kj} 和 l_{ik} , 计算时不必记录中间结果, 故这种算法也称为紧凑格式.

当矩阵 A 完成 LU 分解后, 则线性方程组 $AX = b$ 的解就等价于以下两个三角方程组

$$\begin{cases} LY = b, \\ UX = Y \end{cases}$$

的解. 而求解 $LY = b$ 的递推公式为

$$\begin{cases} y_1 = b_1, \\ y_i = b_i - \sum_{k=1}^{i-1} l_{ik} y_k, \quad i = 2, 3, \dots, n; \end{cases}$$

求解 $UX = Y$ 的递推公式为

$$x_i = \left[y_i - \sum_{k=i+1}^n u_{ik} x_k \right] / u_{ii}, \quad i = n, n-1, \dots, 2, 1.$$

例 3 利用矩阵的 LU 分解求解线性方程组

$$\begin{bmatrix} 1 & 2 & 3 & -4 \\ -3 & -4 & -12 & 13 \\ 2 & 10 & 0 & -3 \\ 4 & 14 & 9 & -13 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} -2 \\ 5 \\ 10 \\ 7 \end{bmatrix}.$$

解 第一步 计算 U 的第一行, L 的第一列, 得

$$u_{11} = 1, \quad u_{12} = 2, \quad u_{13} = 3, \quad u_{14} = -4,$$

$$l_{21} = a_{21}/u_{11} = -3, \quad l_{31} = a_{31}/u_{11} = 2,$$

$$l_{41} = a_{41}/u_{11} = 4.$$

第二步 计算 U 的第二行, L 的第二列, 得

$$u_{22} = a_{22} - l_{21}u_{12} = 2,$$

$$u_{23} = a_{23} - l_{21}u_{13} = -3,$$

$$u_{24} = a_{24} - l_{21}u_{14} = 1,$$

$$l_{32} = (a_{32} - l_{31}u_{12})/u_{22} = 3,$$

$$l_{42} = (a_{42} - l_{41}u_{12})/u_{22} = 3.$$

第三步 计算 U 的第三行, L 的第三列, 得

$$u_{33} = a_{33} - l_{31}u_{13} - l_{32}u_{23} = 3,$$

$$u_{34} = a_{34} - l_{31}u_{14} - l_{32}u_{24} = 2,$$

$$l_{43} = (a_{43} - l_{41}u_{13} - l_{42}u_{23})/u_{33} = 2.$$

第四步 计算 U 的第 4 行, 即 u_{44} 得

$$u_{44} = a_{44} - l_{41}u_{14} - l_{42}u_{24} - l_{43}u_{34} = -4.$$

从而

$$\begin{bmatrix} 1 & 2 & 3 & -4 \\ -3 & -4 & -12 & 13 \\ 2 & 10 & 0 & -3 \\ 4 & 14 & 9 & -13 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ -3 & 1 & 0 & 0 \\ 2 & 3 & 1 & 0 \\ 4 & 3 & 2 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 & 3 & -4 \\ 0 & 2 & -3 & 1 \\ 0 & 0 & 3 & 2 \\ 0 & 0 & 0 & -4 \end{bmatrix}.$$

求解

$$\begin{bmatrix} 1 & 0 & 0 & 0 \\ -3 & 1 & 0 & 0 \\ 2 & 3 & 1 & 0 \\ 4 & 3 & 2 & 1 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \end{bmatrix} = \begin{bmatrix} -2 \\ 5 \\ 10 \\ 7 \end{bmatrix}$$

得 $Y = (-2, -1, 17, -16)^T$. 求解

$$\begin{bmatrix} 1 & 2 & 3 & - & 4 \\ 0 & 2 & - & 3 & 1 \\ 0 & 0 & 3 & 2 \\ 0 & 0 & 0 & - & 4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} - & 2 \\ - & 1 \\ 17 \\ - & 16 \end{bmatrix}$$

得 $X = (1, 2, 3, 4)^T$.

如果 A 是 n 阶对称矩阵, 由定理 1 还可得如下分解定理:

定理 2 若 A 为 n 阶对称矩阵, 且 A 的各阶顺序主子式都不为零, 则 A 可惟一分解为

$$A = LDL^T, \quad (2.1.13)$$

其中 L 为单位下三角阵, D 为对角阵.

证明 因为 A 的各阶顺序主子式都不为零, 由定理 1 知, A 可惟一分解为

$$A = LU = \begin{bmatrix} 1 & & & \\ l_{21} & 1 & & \\ & & \ddots & \\ l_{n1} & l_{n2} & \dots & 1 \end{bmatrix} \begin{bmatrix} u_{11} & u_{12} & \dots & u_{1n} \\ & u_{22} & \dots & u_{2n} \\ & & \ddots & \\ & & & u_{nn} \end{bmatrix}.$$

因为 $u_{ii} \neq 0$ ($i = 1, 2, \dots, n$), 所以可将 U 分解为

$$U = \begin{bmatrix} u_{11} & & & \\ & u_{22} & & \\ & & \ddots & \\ & & & u_{nn} \end{bmatrix} \begin{bmatrix} 1 & \frac{u_{12}}{u_{11}} & \dots & \frac{u_{1n}}{u_{11}} \\ & 1 & \dots & \frac{u_{2n}}{u_{22}} \\ & & \ddots & \\ & & & 1 \end{bmatrix} = DU_1,$$

其中 D 为对角矩阵, U_1 为单位上三角阵. 于是

$$A = LDU_1 = L(DU_1).$$

因为 A 为对称矩阵, 所以

$$A = A^T = U_1^T D^T L^T = U_1^T (DL^T).$$

由 A 的 LU 分解的惟一性即得

$$L = U_1^T,$$

即 $U_1 = L^T$, 故 $A = LDL^T$.

五、平方根法及改进的平方根法

工程技术中的许多实际问题所归结出的线性方程组, 其系数矩阵常有对称正定性, 对于具有此类特性的系数矩阵, 利用矩阵的三角分解法求解是一种较好的有效方法, 这就是对称正定矩阵方程组的平方根法及改进的平方根法, 这种方法目前在计算机上已被广泛应用.

1. 正定矩阵及其性质

定义 2 设 A 是 n 阶实对称矩阵, 若对任何非零 $X \in R^n$, 恒有 $X^T A X > 0$, 则称 A 为对称正定矩阵.

由线性代数知, 正定矩阵具有如下性质(证明略):

(1) 正定矩阵 A 是非奇异的;

(2) 正定矩阵 A 的任一主子矩阵 A_r ($r = 1, 2, \dots, n-1$) 也必为正定矩阵;

(3) 正定矩阵 A 的主对角元 a_{ii} ($i = 1, 2, \dots, n$) 均为正数;

(4) 正定矩阵 A 的特征值 $\lambda_i > 0$ ($i = 1, 2, \dots, n$);

(5) 正定矩阵 A 的行列式必为正数.

定理 3 对称矩阵 A 为正定的充分必要条件是 A 的各阶顺序主子式 $\det(A_i) > 0$ ($i = 1, 2, \dots, n$).

(证明从略)

2. 对称正定矩阵的三角分解

定理 4(Cholesky 分解) 设 A 为 n 阶对称正定矩阵, 则存在唯一的主对角线元素都是正数的下三角阵 L , 使得

$$A = LL^T. \quad (2.1.14)$$

证明 因为 A 为对称正定矩阵, 则由以上性质(1)、(2)和定理 2 知, 必存在唯一的单位下三角阵 L_1 和对角阵 D , 使得

$$A = L_1 D L_1^T.$$

下面证明 D 的对角元素 d_{ii} ($i = 1, 2, \dots, n$) 都是正数.

由于 L_1^T 非奇异, 所以存在一非零列向量 X , 使得 $L_1^T X = e_i$, 其中 $e_i = (0, \dots, 0, 1, 0, \dots, 0)^T$. 由 A 的正定性得

$$\begin{aligned} 0 < X^T A X &= X^T (L_1 D L_1^T) X = (L_1^T X)^T D (L_1^T X) \\ &= e_i^T D e_i = d_{ii} \quad (i = 1, 2, \dots, n). \end{aligned}$$

用 $D^{\frac{1}{2}}$ 表示对角元素为 $\sqrt{d_{ii}} (i = 1, 2, \dots, n)$ 的对角阵, 则有

$$A = L_1 D L_1^T = L_1 D^{\frac{1}{2}} \cdot D^{\frac{1}{2}} L_1^T = (L_1 D^{\frac{1}{2}}) (L_1 D^{\frac{1}{2}})^T.$$

令 $L = L_1 D^{\frac{1}{2}}$, 则得

$$A = L L^T,$$

其中 L 为对角元素都是正数的下三角阵. 证毕.

分解式 $A = L L^T$ 称为正定矩阵的乔列斯基(Cholesky)分解, 利用乔列斯基分解来求解系数矩阵为对称正定矩阵的方程组 $A X = b$ 的方法称为平方根法. 求解步骤具体如下:

设 A 为 n 阶对称正定矩阵, 则由定理 4 知, $A = L L^T$, 即

$$\begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ & & W & \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{bmatrix} = \begin{bmatrix} l_{11} & 0 & \dots & 0 \\ l_{21} & l_{22} & \dots & 0 \\ & & W & \\ l_{n1} & l_{n2} & \dots & l_{nn} \end{bmatrix} \begin{bmatrix} l_{11} & l_{21} & \dots & l_{n1} \\ 0 & l_{22} & \dots & l_{n2} \\ & & W & \\ 0 & 0 & \dots & l_{nn} \end{bmatrix}.$$

将右端矩阵相乘, 并令两端矩阵的 (i, j) 元素相等, 于是不难算得矩阵 L 的元素的计算公式为:

对于 $j = 1, 2, \dots, n$,

$$l_{jj} = \left[a_{jj} - \sum_{k=1}^{j-1} l_{jk}^2 \right]^{\frac{1}{2}}, \quad (2.1.15)$$

$$l_{ij} = \left[a_{ij} - \sum_{k=1}^{j-1} l_{ik} l_{jk} \right] / l_{jj} \quad (2.1.16)$$

$$(i = j + 1, j + 2, \dots, n).$$

于是求解线性方程组 $A X = b$ 就等价于求解下面两个三角方程组:

(1) $L Y = b$, 求 Y ;

(2) $L^T X = Y$, 求 X .

其求解公式为

$$y_i = \left[b_i - \sum_{k=1}^{i-1} l_{ik} y_k \right] / l_{ii}, \quad i = 1, 2, \dots, n, \quad (2.1.17)$$

$$x_i = \left[y_i - \sum_{k=i+1}^n l_{ki} x_k \right] / l_{ii}, \quad i = n, n-1, \dots, 2, 1. \quad (2.1.18)$$

当 L 的元素求出后, L^T 的元素也就求出, 因此平方根法比一般 LU 分解的乘除运算量小得多. 另外, 由 (2.1.15) 式得

$$a_{jj} = \sum_{k=1}^j l_{jk}^2, \quad j = 1, 2, \dots, n,$$

所以 $l_{jk}^2 = a_{jj} - \max_{1 \leq j \leq n} (a_{jj}), \quad l_{jk} = \sqrt{a_{jj}}.$

上式说明, 在矩阵 A 的乔列斯基分解过程中 l_{jk} 的平方不会超过 A 的最大对角元, 舍入误差的放大受到了控制, 从而不选主元的平方根法是数值稳定的, 计算实践也表明了不选主元已有足够的精度, 所以对称正定矩阵的平方根法是目前计算机上解决这类问题的最有效的方法之一.

例 4 用平方根法求解

$$\begin{bmatrix} 1 & 2 & 1 \\ 2 & 8 & 4 \\ 1 & 4 & 6 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 0 \\ -2 \\ 3 \end{bmatrix}.$$

解 首先检验系数矩阵的对称正定性, 这可以通过计算其各阶顺序主子式是否大于零来判断.

$$a_{11} = 1 > 0, \quad \begin{vmatrix} 1 & 2 \\ 2 & 8 \end{vmatrix} = 8 - 4 > 0,$$

$$\begin{vmatrix} 1 & 2 & 1 \\ 2 & 8 & 4 \\ 1 & 4 & 6 \end{vmatrix} = 16 > 0,$$

所以系数矩阵是对称正定的. 记系数矩阵为 A , 则平方根法可按如

下三步进行:

第一步 分解: $A = LL^T$.

由公式(2.1.15)和(2.1.16)可算得 L 矩阵的各元素:

$$l_{11} = 1, \quad l_{21} = 2, \quad l_{22} = 2,$$

$$l_{31} = 1, \quad l_{32} = 1, \quad l_{33} = 2,$$

因此

$$L = \begin{bmatrix} 1 & & \\ 2 & 2 & \\ 1 & 1 & 2 \end{bmatrix}.$$

第二步 求解三角方程组 $LY = b$.

由公式(2.1.17)可解得

$$Y = (0, -1, 2).$$

第三步 求解三角方程组 $L^T X = Y$.

由公式(2.1.18)可求得方程组的解为

$$X = (1, -1, 1)^T.$$

利用平方根法解对称正定线性方程组时, 计算矩阵 L 的元素 l_{ij} 时需要用到开方运算, 另外, 当我们解决工程问题时, 有时得到的是一个系数矩阵为对称但不一定是正定的线性方程组. 为了避免开方运算和求解这类方程组, 我们可以改用定理 2 的分解式 $A = LDL^T$ 去计算, 由此可得到下面的改进平方根法.

设

$$A = LDL^T$$

$$= \begin{bmatrix} 1 & & & \\ l_{21} & 1 & & \\ & & \ddots & \\ l_{n1} & l_{n2} & \dots & 1 \end{bmatrix} \begin{bmatrix} d_1 & & & \\ & d_2 & & \\ & & \ddots & \\ & & & d_n \end{bmatrix} \begin{bmatrix} 1 & l_{21} & \dots & l_{n1} \\ & 1 & \dots & l_{n2} \\ & & \ddots & \\ & & & 1 \end{bmatrix},$$

按行计算 L 的元素 l_{ij} ($j = 1, 2, \dots, i-1$). 由矩阵乘法运算, 并注意 $l_{jj} = 1, l_{jk} = 0$ ($j < k$), 得

$$a_{ij} = \sum_{k=1}^n (LD)_{ik} (L^T)_{kj} = \sum_{k=1}^n l_{ik} d_k l_{jk} = \sum_{k=1}^{j-1} l_{ik} d_k l_{jk} + l_{ij} d_j.$$

于是得到计算 L 的元素及 D 的对角元素公式为:

对 $i = 1, 2, \dots, n$,

$$l_{ij} = \left[a_{ij} - \sum_{k=1}^{j-1} l_{ik} d_k l_{jk} \right] / d_j, \quad j = 1, 2, \dots, i-1, \quad (2.1.19)$$

$$d_i = a_{ii} - \sum_{k=1}^{i-1} l_{ik}^2 d_k. \quad (2.1.20)$$

为了避免重复计算, 引进

$$t_{ij} = l_{ij} d_j.$$

于是由式(2.1.19)和(2.2.20)得到按行计算 L, T($T = LD$)元素的公式为:

对 $i = 1, 2, \dots, n$,

$$\left. \begin{aligned} t_{ij} &= a_{ij} - \sum_{k=1}^{j-1} t_{ik} l_{jk}, \quad j = 1, 2, \dots, i-1 \\ l_{ij} &= t_{ij} / d_j, \quad j = 1, 2, \dots, i-1 \\ d_i &= a_{ii} - \sum_{k=1}^{i-1} t_{ik} l_{ik} \end{aligned} \right\} \quad (2.1.21)$$

这时求解方程组 $AX = b$ 等价于对下列方程组求解:

$$3LY = b, \text{ 求 } Y;$$

$$DL^T X = Y, \text{ 求 } X.$$

这是两个三角方程组, 可用逐步递推方法求其解, 具体计算公式为:

$$y_i = b_i - \sum_{k=1}^{i-1} l_{ik} y_k, \quad i = 1, 2, \dots, n, \quad (2.1.22)$$

$$x_i = \frac{y_i}{d_i} - \sum_{k=i+1}^n l_{ki} x_k, \quad i = n, n-1, \dots, 2, 1. \quad (2.1.23)$$

下面介绍存放问题. 先将计算出 $T = LD$ 的第 i 行元素 t_{ij} ($j = 1, 2, \dots, i-1$) 存放在 A 的第 i 行相应位置. 然后再计算 L 的第 i 行元素存放在 A 的第 i 行, D 的对角元素存放在 A 的相应位置. 例如

$$\begin{aligned}
 \text{(对称矩阵)} \quad A &= \begin{bmatrix} a_{11} & & & \\ a_{21} & a_{22} & & \\ a_{31} & a_{32} & a_{33} & \\ a_{41} & a_{42} & a_{43} & a_{44} \end{bmatrix} = \begin{bmatrix} d_1 & & & \\ l_{21} & d_2 & & \\ l_{31} & l_{32} & d_3 & \\ t_{41} & t_{42} & t_{43} & a_{44} \end{bmatrix} \\
 &\quad \begin{bmatrix} d_1 & & & \\ l_{21} & d_2 & & \\ l_{31} & l_{32} & d_3 & \\ l_{41} & l_{42} & l_{43} & d_4 \end{bmatrix}.
 \end{aligned}$$

例 5 用改进的平方根法解线性方程组

$$\begin{bmatrix} 5 & -4 & 1 & 0 \\ -4 & 6 & -4 & 1 \\ 1 & -4 & 6 & -4 \\ 0 & 1 & -4 & 5 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} 2 \\ -1 \\ -1 \\ 2 \end{bmatrix}.$$

解 对 $i=1$, $d_1 = a_{11} = 5$;

对 $i=2$, 有 $t_{21} = a_{21} = -4$,

$$l_{21} = t_{21}/d_1 = -0.8, \quad d_2 = a_{22} - t_{21}l_{21} = 2.8.$$

存放后数组 A 的形式为

$$\begin{bmatrix} 5 & & & \\ -0.8 & 2.8 & & \\ 1 & -4 & 6 & \\ 0 & 1 & -4 & 5 \end{bmatrix}.$$

对 $i=3$, 有

$$t_{3j} = a_{3j} - \sum_{k=1}^{j-1} t_{3k}l_{jk}, \quad j = 1, 2,$$

$$t_{31} = a_{31} = 1, \quad t_{32} = -3.2, \quad l_{31} = t_{31}/d_1 = 0.2,$$

$$l_{32} = t_{32}/d_2 = -1.14286, \quad d_3 = 2.14285.$$

存放后数组 A 的形式为

$$\begin{bmatrix} 5 \\ -0.8 & 2.8 \\ 0.2 & -1.14286 & 2.14285 \\ 0 & 1 & -4 & 5 \end{bmatrix}.$$

对 $i=4$, 有

$$t_{4j} = a_{4j} - \sum_{k=1}^{j-1} t_{4k} l_{jk}, \quad j = 1, 2, 3,$$

$$t_{41} = 0, \quad t_{42} = 1, \quad t_{43} = -2.85714,$$

$$l_{41} = 0, \quad l_{42} = 0.35714, \quad l_{43} = -1.33334,$$

$$d_4 = 0.83332.$$

所以数组 A 的形式为

$$\begin{bmatrix} 5 \\ -0.8 & 2.8 \\ 0.2 & -1.14286 & 2.14285 \\ 0 & 0.35714 & -1.33334 & 0.83332 \end{bmatrix}.$$

由公式(2.1.22)可求得三角方程组 $LY=b$ 的解为

$$Y = (2, 0.6, -0.71428, 0.83333)^T.$$

再由公式(2.1.23)可求得方程组 $DL^T X=Y$ 的解为

$$X = (1.00002, 1.00003, 1.00003, 1.00002)^T,$$

该方程组的准确解为 $X=(1, 1, 1, 1)^T$.

六、追赶法

在二阶常微分方程边值问题、热传导方程以及船体数学放样中建立的三次样条函数等工程技术问题的求解中, 经常遇到如下形式的特殊线性方程组

$$\begin{bmatrix} b_1 & c_1 & & & \\ a_2 & b_2 & c_2 & & \\ & a_3 & b_3 & c_3 & \\ & & w & w & w \\ & & & a_{n-1} & b_{n-1} & c_{n-1} \\ & & & & a_n & b_n \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ x_{n-1} \\ x_n \end{bmatrix} = \begin{bmatrix} d_1 \\ d_2 \\ d_3 \\ \vdots \\ d_{n-1} \\ d_n \end{bmatrix}. \quad (2.1.24)$$

方程组(2.1.24)称为三对角线性方程组,其系数矩阵 A 为三对角矩阵,这种方程组常常是按行严格对角占优的,即

$$\left. \begin{aligned} b_1 &> c_1 > 0, \\ b_i &\quad a_i + c_i, \quad a_i > 0, c_i > 0, i = 2, 3, \dots, n-1, \\ b_n &> a_n > 0, \end{aligned} \right\} \quad (2.1.25)$$

这个问题是适合于用 LU 分解法求解的典型问题之一. 由于三对角方程组的特殊性,这里并不用现成的 LU 分解公式,而是推导出一套递推关系,既节省存储单元,又减小计算量,其具体的 LU 分解为:

若 $n (n \geq 2)$ 阶三对角矩阵 A 的元素满足(2.1.25)式,则三对角矩阵 A 有如下三角分解

$$A = \begin{bmatrix} 1 & & & & \\ l_2 & 1 & & & \\ & l_3 & 1 & & \\ & & & W & W \\ & & & & 1_n & 1 \end{bmatrix} \begin{bmatrix} u_1 & c_1 & & & \\ & u_2 & c_2 & & \\ & & & W & W \\ & & & & u_{n-1} & c_{n-1} \\ & & & & & u_n \end{bmatrix}, \quad (2.1.26)$$

其中

$$\begin{cases} u_1 = b_1, \\ l_i = a_i / u_{i-1}, \quad i = 2, 3, \dots, n, \\ u_i = b_i - l_i c_{i-1}. \end{cases} \quad (2.1.27)$$

(证明从略)

设有三对角线性方程组

$$AX = d,$$

其中 A 中元素满足(2.1.25)式,则有(2.1.26)式的三角分解 $A = LU$, 从而方程组 $AX = d$ 的求解等价于求解下述方程组

$$\begin{cases} LY = d, \\ UX = Y. \end{cases}$$

由 $LY = d$, 即

$$\begin{bmatrix} 1 & & & & \\ l_1 & 1 & & & \\ & l_2 & 1 & & \\ & & & w & w \\ & & & & l_n & 1 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} d_1 \\ d_2 \\ d_3 \\ \vdots \\ d_n \end{bmatrix},$$

得

$$\begin{cases} y_1 = d_1, \\ y_i = d_i - l_i y_{i-1}, \quad i = 2, 3, \dots, n. \end{cases} \quad (2.1.28)$$

又由 $UX = Y$, 即

$$\begin{bmatrix} u_1 & c_1 & & & \\ & u_2 & c_2 & & \\ & & & w & w \\ & & & & u_{n-1} & c_{n-1} \\ & & & & & u_n \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_{n-1} \\ x_n \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_{n-1} \\ y_n \end{bmatrix},$$

得

$$\begin{cases} x_n = y_n / u_n, \\ x_i = (y_i - c_i x_{i+1}) / u_i, \quad i = n-1, n-2, \dots, 2, 1. \end{cases} \quad (2.1.29)$$

公式(2.1.27), (2.1.28)和(2.1.29)通常称为解三对角方程组的追赶法公式. 一般地, 称计算 y_1, y_2, \dots, y_n 的过程为“追”, 计算 x_1, x_2, \dots, x_n 的过程为“赶”, 故此法叫做追赶法, 这是实际计算中求解三对角方程组的一种有效方法.

七、列主元三角分解法

列主元三角分解法是对应于高斯列主元消去法的一种矩阵的直接分解法.

我们知道, 用三角分解法求解方程组, 要求系数矩阵 A 的各阶顺序主子式均不为零. 否则, 在分解过程中, 将会出现某个主元素为零而无法继续进行分解. 此外, 即使主元素不为零, 但当其绝对值很小时, 计算结果也将导致舍入误差的严重积累. 然而, 如果我们在分解过程中增加选主元的步骤, 即建立列主元三角分解法, 此时, 由于高斯列主元消去法仅在消元过程中进行行交换, 这就相当于用高斯消去法先进行一系列的行交换后, 方程组再进行 LU 分解. 对此, 若 A 非奇异, 可设原方程组 $AX = b$ 经过行交换后的方程组为

$$PAX = Pb,$$

其中 P 为排列矩阵, 若 PA 能进行 LU 分解, 则可通过依次求解三角方程组:

$$(1) LY = Pb, \text{ 求 } Y;$$

$$(2) UX = Y, \text{ 求 } X$$

得出原方程组 $AX = b$ 的解, 从而有如下定理.

定理 5(列主元的三角分解)

若 A 为非奇异矩阵, 则存在排列矩阵 P , 使得 PA 有惟一的杜里特尔(Doolittle)分解

$$PA = LU,$$

其中, L 是单位下三角阵, U 是上三角阵(在同样条件下, 也可推出 PA 有惟一的克劳特分解).

(证明从略)

定理 5 表明对非奇异矩阵 A 施行一系列行交换后, 可以进行杜里特尔分解, 不过在实际上行交换与分解总是交替进行的, 具体作法如下:

对矩阵 A 做列主元分解, 设 $A^{(0)} = A$, 又设已完成了前 $k-1$ 步分解($1 \leq k \leq n-1$), 并将已算出的 L 和 U 的元素存放在 A 的相应位置, 记为

$$A^{(k-1)} = \begin{bmatrix} u_{11} & u_{12} & \dots & u_{1, k-1} & u_{1k} & \dots & u_{1n} \\ l_{21} & u_{22} & \dots & u_{2, k-1} & u_{2k} & \dots & u_{2n} \\ l_{k-1, 1} & l_{k-1, 2} & \dots & u_{k-1, k-1} & u_{k-1, k} & \dots & u_{k-1, n} \\ l_{k1} & l_{k2} & \dots & l_{k, k-1} & a_{kk}^{(k-1)} & \dots & a_{kn}^{(k-1)} \\ l_{n1} & l_{n2} & \dots & l_{n, k-1} & a_{nk}^{(k-1)} & \dots & a_{nn}^{(k-1)} \end{bmatrix}.$$

由于施行行交换, $A^{(k-1)}$ 中方框内的 $a_{ij}^{(k-1)}$ 可能不是原来 A 中的元素 a_{ij} .

第 k 步分解需利用公式(2.1.11)和(2.1.12). 为了避免用零或绝对值小的数作除数, 先计算

$$S_i = a_{ik}^{(k-1)} - \sum_{r=1}^{k-1} l_{ir} u_{rk} \quad (i = k, k+1, \dots, n).$$

于是 S_k 为(2.1.11)中的 u_{kk} , 而 $S_{k+1}, S_{k+2}, \dots, S_n$ 即为(2.1.12)中各式右端的分子部分, 在它们中间选取绝对值最大者为主元素, 记作 S_{i_k} , 即

$$S_{i_k} = \max_{i=k+1, \dots, n} S_i.$$

然后交换 $A^{(k-1)}$ 中的第 k 行与第 i_k 行, 每个位置上的元素仍用原来的记号, 于是

$$u_{kk} = S_{i_k}.$$

将它存放在 $a_{kk}^{(k-1)}$ 的位置, 然后再进行第 k 步分解, u_{kj} ($j = k+1, k+2, \dots, n$) 仍可按公式(2.1.11)计算, 并依次存放在 $a_{k, k+1}^{(k-1)}, \dots, a_{kn}^{(k-1)}$ 的位置. 而 l_{ik} 的计算可直接利用 S_i ($i = k, k+1, \dots, n$), 即

$$l_{ik} = \begin{cases} S_i / S_{i_k}, & i = k+1, k+2, \dots, n, i \neq i_k, \\ S_k / S_{i_k}, & i = i_k. \end{cases}$$

依次将 $l_{(k+1)k}, \dots, l_{nk}$ 存放在 $a_{(k+1)k}^{(k-1)}, \dots, a_{nk}^{(k-1)}$ 的位置.

在列主元三角分解过程中, $b = (b_1, b_2, \dots, b_n)^T$ 参加 PA 的

LU 分解过程中的行变换. 因此, 分解过程结束时已在 b 的位置上得到 Pb .

综上所述, 将列主元三角分解法用于求解方程组 $AX= b$ 时, 由于

$$PAX = Pb,$$

而 $PA= LU$, 所以 $LUX= Pb$.

于是求解方程组 $AX= b$ 转化为求解两个三角方程组

(1) $LY= Pb$, 求 Y ;

(2) $UX= Y$, 求 X .

以上即为求解线性方程组的列主元分解法.

例 6 利用列主元分解法求方程组

$$\begin{bmatrix} 1.00 & 0.333 & 1.50 & - & 0.333 \\ - & 2.01 & 1.45 & 0.500 & 2.95 \\ 4.32 & - & 1.95 & 0.000 & 2.08 \\ 5.11 & - & 4.00 & 3.33 & - & 1.11 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} 3.00 \\ 5.40 \\ 0.130 \\ 3.77 \end{bmatrix}$$

的解.

解 第一步 当 $k= 1$ 时,

$$S_i = a_{i1}^{(0)}, \quad i = 1, 2, 3, 4,$$

$$S_1 = 1.00, \quad S_2 = - \quad 2.01, \quad S_3 = 4.32, \quad S_4 = 5.11.$$

显然主元素为 $S_4= 5.11, i_1= 4$, 交换 $[A \mid b]$ 的第 1 行与第 4 行, 然后计算 U 的第 1 行与 L 的第 1 列, 得

$$[A^{(1)} \mid b^{(1)}] = \left[\begin{array}{cccccc|c} 5.11 & - & 4.00 & 3.33 & - & 1.11 & 3.77 \\ - & 0.393 & 1.45 & 0.500 & 2.95 & & 5.40 \\ & 0.845 & - & 1.95 & 0.000 & 2.08 & 0.130 \\ & 0.196 & 0.333 & 1.50 & - & 0.333 & 3.00 \end{array} \right].$$

第二步 当 $k= 2$ 时,

$$S_i = a_{i2}^{(1)} - l_{i1}u_{12}, \quad i = 2, 3, 4,$$

$$S_2 = - \quad 0.120, \quad S_3 = 1.43, \quad S_4 = 1.12.$$

主元素为 $S_3 = 1.43$, $i_2 = 3$, 交换 $[A^{(1)} \mid b^{(1)}]$ 的第 2 行与第 3 列, 再计算 U 的第 2 行与 L 的第 2 列, 得

$$[A^{(2)} \mid b^{(2)}] = \left[\begin{array}{cccc|c} 5.11 & -4.00 & 3.33 & -1.11 & 3.77 \\ 0.845 & 1.43 & -2.81 & 3.02 & 0.130 \\ -0.393 & 0.0839 & 0.500 & 2.95 & 5.40 \\ 0.196 & 0.783 & 1.50 & -0.333 & 3.00 \end{array} \right].$$

第三步 当 $k = 3$ 时,

$$S_3 = a_{33}^{(2)} - l_{31}u_{13} - l_{32}u_{23} = 1.57,$$

$$S_4 = a_{43}^{(2)} - l_{41}u_{13} - l_{42}u_{23} = 3.05.$$

主元素为 $S_4 = 3.05$, $i_3 = 4$, 交换 $[A^{(2)} \mid b^{(2)}]$ 的第 3 行与第 4 行, 再计算 U 的第 3 行与 L 的第 3 列, 得

$$[A^{(3)} \mid b^{(3)}] = \left[\begin{array}{cccc|c} 5.11 & -4.00 & 3.33 & -1.11 & 3.77 \\ 0.845 & 1.43 & -2.81 & 3.02 & 0.130 \\ 0.196 & 0.783 & 3.05 & -2.47 & 3.00 \\ -0.393 & -0.0839 & 0.515 & 2.95 & 5.40 \end{array} \right].$$

第四步 当 $k = 4$ 时,

$$u_{44} = a_{44}^{(3)} - l_{41}u_{14} - l_{42}u_{24} - l_{43}u_{34} = 4.04.$$

至此分解完毕, 即 $PA = LU$, 其中

$$L = \left[\begin{array}{cccc} 1 & & & \\ 0.845 & 1 & & \\ 0.196 & 0.783 & 1 & \\ -0.393 & -0.0839 & 0.515 & 1 \end{array} \right],$$

$$U = \left[\begin{array}{cccc} 5.11 & -4.00 & 3.33 & -1.11 \\ & 1.43 & -2.81 & 3.02 \\ & & 3.05 & -2.47 \\ & & & 4.04 \end{array} \right].$$

最后, 求解 $LY = b^{(3)}$ 得

$$Y = (3.77, -3.06, 4.66, 4.22)^T.$$

再求解 $UX = Y$ 得方程组的解为

$$X = (-0.329, 0.322, 2.37, 1.04)^T.$$

§ 2 线性方程组的迭代解法

前面我们介绍了解线性方程组的直接解法, 这对于变量个数不多的线性方程组是很有效的. 但由于采用直接方法在多次消元、回代的过程中, 四则运算的误差积累与传播无法控制, 致使计算结果精度也就无法保证. 对此, 本节将继续介绍线性方程组的另一类解法——迭代法. 由于它具有保持迭代矩阵不变的特点, 因此这类方法特别适用于求解大型稀疏系数矩阵的方程组. 此外, 利用迭代法只要断定系数矩阵满足收敛条件, 尽管多次迭代计算工作量较大, 都能达到预定的精度, 且迭代法在计算机内存和运算两方面通常都可利用系数矩阵中有大量零元素的特点, 而高速计算机能胜任那些程序简单、重复量大的迭代计算.

线性方程组的迭代解法就是根据所给的方程组 $AX = b$, 设计出一个迭代公式, 然后将任意选取的一初始向量 $X^{(0)}$ 代入迭代公式, 求出 $X^{(1)}$, 再以 $X^{(1)}$ 代入同一迭代公式, 求出 $X^{(2)}$, 如此反复进行, 得到向量序列 $\{X^{(k)}\}$. 当 $\{X^{(k)}\}$ 收敛时, 其极限即为原方程组的解. 但由于实际计算都只能计算到某个 $X^{(k)}$ 就停止, 因此, 即使不考虑舍入误差的影响, 通常在有限步骤内迭代法也得不到方程组的准确解, 只能得到逐步逼近解.

下面介绍雅可比(Jacobi)迭代法, 高斯-塞德尔(Gauss-Seidel)迭代法与逐次超松弛迭代法(SOR 迭代法: Successive Over Relaxation Method).

一、雅可比(Jacobi)迭代法

设有 n 元线性方程组

$$AX = b, \tag{2.2.1}$$

其中系数矩阵 A 的对角元素 $a_{ii} \neq 0$ ($i=1, 2, \dots, n$)。

从方程组 $AX = b$ 的第 i 个方程中解出 x_i , 可得到与 $AX = b$ 等价的方程组

$$\left\{ \begin{array}{l} x_1 = \frac{1}{a_{11}}(-a_{12}x_2 - a_{13}x_3 - \dots - a_{1n}x_n + b_1), \\ x_2 = \frac{1}{a_{22}}(-a_{21}x_1 - a_{23}x_3 - \dots - a_{2n}x_n + b_2), \\ \dots\dots\dots \\ x_n = \frac{1}{a_{nn}}(-a_{n1}x_1 - a_{n2}x_2 - \dots - a_{n,n-1}x_{n-1} + b_n). \end{array} \right.$$

(2 . 2 . 2)

记

$$\mathbf{D} = \begin{bmatrix} \mathbf{a}_{11} & & & & \\ & \mathbf{a}_{22} & & & \\ & & \mathbf{w} & & \\ & & & \mathbf{a}_{nn} & \\ & & & & \end{bmatrix}, \quad \mathbf{L} = \begin{bmatrix} 0 & & & & \\ \mathbf{a}_{21} & 0 & & & \\ \mathbf{a}_{31} & \mathbf{a}_{32} & 0 & & \\ & & & \mathbf{w} & \\ \mathbf{a}_{n1} & \mathbf{a}_{n2} & \mathbf{a}_{n3} & \dots & 0 \end{bmatrix},$$

$$\mathbf{U} = \begin{bmatrix} 0 & \mathbf{a}_{12} & \mathbf{a}_{13} & \dots & \mathbf{a}_{1n} \\ & 0 & \mathbf{a}_{23} & \dots & \mathbf{a}_{2n} \\ & & \mathbf{w} & & \\ & & & 0 & \mathbf{a}_{n-1,n} \\ & & & & 0 \end{bmatrix},$$

则(2.2.2)式可用矩阵形式写为

$$\mathbf{X} = -\mathbf{D}^{-1}(\mathbf{L} + \mathbf{U})\mathbf{X} + \mathbf{D}^{-1}\mathbf{b}.$$

令

$$\mathbf{B} = -\mathbf{D}^{-1}(\mathbf{L} + \mathbf{U}), \quad \mathbf{d} = \mathbf{D}^{-1}\mathbf{b},$$

于是(2.2.2)式又可写为

$$\mathbf{X} = \mathbf{B}\mathbf{X} + \mathbf{d}. \quad (2.2.3)$$

迭代计算的过程为：首先取 $X^{(0)} = (x_1^{(0)}, x_2^{(0)}, \dots, x_n^{(0)})^T$ ，将其

代入(2.2.2)式右端,得

[illegible]

即 $\mathbf{X}^{(1)} = \mathbf{B}\mathbf{X}^{(0)} + \mathbf{d}.$

再将 $X^{(1)}$ 代入(2.2.2)式右端, 求得 $X^{(2)} = BX^{(1)} + d$, 如此反复进行迭代, 一般地有

$$\mathbf{X}^{(k+1)} = \mathbf{B}\mathbf{X}^{(k)} + \mathbf{d}, \quad k = 0, 1, 2, \dots,$$

即

$$\left\{ \begin{aligned} \mathbf{x}_1^{(k+1)} &= \frac{1}{\mathbf{a}_{11}}(-\mathbf{a}_{12}\mathbf{x}_2^{(k)} - \mathbf{a}_{13}\mathbf{x}_3^{(k)} - \dots - \mathbf{a}_{1n}\mathbf{x}_n^{(k)} + \mathbf{b}_1), \\ \mathbf{x}_2^{(k+1)} &= \frac{1}{\mathbf{a}_{22}}(-\mathbf{a}_{21}\mathbf{x}_1^{(k)} - \mathbf{a}_{23}\mathbf{x}_3^{(k)} - \dots - \mathbf{a}_{2n}\mathbf{x}_n^{(k)} + \mathbf{b}_2), \\ &\dots\dots\dots \\ \mathbf{x}_n^{(k+1)} &= \frac{1}{\mathbf{a}_{nn}}(-\mathbf{a}_{n1}\mathbf{x}_1^{(k)} - \mathbf{a}_{n2}\mathbf{x}_2^{(k)} - \dots - \mathbf{a}_{n,n-1}\mathbf{x}_{n-1}^{(k)} + \mathbf{b}_n). \end{aligned} \right.$$

(2. 2. 4)

由此即得到一个向量序列 $\{X^{(k)}\}$. 若 $\lim_{k \rightarrow \infty} X^{(k)} = X^*$, 则 X^* 就是方程组 $AX = b$ 的解. 这种求解线性方程组 (2.2.1) 解的方法称为雅可比迭代法, 矩阵 B 称为迭代矩阵. 为了便于编制程序, 可将 (2.2.4) 式改写为如下形式:

$$\begin{aligned} x_i^{(k+1)} &= \frac{1}{a_{ii}} \left[- \sum_{j=1}^{i-1} a_{ij} x_j^{(k)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} + b_i \right] \\ &= x_i^{(k)} + \frac{1}{a_{ii}} \left[b_i - \sum_{j=1}^n a_{ij} x_j^{(k)} \right], \end{aligned} \quad (2.2.5)$$

$$i = 1, 2, \dots, n; \quad k = 0, 1, 2, \dots$$

二、高斯-塞德尔(Gauss-Seidel)迭代法

仔细研究雅可比迭代法我们不难发现, 在逐个求 $x^{(k+1)}$ 的分量 $x_i^{(k+1)}$ 时, 分量 $x_1^{(k+1)}, x_2^{(k+1)}, \dots, x_{i-1}^{(k+1)}$ 都已求得, 但却未被利用, 而是仍用旧分量 $x_1^{(k)}, x_2^{(k)}, \dots, x_{i-1}^{(k)}$ 进行计算. 事实上, 最新计算出来的分量更比旧的分量接近方程组的准确解. 因此, 设想当新的分量求得后, 马上用它来代替旧的分量, 则可能会更快地接近方程组的准确解. 基于这种设想构造的迭代公式就称为高斯-塞德尔迭代法. 其具体迭代过程如下:

任取 $X^{(0)} = (x_1^{(0)}, x_2^{(0)}, \dots, x_n^{(0)})^T$, 第一次迭代为

[illegible]

反复迭代,便得到下面的迭代公式:

$$\left\{ \begin{array}{l} \mathbf{x}_1^{(k+1)} = \frac{1}{\mathbf{a}_{11}}(-\mathbf{a}_{12}\mathbf{x}_2^{(k)} - \mathbf{a}_{13}\mathbf{x}_3^{(k)} - \dots - \mathbf{a}_{1n}\mathbf{x}_n^{(k)} + \mathbf{b}_1), \\ \mathbf{x}_2^{(k+1)} = \frac{1}{\mathbf{a}_{22}}(-\mathbf{a}_{21}\mathbf{x}_1^{(k+1)} - \mathbf{a}_{23}\mathbf{x}_3^{(k)} - \dots - \mathbf{a}_{2n}\mathbf{x}_n^{(k)} + \mathbf{b}_2), \\ \dots\dots\dots \\ \mathbf{x}_n^{(k+1)} = \frac{1}{\mathbf{a}_{nn}}(-\mathbf{a}_{n1}\mathbf{x}_1^{(k+1)} - \mathbf{a}_{n2}\mathbf{x}_2^{(k+1)} - \dots - \mathbf{a}_{n,n-1}\mathbf{x}_{n-1}^{(k+1)} + \mathbf{b}_n). \end{array} \right. \quad (2.2.6)$$

类似地, (2.2.6)式可用矩阵形式表示为

$$\mathbf{X}^{(k+1)} = -\mathbf{D}^{-1}(\mathbf{L}\mathbf{X}^{(k+1)} + \mathbf{U}\mathbf{X}^{(k)}) + \mathbf{D}^{-1}\mathbf{b}.$$

上式两端左乘 D 得

$$DX^{(k+1)} = -LX^{(k+1)} - UX^{(k)} + b.$$

移项得

$$(D + L)X^{(k+1)} = -UX^{(k)} + b.$$

因为 $a_{ii} \neq 0$ ($i = 1, 2, \dots, n$), 所以行列式 $|D + L| \neq 0$, 故将上式两端左乘 $(D + L)^{-1}$ 得

$$X^{(k+1)} = -(D + L)^{-1}UX^{(k)} + (D + L)^{-1}b.$$

令 $G = -(D + L)^{-1}U$, $d_1 = (D + L)^{-1}b$,
则

$$X^{(k+1)} = GX^{(k)} + d_1. \quad (2.2.7)$$

迭代公式(2.2.6)或(2.2.7)称为解线性方程组 $AX = b$ 的高斯-塞德尔迭代法, 矩阵 G 称为迭代矩阵. 为了便于编制程序, 可将(2.2.6)式改写为如下形式:

$$\begin{aligned} x_i^{(0)} \quad (i = 1, 2, \dots, n) \text{ 为任意给定数,} \\ x_i^{(k+1)} &= \frac{1}{a_{ii}} \left[- \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} + b_i \right] \\ &= x_i^{(k)} + \frac{1}{a_{ii}} \left[b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right], \\ i &= 1, 2, \dots, n; \quad k = 0, 1, 2, \dots \end{aligned} \quad (2.2.8)$$

由于当新的分量求得后, 便马上用它来代替旧的分量. 因此高斯-塞德尔迭代法与雅可比迭代法相比有一个明显的优点, 就是上机计算时已不需要两组工作单元存放 $X^{(k)}$ 和 $X^{(k+1)}$, 而仅需一组工作单元用来存放 $X^{(k)}$ 的分量. 当计算出 $x_i^{(k+1)}$ 就冲掉旧分量 $x_i^{(k)}$, 其计算量与雅可比迭代法相同, 但计算速度加快且存储量又小, 故高斯-塞德尔迭代法可看作是雅可比迭代法的一种修正.

三、逐次超松弛(SOR)迭代法

松弛迭代法是高斯-塞德尔迭代法的一种加速方法, 其基本思想是将高斯-塞德尔迭代法得到的第 $k+1$ 次近似解向量 $X^{(k+1)}$ 与第 k 次近似解向量 $X^{(k)}$ 作加权平均, 当权因子(即松弛因子)选取适当时, 加速效果很显著. 因此, 这一方法的关键是如何选取最

佳松弛因子, 现具体介绍如下.

设有线性方程组

$$AX = b,$$

将矩阵 A 分解为 $A = I - B$, 则该方程组等价于

$$X = BX + d \quad (d = b),$$

于是迭代公式为

$$X^{(k+1)} = BX^{(k)} + d. \quad (2.2.9)$$

由于第 k 次近似解 $X^{(k)}$ 并非 $AX = b$ 的解, 故 $b - AX^{(k)} \neq 0$. 令

$$r^{(k)} = b - AX^{(k)},$$

其中 $r^{(k)}$ 称为剩余向量. 于是 (2.2.9) 式可改写为

$$\begin{aligned} X^{(k+1)} &= (I - A)X^{(k)} + b = X^{(k)} + b - AX^{(k)} \\ &= X^{(k)} + r^{(k)} \quad (k = 0, 1, 2, \dots). \end{aligned}$$

上式说明, 应用迭代法实际上是用剩余向量 $r^{(k)}$ 来改进解的第 k 次近似, 也就是说, 第 $k+1$ 次近似是由第 k 次近似加上剩余向量 $r^{(k)}$ 而得到的. 为了加速 $X^{(k+1)}$ 的收敛速度, 可考虑给 $r^{(k)}$ 乘上一个适当因子, 从而得到一个加速迭代公式

$$X^{(k+1)} = X^{(k)} + \omega (b - AX^{(k)}), \quad (2.2.10)$$

其中 ω 称为松弛因子. (2.2.10) 式的分量形式为

$$\begin{aligned} x_i^{(k+1)} &= x_i^{(k)} + \omega \left[b_i - \sum_{j=1}^n a_{ij} x_j^{(k)} \right], \\ i &= 1, 2, \dots, n; \quad k = 0, 1, 2, \dots \end{aligned}$$

只要松弛因子 ω 选择得当, 由 (2.2.10) 式算出的第 $k+1$ 次近似就会更快地接近方程组 $AX = b$ 的解, 从而可以达到加快收敛速度的目的. 然而以上这种在带松弛因子的同时的迭代法技巧要求很高, 很难掌握, 且没有充分利用已经算出的分量信息, 故并不经常使用.

考虑到高斯-塞德尔迭代法的程序设计简单, 且已充分利用了最新计算出来的分量的信息, 故依上述加速收敛思想, 对高斯-塞德尔迭代法加以修正, 便得到下面的逐次超松弛迭代法, 简称 SOR 法. 其迭代公式如下:

任给 $x_i^{(0)}$ ($i = 1, 2, \dots, n$),

$$x_i^{(k+1)} = x_i^{(k)} + \frac{1}{a_{ii}} \left[b_i - \sum_{j=1}^{i-1} a_{ij} x_j^{(k+1)} - \sum_{j=i+1}^n a_{ij} x_j^{(k)} \right]. \quad (2.2.11)$$

$i = 1, 2, \dots, n; \quad k = 0, 1, 2, \dots$

当 $0 < \omega < 1$ 时, (2.2.11) 式称为低松弛迭代法 (SUR 法); 当 $\omega > 1$ 时, (2.2.11) 式称为超松弛迭代法 (SOR 法); 当 $\omega = 1$ 时即为高斯-塞德尔迭代法.

超松弛迭代法是解大型方程组, 特别是大型稀疏矩阵方程组的有效方法之一. 它具有计算公式简单, 程序设计容易, 占用计算机内存单元较少等优点, 只要松弛因子 ω 选择得好, 其收敛速度就会加快.

对于以上介绍的解线性方程组的三种迭代解法, 计算时, 我们都可用 $\max_{1 \leq i \leq n} |x_i^{(k+1)} - x_i^{(k)}| < \epsilon$ (ϵ 为精度要求) 控制迭代终止.

例 1 试分别用雅可比迭代法, 高斯-塞德尔迭代法和超松弛迭代法 (取 $\omega = 1.15$) 解线性方程组

$$\begin{bmatrix} 5 & 1 & -1 & -2 \\ 2 & 8 & 1 & 3 \\ 1 & -2 & -4 & -1 \\ -1 & 3 & 2 & 7 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} -2 \\ -6 \\ 6 \\ 12 \end{bmatrix},$$

当 $\max_{1 \leq i \leq n} |x_i^{(k+1)} - x_i^{(k)}| < 10^{-5}$ 时迭代终止 (方程组的精确解为 $X^* = (1, -2, -1, 3)^T$).

解 取 $X^{(0)} = (0, 0, 0, 0)^T$, 雅可比公式为

$$\begin{cases} x_1^{(k+1)} = x_1^{(k)} + \frac{1}{5}(-2 - x_1^{(k)} - x_2^{(k)} + x_3^{(k)} + 2x_4^{(k)}), \\ x_2^{(k+1)} = x_2^{(k)} + \frac{1}{8}(-6 - 2x_1^{(k)} - 8x_2^{(k)} - x_3^{(k)} - 3x_4^{(k)}), \\ x_3^{(k+1)} = x_3^{(k)} - \frac{1}{4}(6 - x_1^{(k)} + 2x_2^{(k)} + 4x_3^{(k)} + x_4^{(k)}), \\ x_4^{(k+1)} = x_4^{(k)} + \frac{1}{7}(12 + x_1^{(k)} - 3x_2^{(k)} - 2x_3^{(k)} - 7x_4^{(k)}). \end{cases}$$

迭代 24 次后得方程组的近似解为

$$X^{(24)} = (0.9999941, -1.9999950, -1.0000040, 2.9999990)^T.$$

高斯-塞德尔迭代公式为

$$\begin{cases} x_1^{(k+1)} = x_1^{(k)} + \frac{1}{5}(-2 - 5x_1^{(k)} - x_2^{(k)} + x_3^{(k)} + 2x_4^{(k)}), \\ x_2^{(k+1)} = x_2^{(k)} + \frac{1}{8}(-6 - 2x_1^{(k+1)} - 8x_2^{(k)} - x_3^{(k)} - 3x_4^{(k)}), \\ x_3^{(k+1)} = x_3^{(k)} - \frac{1}{4}(6 - x_1^{(k+1)} + 2x_2^{(k+1)} + 4x_3^{(k)} + x_4^{(k)}), \\ x_4^{(k+1)} = x_4^{(k)} + \frac{1}{7}(12 + x_1^{(k+1)} - 3x_2^{(k+1)} - 2x_3^{(k+1)} - 7x_4^{(k)}). \end{cases}$$

迭代 14 次后得方程组的近似解为

$$X^{(14)} = (0.9999966, -1.9999970, -1.0000040, 2.9999990)^T.$$

超松弛迭代法的迭代公式为

$$\begin{cases} x_1^{(k+1)} = x_1^{(k)} + \frac{1}{5}(-2 - 5x_1^{(k)} - x_2^{(k)} + x_3^{(k)} + 2x_4^{(k)}), \\ x_2^{(k+1)} = x_2^{(k)} + \frac{1}{8}(-6 - 2x_1^{(k+1)} - 8x_2^{(k)} - x_3^{(k)} - 3x_4^{(k)}), \\ x_3^{(k+1)} = x_3^{(k)} - \frac{1}{4}(6 - x_1^{(k+1)} + 2x_2^{(k+1)} + 4x_3^{(k)} + x_4^{(k)}), \\ x_4^{(k+1)} = x_4^{(k)} + \frac{1}{7}(12 + x_1^{(k+1)} - 3x_2^{(k+1)} - 2x_3^{(k+1)} - 7x_4^{(k)}). \end{cases}$$

取 $\omega = 1.15$, 迭代 8 次后得方程组的近似解为

$$X^{(8)} = (0.9999965, -1.9999970, -1.0000010, 2.9999990)^T.$$

§ 3 迭代法的收敛性

迭代法的一个重要问题就是在什么条件下才能保证迭代法产生的向量序列 $\{X^{(k)}\}$ 收敛? 为了研究线性方程组近似解的误差估计和迭代法的收敛性, 我们先介绍向量范数和矩阵范数的概念.

一、向量范数与矩阵范数

向量或矩阵范数实际上是对 n 维向量空间中的向量及实数域中的 n 阶方阵的“大小”进行某种度量. 如 R^n 中向量范数是 R^3 中向量长度概念的推广.

定义 1(向量范数) 对任意 n 维向量 $X \in R^n$, 若按一定规则对应一非负实数 $\|X\|$, 它满足以下条件:

(1) 正定条件: $\|X\| \geq 0$, 当且仅当 $X=0$ 时, $\|X\|=0$;

(2) 齐次性: $\|kX\| = |k| \cdot \|X\|$, k 为任意实数;

(3) 三角不等式: $\|X+Y\| \leq \|X\| + \|Y\|$, 对任意 $X, Y \in R^n$, 则称 $\|X\|$ 为向量 X 的范数或模.

设 $X = (x_1, x_2, \dots, x_n)^T$, 常用的向量范数有:

$$\|X\|_1 = |x_1| + |x_2| + \dots + |x_n|,$$

$$\|X\|_2 = \sqrt{|x_1|^2 + |x_2|^2 + \dots + |x_n|^2},$$

$$\|X\|_\infty = \max_{1 \leq i \leq n} |x_i|,$$

分别称为向量 1 范数、向量 2 范数、无穷范数. 易证它们都满足定义 1 中的三个条件.

向量的不同范数的数值是不一样的, 这不影响度量向量的大小, 因为向量的不同范数之间都有一定关系. 可以证明向量 1 范数, 向量 2 范数及无穷范数之间有如下关系:

$$\begin{cases} \|X\|_\infty \leq \|X\|_1 \leq n \|X\|_\infty, \\ \|X\|_2 \leq \|X\|_1 \leq \sqrt{n} \|X\|_2, \\ \frac{1}{\sqrt{n}} \|X\|_1 \leq \|X\|_2 \leq \|X\|_1. \end{cases} \quad (2.3.1)$$

这一关系称为向量之间的等价关系. 它表明, 若一个向量的某种范数是一个小量, 则它的任何一种范数也是一个小量. 因此, 不同范数在数量上的差别对分析误差并不重要, 反而使我们可以根据具体问题选择适当的范数以利于分析和计算.

例 1 设 $X = (1, 0, -5, 2)^T$, 求 $\|X\|_1, \|X\|_2, \|X\|$.

解 $\|X\|_1 = 1 + 5 + 2 = 8,$

$$\|X\|_2 = \sqrt{1^2 + 0^2 + (-5)^2 + 2^2} = \sqrt{30},$$

$$\|X\| = \max\{1, 5, 2\} = 5.$$

设 $R^{n \times n}$ 为全体 n 阶方阵的集合, 类似向量范数的定义, 我们给出矩阵范数的定义.

定义 2(矩阵的范数) 对任何 n 阶方阵 $A \in R^{n \times n}$, 若对应一个非负实数 $\|A\|$ 满足:

(1) $\|A\| \geq 0$, 当且仅当 $A = 0$ 时, $\|A\| = 0$;

(2) 对任意数 k , 有 $\|kA\| = |k| \cdot \|A\|$;

(3) 对任意两个 n 阶方阵 $A, B \in R^{n \times n}$, 有

$$\|A + B\| \leq \|A\| + \|B\|;$$

(4) $\|AB\| \leq \|A\| \cdot \|B\|$,

则称 $\|A\|$ 为 n 阶方阵 A 的范数(或称 A 的模).

与向量范数的定义相比较, 前三条性质只是向量范数定义的推广, 而第四条性质则是矩阵乘法性质的要求.

由于很多误差估计问题, 矩阵范数常与向量范数混合在一起使用, 例如线性方程组 $AX = b$, 左端就是一个矩阵与一个向量的乘积. 因此在分析其误差估计时, 必须同时涉及矩阵范数和向量范数. 所以当我们考虑矩阵范数时, 应该使它和向量范数联系起来. 为此引进范数相容的概念.

定义 3(相容性) 对任意的 n 阶方阵 $A \in R^{n \times n}$ 和 n 维向量 $X \in R^n$, 若不等式

$$\|AX\| \leq \|A\| \|X\| \quad (2.3.2)$$

成立, 则称矩阵范数与向量范数是相容的.

上述不定式也称为矩阵范数与向量范数的相容性条件. 在同一个问题中要同时使用矩阵范数与向量范数时, 这两种范数应当是相容的.

$$\lim_k X^{(k)} = X^* \text{ 或简记为 } X^{(k)} \xrightarrow{k} X^*.$$

显然, 向量序列 $\{X^{(k)}\}$ 收敛于 X^* 的充要条件是

$$\max_{1 \leq i \leq n} |x_i^* - x_i^{(k)}| \xrightarrow{k} 0,$$

$$\text{即} \quad \lim_k \|X^* - X^{(k)}\| = 0,$$

其中 $\|\cdot\|$ 为向量的任何一种范数. 由范数的等价性, 即(2.3.1)式可知

$$\lim_k \|X^* - X^{(k)}\|_2 = 0$$

$$\text{和} \quad \lim_k \|X^* - X^{(k)}\|_1 = 0$$

同样是 $\{X^{(k)}\}$ 收敛于 X^* 的充要条件. 因此, 对某种迭代法的收敛性, 常用按某种范数的收敛来加以证明.

在讨论方程组迭代法的收敛条件时, 常用到谱半径的概念, 下面我们给出定义.

定义 5 设 n 阶矩阵 $A \in R^{n \times n}$ 的特征值为 λ_i ($i = 1, 2, \dots, n$), 称

$$\rho(A) = \max_{1 \leq i \leq n} |\lambda_i| \quad (2.3.3)$$

为矩阵 A 的谱半径.

下面继续讨论谱半径与范数之间的关系.

设 λ 为 A 的任意特征值, X 为对应于 λ 的 A 的特征向量, 则由

$$X = AX$$

得 $\|X\| = \|AX\|$, 再依相容性条件有

$$\|X\| = \|AX\| \leq \|A\| \cdot \|X\|.$$

因为 X 为非零向量, $\|X\| > 0$, 故有

$$1 \leq \|A\|.$$

由于 λ 是 A 的任何特征值, 因此有

$$|\lambda| \leq \|A\|, \quad (2.3.4)$$

即矩阵 A 的谱半径不超过 A 的任何一种范数. 在讨论线性方程组迭代法的收敛性时, 当变元个数较多时, 由于 $\rho(A)$ 不容易求, 而

$\|A\|$ 较容易求, 故可将条件适当放宽, 改用 $\|A\|$ 去判别.

下面介绍一般线性迭代法收敛的一些基本定理.

设有线性方程组 $AX = b$, 其中 A 为非奇异矩阵, 将其转化为与之等价的方程组

$$X = MX + d$$

且 $\{X^{(k)}\}$ 为由迭代法

$$X^{(k+1)} = MX^{(k)} + d \quad (2.3.5)$$

(其中 $X^{(0)}$ 为任意选取的初始向量) 产生的向量序列, M 称为迭代矩阵, d 称为右端向量.

定理 1 对任意的初始向量 $X^{(0)}$ 及任意的右端向量 d , 迭代法 (2.3.5) 收敛的充分必要条件是谱半径 $\rho(M) < 1$.

(证明从略)

一般来说, 计算矩阵的谱半径比较困难, 故用定理 1 判断迭代法是否收敛往往不太容易, 以下介绍用矩阵范数或其他方法判别迭代法收敛的充分条件.

定理 2 若 $\|M\| < 1$, 则迭代法 (2.3.5) 收敛, 且有误差估计式

$$\|X^* - X^{(k)}\| \leq \frac{1}{1 - \|M\|} \|X^{(k+1)} - X^{(k)}\|, \quad (2.3.6)$$

$$\|X^* - X^{(k)}\| \leq \frac{\|M\|^k}{1 - \|M\|} \|X^{(1)} - X^{(0)}\|. \quad (2.3.7)$$

证明 由于 $\rho(M) = \|M\|$, 迭代法 (2.3.5) 收敛是显然的, 且有 $\lim_{k \rightarrow \infty} X^{(k)} = X^*$. 下证 (2.3.6) 与 (2.3.7) 成立.

由于 X^* 满足方程组

$$X^* = MX^* + d. \quad (2.3.8)$$

由迭代公式 (2.3.5) 与 (2.3.8) 可得

$$X^{(k+1)} - X^{(k)} = M(X^{(k)} - X^{(k-1)}),$$

$$X^* - X^{(k+1)} = M(X^* - X^{(k)}),$$

于是

$$\|X^{(k+1)} - X^{(k)}\| = \|M\| \cdot \|X^{(k)} - X^{(k-1)}\|, \quad (2.3.9)$$

$$\|X^* - X^{(k+1)}\| = \|M\| \cdot \|X^* - X^{(k)}\|,$$

$$\begin{aligned} \text{而 } \|X^{(k+1)} - X^{(k)}\| &= \|X^* - X^{(k)} - (X^* - X^{(k+1)})\| \\ &= \|X^* - X^{(k)}\| - \|X^* - X^{(k+1)}\| \\ &= (1 - \|M\|) \|X^* - X^{(k)}\|, \end{aligned}$$

$$\text{即有 } \|X^* - X^{(k)}\| = \frac{1}{1 - \|M\|} \|X^{(k+1)} - X^{(k)}\|,$$

于是(2.3.6)得证. 进而反复用(2.3.9)即可得到(2.3.7):

$$\|X^* - X^{(k)}\| = \frac{\|M\|^k}{1 - \|M\|} \|X^{(1)} - X^{(0)}\|.$$

用迭代矩阵 $\|M\| < 1$ 作为收敛性的判别是方便的, 但要注意这只是收敛的充分条件. 例如, 考虑方程组

$$X = MX + d,$$

$$\text{其中 } M = \begin{bmatrix} 0.8 & 0 \\ 0.5 & 0.7 \end{bmatrix}, \quad d = \begin{bmatrix} 1 \\ 1 \end{bmatrix},$$

计算矩阵 M 的范数得

$$\|M\|_1 = 1.3, \quad \|M\|_2 = 1.09, \quad \|M\|_\infty = 1.2.$$

虽然 M 的这些范数都大于 1, 但 M 的特征值为 $\lambda_1 = 0.8$, $\lambda_2 = 0.7$, 即 $\rho(M) = 0.8$, 由定理 1 知此方程组的迭代法是适用的.

下面我们再给出雅可比迭代法与高斯-塞德尔迭代法收敛的充分条件.

定义 6(严格对角占优阵) 设 $A = (a_{ij})_{n \times n}$, 如果 A 满足条件

$$|a_{ii}| > \sum_{j=1, j \neq i}^n |a_{ij}|, \quad i = 1, 2, \dots, n,$$

即矩阵 A 的每一行对角元素的绝对值都严格大于同行的其他元素的绝对值之和, 则称 A 为严格对角占优矩阵.

定理 3 若 $A = (a_{ij})_{n \times n}$ 为严格对角占优阵, 则 A 为非奇异矩阵.

证明 用反证法. 若 $A = 0$, 则齐次线性方程组 $AX = 0$ 有非

零解, 记为 $X = (x_1, x_2, \dots, x_n)^T$, 且记 $x_k = \max_{1 \leq i \leq n} x_i = 0$, 于是由 $AX = 0$ 的第 k 个方程

$$\sum_{j=1}^n a_{kj} x_j = 0,$$

得

$$a_{kk} x_k = - \sum_{\substack{j=1 \\ j \neq k}}^n a_{kj} x_j$$

即

$$a_{kk} \leq \sum_{\substack{j=1 \\ j \neq k}}^n a_{kj}.$$

与假设矛盾, 故 $A \neq 0$, 即 A 为非奇异矩阵.

定理 4 若 $AX = b$ 的系数矩阵 $A \in R^{n \times n}$ 为严格对角占优阵, 则解此方程组的雅可比迭代法和高斯-塞德尔迭代法都收敛.

证明 (1) 首先证明解 $AX = b$ 的雅可比迭代法收敛. 因为 A 为严格对角占优阵, 所以

$$a_{ii} > \sum_{\substack{j=1 \\ j \neq i}}^n a_{ij}, \quad i = 1, 2, \dots, n,$$

即

$$\sum_{\substack{j=1 \\ j \neq i}}^n \left| \frac{a_{ij}}{a_{ii}} \right| < 1, \quad i = 1, 2, \dots, n.$$

雅可比迭代矩阵为 $B = -D^{-1}(L+U)$, 由此有

$$\|B\| = \max_{1 \leq i \leq n} \sum_{\substack{j=1 \\ j \neq i}}^n \left| \frac{a_{ij}}{a_{ii}} \right| < 1.$$

由定理 2 知解 $AX = b$ 的雅可比迭代法收敛.

(2) 再证高斯-塞德尔迭代法收敛.

由假设可知 $a_{ii} \neq 0$ ($i = 1, 2, \dots, n$), 而解方程组 $AX = b$ 的高斯-塞德尔方法的迭代矩阵为 (2.2.7) 中的 G , 其中的矩阵 $G = -(D+L)^{-1}U$, 考虑 G 的特征值, 令

$$\begin{aligned} I - G &= I + (D + L)^{-1}U \\ &= (D + L)^{-1} \cdot (D + L) + U = 0. \end{aligned}$$

由于 $(D + L)^{-1} = 0$, 于是

$$(D + L) + U = 0. \quad (2.3.10)$$

今记

$$C = (D + L) + U = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{bmatrix}.$$

以下证明当 $\rho(C) < 1$ 时, $C = 0$. 若该结论成立, 则 $C = 0$ 的根均满足 $\rho(C) < 1$, 亦即 $\rho(G) < 1$, 于是由定理 1 知高斯-塞德尔迭代法收敛.

事实上, 由于 A 为严格对角占优阵, 故有

$$a_{ii} > \sum_{j=1, j \neq i}^n a_{ij}, \quad i = 1, 2, \dots, n.$$

当 $\rho(C) < 1$ 时, 有

$$a_{ii} > \sum_{j=1}^{i-1} a_{ij} + \sum_{j=i+1}^n a_{ij}, \quad i = 1, 2, \dots, n.$$

这说明矩阵 C 为严格对角占优阵, 故由定理 3 知, $(D + L) + U = 0$, 从而 $\rho(G) < 1$, 再由定理 1 知, 高斯-塞德尔迭代法收敛.

用某种迭代法求解线性方程组是否收敛, 取决于方程组的系数矩阵 A . 对此, 再给出迭代法收敛的如下定理.

定理 5 若 $AX = b$ 的系数矩阵 A 为对称正定矩阵, 则解此线性方程组的高斯-塞德尔迭代法收敛.

(证明从略)

关于超松弛迭代法有下述定理.

定理 6 若解 $AX = b$ ($a_{ii} > 0, i = 1, 2, \dots, n$) 的 SOR 法收敛, 则 $0 < \omega < 2$.

这个定理给出了超松弛迭代法(SOR 法)收敛的必要条件. 即只有松弛因子 ω 在 $(0, 2)$ 内选取时, 超松弛迭代法才可能收敛. 但当系数矩阵 A 为对称矩阵且 λ 满足 $0 < \lambda < 2$ 时, 我们还可证明超松弛迭代法一定收敛.

定理 7 若 $AX = b$ 的系数矩阵 A 为对称正定矩阵, 且 $0 < \omega < 2$, 则解此方程组的 SOR 法收敛.

最后, 关于线性方程组的迭代解法还指出两点:

(1) 从理论上讲, 迭代法可以得到任意精度要求的近似解, 但是由于受到机器字长的限制, 不可能达到任意的精度, 最多只能达到机器精度. 因此使用误差估计式 $\max_{1 \leq i \leq n} |x_i^{(k+1)} - x_i^{(k)}| < \epsilon$ 来控制迭代终止时, 精度要求 ϵ 要选得恰当, 小于或接近机器的精度, 都可能造成死循环.

(2) 当所给的方程组不满足迭代法的收敛条件时, 适当调整方程组中方程的次序或作一定的线性组合, 即可得到满足迭代法收敛条件的同解方程组.

例如方程组

$$\begin{cases} 2x_1 + 9x_2 = -5, \\ 8x_1 + 3x_2 = 13, \end{cases}$$

容易验证用雅可比迭代法和高斯-塞德尔迭代法都不收敛. 但只需将方程组的两个方程次序调换, 变为

$$\begin{cases} 8x_1 + 3x_2 = 13, \\ 2x_1 + 9x_2 = -5, \end{cases}$$

显然, 该方程组的系数矩阵

$$A = \begin{bmatrix} 8 & 3 \\ 2 & 9 \end{bmatrix}$$

是严格对角占优的, 故用两种迭代法求解都收敛.

又如线性方程组

$$\begin{cases} 5x_1 + x_2 + 2x_3 = 0, \\ -11x_1 + 8x_2 + x_3 = 21, \\ -4x_1 - 2x_2 + 3x_3 = 8. \end{cases}$$

将第 1 个方程二倍加到第 2 个方程上, 得

$$-x_1 + 10x_2 + 5x_3 = 21,$$

又将第 1 个方程加到第 3 个方程, 得

$$x_1 - x_2 + 5x_3 = 8.$$

从而得到与原方程组同解的方程组

$$\begin{cases} 5x_1 + x_2 + 2x_3 = 0, \\ -x_1 + 10x_2 + 5x_3 = 21, \\ x_1 - x_2 + 5x_3 = 8, \end{cases}$$

此方程组的系数矩阵显然是严格对角占优的, 故无论用雅可比迭代法或高斯-塞德尔迭代法求解都收敛.

本章小结

本章主要讨论了线性方程组的直接解法和迭代解法.

直接解法的重点是高斯列主元消去法及其列主元直接三角分解法. 引进选列主元的技巧是为了控制计算过程中舍入误差的增长, 减少舍入误差的影响. 一般说来, 列主元消去法及列主元三角分解法是数值稳定的算法, 它具有精确度较高、计算量不大和算法组织容易等优点, 是目前计算机上解中、小型稠密矩阵方程组可靠而有效的常用方法.

在实际应用中, 对于一些特殊类型的方程组可用特殊方法求解. 例如三对角矩阵方程组(A 的对角元占优)可用追赶法求解, 对称正定矩阵方程组可用平方根法求解, 这些方法都是数值稳定的方法, 且不选主元也具有较高的精度.

关于迭代解法, 本章主要介绍了雅可比迭代法、高斯-塞德尔迭代法和超松弛迭代法. 迭代法是利用计算机求解方程组时常用

的方法,它具有计算公式简单,程序设计容易,占用计算机内存较少,容易上机实现等优点,适用于解大型、稀疏矩阵的线性方程组.超松弛迭代法在实用中比较重要,但要选择好松弛因子,才能加快收敛速度.

在使用迭代法时,还要特别注意检验所用方法的收敛性及其收敛速度问题,为了讨论迭代法的收敛性,本章还介绍了向量及矩阵范数的概念,并给出了迭代法收敛的一些基本定理.

算法与程序设计实例

1. 用列主元高斯消去法求解方程组

算法

将方程组用增广矩阵 $[A \mid b] = (a_{ij})_{n \times (n+1)}$ 表示.

(1) 消元过程:

对 $k = 1, 2, \dots, n-1$,

选主元,找 $i_k \in \{k, k+1, \dots, n\}$ 使得

$$a_{i_k, k} = \max_{k \leq i \leq n} a_{ik}.$$

如果 $a_{i_k, k} = 0$, 则矩阵 A 奇异, 程序结束; 否则执行 .

如果 $i_k \neq k$, 则交换第 k 行与第 i_k 行对应元素位置,

$$a_{kj} \leftrightarrow a_{i_k j}, \quad j = k, \dots, n+1.$$

消元, 对 $i = k+1, \dots, n$, 计算

$$l_{ik} = a_{ik} / a_{kk},$$

对 $j = k+1, \dots, n+1$, 计算

$$a_{ij} = a_{ij} - l_{ik} a_{kj}.$$

(2) 回代过程:

若 $a_{nn} = 0$, 则矩阵 A 奇异, 程序结束; 否则执行 .

$x_n = a_{n, n+1} / a_{nn}$; 对 $i = n-1, \dots, 2, 1$, 计算

$$x_i = \left[a_{i, n+1} - \sum_{j=i+1}^n a_{ij} x_j \right] / a_{ii}.$$

实例

例 1 解方程组

$$\begin{cases} 0.101x_1 + 2.304x_2 + 3.555x_3 = 1.183, \\ -1.347x_1 + 3.712x_2 + 4.623x_3 = 2.137, \\ -2.835x_1 + 1.072x_2 + 5.643x_3 = 3.035. \end{cases}$$

程序和输出结果

```
/* 列主元 Gauss 消去法 */
#include <stdio.h>
#include <conio.h>
#include <alloc.h>
#include <math.h>
main()
{
    int i;
    float * x;
    float c[3][4] = {0.101, 2.304, 3.555, 1.183,
                     - 1.347, 3.712, 4.623, 2.137,
                     - 2.835, 1.072, 5.643, 3.035};
    float * ColPivot(float * , int);
    x = ColPivot(c[0], 3);
    clrscr(); /* clear screen */
    for(i = 0; i <= 2; i++) printf( "x[ %d] = %f\n", i, x[i]);
    getch();
}

float * ColPivot(float * c, int n)
{
    int i, j, t, k;
    float * x, * p;
```

```

x= (float * )malloc(n* sizeof( float));    /* 分配内存 */
for(i= 0;i< = n- 2;i+ + )
{
k= i;
for(j= i+ 1;j< = n- 1;j+ + )
if(fabs(* (c+ j* (n+ 1)+ i))> (fabs(* (c+ k* (n+ 1)
+ i)))) k= j;
if(k!= i)
for(j= i;j< = n;j+ + )
{
p= * (c+ i* (n+ 1)+ j);
* (c+ i* (n+ 1)+ j)= * (c+ k* (n+ 1)+ j);
* (c+ k* (n+ 1)+ j)= p;
}
for(j= i+ 1;j< = n- 1;j+ + )
{
p= (* (c+ j* (n+ 1)+ i))/( * (c+ i* (n+ 1)+ i));
for(t= i;t< = n;t+ + )
* (c+ j* (n+ 1)+ t)- = p* (* (c+ i* (n+ 1)+ t));
}
}
for(i= n- 1;i> = 0;i- - )
{
for(j= n- 1;j> = i+ 1;j- - ) (* (c+ i* (n+ 1)+ n))-
= x[j] * (* (c+ i* (n+ 1)+ j));
x[i]= * (c+ i* (n+ 1)+ n)/( * (c+ i* (n+ 1)+ i));
}
return x;
}

```


输出结果如下:

$$x[0] = -0.398234$$

$$x[1] = 0.013795$$

$$x[2] = 0.335144$$

2. 用雅可比迭代法解方程组

算法

设方程组 $Ax = b$ 的系数矩阵的对角线元素 $a_{ii} \neq 0$ ($i = 1, 2, \dots, n$), M 为迭代次数容许的最大值, ϵ 为容许误差.

取初始向量 $x = (x_1^{(0)}, x_2^{(0)}, \dots, x_n^{(0)})^T$, 令 $k = 0$.

对 $i = 1, 2, \dots, n$, 计算

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left[b_i - \sum_{j=1, j \neq i}^n a_{ij} x_j^{(k)} \right].$$

如果 $\max_{i=1}^n |x_i^{(k+1)} - x_i^{(k)}| < \epsilon$, 则输出 $x^{(k+1)}$, 结束; 否则执行

如果 $k = M$, 则不收敛, 终止程序; 否则 $k = k + 1$, 转 .

实例

例 2 用雅可比迭代法解方程组

$$\begin{cases} 5x_1 + 2x_2 + x_3 = 8, \\ 2x_1 + 8x_2 - 3x_3 = 21, \\ x_1 - 3x_2 - 6x_3 = 1. \end{cases}$$

程序和输出结果

```
# include <stdio.h>
# include <conio.h>
# include <alloc.h>
# include <math.h>
# define EPS 1e- 6
```

```

# define MAX 100
float * Jacobi(float a[3][4], int n)
{
float * x, * y, epsilon, s;
int i,j,k= 0;
x= (float * )malloc(n* sizeof( float));
y= ( float * )malloc( n* sizeof( float));
for(i= 0;i< n;i+ + ) x[i]= 0;
while( 1)
{
epsilon= 0;
k+ + ;
for( i= 0;i< n;i+ + )
{
s= 0;
for(j= 0;j< n;j+ + )
{
if(j= = i) continue;
s+ = a[i][j]* x[j];
}
y[i]= ( a[i][n] - s)/a[i][i];
epsilon+ = fabs(y[i]- x[i]);
}
if(epsilon< EPS){printf(" 迭代次数为: % d\n ",k);return
if(k> = MAX)
{printf(" The Method is disconvergent ");
return y;}
for( i= 0;i< n;i+ + ) x[i]= y[i];
}
}

```

```

}
main()
{
int i;
float a[3][4]= {5, 2, 1, 8, 2, 8, - 3, 21, 1, - 3, - 6, 1};
float * x;
x= (float * )malloc(3* sizeof(float));
x= Jacobi(a, 3);
clrscr();
for(i= 0; i< 3; i+ + )printf( x[ % d]= % f\n , i, x[i] );
getch();
}

```

输出结果如下:

迭代次数为 20

$x[0] = 1.000000$

$x[1] = 2.000000$

$x[2] = -1.000000$

思考题

1. 何谓高斯消去法? 它与一般消去法有何不同? 怎样利用高斯消去法计算系数矩阵的行列式?
2. 计算机上为什么不用克莱姆法则与约当消去法?
3. 为何要采用列主元消去法? 它是怎样从高斯消去法演变过来的?
4. 追赶法适用于何种类型的方程组? 它是怎样从高斯消去法演变过来的?
5. 何谓三角分解法? 主要有哪几种? 计算公式有何异同? 主

要用于哪些情形?

6. 改进的平方根法适用于何种类型的方程组? 怎样用紧凑格式的方法来记忆改进的平方根法?

7. 写出雅可比迭代法和高斯-塞德尔迭代法的计算公式. 它们各有什么特点?

8. 雅可比迭代法和高斯-塞德尔迭代法的矩阵表示形式是什么? 为何要研究它们的矩阵表示形式?

9. 判别迭代法收敛的充分必要条件及充分条件是什么?

10. 雅可比迭代法和高斯-塞德尔迭代法收敛性的各种判别条件是什么?

习 题 二

1. 分别用高斯消去法和列主元素消去法求解下列方程组.

(计算取 4 位小数)

$$(1) \begin{cases} 2x_1 - x_2 - x_3 = 4, \\ 3x_1 + 4x_2 - 2x_3 = 11, \\ 3x_1 - 2x_2 + 4x_3 = 11; \end{cases}$$

$$(2) \begin{cases} 3x_1 - x_2 + 4x_3 = 7, \\ -x_1 + 2x_2 - 2x_3 = -1, \\ 2x_1 - 3x_2 - 2x_3 = 0; \end{cases}$$

$$(3) \begin{cases} 1.1161x_1 + 0.1254x_2 + 0.1397x_3 + 0.1490x_4 = 1.5471, \\ 0.1582x_1 + 1.1675x_2 + 0.1768x_3 + 0.1871x_4 = 1.6471, \\ 0.1968x_1 + 0.2071x_2 + 1.2168x_3 + 0.2271x_4 = 1.7471, \\ 0.2368x_1 + 0.2471x_2 + 0.2568x_3 + 1.2671x_4 = 1.8471. \end{cases}$$

2. 用 LU 三角分解法求解方程组:

$$\begin{bmatrix} 6 & 2 & 1 & -1 \\ 2 & 4 & 1 & 0 \\ 1 & 1 & 4 & -1 \\ -1 & 0 & -1 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} 6 \\ -1 \\ 5 \\ -5 \end{bmatrix}.$$

3. 用平方根法解下列方程组:

$$(1) \begin{bmatrix} 3 & 2 & 1 \\ 2 & 2 & 0 \\ 1 & 0 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 5 \\ 4 \\ 3 \end{bmatrix};$$

$$(2) \begin{bmatrix} 3 & 2 & 3 \\ 2 & 2 & 0 \\ 3 & 0 & 12 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 5 \\ 3 \\ 7 \end{bmatrix}.$$

4. 用改进的平方根法解方程组:

$$\begin{bmatrix} 2 & -1 & 1 \\ -1 & -2 & 3 \\ 1 & 3 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 4 \\ 5 \\ 6 \end{bmatrix}.$$

5. 用追赶法解下列方程组:

$$(1) \begin{bmatrix} 5 & 6 & & & \\ & 1 & 5 & 6 & \\ & & 1 & 5 & 6 \\ & & & 1 & 5 & 6 \\ & & & & 1 & 5 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \\ x_5 \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \\ 0 \\ 0 \\ 1 \end{bmatrix};$$

$$(2) \begin{bmatrix} 5 & 1 & \\ & 1 & 5 & 1 \\ & & 1 & 5 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 17 \\ 14 \\ 7 \end{bmatrix}.$$

6. 证明下列方程组的雅可比迭代法和相应的高斯-塞德尔迭代法收敛, 并写出迭代公式:

$$(1) \begin{bmatrix} 7 & 1 & 2 \\ 2 & 8 & 2 \\ 2 & 2 & 9 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 10 \\ 8 \\ 6 \end{bmatrix};$$

$$(2) \begin{bmatrix} 5 & -2 & 1 \\ 1 & 5 & -3 \\ 2 & 1 & -5 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 4 \\ 2 \\ -11 \end{bmatrix}.$$

7. 设有方程组

$$\begin{cases} 5x_1 + 2x_2 + x_3 = -12, \\ -x_1 + 4x_2 + 2x_3 = 20, \\ 2x_1 - 3x_2 + 10x_3 = 3, \end{cases}$$

(1) 证明用雅可比迭代法与高斯-塞德尔迭代法解此方程组均收敛;

(2) 取初始向量 $X^{(0)} = (-3, 1, 1)^T$, 分别用雅可比迭代法与高斯-塞德尔迭代法求解, 要求 $\max_{1 \leq i \leq 3} x_i^{(k+1)} - x_i^{(k)} < 10^{-3}$ 时迭代终止.

8. 取 $\omega = 0.8$, 初始向量 $X^{(0)} = (0, 0, 0)^T$, 用 SOR 方法解方程组

$$\begin{bmatrix} 4 & -1 & 0 \\ -1 & 4 & -1 \\ 0 & -1 & 4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 1 \\ 4 \\ -3 \end{bmatrix},$$

并且要求 $\max_{1 \leq i \leq 3} x_i^{(k+1)} - x_i^{(k)} < 10^{-4}$ 时终止迭代. 试与精确解 $X = (1/2, 1, -1/2)^T$ 比较.

9. 设线性方程组 $AX = b$ 的系数矩阵为

$$A = \begin{bmatrix} -1 & 0 & 1 \\ -1 & 1 & 0 \\ 1 & 2 & -3 \end{bmatrix},$$

证明用雅可比迭代法收敛, 而用高斯-塞德尔迭代法不收敛.

10. 设线性方程组 $AX = b$ 的系数矩阵为

$$A = \begin{bmatrix} 2 & -1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & -2 \end{bmatrix},$$

证明用雅可比迭代法不收敛, 而用高斯-塞德尔迭代法收敛.

11. 求证矩阵 $A = \begin{bmatrix} 1 & a & a \\ a & 1 & a \\ a & a & 1 \end{bmatrix}$, 当 $-0.5 < a < 1$ 时正定; 当

- $0.5 < a < 0$ 时用雅可比迭代法解 $AX = b$ 收敛.

12. 设

$$A = \begin{bmatrix} 0.6 & 0.5 \\ 0.1 & 0.3 \end{bmatrix},$$

计算 A 的行范数、列范数、2-范数及 F -范数.

13. 设 $X \in \mathbb{R}^n$, $A \in \mathbb{R}^{n \times n}$, 证明:

(1) $\|X\| \leq \|X\|_1 \leq n \|X\|$;

(2) $\frac{1}{\sqrt{n}} \|A\|_F \leq \|A\|_2 \leq \|A\|_F$.

第三章 非线性方程的数值解法

在科学研究与工程技术中常会遇到求解非线性方程 $f(x) = 0$ 的问题. 而方程按 $f(x)$ 是多项式或超越函数又分别称为代数方程或超越方程. 例如代数方程

$$x^4 - 10x^3 + 35x^2 - 50x + 24 = 0,$$

超越方程

$$e^{-x} - \sin\left[\frac{n}{2}\right] = 0.$$

对于不高于 4 次的代数方程已有求根公式, 而高于 4 次的代数方程则无精确的求根公式, 至于超越方程就更无法求出其精确解了. 因此, 如何求得满足一定精度要求的方程的近似根也就成为了广大科技工作者迫切需要解决的问题. 为此, 本章介绍几种常用的非线性方程的近似求根方法.

§ 1 根的搜索与二分法

一、根的搜索

在用近似方法求方程的根时, 需要知道方程的根所在区间. 如果在区间 $[a, b]$ 内只有方程 $f(x) = 0$ 的一个根, 则称区间 $[a, b]$ 为隔根区间.

寻找方程 $f(x) = 0$ 的隔根区间, 通常有如下两种方法:

1. 描图法

画出 $y = f(x)$ 的简图, 由曲线与 x 轴交点的位置确定出隔根区间, 或者将方程等价变形为 $g_1(x) = g_2(x)$, 画出函数 $y = g_1(x)$

和 $y = g_2(x)$ 的简图, 从两条曲线交点的横坐标的位置确定隔根区间.

2. 逐步搜索法

先确定方程 $f(x) = 0$ 的所有实根所在区间 $[a, b]$, 再按选定的步长 $h = \frac{b-a}{n}$ (n 为正整数), 逐点计算 $x_k = a + kh$ ($k = 0, 1, 2, \dots, n$) 处的函数值 $f(x_k)$, 当 $f(x_k)$ 与 $f(x_{k+1})$ 的值异号时, 则 $[x_k, x_{k+1}]$ 即为方程 $f(x) = 0$ 的一个隔根区间.

对于 m 次代数方程

$$f(x) = x^m + a_1x^{m-1} + a_2x^{m-2} + \dots + a_{m-1}x + a_m = 0, \tag{3.1.1}$$

如果能事先确定实根的上下界, 那么在找方程的隔根区间时, 就可以减少一些不必要的计算量. 关于方程 (3.1.1) 根的绝对值 (即根模) 的上下界有如下结论:

(1) 若 $\mu = \max\{a_1, a_2, \dots, a_m\}$, 则方程 (3.1.1) 的根的绝对值小于 $\mu + 1$;

(2) 若 $\mu = \frac{1}{a_m} \max\{1, a_1, a_2, \dots, a_{m-1}\}$, 则方程 (3.1.1) 的根的绝对值大于 $\frac{1}{1+\mu}$.

利用以上结论可以求得实根的范围.

例 1 求方程 $3x - 1 - \cos x = 0$ 的隔根区间.

解 用作图法, 将方程等价变形为

$$3x - 1 = \cos x,$$

令 $y = 3x - 1, y = \cos x$, 作两个函数的图形, 如图 3-1. 由图 3-1 知, 方程仅有一实根, 隔根区间为 $[0.5, 1]$.




图 3-1

例 2 求方程 $x^3 - 3.2x^2 + 1.9x + 0.8 = 0$ 的隔根区间.

解 用逐步搜索法. 设方程的根为 μ , 因为

$$\begin{aligned}\mu &= \max\{-3.2, 1.9, 0.81\} = 3.2, \\ &= \frac{1}{0.8} \max\{1, -3.2, 1.91\} = 4,\end{aligned}$$

所以

$$0.2 = \frac{1}{1+} < \mu + 1 = 4.2.$$

即隔根区间为

$$-4.2 < \mu < -0.2 \quad \text{和} \quad 0.2 < \mu < 4.2.$$

由表 3-1 计算 $f(x_k)$, 取 $n=8, h=0.5$.

表 3-1

x_k	- 4.2	...	- 0.7	- 0.2	0.2	0.7	1.2	1.7	2.2	...	4.2
$f(x_k)$	- 137.72	...	- 2.44	0.28	1.06	0.91	0.20	- 0.31	0.14	...	26.42

由表 3-1 可以看出, 隔根区间为 $[-0.7, -0.2], [1.2, 1.7], [1.7, 2.2]$.

这种逐步搜索寻找隔根区间的方法, 在计算机上实现十分方便, 只需将函数 $f(x)$ 排一个程序, 然后由键盘输入起点 x_0 及步长 h , 根据计算的结果, 调整步长 h 的大小, 总可以把隔根区间全部找出来. 当步长 h 越小时, 找出的隔根区间越小, 这时以区间内的某个值作为根的近似值就越精确. 但 h 越小, 计算量就越大. 因此, 应考虑如何在此基础上找出更精确的近似根. 对此下面我们继续介绍二分法.

二、二分法

二分法的基本思想是通过计算隔根区间的中点, 逐步将隔根区间缩小, 从而可得方程的近似根数列 $\{x_n\}$.

设 $f(x)$ 为连续函数, 又设方程 $f(x) = 0$ 的隔根区间为 $[a, b]$, 为确定起见, 设 $f(a) < 0, f(b) > 0$. 二分法的做法就是首先将区间

$[a, b]$ 二分得中点 $(a+b)/2$, 将 $[a, b]$ 分为两个相等区间, 计算 $f(x)$ 在中点的函数值 $f\left[\frac{a+b}{2}\right]$. 若 $f\left[\frac{a+b}{2}\right] = 0$, 则 $x^* = \frac{a+b}{2}$ 就是方程 $f(x) = 0$ 的根; 否则, 若 $f\left[\frac{a+b}{2}\right] < 0$, 由于 $f(x)$ 在左半区间 $\left[a, \frac{a+b}{2}\right]$ 内不变号, 所以方程的隔根区间变为 $\left[\frac{a+b}{2}, b\right]$. 同理, 若 $f\left[\frac{a+b}{2}\right] > 0$, 则方程的有根区间变为 $\left[a, \frac{a+b}{2}\right]$, 将新的隔根区间记为 $[a_1, b_1]$.

其次, 将 $[a_1, b_1]$ 二分, 重复上述过程, 又得到新的隔根区间 $[a_2, b_2]$, 这样不断作下去, 就得到一系列隔根区间:

$$[a, b] \quad [a_1, b_1] \quad \dots \quad [a_k, b_k] \quad \dots$$

并有 $f(a_k) \cdot f(b_k) < 0$, $x^* \in (a_k, b_k)$, 且后一区间的长度都是前区间长度的一半, 所以 $[a_k, b_k]$ 的长度为

$$b_k - a_k = \frac{b - a}{2^k}.$$

当 $k \rightarrow \infty$ 时, 区间 $[a_k, b_k]$ 的长度必趋于零, 即这些区间最终收缩于一点 x^* , 显然 x^* 就是方程 $f(x) = 0$ 的根.

实际计算时, 只要二分的次数 n 足够大, 就可取最后区间的中点 $x_k = \frac{a_k + b_k}{2}$ 作为方程 $f(x) = 0$ 的根的近似值, 即

$$x^* \approx \frac{a_k + b_k}{2}.$$

此时所产生的误差为

$$x^* - x_k = \frac{b_k - a_k}{2} = \frac{b - a}{2^{k+1}}.$$

若事先给定的精度要求为 ϵ , 则只需

$$x^* - x_k = \frac{b - a}{2^{k+1}} < \epsilon$$

便可停止计算.

例 3 用二分法求方程 $x^3 + 4x^2 - 10 = 0$ 在 $[1, 2]$ 内的根的近似

似值, 要求绝对误差不超过 $\frac{1}{2} \times 10^{-2}$.

解 $f(x) = x^3 + 4x^2 - 10$ 在 $[1, 2]$ 上

$$f'(x) = 3x^2 + 4x > 0,$$

故 $f(x)$ 在 $[1, 2]$ 上严格单调增加, 且 $f(1) < 0, f(2) > 0$, 所以方程在 $[1, 2]$ 内有惟一实根.

令 $\frac{b-a}{2^{k+1}} \leq \frac{1}{2} \times 10^{-2}$, 则得

$$k + 1 \geq \frac{\ln 200(b-a)/\ln 2}{\ln 2},$$

所以至少对分 8 次.

取 $x_1 = \frac{1+2}{2} = 1.5$ 开始计算, 列表 3-2 如下所示. 所以有

$$x^* = \frac{1}{2}(1.359375 + 1.3671875) = 1.363.$$

表 3-2

k	x_k	$f(x_k)$ 符号	隔根区间
1	$x_1 = 1.5$	+	$[1, 2]$
2	$x_2 = 1.25$	-	$[1, 1.5]$
3	$x_3 = 1.375$	+	$[1.25, 1.5]$
4	$x_4 = 1.3125$	-	$[1.25, 1.375]$
5	$x_5 = 1.34375$	-	$[1.3125, 1.375]$
6	$x_6 = 1.359375$	-	$[1.34375, 1.375]$
7	$x_7 = 1.3671875$	+	$[1.359375, 1.375]$
8	$x_8 = 1.36328125$	-	$[1.359375, 1.3671875]$

二分法又称对分法, 其优点是运算简单, 方法可靠, 对函数 $y = f(x)$ 的要求不高, 只要求函数 $y = f(x)$ 在区间 $[a, b]$ 连续, 易于在计算机上实现, 但缺点是不能用其来求复根及偶数重根, 且由于每步误差是以 $1/2$ 因子下降, 故收敛速度也较慢. 因此, 常用该方法为其他求根方法提供较好的近似初始值, 再用其他的求根方法精确化.

用二分法求近似根流程图如图 3-2.

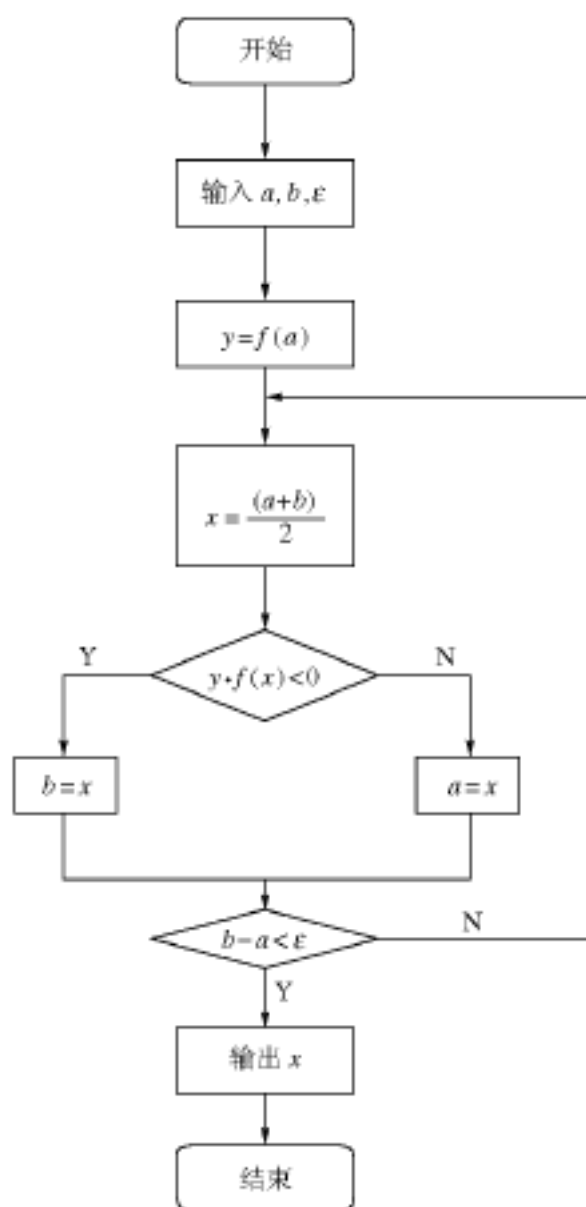


图 3-2

§ 2 迭代法及其迭代收敛的加速方法

迭代法是方程求根最常用的方法,尤其是计算机的普遍应用,使迭代法的应用更为广泛.

一、迭代法

迭代法是一种逐次逼近的方法,其基本思想是利用某种递推算式,使某个预知的近似根(简称初值)逐次精确化,直到满足精度要求的近似根为止,具体做法如下:

给定方程

$$f(x) = 0, \quad (3.2.1)$$

其中 $f(x)$ 在有根区间 $[a, b]$ 上连续, 并设 x_0 是方程的一个近似根, 将方程 $f(x) = 0$ 改写等价形式

$$x = \varphi(x). \quad (3.2.2)$$

为了求出(3.2.1)在 $[a, b]$ 上的根, 由(3.2.2)构造迭代序列

$$\begin{cases} x_1 = \varphi(x_0), \\ x_2 = \varphi(x_1), \\ \dots\dots\dots \\ x_{k+1} = \varphi(x_k), \\ \dots\dots\dots \end{cases} \quad (3.2.3)$$

这种方法称为迭代法(或简单迭代法), $\varphi(x)$ 称为迭代函数. 若由迭代法产生的序列 $\{x_k\}$ 的极限存在, 即 $\lim_{k \rightarrow \infty} x_k = x^*$, 则称 $\{x_k\}$ 收敛或迭代过程(3.2.3)收敛, 否则称 $\{x_k\}$ 发散.

迭代法的几何意义可解释为: 求方程 $x = \varphi(x)$ 的根 x^* , 在几何上就是求直线 $y = x$ 与曲线 $y = \varphi(x)$ 交点 P^* 的横坐标, 见图 3-3.

对于 x^* 的某个初始近似值 x_0 , 对应于曲线 $y = \varphi(x)$ 上一点 $P_0(x_0, \varphi(x_0))$, 过 P_0 点引平行于 x 轴的直线, 交直线 $y = x$ 于点 $Q_1(x_1, x_1)$; 过 Q_1 再作平行于 y 轴的直线, 它与曲线 $y = \varphi(x)$ 的交点记作 $P_1(x_1, \varphi(x_1))$; 过 P_1 再作平行于 x 轴的直线, 又交直线 $y = x$ 于点 $Q_2(x_2, x_2)$, 继续如此做下去, 就在曲线 $y = \varphi(x)$ 上得点列 P_0, P_1, P_2, \dots , 逐渐逼近于交点 P^* , 点列的横坐标 $x_0, x_1,$

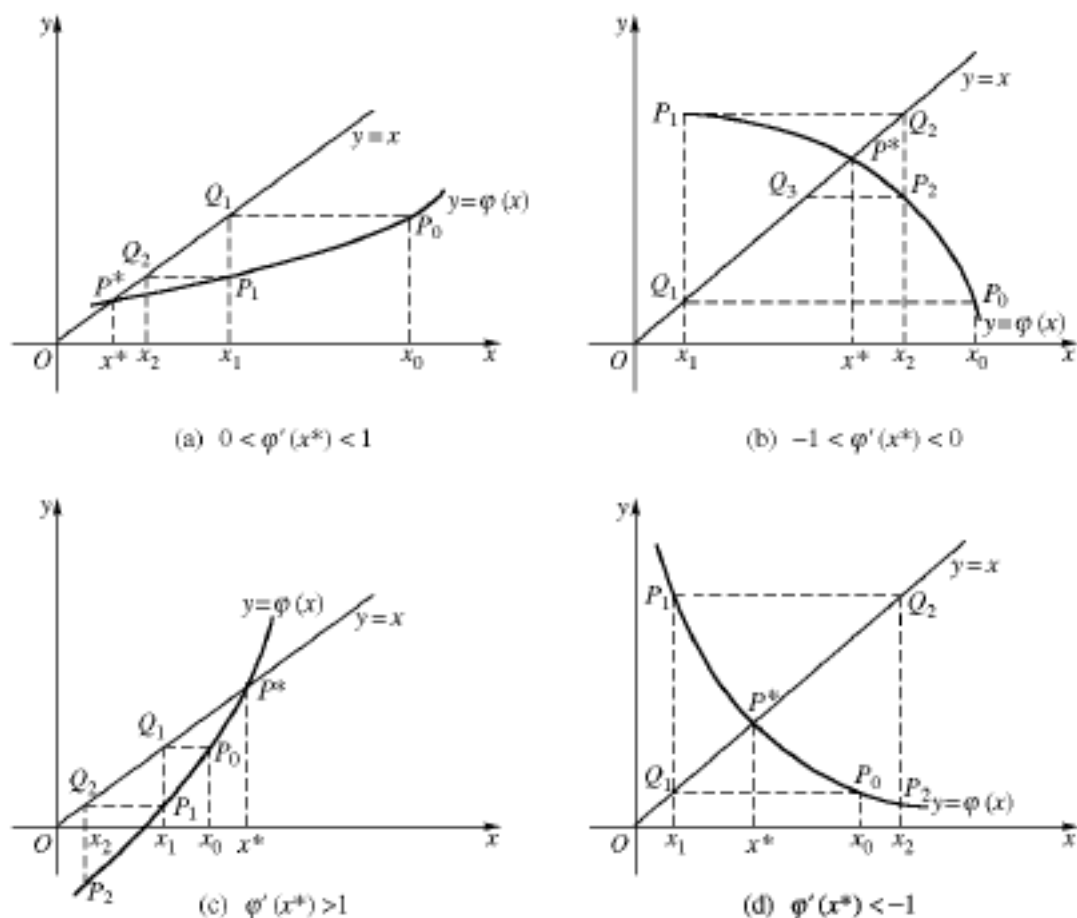


图 3-3

x_2, \dots , 逐渐趋于根 x^* . 可见, 此时迭代格式收敛, 如图 3-3 中的 (a), (b), 否则迭代格式发散, 如图 3-3 中的 (c), (d).

从图中可知, 当迭代函数 $\varphi(x)$ 的导数 $\varphi'(x)$ 在根 x^* 处满足不同条件时, 迭代过程的收敛情况也有所不同. 由此可见, 迭代过程的收敛依赖于迭代函数 $\varphi(x)$ 的构造, 为使迭代法有效, 必须保证它的收敛性, 一个产生发散序列的迭代函数是没有任何使用价值的.

设 $\varphi(x)$ 为连续函数, 且 $\lim_{k \rightarrow \infty} x_k = x^*$, 则有 $x^* = \varphi(x^*)$. 故 x^* 是方程 $x = \varphi(x)$ 的解, 称 x^* 为迭代函数的不动点, 简单迭代法又称为不动点迭代法.

显然, 将 $f(x) = 0$ 转化为等价方程 $x = \varphi(x)$ 的方法有多种, 并

不是惟一的,例如方程 $f(x) = x - \sin x - 0.5 = 0$ 可改写为如下两种等价方程:

- (1) $x = \sin x + 0.5 = \varphi_1(x)$;
- (2) $x = \arcsin(x - 0.5) = \varphi_2(x)$.

而在由方程 $f(x) = 0$ 转化为等价方程 $x = \varphi(x)$ 时,选择迭代函数 $\varphi(x)$ 是很重要的.选择不同的迭代函数 $\varphi(x)$,就会产生不同的序列 $\{x_k\}$,且这些序列的收敛情况也不一定相同,即使初始值选择相同但收敛情况也不一定相同.

例 1 已知方程 $10^x - x - 2 = 0$ 在 $[0.3, 0.4]$ 内有一个根,用两种不同的迭代公式

- (1) $x_{k+1} = 10^{x_k - 2}$;
- (2) $x_{k+1} = \lg(x_k + 2)$,

进行迭代,观察所得序列的收敛性.

计算结果见表 3-3.

表 3-3

k	(1)	(2)
0	$x_0 = 0.3$	$x_0 = 0.3$
1	$x_1 = -0.0047$	$x_1 = 0.3617$
2	$x_2 = -1.0108$	$x_2 = 0.3732$
3		$x_3 = 0.3753$
4		$x_4 = 0.3757$

由计算结果知,该例中的迭代公式(1)产生的数列是发散的,迭代公式(2)产生的数列是收敛的.

由此看来,必须讨论迭代法收敛的条件.

由迭代法的几何意义可知,为了保证迭代过程收敛,就要求迭代函数 $\varphi(x)$ 在区间 $[a, b]$ 上变化不要太快,即 $\varphi(x)$ 的绝对值应较小.从图 3-3 看出,当 $|\varphi(x)| < 1$ 时,迭代过程收敛,这种情况可见图中(a),(b),否则发散,如图中(c),(d).

综上所述,即可给出如下迭代法收敛定理.

定理 1 设有方程 $x = \varphi(x)$, 若迭代函数 $\varphi(x)$ 在有根区间 $[a, b]$ 上满足:

(1) 当 $x \in [a, b]$ 时, $\varphi(x) \in [a, b]$;

(2) $\varphi(x)$ 在 $[a, b]$ 上可导, 且有 $|\varphi'(x)| \leq L < 1, x \in [a, b]$, 则有

(1) 方程 $x = \varphi(x)$ 在 $[a, b]$ 上有惟一的根 x^* ;

(2) 对任意初值 $x_0 \in [a, b]$, 迭代公式 $x_{k+1} = \varphi(x_k)$ ($k = 0, 1, 2, \dots$) 产生的数列 $\{x_k\}$ 收敛于方程的惟一根 x^* , 即 $\lim_{k \rightarrow \infty} x_k = x^*$;

(3) 误差估计

$$|x^* - x_k| \leq \frac{L^k}{1 - L} |x_1 - x_0|. \quad (3.2.4)$$

证明 (1) 先证方程根的存在性: 作函数 $g(x) = x - \varphi(x)$, 由 $\varphi(x)$ 在 $[a, b]$ 上可导知 $g(x)$ 亦在 (a, b) 内可导, 故 $g(x)$ 在 $[a, b]$ 上连续. 由本定理条件 (1) 有

$$g(a) = a - \varphi(a) \leq 0, \quad g(b) = b - \varphi(b) \geq 0,$$

于是由连续函数的介值定理, 必存在 $x^* \in [a, b]$ 使得 $g(x^*) = 0$, 即 $x^* = \varphi(x^*)$. 因此, x^* 是方程 $x = \varphi(x)$ 的根.

再证惟一性: 假设存在两个根 $x_1^*, x_2^* \in [a, b], x_1^* \neq x_2^*$, 使得

$$x_1^* = \varphi(x_1^*), \quad x_2^* = \varphi(x_2^*).$$

两式相减并由微分中值定理有

$$\begin{aligned} x_1^* - x_2^* &= \varphi(x_1^*) - \varphi(x_2^*) \\ &= \varphi'(\xi) \cdot x_1^* - x_2^*, \end{aligned}$$

其中 ξ 在 x_1^* 与 x_2^* 之间, 因而 $\xi \in [a, b]$, 由条件 (2), 得

$$|x_1^* - x_2^*| \leq L |x_1^* - x_2^*| < |x_1^* - x_2^*|.$$

上式是不可能成立的, 故必有 $x_1^* = x_2^* = x^*$.

(2) 证收敛性: 由迭代过程 (3.2.3) 及本定理条件 (1), 当取 $x_0 \in [a, b]$ 时, 则有

$$x_k \in [a, b] \quad (k = 1, 2, \dots),$$

$$x^* - x_k = (x^*) - (x_{k-1}).$$

于是由微分中值定理和条件(2)可得

$$\begin{aligned} x^* - x_k &= (x^*) - (x_{k-1}) = (\xi_{k-1}) x^* - x_{k-1} \\ &= L x^* - x_{k-1} = L^2 x^* - x_{k-2} \\ &\dots = L^k x^* - x_0, \end{aligned}$$

其中 ξ_{k-1} 在 x^* 与 x_{k-1} 之间. 因为 $L < 1$, 所以

$$\lim_k L^k x^* - x_0 = 0,$$

故 $\lim_k x_k = x^*.$

(3) 下证误差估计式(3.2.4): 由迭代公式 $x_{k+1} = (x_k)$, 显然对任意正整数 k 有

$$\begin{aligned} x^* - x_{k+1} &= (x^*) - (x_k) = (\xi_k) x^* - x_k \\ &= L x^* - x_k, \end{aligned}$$

其中 ξ_k 在 x^* 与 x_k 之间.

同理

$$x_{k+1} - x_k = L x_k - x_{k-1}, \quad (3.2.5)$$

但是

$$\begin{aligned} x_{k+1} - x_k &= (x^* - x_k) - (x^* - x_{k+1}) \\ &= x^* - x_k - x^* + x_{k+1} \\ &= x^* - x_k - L x^* + x_k \\ &= (1 - L) x^* - x_k, \end{aligned}$$

从而有

$$\begin{aligned} x^* - x_k &= \frac{1}{1 - L} x_{k+1} - x_k = \frac{L}{1 - L} x_k - x_{k-1}. \end{aligned} \quad (3.2.6)$$

反复应用(3.2.5)式可得

$$x^* - x_k = \frac{L^k}{1 - L} x_1 - x_0 \quad (k = 1, 2, \dots).$$

定理得证.

容易推得例 1 中的迭代公式(2)满足定理(1)的条件.

在实际计算中, (3.2.4)式不仅可以用来估计迭代 k 次时的误差, 还可以用来估计达到给定的精度要求时, 所需迭代的次数 k .

若欲使 $x^* - x_k$, 只要

$$\frac{L^k}{1-L} x_1 - x_0, \quad ,$$

从而迭代次数满足

$$k > \ln \frac{(1-L)}{x_1 - x_0} / \ln L. \quad (3.2.7)$$

注意到估计式(3.2.6), 当 $0 < L < 1$ 越小时, 序列 $\{x_k\}$ 收敛越快, 只要相邻两次迭代的偏差 $x_k - x_{k-1}$ 足够小时, 就可以保证近似解 x_k 有足够的精度. 因此, 上机计算时, 常采用条件 $x_k - x_{k-1}$

来控制迭代终止. 但要注意的是, 当 $L \rightarrow 1$ 时, 即使 $x_k - x_{k-1}$ 很小, 但误差 $x^* - x_k$ 还是可能较大.

由于定理 1 中的条件(1)一般不易验证, 且对于较大范围的隔根区间此条件也不一定成立, 而在根的邻近, 定理的条件是成立的. 为此再给出下述迭代过程的局部收敛性定理.

定理 2(迭代法的局部收敛性定理) 设 x^* 是方程 $x = \varphi(x)$ 的根, $\varphi(x)$ 在 x^* 的某一邻域连续, 且 $|\varphi'(x^*)| < 1$, 则必存在 x^* 的一个邻域 $S = \{x \mid x - x^* < \delta\}$, 对任意选取的初值 $x_0 \in S$, 迭代公式 $x_{k+1} = \varphi(x_k)$ ($k = 1, 2, \dots$) 产生的数列 $\{x_k\}$ 收敛于方程的根 x^* (这时称迭代法在 x^* 的 S 邻域具有局部收敛性).

证明 取 $[a, b] = [x^* - \delta, x^* + \delta]$, 于是只要验证定理 1 中的条件(1)成立即可.

设 $x \in S$, 即 $x - x^* < \delta$ 时, 由微分中值定理及 $|\varphi'(x^*)| < 1$, 有

$$\begin{aligned} |x - x^*| &= |\varphi(x) - \varphi(x^*)| \\ &= |\varphi'(\xi)| |x - x^*| \end{aligned}$$

$$\begin{aligned} & L(x) - x^* \\ & < x - x^* \end{aligned},$$

其中 S , 故 $(x) \leq S$.

由于在实际应用中 x^* 事先不知道, 故条件 $(x^*) < 1$ 无法验证. 但如果已知根的初始值 x_0 在根 x^* 的附近, 又根据 (x) 的连续性, 则可采用条件

$$(x) < 1$$

来代替 $(x^*) < 1$.

例 2 求方程 $f(x) = 2x - \lg x - 7 = 0$ 的最大根, 要求精度为 10^{-4} .




图 3-4

解 (1) 求隔根区间方程等价形式为

$$2x - 7 = \lg x.$$

作函数 $y = 2x - 7$ 和 $y = \lg x$ 的图形, 如图 3-4 所示. 由图知, 方程的最大根在区间 $[3.5, 4]$ 内.

(2) 建立迭代公式, 判别收敛性.

将方程等价变形为

$$x = \frac{1}{2}(\lg x + 7),$$

迭代公式为

$$x_{k+1} = \frac{1}{2}(\lg x_k + 7).$$

因为 $(x) = \frac{1}{2 \ln 10} \cdot \frac{1}{x}$, 所以 (x) 在区间 $[3.5, 4]$ 可导.

因为 (x) 在区间 $[3.5, 4]$ 上是增函数, 且

$$(3.5) \approx 3.77, \quad (4) \approx 3.80.$$

所以, 当 $x \in [3.5, 4]$ 时, $(x) \in [3.5, 4]$.

因为

$$L = \max_{3.5 \leq x \leq 4} (x) = 0.06, \quad (3.5)$$

所以对于区间 $[3.5, 4]$ 上的一切 x , 有

$$(x) = 0.06 < 1.$$

由定理 1 知, 迭代法收敛.

(3) 计算.

取 $x_0 = 3.5$, 有

$$x_1 = \frac{1}{2}(\lg x_0 + 7) = 3.78989,$$

$$x_2 = \frac{1}{2}(\lg x_1 + 7) = 3.78931,$$

$$x_3 = \frac{1}{2}(\lg x_2 + 7) = 3.78928.$$

因为 $|x_3 - x_2| = 10^{-4}$, 所以方程的最大根

$$x^* = x_3 = 3.789.$$

例 3 用迭代法求方程 $x^3 - x^2 - 1 = 0$ 在隔根区间 $[1.4, 1.5]$ 内的根, 要求精确到小数点后第 4 位.

解 (1) 构造迭代公式.

方程的等价形式为

$$x = \sqrt[3]{x^2 + 1} = (x),$$

迭代格式

$$x_{k+1} = \sqrt[3]{x_k^2 + 1}.$$

(2) 判断迭代法的收敛性.

用定理 2 判定

$$(x) = \frac{2x}{3\sqrt[3]{(x^2 + 1)^2}}.$$

因为 (x) 在区间 $(1.4, 1.5)$ 内可导, 且

$$(x) = 0.5 < 1,$$

所以, 迭代法收敛.

(3) 列表计算见表 3-4.

表 3-4

k	x_k	$x_{k+1} - x_k$	$\frac{1}{2} \times 10^{-4}$
0	$x_0 = 1.5$		
1	$x_1 = 1.4812480$	$x_1 - x_0$	0.02
2	$x_2 = 1.4727057$	$x_2 - x_1$	0.009
3	$x_3 = 1.4688173$	$x_3 - x_2$	0.004
4	$x_4 = 1.4670480$	$x_4 - x_3$	0.002
5	$x_5 = 1.4662430$	$x_5 - x_4$	0.0009
6	$x_6 = 1.4658786$	$x_6 - x_5$	0.0004
7	$x_7 = 1.4657020$	$x_7 - x_6$	0.0002
8	$x_8 = 1.4656344$	$x_8 - x_7$	0.00007
9	$x_9 = 1.4656000$	$x_9 - x_8$	$\frac{1}{2} \times 10^{-4}$

由表 3-4 可见, 第 9 次迭代结果满足精度要求, 故取 x^*
1.4656.

综上所述, 用迭代法求方程 $f(x) = 0$ 的根的近似值的计算步骤如下:

- (1) 准备: 选定初始值 x_0 和确定方程 $f(x) = 0$ 的等价方程 $x = \varphi(x)$;
- (2) 迭代: 按迭代公式 $x_{k+1} = \varphi(x_k)$ 计算出 x_k ($k = 1, 2, \dots$);
- (3) 判别: 若 $|x_{k+1} - x_k| < \epsilon$ (ϵ 为事先给定的精度), 则终止迭代, 取 x_{k+1} 作为根 x^* 的近似值. 否则, 转(2)继续迭代.

迭代法的优点是计算程序简单, 且可计算复根.

对于收敛的迭代公式, 只要迭代足够次数, 就可以使结果达到要求的精度. 从(3.2.4)式知, L 越接近于零, 迭代过程收敛得越快. 而有些迭代过程, 虽然收敛但比较缓慢, 计算起来需花费很多时间, 故如何使迭代过程加速是数值计算的一个重要课题. 对此, 下面继续介绍迭代收敛的加速方法.

二、迭代收敛的加速方法

1. 迭代-加速公式

记 $x_{k+1} = (x_k)$, 则由微分中值定理有

$$x_{k+1} - x^* = (f'(x)) (x_k - x^*), \quad (3.2.8)$$

其中 $f'(x)$ 在 x_k 与 x^* 之间.

设 $f'(x)$ 在根 x^* 附近变化不大, 又设 $|f'(x)| = q$, 由迭代收敛条件有 $|q| < 1$, 故上式为

$$x_{k+1} - x^* = q(x_k - x^*),$$

整理为 $x_{k+1} - x^* = \frac{q}{1-q}(x_k - x_{k+1}).$

上式说明, 把 x_{k+1} 作为根的近似值时, 其绝对误差大致为 $\frac{q}{1-q}(x_k - x_{k+1})$. 如果把该误差值作为对 x_{k+1} 的一种补偿, 便得到更好的近似值

$$x^* = x_{k+1} + \frac{q}{1-q}(x_{k+1} - x_k).$$

记 $x_{k+1} = x_{k+1} + \frac{q}{1-q}(x_{k+1} - x_k),$

得迭代-加速公式

$$\begin{cases} x_{k+1} = (x_k), \\ x_{k+1} = \frac{1}{1-q}x_{k+1} - \frac{q}{1-q}x_k, \end{cases} \quad (k = 0, 1, 2, \dots) \quad (3.2.9)$$

由该公式可得近似根数列 $\{x_k\}$.

例 4 对例 3 用迭代-加速公式(3.2.9)求方程的根.

解 $f'(x)$ 在根附近变化不大, $|f'(x)| = 0.45 = q$, 迭代-加速公式为

$$\begin{cases} x_{k+1} = \sqrt[3]{x_k^2 + 1}, \\ x_{k+1} = \frac{20}{11}x_{k+1} - \frac{9}{11}x_k. \end{cases} \quad (k = 0, 1, 2, \dots)$$

列表计算见表 3-5.

表 3-5

k	X_k	X_k	$X_{k+1} - X_k$	10^{-4}
0		$X_0 = 1.5$		
1	$X_1 = 1.481248$	$X_1 = 1.465905$		
2	$X_2 = 1.465746$	$X_2 = 1.465575$	$X_2 - X_1$	0.0003
3	$X_3 = 1.465573$	$X_3 = 1.465572$	$X_3 - X_2$	$< 10^{-4}/2$

由表 3-5 知, 第 3 次迭代结果满足精度要求, 故取 $X^* = 1.4656$.

上例说明, 达到同样的精度, 用迭代-加速公式仅迭代了 3 次.

2. 埃特金(Aitken)加速方法
记

$$X_{k+1} = (X_k), \quad X_{k+2} = (X_{k+1}).$$

用平均变化率

$$\frac{(X_{k+1}) - (X_k)}{X_{k+1} - X_k} = \frac{X_{k+2} - X_{k+1}}{X_{k+1} - X_k}$$

代替(3.2.8)式中的 $()$, 则有

$$X_{k+1} - X^* = \frac{X_{k+2} - X_{k+1}}{X_{k+1} - X_k} (X_k - X^*),$$

进而有

$$X^* = \frac{X_{k+2}X_k - X_{k+1}^2}{X_{k+2} - 2X_{k+1} + X_k} = X_{k+2} - \frac{(X_{k+2} - X_{k+1})^2}{X_{k+2} - 2X_{k+1} + X_k}.$$

从上式可看出, 第二项是对 X_{k+2} 的一种补偿. 记

$$X_{k+1} = \frac{X_{k+2}X_k - X_{k+1}^2}{X_{k+2} - 2X_{k+1} + X_k},$$

得埃特金加速公式

$$\left. \begin{aligned} X_{k+1} &= (X_k), \\ X_{k+2} &= (X_{k+1}), \\ X_{k+1} &= \frac{X_{k+2}X_k - X_{k+1}^2}{X_{k+2} - 2X_{k+1} + X_k}, \end{aligned} \right\} \quad (k=0, 1, 2, \dots) \quad (3.2.10)$$

由此得近似根数列 $\{x_k\}$.

因为迭代过程 $x_{k+1} = \varphi(x_k)$ 总是在根 x^* 附近进行, 因此用平均变化率代替(3.2.8)式中的 $\varphi'(x)$ 是有意义的.

下面给出埃特金加速方法的一个定理.

定理 3 若由迭代公式 $x_{k+1} = \varphi(x_k)$ 产生的数列 $\{x_k\}$ 满足:

- (1) 收敛于根 x^* ;
- (2) $\lim_k \frac{e_{k+1}}{e_k} = C (0 < C < 1)$, $e_k = x_k - x^* \quad (k = 0, 1, 2, \dots)$,

则由埃特金加速公式(3.2.10)产生的数列 $\{x_k\}$ 比数列 $\{x_k\}$ 较快的收敛于根 x^* , 即

$$\lim_k \frac{x_k - x^*}{x_k - x^*} = 0.$$

(证明从略)

例 5 对例 3 用埃特金加速方法求方程的根.

解 埃特金加速公式为

$$\begin{cases} x_{k+1} = \sqrt[3]{x_k^2 + 1}, \\ x_{k+2} = \sqrt[3]{x_{k+1}^2 + 1}, \\ x_{k+1} = \frac{x_{k+2}x_k - x_{k+1}^2}{x_{k+2} - 2x_{k+1} + x_k}. \end{cases} \quad (k = 0, 1, 2, \dots)$$

列表计算见表 3-6.

表 3-6

k	x_k	x_{k+1}	x_k	$x_{k+1} - x_k$	10^{-4}
0			$x_0 = 1.5$		
1	$x_1 = 1.481248$	$x_2 = 1.472706$	$x_1 = 1.465559$		
2	$x_2 = 1.465565$	$x_3 = 1.465569$	$x_2 = 1.465570$	$x_2 - x_1 < 10^{-4}/2$	

由表 3-6 知, 第 2 次迭代结果满足精度要求, 故取 $x^* = 1.4656$.

§ 3 牛顿(Newton)迭代法

一、牛顿迭代法

牛顿迭代法的应用范围较广,可用于解代数方程和超越方程,既可求方程的实根,也可求方程的复根,既可求单根,也能求重根. 牛顿迭代法的基本思想是将非线性方程 $f(x) = 0$ 逐步转化为线性方程来求解. 牛顿法的最大优点是在方程单根附近具有较高的收敛速度,因此,牛顿法是将近似根精确化的一种相当有效的迭代法.

下面介绍牛顿迭代法的具体作法:

设 x^* 是非线性方程 $f(x) = 0$ 在隔根区间 $[a, b]$ 内的根, $f(x)$ 在区间 $[a, b]$ 可导,且对于 $x \in [a, b]$ 有 $f'(x) \neq 0$.

任取初始值 $x_0 \in [a, b]$, 过曲线 $y = f(x)$ 上的点 $(x_0, f(x_0))$ 作切线. 如图 3-5 所示, 切线方程为

$$y = f(x_0) + f'(x_0)(x - x_0).$$




图 3-5

以它作为 $y = f(x)$ 的近似表达式, 它与 x 轴交点的横坐标 x_1 为

$$x_1 = x_0 - \frac{f(x_0)}{f'(x_0)}.$$

以 x_1 作为根 x^* 的第一次近似值, 然后又过曲线 $y = f(x)$ 上的点 $(x_1, f(x_1))$ 作切线, 切线方程为

$$y = f(x_1) + f'(x_1)(x - x_1).$$

它与 x 轴交点的横坐标 x_2 为

$$x_2 = x_1 - \frac{f(x_1)}{f'(x_1)},$$

以 x_2 作为根 x^* 的第二次近似值. 仿此不断作下去, 第 $n+1$ 条切线方程为

$$y = f(x_n) + f'(x_n)(x - x_n).$$

它与 x 轴交点的横坐标 x_{n+1} 为

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)} \quad (n = 0, 1, 2, \dots), \quad (3.3.1)$$

由此得方程的近似根数列 $\{x_n\}$. 上述这种求方程 $f(x) = 0$ 根的迭代方法称为牛顿法, (3.3.1) 式为牛顿迭代公式.

牛顿迭代法的几何意义是, 依次用切线代替曲线, 用线性函数的零点作为函数 $f(x)$ 零点的近似值. 由于这种方法的每一步都是用切线来逼近方程, 所以牛顿法又称为切线法.

因为方程 $f(x) = 0$ 与方程 $x = x - \frac{f(x)}{f'(x)}$ ($f'(x) \neq 0$) 等价, 所以牛顿迭代公式也可由等价方程写出, 迭代函数为

$$\varphi(x) = x - \frac{f(x)}{f'(x)}.$$

因此, 牛顿法也是迭代法, 可用下面定理 1 判别其收敛性.

定理 1 (牛顿迭代法局部收敛性定理) 设 x^* 是方程 $f(x) = 0$ 的根, 若

(1) 函数 $f(x)$ 在 x^* 的邻域内具有连续的二阶导数;

(2) 在 x^* 的邻域内 $f'(x) \neq 0$,

则存在 x^* 的某个邻域 $S = \{x \mid x - x^* < \delta\}$, 对于任意的初始值 $x_0 \in S$, 由牛顿迭代法 (3.3.1) 产生的数列收敛于根 x^* .

证明 只要证得 $\varphi(x)$ 在 x^* 的邻域内满足定理 2 的条件成立即可.

由迭代函数的导数

$$\phi'(x) = \frac{f(x)f'(x)}{[f'(x)]^2}$$

及条件(1), (2)知, $\phi(x)$ 在 x^* 的邻域内可导.

由 $\phi(x^*) = x^*$ 及连续函数的性质, 一定存在 x^* 的某个邻域 $S = \{x \mid x - x^* < \delta\}$, 对于任意 $x \in S$, 有

$$|\phi(x) - x^*| \leq L|x - x^*|, \quad L < 1. \quad \text{证毕.}$$

牛顿法的局部收敛性对初始值 x_0 要求较高, 即要求初始值必须选取得充分接近方程的根才能保证迭代序列 $\{x_n\}$ 收敛于 x^* . 实际上, 若初始值 x_0 不是选取得充分接近根 x^* 时, 牛顿法则收敛得很慢, 甚至会发散. 为了保证牛顿法的非局部收敛, 必须再增加一些条件.

定理 2(非局部收敛定理) 设 x^* 是方程 $f(x) = 0$ 在隔根区间 $[a, b]$ 内的根, 若

(1) 对于 $x \in [a, b]$, $f(x)$, $f'(x)$ 连续且不变号;

(2) 选取初始值 $x_0 \in [a, b]$, 使 $f(x_0)f'(x_0) > 0$,

则由牛顿迭代公式(3.3.1)产生的数列收敛于根 x^* .

定理的几何解释如图 3-6 所示, 满足定理条件的情况只有四种.

由图 3-6 不难看出, 用牛顿法求得的序列 $\{x_n\}$ 都是单调地趋于 $f(x) = 0$ 的根 x^* , 所以牛顿法是收敛的, 且还可看出, 凡满足关系式

$$f(x_0)f'(x_0) > 0$$

的 x_0 都可做为初始值, 例如图(a)和(d)的情形取 $x_0 = b$, 图(b)和(c)的情形取 $x_0 = a$.

证明 仅以图 3-6(a)的情形进行证明, 其他三种情形类似.

此时设对于 $x \in [a, b]$, $f(x) > 0$, $f'(x) > 0$, 满足条件(2)的 x_0 应满足 $x^* < x_0$.

要证 $\lim_{n \rightarrow \infty} x_{n+1} = x^*$, 依情形(a), 应证数列 $\{x_n\}$ 是单调递减有

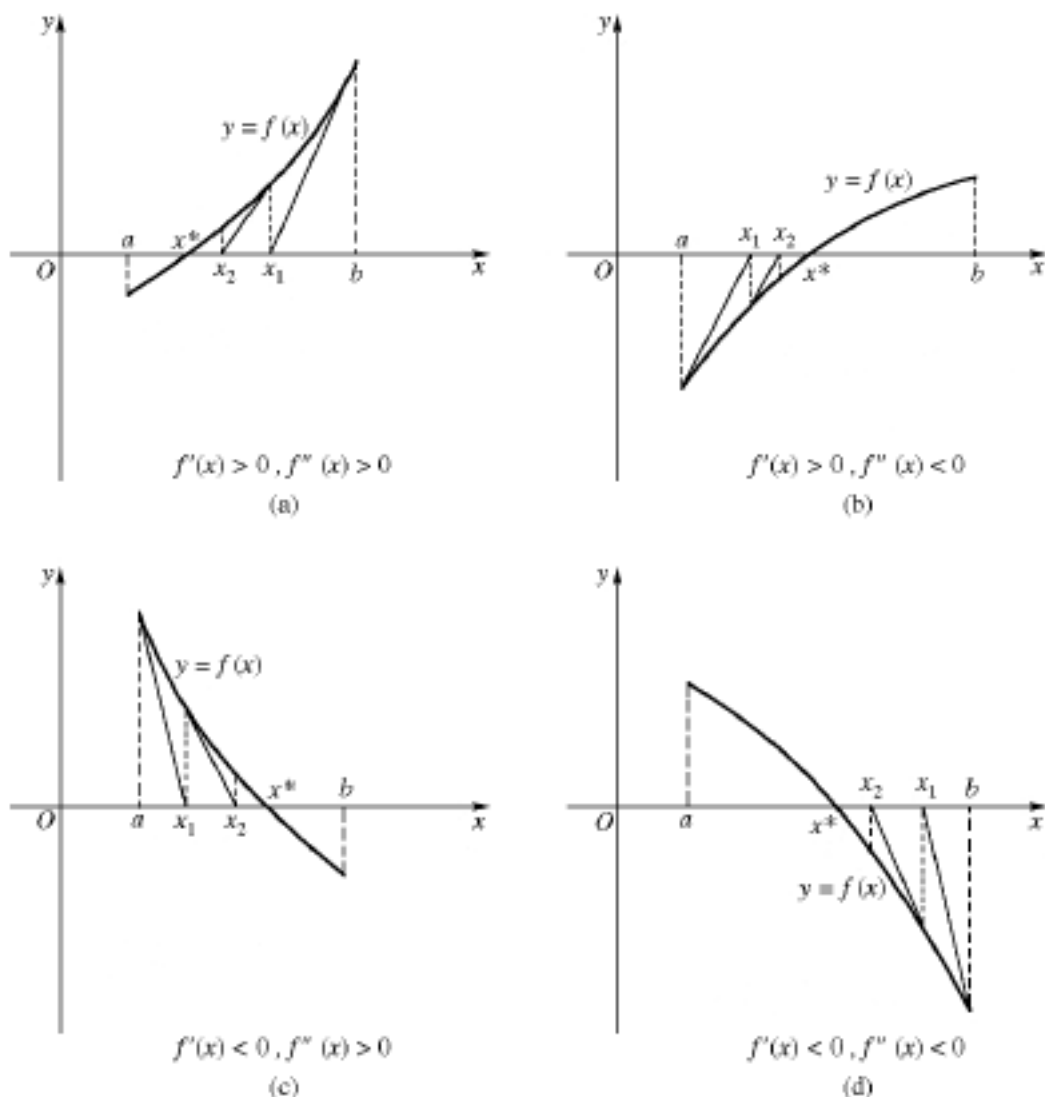


图 3-6

下界的数列.

(1) 用数学归纳法证明数列有下界, 即证 $x^* < x_n$.

当 $n = 0$ 时, $x^* < x_0$ 成立.

设 $n = k$ 时, 不等式 $x^* < x_k$ 成立.

下证当 $n = k + 1$ 时, 不等式 $x^* < x_{k+1}$ 亦成立. 为此, 将函数 $f(x)$ 在 x_k 处一阶泰勒展开

$$f(x) = f(x_k) + f'(x_k)(x - x_k) + \frac{f''(\xi_k)}{2!}(x - x_k)^2,$$

其中 ξ_k 在 x 与 x_k 之间, 因为 $x, x_k \in [a, b]$, 所以 $\xi_k \in (a, b)$.

将 $x = x^*$ 代入上式

$$f(x^*) = f(x_k) + f'(x_k)(x^* - x_k) + \frac{f''(\xi_k)}{2!}(x^* - x_k)^2 = 0,$$

于是

$$\begin{aligned} x^* &= x_k - \frac{f(x_k)}{f'(x_k)} - \frac{f''(\xi_k)}{2!f'(x_k)}(x^* - x_k)^2, \\ x^* &= x_{k+1} - \frac{f''(\xi_k)}{2!f'(x_k)}(x^* - x_k)^2. \end{aligned} \quad (3.3.2)$$

由条件知, 上式右端的第二项大于零, 所以 $x^* < x_{k+1}$, 故

$$x^* < x_n \quad (n = 0, 1, 2, \dots).$$

(2) 再证数列单调递减. 因为 $f'(x) > 0$, $x^* < x_n$, 所以 $f'(x_n) > 0$, $f''(\xi_n) > 0$, 于是牛顿迭代公式(3.3.1)右端第二项大于零, 故

$$x_{n+1} < x_n,$$

因此

$$x^* < \dots < x_{n+1} < x_n < \dots < x_0,$$

即数列 $\{x_n\}$ 是单调递减有下界的数列, 且下界为 x^* .

(3) 证明 $\lim_{n \rightarrow \infty} x_n = x^*$. 由高等数学知, 单调递减有下界的数列必有极限, 现设该数列极限为 x , 于是对(3.3.1)式两边取极限, 有

$$x = x - \frac{f(x)}{f'(x)} \quad (\text{其中 } f'(x) > 0),$$

得

$$f(x) = 0.$$

由于方程 $f(x) = 0$ 在隔根区间 $[a, b]$ 只有一个根, 所以 $x = x^*$, 故

$$\lim_{n \rightarrow \infty} x_n = x^*.$$

定理证毕.

使用牛顿法, 初始值 x_0 的选取是很重要的. 如果在 $[a, b]$ 上 $f'(x)$ 、 $f''(x)$ 的符号不容易判别, 如何选取初始值 x_0 呢?

从公式

$$x_1 = x_0 - \frac{f(x_0)}{f'(x_0)}$$

可得
$$x_1 - x^* = (x_0 - x^*) - \frac{f(x_0)}{f'(x_0)}.$$

用 $e_1 = x_1 - x^*$ 和 $e_0 = x_0 - x^*$ 分别表示 x_1, x_0 与 x^* 的误差, 上式除以 e_0 得

$$\frac{e_1}{e_0} = 1 - \frac{f(x_0)}{f'(x_0)(x_0 - x^*)}.$$

利用一阶泰勒公式

$$0 = f(x^*) = f(x_0) + f'(x_0)(x^* - x_0) + \frac{1}{2}f''(\xi)(x^* - x_0)^2$$

和零阶泰勒公式

$$0 = f(x^*) = f(x_0) + f(\xi)(x^* - x_0),$$

其中 ξ 在 x^* 与 x_0 之间, 则有

$$\begin{aligned} \frac{e_1}{e_0} &= \frac{\frac{1}{2}f''(\xi)(x^* - x_0)^2}{-f'(x_0)(x^* - x_0)} = -\frac{1}{2} \frac{f''(\xi)(x^* - x_0)}{f'(x_0)} \\ &= \frac{f(\xi)f(x_0)}{2f'(x_0)f'(\xi)}. \end{aligned}$$

在 x_0 处我们可以计算 $f(x_0), f'(x_0), f''(x_0)$ 的值, 但无法计算 $f(\xi)$ 和 $f'(\xi)$ 的值. 假如 $f(x), f'(x)$ 在 x_0 附近相对变化不大, 也就是说, 只要 $f'(x_0) \neq 0$, 则有近似公式:

$$\frac{e_1}{e_0} \approx \frac{f''(x_0)f(x_0)}{2[f'(x_0)]^2}.$$

因此, 要使牛顿法收敛, 则误差必须减少, 即要求 $e_1 < e_0$, 亦即要求

$$[f''(x_0)]^2 > \left| \frac{f''(x_0)}{2} \right| |f'(x_0)|. \quad (3.3.3)$$

如果在 x_0 处, $f(x)$ 满足(3.3.3)式且 $f'(x_0) \neq 0$, 我们就用 x_0 作为牛顿法的初始值, 否则另选初始值. 这样做在大多数情况下可以保证牛顿法是收敛的.

牛顿法的计算步骤可归纳如下:

- (1) 准备: 按(3.3.3)选定初始值 x_0 , 计算 $f(x_0)$, $f'(x_0)$.
- (2) 迭代: 依公式

$$x_1 = x_0 - \frac{f(x_0)}{f'(x_0)}$$

迭代一次得新近似值 x_1 , 并计算 $f(x_1)$, $f'(x_1)$.

- (3) 控制: 如果 $|f(x_1)| < \epsilon$ (ϵ 是允许误差), 则终止迭代, x_1 即为所求的根; 否则转(4).

- (4) 准备迭代: 如果迭代次数超过预先指定的次数 N , 或者 $f'(x_1) = 0$, 则方法失败; 否则以 $x_1, f(x_1), f'(x_1)$ 代替 $x_0, f(x_0), f'(x_0)$, 转(2)继续迭代.

例 1 用牛顿迭代法求 § 2 例 3 的方程的根.

解 令 $f(x) = x^3 - 2x^2 - 1$.

- (1) 写出牛顿迭代公式 $x_{n+1} = \frac{2x_n^3 - x_n^2 + 1}{3x_n^2 - 2x_n}$.

- (2) 判断牛顿迭代法的收敛性:

$$\begin{aligned} f(1.4) &= -0.2, & f(1.5) &= 0.2, \\ f'(x) &= 3x^2 - 2x > 0 \quad (x \in [1.4, 1.5]), \\ f''(x) &= 6x > 0 \quad (x \in [1.4, 1.5]). \end{aligned}$$

因为 $f(1.4)f(1.5) < 0$, 所以 $x_0 = 1.4$, 故牛顿迭代法收敛.

- (3) 列表计算见表 3-7.

表 3-7

n	x_n	$x_{n+1} - x_n$	$\frac{1}{2} \times 10^{-4}$
0	$x_0 = 1.5$		
1	$x_1 = 1.466667$	$x_2 - x_1$	0.04
2	$x_2 = 1.465572$	$x_3 - x_2$	0.002
3	$x_3 = 1.465571$	$x_4 - x_3$	$\frac{1}{2} \times 10^{-4}$

由表 3-7 知, 第 3 次迭代结果满足精度要求, 故取 x^*

1. 4656.

例 2 用牛顿法求方程

$$f(x) = x^{41} + x^3 + 1 = 0$$

在 $x_0 = -1$ 附近的实根, 精确到小数点后第 4 位.

解 因为

$$f'(x) = 41x^{40} + 3x^2,$$
$$\frac{1}{2}f''(x) = 820x^{39} + 3x,$$

所以

$$f(-1) = -1, \quad f'(-1) = 44, \quad \frac{1}{2}f''(-1) = -823.$$

而

$$[f'(-1)]^2 = (44)^2 = 1936 > \left| \frac{1}{2}f''(-1) \right| \cdot f(-1) = 823,$$

(3.3.3) 式成立, 故可取 $x_0 = -1$ 为初始值.

用牛顿迭代法计算出的序列为

$$x_0 = -1, \quad x_1 = -0.9773, \quad x_2 = -0.9605,$$
$$x_3 = -0.9525, \quad x_4 = -0.9525,$$

故可取 -0.9525 作为所求根的近似值.

例 3 用牛顿法建立计算 \sqrt{C} ($C > 0$) 近似值的迭代公式.

解 令 $x = \sqrt{C}$, 则可将以上问题化为求方程

$$f(x) = x^2 - C = 0$$

的正根, 如图 3-7. 牛顿迭代公式为

$$x_{n+1} = x_n - \frac{x_n^2 - C}{2x_n} = \frac{1}{2} \left[x_n + \frac{C}{x_n} \right]. \quad (3.3.4)$$

因为 $x > 0$ 时, $f'(x) > 0$, $f''(x) = 2 > 0$, 所以取任意 $x_0 > \sqrt{C}$ 作初始值, 迭代序列必收敛于 \sqrt{C} , 故迭代公式是收敛的.

以上就是求平方根准确有效而又简单的方法, 如果 x_n 已有 m 位有效数字, 则 x_{n+1} 大致有 $2m$ 位有效数字. 现在计算机上多用牛




图 3-7

顿法求平方根,适当选取初始近似值,只需很少几次迭代就可得出相当精确的结果.

二、迭代法的收敛阶

在迭代法中,为了刻画由迭代法产生的数列的收敛速度,下面引进迭代法收敛阶的概念.

定义 1 设数列 $\{x_n\}$ 收敛于 x^* , 令误差 $e_n = x_n - x^*$, 如果存在某个实数 $p > 1$ 及正常数 C , 使

$$\lim_{n \rightarrow \infty} \frac{e_{n+1}}{e_n^p} = C, \quad (3.3.5)$$

则称数列 $\{x_n\}$ 为 p 阶收敛, 也称相应的迭代法是 p 阶方法. 当 $p = 1$ 且 $0 < C < 1$ 时, 称数列 $\{x_n\}$ 为线性收敛. 当 $p = 2$ 时, 称数列 $\{x_n\}$ 为平方收敛(或二阶收敛). 当 $p > 1$ 时, 称数列 $\{x_n\}$ 为超线性收敛. 显然, p 越大, 数列收敛得越快. 所以, 迭代法的收敛阶是对迭代法收敛速度的一种度量.

定理 3 (1) 在 § 2 定理 2 的条件下, 且在根 x^* 的某个邻域内有 $f'(x) \neq 0$, 则迭代法线性收敛.

(2) 在 § 2 定理 3 的条件下, 牛顿迭代法平方收敛.

证明 因为迭代函数 $\varphi(x)$ 在根 x^* 的某个邻域可导, 所以由

拉格朗日中值定理有

$$e_{n+1} = X_{n+1} - X^* = \left(\frac{f'(x_n)}{f'(x^*)} \right) (X_n - X^*) = \left(\frac{f'(x_n)}{f'(x^*)} \right) \cdot e_n,$$

其中 ξ_n 在 X_n 与 X^* 之间.

进而有

$$\begin{aligned} \lim_n \frac{e_{n+1}}{e_n} &= \lim_n \frac{\left(\frac{f'(x_n)}{f'(x^*)} \right) e_n}{e_n} \\ &= \lim_{x \rightarrow x^*} \left(\frac{f'(x)}{f'(x^*)} \right) = \left(\frac{f'(x^*)}{f'(x^*)} \right) = 1. \end{aligned}$$

又由于在 x^* 的某邻域内 $\left| \frac{f'(x)}{f'(x^*)} \right| < 1$ 及 $f'(x^*) \neq 0$, 故有

$$0 < \left| \frac{f'(x^*)}{f'(x^*)} \right| < 1,$$

所以牛顿迭代法线性收敛.

(2) 由(3.3.2)式有

$$\frac{e_{n+1}}{e_n^2} = \frac{f''(\xi_n)}{2! f'(x_n)}.$$

因为 $f''(x)$ 与 $f'(x)$ 在区间 $[a, b]$ 不变号, 所以

$$\lim_n \frac{e_{n+1}}{e_n^2} = \frac{f''(x^*)}{2! f'(x^*)} \neq 0,$$

故牛顿迭代法平方收敛. 证毕.

§ 4 弦 截 法

用牛顿法解方程 $f(x) = 0$ 的优点是收敛速度快, 但牛顿法有个明显的缺点就是每迭代一次, 除需计算 $f(x_k)$ 外, 还要计算 $f'(x_k)$ 的值, 如果 $f(x)$ 比较复杂, 计算 $f'(x_k)$ 就可能十分麻烦. 尤其当 $f'(x_k)$ 很小时, 计算须很精确, 否则会产生很大的误差. 若用本书介绍的弦截法, 则不需计算导数, 虽然它的收敛速度低于牛顿法, 但又高于简单迭代法. 因此, 弦截法在非线性方程的求解中得到广泛的应用, 也是工程计算中的常用方法之一.

设方程 $f(x) = 0$ 的一个隔根区间为 $[a, b]$, 如图 3-8 所示. 连结曲线 $y = f(x)$ 上的两点 $A(a, f(a))$ 和 $B(b, f(b))$ 得弦 AB , 令

$x_0 = a, x_1 = b$, 则弦 AB 的方程为

$$y = f(x_1) + \frac{f(x_1) - f(x_0)}{x_1 - x_0}(x - x_1).$$




图 3-8

令 $y = 0$ 得弦 AB 与 x 轴的交点的横坐标 x_2 为

$$\begin{aligned} x_2 &= \frac{x_0 f(x_1) - x_1 f(x_0)}{f(x_1) - f(x_0)} \\ &= x_1 - \frac{f(x_1)}{f(x_1) - f(x_0)}(x_1 - x_0). \end{aligned}$$

以 x_2 作为根 x^* 的一个近似值, 又过曲线 $y = f(x)$ 上的两点 $(x_1, f(x_1))$ 和 $(x_2, f(x_2))$ 作弦, 得它与 x 轴交点的横坐标 x_3 为

$$\begin{aligned} x_3 &= \frac{x_1 f(x_2) - x_2 f(x_1)}{f(x_2) - f(x_1)} \\ &= x_2 - \frac{f(x_2)}{f(x_2) - f(x_1)}(x_2 - x_1), \end{aligned}$$

则又可以 x_3 作为根 x^* 的一个新的近似值. 继续这样作下去, 即可得到一般迭代公式为

$$x_{n+1} = x_n - \frac{f(x_n)}{f(x_n) - f(x_{n-1})}(x_n - x_{n-1}). \quad (3.4.1)$$

利用上述公式求方程 $f(x) = 0$ 的根的近似值的方法就叫做弦截法.

弦截法的几何意义是, 依次用弦线代替曲线, 用线性函数的零

点作为函数 $f(x)$ 零点的近似值.

下面继续介绍弦截法的收敛定理.

定理 1 若 $f(x)$ 在根 x^* 的某个邻域 $S = \{x \mid x - x^* \leq \delta\}$ 内有二阶连续导数, 且对任意 $x \in S$, 有 $f'(x) \neq 0$, 则当 S 邻域充分小时, 对 S 邻域内任意的 x_0, x_1 , 由弦截法的迭代公式 (3.4.1) 得到的近似值序列 $\{x_n\}$ 收敛到方程 $f(x) = 0$ 的根 x^* . 并可证明弦截法是按阶 $p = (1 + \sqrt{5})/2 \approx 1.618$ 收敛的.

(证明从略).

综上所述, 弦切法的计算步骤可归纳如下:

- (1) 准备: 选定初始近似值 x_0, x_1 , 并计算 $f(x_0), f(x_1)$.
- (2) 迭代: 依公式

$$x_2 = x_1 - \frac{f(x_1)}{f(x_1) - f(x_0)}(x_1 - x_0)$$

迭代一次得到新近似值 x_2 , 并计算 $f(x_2)$.

- (3) 控制: 若 $|f(x_2)| < \epsilon_1$ 或 $|x_2 - x_1| < \epsilon_2$ (ϵ_1, ϵ_2 为事先指定的误差范围), 则终止迭代, x_2 就是方程的近似根; 否则执行 (4).
- (4) 迭代准备: 若迭代次数超过预先指定的次数 N , 则方法失败; 否则以 $(x_1, f(x_1)), (x_2, f(x_2))$ 分别代替 $(x_0, f(x_0))$ 和 $(x_1, f(x_1))$, 转 (2) 继续迭代.

例 1 用弦截法求方程 $e^{2x} + x - 4 = 0$ 在区间 $[0.5, 1]$ 内根的近似值.

解 令 $f(x) = e^{2x} + x - 4$, 取 $x_0 = 0.5, x_1 = 1$, 计算结果如表 3-8 所示. 故可取方程的近似根为 0.61036.

表 3-8

n	0	1	2	3	4	5	6
x_n	0.5	1	0.57559	0.59954	0.61069	0.61036	0.61036

牛顿法和弦截法都是先将 $f(x)$ 线性化然后再求根, 但线性化的方式不同: 牛顿法是作切线的方程, 而弦截法是作弦线的方程;

牛顿法只需一个初始值 x_0 , 而弦截法需要两个初始值 x_0 和 x_1 .

本章小结

本章介绍了方程 $f(x) = 0$ 求根的一些数值解法, 在这些求根方法中, 首先要对 $f(x)$ 的形态及根的近似位置有一个粗略了解, 使用较小的有根区间把方程的根分离出来. 在考察一种解法的有效性时, 一般都要讨论其收敛速度.

在本章所介绍的各种求根方法中, 除二分法仅限于求实根外, 其他均无此限制.

二分法简单易行, 但收敛较慢, 仅有线性收敛速度, 且对 $f(x)$ 的性质要求不高. 该方法不能用于求偶数重根或复根, 但可以用来确定迭代法的初始值.

迭代法(或简单迭代法)是一种逐次逼近的方法, 它是数值计算中方程求根的一种主要方法. 使用各种迭代公式关键是要判断它的收敛性以及了解收敛速度, 简单迭代法具有线性收敛速度, 可采用埃特金加速方法, 使收敛速度加快. 要特别注意, 只具有局部收敛性的简单迭代方法, 往往对初始值 x_0 的选取要求特别高.

牛顿法是方程求根中常用的一种迭代方法, 它除了具有简单迭代法的优点外, 还具有二阶收敛速度(在单根邻近处)的特点. 但牛顿法对初值选取比较苛刻(必须充分靠近方程的根), 否则牛顿法可能不收敛.

弦截法是牛顿法的一种修改, 虽然比牛顿法收敛慢, 但因它不需要计算 $f(x)$ 的导数, 故有时宁可用弦截法而不用牛顿法. 弦截法也要求初始值必须选取得充分靠近方程的根, 否则也可能不收敛.

在各种迭代法中, 迭代函数的构造直接影响收敛速度的快慢. 在实际计算中, 可以根据方程特点, 灵活选择其中一种迭代格式. 关于方程求根问题, 现在已有各种专用程序供实际计算时参阅使用.

算法与程序设计实例

用牛顿迭代法求方程的根.

算法

给定初始值 x_0 , 为根的容许误差, 为 $f(x)$ 的容许误差, N 为迭代次数的容许值.

如果 $f(x_0) = 0$ 或迭代次数大于 N , 则算法失败, 结束; 否则执行 .

计算 $x_1 = x_0 - \frac{f(x_0)}{f'(x_0)}$.

若 $x_1 - x_0 < \epsilon$ 或 $f(x_1) < \delta$, 则输出 x_1 , 程序结束; 否则执行 .

令 $x_0 = x_1$, 转向 .

实例

求方程 $f(x) = x^3 + x^2 - 3x - 3 = 0$ 在 1.5 附近的根.

程序和输出结果

```
# include <stdio.h>
# include <conio.h>
# include <math.h>
# define N 100
# define EPS 1e-6
# define ETA 1e-8
void main()
{
    float f(float);
    float f1(float);
    float x0, y0;
    float Newton(float (*)(float), float (*)(float), float);
```

```

clrscr();
printf( Please input x0\n );
scanf( % f , &x0);
printf( x(0)= % f\n , x0);
y0= Newton(f, f1, x0);
printf( \nThe root of the equation is x= % f\n , y0);
getch();
}

float Newton(float (* f)(float), float (* f1)(float), float x0)
{
    float x1, d;
    int k= 0;
    do
    {
        x1= x0- f(x0)/f1(x0);
        if((k++ > N)  (fabs(f1(x1))< EPS))
        {
            printf( \nNewton method failed );
            getch();
            exit();
        }
        d= (fabs(x1)< 1? x1- x0:(x1- x0)/ x1);
        x0= x1;
        printf( x(% d)= % f\t , k, x0);    /* 可省略 */
    }
    while( fabs(d)) > EPS&&fabs(f(x1))> ETA);
    return x1;
}

float f(float x)

```



```

{
    return x* x* x+ x* x- 3* x- 3;
}
float f1(float x)
{
    return 3.0* x* x+ 2* x- 3;
}

```

输出结果如下:

若取初值 $x(0) = 1.000000$, 则

$x(1) = 3.000000$, $x(2) = 2.200000$, $x(3) = 1.830151$,
 $x(4) = 1.737795$, $x(5) = 1.732072$, $x(6) = 1.732051$,
 $x(7) = 1.732051$.

原方程的根为 $x = 1.732051$.

若取初值 $x(0) = 1.500000$, 则

$x(1) = 1.777778$, $x(2) = 1.733361$, $x(3) = 1.732052$,
 $x(4) = 1.732051$.

原方程的根为 $x = 1.732051$.

若取初值 $x(0) = 2.500000$, 则

$x(1) = 1.951807$, $x(2) = 1.758036$, $x(3) = 1.732482$,
 $x(4) = 1.732051$, $x(5) = 1.732051$.

原方程的根为 $x = 1.732051$.

说明: 上面程序取 3 个不同初值, 得到同样的结果, 但迭代次数不同. 初值越接近所求的根, 迭代次数越少.

思 考 题

1. 何谓二分法? 二分法的优点是什么? 如何估计误差?
2. 何谓迭代法? 它的收敛条件、几何意义、误差估计式是什么?

么?

3. 如何加速迭代序列的收敛速度? 埃特金加速法的处理思想是什么? 它具有什么优点?

4. 怎样比较迭代法收敛的快慢? 何谓收敛阶数?

5. 牛顿迭代格式是什么? 它是怎样得出的? 叙述牛顿迭代法的收敛条件与收敛阶数.

6. 如何导出弦截法迭代公式? 叙述其收敛条件与收敛阶数并比较弦截法与牛顿法的优劣.

习 题 三

1. 用二分法求方程 $x^4 - 3x + 1 = 0$ 在区间 $[0.3, 0.4]$ 内的根, 要求误差不超过 $\frac{1}{2} \times 10^{-2}$.

2. 已知方程 $x^3 + x - 4 = 0$ 在区间 $[1, 2]$ 内有一根, 试问用二分法求根, 使其具有 5 位有效数字至少应二分多少次?

3. 判断下列方程有几个根, 求出隔根区间, 并写出收敛的迭代公式.

(1) $\cos x + \sin x - 4x = 0$;

(2) $x + 2^x - 4 = 0$.

4. 方程 $x^3 - x^2 - 1 = 0$ 在 1.5 附近有根, 把方程写成 4 种不同的等价形式, 并建立相应的迭代公式:

(1) $x^3 = 1 + x^2$, $x_{n+1} = \sqrt[3]{1 + x_n^2}$;

(2) $x = 1 + \frac{1}{x^2}$, $x_{n+1} = 1 + \frac{1}{x_n^2}$;

(3) $x^2 = \frac{1}{x - 1}$, $x_{n+1} = \frac{1}{\sqrt{x_n - 1}}$;

(4) $x^2 = x^3 - 1$, $x_{n+1} = \sqrt{x_n^3 - 1}$.

判断每种迭代公式产生的数列在 1.5 附近的收敛性, 并用 (1) 的迭

代公式求方程的根, 要求误差不超过 $\frac{1}{2} \times 10^{-3}$.

5. 用迭代法求 $x^5 - x - 0.2 = 0$ 的正根, 要求准确到小数点后第 5 位.

6. 用迭代法求方程 $e^x + 10x - 2 = 0$ 的根, 要求准确到小数点后第 4 位.

7. 用迭代-加速公式求方程 $x = e^{-x}$ 在 $x = 0.5$ 附近的根, 要求准确到小数点后第 4 位.

8. 用埃特金加速法求方程 $x = x^3 - 1$ 在区间 $[1, 1.5]$ 内的根, 要求准确到小数点后第 4 位.

9. 应用牛顿法于方程 $f(x) = x^n - a = 0$ 和 $f(x) = 1 - \frac{a}{x^n} = 0$, 分别导出求 $\sqrt[n]{a}$ 的迭代公式, 并求

$$\lim_k (\sqrt[n]{a} - x_{k+1}) / (\sqrt[n]{a} - x_k)^2.$$

10. 用牛顿法求方程 $x^3 - 3x - 1 = 0$ 在 $x_0 = 2$ 附近的根, 要求准确到小数点后第 3 位.

11. 证明计算 $\sqrt[3]{C}$ 的牛顿迭代格式为

$$x_{n+1} = \frac{1}{3} \left[2x_n + \frac{C}{x_n^2} \right].$$

取 $x_0 = 1$, 计算 $\sqrt[3]{3}$, 要求 $x_{n+1} - x_n < \frac{1}{2} \times 10^{-6}$.

12. 用弦截法求 $1 - x - \sin x = 0$ 的根, 取 $x_0 = 0, x_1 = 1$, 计算直到 $1 - x - \sin x < \frac{1}{2} \times 10^{-2}$ 为止.

*第四章 矩阵的特征值及特征向量的计算

自然科学和工程技术中的许多问题,如振动问题(桥梁或建筑物的振动、机械振动、电磁振动等),物理学中某些临界值的确定等,常常要归结为求矩阵的特征值和特征向量.即求满足

$$AX = \lambda X \quad (X \neq 0)$$

的数 λ 和非零列向量 X , 其中数 λ 称为 A 的特征值, 非零列向量 X 称为 A 的与特征值对应的特征向量. 于是计算 n 阶矩阵 A 的特征值, 就是求特征方程

$$A - \lambda I = 0$$

的非零解 λ_i ($i = 1, 2, \dots, n$). 而齐次线性方程组

$$(A - \lambda_i I)X = 0$$

的非零解 X_i 就是与 λ_i 对应的特征向量.

求矩阵特征值和特征向量的问题是工程计算中的一个重要问题. 一般来说, 用求特征方程的根的方法去求矩阵 A 的特征值, 只适用于低阶矩阵. 当矩阵 A 的阶数较高时, 其特征方程就是一个的高次代数方程, 而高次代数方程求根的计算稳定性较差. 因此, 必须寻求一些在电子计算机上计算矩阵的特征值和特征向量的较为稳定的数值算法. 这就是本章将要介绍的几种在计算机上计算矩阵特征值和特征向量的常用数值方法——幂法、反幂法和雅可比方法.

*§ 1 幂法与反幂法

幂法与反幂法都是迭代法. 幂法是求实矩阵 A 的主特征值

(即矩阵 A 的按模最大的特征值, 其模称为谱半径) 及其对应的特征向量的一种迭代方法; 而当零不是特征值时, 反幂法则可用来计算非奇异矩阵按模最小的特征值及相应的特征向量. 下面分别介绍幂法及反幂法.

一、幂法

设有 n 阶实矩阵 A , 其 n 个特征向量 X_1, X_2, \dots, X_n 线性无关 (即 X_1, X_2, \dots, X_n 为 A 的一个完全特征向量组), 其相应的特征值 $\lambda_1, \lambda_2, \dots, \lambda_n$ 满足

$$1 \geq 2 \dots n. \quad (4.1.1)$$

由特征值定义

$$AX_i = {}_iX_i \quad (i = 1, 2, \dots, n). \quad (4.1.2)$$

现来讨论计算主特征值 λ_1 及对应的特征向量的方法.

幂法(又称乘幂法)的基本思想是任取一个非零初始向量 u_0 , 由矩阵 A 构造一个向量序列:

$$\left\{ \begin{array}{l} \mathbf{u}_1 = \mathbf{A}\mathbf{u}_0, \\ \mathbf{u}_2 = \mathbf{A}\mathbf{u}_1 = \mathbf{A}^2\mathbf{u}_0, \\ \dots\dots\dots \\ \mathbf{u}_k = \mathbf{A}\mathbf{u}_{k-1} = \mathbf{A}^k\mathbf{u}_0, \end{array} \right. \quad (4.1.3)$$

上述向量称为迭代向量. 因为 X_1, X_2, \dots, X_n 线性无关, 所以初始向量 u_0 可表示为矩阵 A 的特征向量组的一个线性组合, 即

$$\mathbf{u}_0 = \sum_{i=1}^n \mathbf{X}_i.$$

并假定 $\lambda_1 = 0$, 于是

$$\begin{aligned} \mathbf{u}_k &= \mathbf{A} \mathbf{u}_{k-1} = \mathbf{A}^k \mathbf{u}_0 = \sum_{i=1}^n \mathbf{A}^k \mathbf{X}_i = \sum_{i=1}^n \mathbf{X}_i \\ &= \mathbf{I} \left[\sum_{i=1}^n \mathbf{X}_i \right]. \end{aligned} \quad (4.1.4)$$

记

$$b_k = \sum_{i=2}^n \left[\frac{a_i}{b_{k-1}} \right]^k X_i,$$

$$\text{则 } u_k = \frac{1}{b_{k-1}} (b_{k-1} X_1 + b_k). \quad (4.1.5)$$

由(4.1.1)式知

$$|a_i / b_{k-1}| < 1 \quad (i = 2, 3, \dots, n),$$

所以当 $k \rightarrow \infty$ 时, $b_k \rightarrow 0$, 从而

$$\lim_{k \rightarrow \infty} \frac{u_k}{b_{k-1}} = X_1.$$

上式说明, 序列 u_k / b_{k-1} 越来越接近 A 的与 λ_1 对应的特征向量 (因为特征向量可以相差一个常数因子). 因此, 当 k 充分大时, 有

$$u_k / b_{k-1} \approx X_1,$$

即

$$A^k u_0 \approx b_{k-1} X_1.$$

故当 k 充分大时, $A^k u_0$ 可近似表示矩阵 A 的与 λ_1 对应的特征向量.

以下我们通过特征向量来计算特征值 λ_1 . 用 $(u_k)_i$ 表示 u_k 的第 i 个分量, 由于

$$\frac{(u_{k+1})_i}{(u_k)_i} = \lambda_1 \cdot \frac{\lambda_1 (X_1)_i + (b_{k+1})_i}{\lambda_1 (X_1)_i + (b_k)_i},$$

所以

$$\lim_{k \rightarrow \infty} \frac{(u_{k+1})_i}{(u_k)_i} = \lambda_1.$$

上述极限说明, 两个相邻迭代向量的分量之比值收敛到主特征值 λ_1 . 但要注意的是, 实际计算时, k 不可能趋于无穷大, 只能是某个相当大的 k 值, 这时相邻迭代向量的不同分量之比就不相同, λ_1 也不相同, 此时可用 $(u_{k+1})_i / (u_k)_i$ 的平均值作为 λ_1 的近似值.

以上这种由已知非零向量 u_0 及矩阵 A 的乘幂 A^k 构造向量序列 $\{u_k\}$ 用来计算 A 的主特征值 λ_1 及相应特征向量的方法称为幂法.

综上所述, 用幂法求主特征值 λ_1 及相应特征向量的计算步骤为:

- (1) 任给 n 维初始向量 $u_0 \neq 0$;
- (2) 按 $u_{k+1} = Au_k$ ($k=0, 1, 2, \dots$) 计算 u_{k+1} ;
- (3) 若 $k+1$ 从某个数以后分量之比

$$\frac{(u_{k+1})_i}{(u_k)_i} \rightarrow C(\text{常数}) \quad (i=1, 2, \dots, n),$$

则 $\lambda_1 = C$, 而 u_k 即是与 λ_1 对应的一个近似特征向量.

例 1 设有矩阵

$$A = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix},$$

试用幂法计算 A 的主特征值及其对应的特征向量.

解 取 $u_0 = (1, 1, 1)^T$, 由迭代向量 $u_k = A^k u_0$ 进行计算, 计算结果见表 4-1.

表 4-1

k	1	2	3	4	5	6	7
$(A^k u_0)_1$	1	2	6	20	68	232	792
$(A^k u_0)_2$	1	-2	-8	-28	-96	-328	-1120
$(A^k u_0)_3$	1	2	6	20	68	232	792

由上表可算得

$$\frac{(A^6 u_0)_1}{(A^5 u_0)_1} \rightarrow 3.41, \quad \frac{(A^7 u_0)_1}{(A^6 u_0)_1} \rightarrow 3.41.$$

可见第一个分量已趋于稳定, 而对第 2、第 3 个分量:

$$\frac{(A^7 u_0)_2}{(A^6 u_0)_2} \rightarrow 3.41, \quad \frac{(A^7 u_0)_3}{(A^6 u_0)_3} \rightarrow 3.41,$$

由此可得 $\lambda_1 = 3.41$. 因为 $A^7 u_0 = (792, -1120, 792)^T$, 而特征向量可相差一个常数因子, 所以取与主特征值 λ_1 相对应的特征向量为

$$X_1 = \frac{A^7 u_0}{792} = (1, -1.41, 1)^T.$$

由(4.1.4)式可看出, 当 $|\lambda_1| > 1$ 时, $A^k u_0$ 的分量会趋于无穷

大; 当 $\lambda_1 < 1$ 时, $A^k u_0$ 的分量又会趋于零, 因此在实际计算时需要作适当的规范化, 以免发生计算机的上溢和下溢现象.

设有一向量 $u = (u_1, u_2, \dots, u_n)^T$, 用 $\max(u)$ 表示向量 u 中绝对值为最大的分量, 即

$$\max(u) = \max_{1 \leq i \leq n} |u_i|,$$

则称
$$v = \frac{u}{\max(u)}$$

为 u 的规范化(即归一化)向量, 或者说将向量 u 规范化.

这样, 实际计算中幂法的迭代格式为

$$\begin{cases} u_0 = v_0 & 0, \\ u_k = A v_{k-1}, & k = 1, 2, \dots, \\ v_k = \frac{u_k}{\max(u_k)}, \end{cases} \quad (4.1.6)$$

可以证明: 当 $k \rightarrow \infty$ 时, 有

$$v_k \rightarrow \frac{X_1}{\max(X_1)}, \quad (4.1.7)$$

即规范化迭代向量序列收敛到主特征值对应的特征向量. 而

$$\max(u_k) \rightarrow \lambda_1,$$

就是说 u_k 的绝对值最大的分量收敛到主特征值.

事实上, 由(4.1.4)式和(4.1.6)式可得

$$\begin{aligned} v_k &= \frac{A^k u_0}{\max(A^k u_0)} = \frac{\lambda_1^k \left[\lambda_1 X_1 + \sum_{i=2}^n \left(\frac{\lambda_i}{\lambda_1} \right)^k X_i \right]}{\max \left[\lambda_1^k \left[\lambda_1 X_1 + \sum_{i=2}^n \left(\frac{\lambda_i}{\lambda_1} \right)^k X_i \right] \right]} \\ &= \frac{\lambda_1 X_1 + \sum_{i=2}^n \left(\frac{\lambda_i}{\lambda_1} \right)^k X_i}{\max \left[\lambda_1 X_1 + \sum_{i=2}^n \left(\frac{\lambda_i}{\lambda_1} \right)^k X_i \right]} = \frac{X_1}{\max(X_1)} \quad (k \rightarrow \infty). \end{aligned}$$

同理

$$u_k = \frac{A^k u_0}{\max(A^{k-1} u_0)} = \frac{\lambda_1^k \left[\lambda_1 X_1 + \sum_{i=2}^n \left(\frac{\lambda_i}{\lambda_1} \right)^k X_i \right]}{\max \left[\lambda_1^{k-1} \left[\lambda_1 X_1 + \sum_{i=2}^n \left(\frac{\lambda_i}{\lambda_1} \right)^{k-1} X_i \right] \right]},$$

所以

$$\max(u_k) = \frac{\lambda_1 \max \left[\lambda_1 X_1 + \sum_{i=2}^n \left(\frac{\lambda_i}{\lambda_1} \right)^k X_i \right]}{\max \left[\lambda_1 X_1 + \sum_{i=2}^n \left(\frac{\lambda_i}{\lambda_1} \right)^{k-1} X_i \right]} \quad (k \geq 1).$$

应当指出,用幂法求 A 的主特征值的最大优点是方法简单,且特别适用于大型稀疏矩阵.但有时收敛速度很慢,其迭代的收敛速度主要取决于比值 $r = \lambda_2/\lambda_1$, r 越小,收敛越快,当 $r = 1$ 时,收敛速度就很慢.为了加速收敛速度,下面简要介绍一种加速收敛的原点平移法.

引进矩阵

$$B = A - pI,$$

其中 I 为单位矩阵, p 为可选择的参数.

若 A 的特征值为 $\lambda_1, \lambda_2, \dots, \lambda_n$, 则 B 的特征值为 $\lambda_1 - p, \lambda_2 - p, \dots, \lambda_n - p$. 不难证明, A, B 有相同的特征向量.事实上,若 X 是 A 的与 λ_1 对应的特征向量,即

$$AX = \lambda_1 X,$$

则 $(A - pI)X = AX - pX = \lambda_1 X - pX = (\lambda_1 - p)X$,

故 X 也是 $B = A - pI$ 的特征向量.

只要我们适当选取 p , 使得

$$(1) \quad \lambda_1 - p > \lambda_2 - p > \lambda_3 - p > \dots > \lambda_n - p;$$

$$(2) \quad \left| \frac{\lambda_2 - p}{\lambda_1 - p} \right| < \left| \frac{\lambda_2}{\lambda_1} \right|,$$

则我们用幂法分别求 $B = A - pI$ 和 A 的主特征值时,前者的收敛速度远比后者为快.当求出矩阵 $B = A - pI$ 的主特征值 λ_1 和特征向量 X_1 后,矩阵 A 的主特征值为 $\lambda_1 + p$, 特征向量仍为 X_1 , 这种方

法通常称为原点平移法. 但由于特征值的分布事先不知道, 实际上使用时必须经过多次选择才能选到适当的 p 值.

二、反幂法

反幂法可用来计算非奇异矩阵按模最小的特征值和对应的特征向量, 也可用来计算对应于一个给定近似特征值的特征向量.

设有 n 阶非奇异矩阵 A , 其特征值与相应的特征向量分别为 λ_i 及 X_i ($i=1, 2, \dots, n$), 由定义

$$AX_i = \lambda_i X_i \quad (i=1, 2, \dots, n).$$

因 A 可逆, 则特征值 λ_i 均不为零, 于是由上式得

$$A^{-1}X_i = \lambda_i^{-1}X_i.$$

这说明 λ_i^{-1} 一定是 A^{-1} 的特征值, 所对应的特征向量仍是 X_i . 并设 A 的特征值如下:

$$\lambda_1 < \lambda_2 < \dots < \lambda_{n-1} < \lambda_n > 0,$$

则 λ_n^{-1} 一定是 A^{-1} 的主特征值. 这样, 对 A^{-1} 用幂法即可求得 $\mu = \frac{1}{\lambda_n}$, 从而得 A 的按模最小的特征值 $\lambda_n = \mu^{-1}$, 具体计算如下:

任取初始向量 $u_0 \neq 0$, 可作如下迭代

$$u_{k+1} = A^{-1}u_k \quad (k=0, 1, 2, \dots). \quad (4.1.8)$$

但由(4.1.8)式可知, 要作此迭代必须计算 A^{-1} , 这是一件不易的事, 故往往将(4.1.8)式改为解方程组

$$Au_{k+1} = u_k \quad (k=0, 1, 2, \dots),$$

若采用“规范化”方法, 可按如下步骤计算:

$$\begin{cases} Au_k = v_{k-1}, \\ m_k = \max(u_k), \\ v_k = u_k / m_k. \end{cases} \quad (4.1.9)$$

以上每迭代一次, 需要解一个线性方程组 $Au_k = v_{k-1}$. 由于每步所解方程组具有相同的系数矩阵 A , 故常常是先将 A 作 LU 分

解, 然后转化为每步只需用回代公式解两个三角方程组, 这样可减少计算工作量.

根据反幂法与幂法的上述关系, 如果有矩阵 A 的某个特征值 λ_{i_0} (不是按模最大也不是按模最小) 的粗略近似 $\lambda_{i_0}^*$, 则用反幂法不难得到 λ_{i_0} 的更好的近似值 (见习题四中第 3 题).

从幂法可知, 反幂法收敛速度取决于比值 λ_n/λ_{n-1} . 当 λ_n/λ_{n-1} 越小时, 收敛越快.

例 2 用反幂法求矩阵

$$A = \begin{bmatrix} 2 & 8 & 9 \\ 8 & 3 & 4 \\ 9 & 4 & 7 \end{bmatrix}$$

按模最小的特征值及其对应的特征向量.

解 对矩阵 A 作 LU 分解, 可得

$$L = \begin{bmatrix} 1 & & & \\ 4 & & 1 & \\ 4.5 & 1.1034 & & 1 \end{bmatrix}, \quad U = \begin{bmatrix} 2 & 8 & 9 \\ & -29 & -32 \\ & & 1.8103 \end{bmatrix}.$$

取初始向量 $v_0 = u_0 = (1, 1, 1)^T$, 作规范化计算, 有如下计算公式:

$$\begin{cases} LY_k = v_{k-1}, \\ Uu_k = Y_k, \\ m_k = \max(u_k), \\ v_k = u_k/m_k, \end{cases} \quad (k = 1, 2, \dots)$$

计算结果见表 4-2.

表 4-2

k	v_k (归一化向量)	$\max(u_k)$
0	(1.0000 1.0000 1.0000)	1.0000
1	(0.4348 1.0000 - 0.4783)	0.5652
2	(0.1902 1.0000 - 0.8834)	0.9877
3	(0.1843 1.0000 - 0.9124)	0.8245
4	(0.1831 1.0000 - 0.9129)	0.8134
5	(0.1832 1.0000 - 0.9130)	0.8134

迭代 5 次可得 $\frac{1}{3} = 0.3333$, 所以 $\lambda_3 = 1.2294$, 其对应的特征向量为

$$X_3 = (0.1832, 1.0000, -0.9130).$$

§ 2 雅可比方法

雅可比方法是建立在线性代数基础上的一种求对称矩阵全部特征值与特征向量的迭代方法. 为此, 先回顾一个线性代数的有关知识.

(1) 若矩阵 A 与 B 相似, 即有可逆矩阵 P , 使 $P^{-1}AP = B$, 则 A 与 B 有相同的特征值;

(2) 若 A 为实对称矩阵, 则其特征值 λ_i 一定是实数, 并存在正交矩阵 R , 使

$$R^{-1}AR = R^TAR = \begin{bmatrix} \lambda_1 & & & \\ & \lambda_2 & & \\ & & \ddots & \\ & & & \lambda_n \end{bmatrix} = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n),$$

且 R 的第 j 列是 λ_j 对应的特征向量;

(3) 若 R 为正交矩阵, 则

$$\|RA\|_F^2 = \|AR\|_F^2 = \|A\|_F^2,$$

这里
$$\|A\|_F^2 = \sum_{i=1}^n \sum_{j=1}^n a_{ij}^2.$$

由于 R^T 也是正交矩阵, 从而有 $\|R^TAR\|_F^2 = \|A\|_F^2$.

雅可比方法的基本思想是对给定的实对称矩阵 A 进行一系列的正交相似变换, 使其逐渐趋于对角阵, 即寻求正交矩阵 $R_1, R_2, \dots, R_k, \dots$, 使

$$\lim_k R_k^T R_{k-1}^T \dots R_1^T A R_1 \dots R_{k-1} R_k = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n).$$

从而当 k 充分大时, $R_k^T R_{k-1}^T \dots R_1^T A R_1 \dots R_{k-1} R_k$ 的对角元就是 A 的

近似特征值, 而 $R_1 \dots R_{k-1} R_k$ 的各列就是相应的近似特征向量. 因此, 问题的关键是如何找到合适的正交矩阵 R_k . 为此, 还须继续讨论.

一、古典雅可比方法

先以二阶实对称矩阵 $A = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}$ 为例进行讨论, 其中 $a_{12} = a_{21} \neq 0$.

由线性代数知, 对任意 $\begin{bmatrix} -\frac{\theta}{4}, \frac{\theta}{4} \end{bmatrix}$, 平面旋转矩阵

$$R = \begin{bmatrix} \cos \theta & \sin \theta \\ -\sin \theta & \cos \theta \end{bmatrix}$$

显然是一正交矩阵. 于是, 做正交相似变换

$$A_1 = RAR^{-1} = RAR^T,$$

容易求得 A_1 的元素 $a_{ij}^{(1)}$ 为

$$\left. \begin{aligned} a_{11}^{(1)} &= a_{11} \cos^2 \theta + 2a_{12} \cos \theta \sin \theta + a_{22} \sin^2 \theta, \\ a_{22}^{(1)} &= a_{11} \sin^2 \theta - 2a_{12} \sin \theta \cos \theta + a_{22} \cos^2 \theta, \\ a_{12}^{(1)} &= \frac{1}{2}(a_{22} - a_{11}) \sin 2\theta + a_{12} \cos 2\theta = a_{21}^{(1)}. \end{aligned} \right\} \quad (4.2.1)$$

令 $a_{12}^{(1)} = a_{21}^{(1)} = 0$, 得

$$\tan 2\theta = \frac{2a_{12}}{a_{11} - a_{22}}. \quad (4.2.2)$$

所以, 如果取 θ 满足 (4.2.2) 式, 则必有

$$A_1 = RAR^T = \begin{bmatrix} a_{11}^{(1)} & 0 \\ 0 & a_{22}^{(1)} \end{bmatrix}.$$

从而原矩阵 A 的两个特征值就是 $a_{11}^{(1)}$ 和 $a_{22}^{(1)}$, 而

$$R^T = \begin{bmatrix} \cos \theta & \sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}$$

的两个列向量是相应的特征向量.

将二阶平面旋转矩阵推广, 对一般 n 阶实对称矩阵 $A = (a_{ij})_{n \times n}$, 若有非对角元 $a_{pq} \neq 0$ ($p < q$), 引入 n 阶平面旋转矩阵, 此时考虑 n 阶正交矩阵

$$R = \begin{bmatrix} 1 & & & & & & & \\ & \ddots & & & & & & \\ & & \cos & & \sin & & & \\ & & & \ddots & & & & \\ & & & & 1 & & & \\ & & & & & \ddots & & \\ & & & & & & \cos & \\ & & & & & & & \ddots \\ & & & & & & & & 1 \end{bmatrix} \quad \left[\begin{array}{c} p \\ q \end{array} \right],$$

除了 p, q 行和 p, q 列交叉位置上的 4 个元素外, 这里 R 的其余元素与单位矩阵相同.

作正交相似变换

$$A_1 = RAR^T.$$

由矩阵乘法不难得到 $A_1 = (a_{ij}^{(1)})_{n \times n}$ 的元素为

$$\left. \begin{aligned} a_{ij}^{(1)} &= a_{ij} \quad (i, j \neq p, q), \\ a_{pj}^{(1)} &= a_{jp}^{(1)} = a_{pj} \cos + a_{qj} \sin \quad (j \neq p, q), \\ a_{qj}^{(1)} &= a_{jq}^{(1)} = -a_{pj} \sin + a_{qj} \cos \quad (j \neq p, q), \\ a_{pp}^{(1)} &= a_{pp} \cos^2 + 2a_{pq} \sin \cos + a_{qq} \sin^2, \\ a_{qq}^{(1)} &= a_{pp} \sin^2 - 2a_{pq} \sin \cos + a_{qq} \cos^2, \\ a_{pq}^{(1)} &= a_{qp}^{(1)} = \frac{1}{2}(a_{qq} - a_{pp}) \sin 2 + a_{pq} \cos 2. \end{aligned} \right\} \quad (4.2.3)$$

为使 A_1 的非对角元 $a_{pq}^{(1)}$ 成为零, 由 (4.2.3) 式最后一式知, 只需取满足

$$\tan 2 = \frac{2a_{pq}}{a_{pp} - a_{qq}} \left[\begin{array}{c} \frac{1}{4} \end{array} \right], \quad (4.2.4)$$

进而有

$$= \begin{cases} \frac{1}{2} \arctan \frac{2a_{pq}}{a_{pp} - a_{qq}}, & a_{pp} \neq a_{qq}, \\ \frac{\pi}{4}, & a_{pp} = a_{qq}, a_{pq} > 0, \\ -\frac{\pi}{4}, & a_{pp} = a_{qq}, a_{pq} < 0 \end{cases}$$

即可, 这就完成了雅可比方法将一个非对角元 a_{pq} 化为零的计算过程, 从而由矩阵 A 产生了矩阵 A_1 . 而将新矩阵 A_1 的非对角元化为零的计算过程与上边完全类似, 从而可类似得到矩阵 $A_2, A_3, \dots, A_k, \dots$.

下面讨论雅可比方法的收敛性, 即矩阵序列 $\{A_k\}$ 向对角阵的收敛性. 由 (4.2.3) 易知

$$\left. \begin{aligned} [a_{ij}^{(1)}]^2 &= a_{ij}^2 \quad (i, j \neq p, q), \\ [a_{pj}^{(1)}]^2 + [a_{qj}^{(1)}]^2 &= a_{pj}^2 + a_{qj}^2 \quad (j \neq p, q), \\ [a_{pp}^{(1)}]^2 + [a_{qq}^{(1)}]^2 + 2[a_{pq}^{(1)}]^2 &= a_{pp}^2 + a_{qq}^2 + 2a_{pq}^2, \end{aligned} \right\} \quad (4.2.5)$$

在 (4.2.5) 式的第一式中取 $i = j \neq p, q$ 并求和, 有

$$\sum_{i=1, i \neq p, q}^n [a_{ii}^{(1)}]^2 = \sum_{i=1, i \neq p, q}^n a_{ii}^2.$$

将 (4.2.5) 式的第三式与上式相加 (注意 $a_{pq}^{(1)} = 0$), 则

$$\sum_{i=1}^n [a_{ii}^{(1)}]^2 = \sum_{i=1}^n a_{ii}^2 + 2a_{pq}^2. \quad (4.2.6)$$

记

$$D(A) = \sum_{i=1}^n a_{ii}^2 \quad (\text{对角元的平方}),$$

$$S(A) = \sum_{i \neq j} a_{ij}^2 \quad (\text{非对角元平方}),$$

则 (4.2.6) 式可写为

$$D(A_1) = D(A) + 2a_{pq}^2. \quad (4.2.7)$$

这说明了由 A 到 A_1 , 对角元的平方和增加了 $2a_{pq}^2$. 根据前述线性代数知识 (3), 有

$$\|A_l\|_F^2 = \|RAR^T\|_F^2 = \|A\|_F^2,$$

即 A_l 和 A 的总元素平方和保持不变, 亦即

$$D(A_l) + S(A_l) = D(A) + S(A). \quad (4.2.8)$$

(4.2.8) - (4.2.7) 得

$$S(A_l) = S(A) - 2a_{pq}^2, \quad (4.2.9)$$

即由 A 到 A_l 非对角元的平方和必然减少 $2a_{pq}^2$. 还可进一步证明

$$S(A_l) = \left[1 - \frac{2}{n(n-1)}\right] S(A).$$

一般地有

$$S(A_k) = \left[1 - \frac{2}{n(n-1)}\right] S(A_{k-1}),$$

从而有

$$S(A_k) = \left[1 - \frac{2}{n(n-1)}\right]^k S(A_0) \quad (A_0 = A).$$

显然 $\lim_k S(A_k) = 0$, 即非对角元的平方和趋向于零, A_k 趋向于对角阵, 雅可比方法收敛.

综上所述, 可得雅可比方法的计算步骤如下:

(1) 首先在 A 的非对角线元素中挑选主元(绝对值最大者) a_{pq} , 确定 p, q ;

(2) 由公式(4.2.4)求得 $\tan 2$, 并利用 $\tan 2$ 与 \sin, \cos 之间的关系, 求出 \sin 及 \cos ;

(3) 由公式(4.2.3)求出

$$a_{pp}^{(1)}, a_{qq}^{(1)}, a_{pj}^{(1)}, a_{qj}^{(1)} \quad (j = 1, 2, \dots, n; j \neq p, q);$$

(4) 以 A_l 代 A , 继续重复(1), (2), (3), 直至 $a_{pq}^{(k)} < \epsilon$ 时为止 ($p \neq q$).

此时 A_k 中对角线元素即为所求的特征值, 逐次变换矩阵 R_k 的乘积

$$U_k = R_1 R_2 \dots R_k$$

的列向量即为所求的特征向量, 具体计算时可令

$$\begin{cases} U_0 = I, \\ U_m = U_{m-1} R_m \quad (m = 1, 2, \dots, k), \end{cases}$$

每一步的计算公式为

$$\begin{cases} u_{jp}^m = u_{jp}^{(m-1)} \cos + u_{jq}^{(m-1)} \sin, \\ u_{jq}^m = -u_{jp}^{(m-1)} \sin + u_{jq}^{(m-1)} \cos. \end{cases} \quad (j = 1, 2, \dots, n)$$

在实际计算中常常采用一些措施来提高精度和节省工作量.

(1) 减少舍入误差的影响

从公式中可知, 具体计算时只需用到 \sin , \cos 的值, 为了提高精度, 舍入误差越小越好. 常常利用三角函数之间的关系, 写成便于计算的公式. 令

$$y = a_{pp} - a_{qq}, \quad x = 2a_{pq} \operatorname{sgn}(a_{pp} - a_{qq}),$$

于是
$$\tan 2 = \frac{x}{y}.$$

当 $\frac{1}{4}$ 时, $\cos 2$ 和 \cos 取非负值, 利用三角恒等式

$$2\cos^2 - 1 = \cos 2 = \frac{1}{\sqrt{1 + \tan^2 2}},$$

$$\sin 2 = \tan 2 \cos 2,$$

即得

$$\begin{cases} \cos 2 = \frac{y}{\sqrt{x^2 + y^2}}, \\ \cos = \sqrt{\frac{1}{2}(1 + \cos 2)}, \\ \sin 2 = \frac{x}{\sqrt{x^2 + y^2}}, \\ \sin = \frac{\sin 2}{2\cos}. \end{cases}$$

(2) 节省工作时间

在雅可比方法中, 每次变换是把非对角元绝对值最大者化为零, 但在 n 阶矩阵中要去找这个最大元素要花很多机时, 所以一

般不选最大元,而是采用一种改进方法——雅可比过关法来达到节省机时的目的.

二、雅可比过关法

实用中雅可比过关法的具体步骤是:

(1) 给定控制误差限 .

(2) 计算非对角元的平方和 $v_0 = 2 \sum_{i=1}^{n-1} \sum_{j=i+1}^n a_{ij}^2$.

(3) 设置一个阈值 $v_1 > 0$, 比如可取 $v_1 = \frac{v_0}{n}$.

(4) 对 A 的非对角元 $a_{ij} (i < j)$ 逐个顺序扫描, 若某个 $a_{ij} > v_1$, 则立即对 A 做一次雅可比正交相似变换, 之后对所得新矩阵继续扫描并当有非对角元的绝对值大于 v_1 时做一次相应的雅可比正交相似变换. 如此多次扫描和变换, 直到每个非对角元 $a_{ij} < v_1$.

(5) 若 $v_1 = 0$, 则计算结束, 特征值及相应的特征向量已得到, 停机; 否则转向(6).

(6) 缩小阈值, 比如用 $\frac{v_1}{n}$ 替代 v_1 , 重复(4) ~ (5).

雅可比算法稳定, 精度高, 求得的特征向量正交性好, 缺点是当 A 为稀疏矩阵时, 雅可比变换将破坏其稀疏性.

例 1 用雅可比方法求对称矩阵

$$A = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}$$

的特征值及特征向量.

解 记 $A_0 = A$ 并在 A 的非对角元中选主元为 $a_{12} = -1$, 由于 $a_{11} = a_{22} = 2$, 故可取 $\theta = -\frac{\pi}{4}$, 从而 $\sin \theta = -\frac{\sqrt{2}}{2}$, $\cos \theta = \frac{\sqrt{2}}{2}$. 于是依公式(4.2.3)计算可得

$$A_1 = \begin{bmatrix} 3 & 0 & 0.7071 \\ 0 & 1 & -0.7071 \\ 0.7071 & -0.7071 & 2 \end{bmatrix}.$$

同理计算以后各步, 具体计算结果见表 4-3. 则从表中可得

$$1 \quad a_{11}^{(5)} = 3.4135,$$

$$2 \quad a_{22}^{(5)} = 0.5859,$$

$$3 \quad a_{33}^{(5)} = 2.004,$$

$$U \quad R_1 R_2 R_3 R_4 R_5 = \begin{bmatrix} 0.5000 & 0.5000 & 0.7071 \\ -0.7071 & 0.7071 & 0 \\ 0.5000 & 0.5000 & -0.7071 \end{bmatrix},$$

即

$$u_1 = (0.5000, -0.7071, 0.5000)^T,$$

$$u_2 = (0.5000, 0.7071, 0.5000)^T,$$

$$u_3 = (0.7071, 0, -0.7071)^T$$

分别为特征值 $\lambda_1, \lambda_2, \lambda_3$ 所对应的特征向量.

矩阵 A 的精确特征值为

$$\lambda_1 = 2 + \sqrt{2} = 3.4142, \quad \lambda_2 = 2 - \sqrt{2} = 0.5858, \quad \lambda_3 = 2.$$

限于篇幅, 求实对称矩阵特征值的二分法及求一般矩阵全部特征值和特征向量的 QR 方法在此不作介绍, 对计算矩阵特征值问题有兴趣的读者可参阅相关书籍.

本章小结

本章介绍了求矩阵特征值和特征向量的常用方法.

幂法是求矩阵主特征值及其对应特征向量的一种有效方法, 特别是当矩阵为大型稀疏(即矩阵元素中零元素较多)时, 更显有效. 幂法的优点是算法简单, 但当 $\lambda_2/\lambda_1 \rightarrow 1$ 时收敛速度很慢, 必须用加速方法(如原点平移法)改进收敛速度. 而反幂法则是已知

特征值近似值时, 求对应特征向量和更准确特征值的有效方法, 但每迭代一次, 需要解一个线性方程组, 计算量较大, 为了减少计算量, 矩阵的 LU 分解在这里非常有用.

雅可比方法是通过一系列正交相似变换(即平面旋转矩阵)把对称矩阵 A 化为对角阵(近似), 从而求出 A 的全部特征值和特征向量近似值的有效方法, 雅可比方法能使求得特征向量保持良好的正交性. 对于中小型实对称矩阵, 用雅可比方法求全部特征值及特征向量是有效的, 但如果矩阵具有稀疏性, 经过一次变换后, 稀疏性会被破坏, 所以此时雅可比方法的计算量也很大.

本章介绍的几种方法, 在算法上都比较成熟, 精度和收敛性也都可以保证, 但在实际计算中, 选择何种方法较好, 还需认真考虑.

算法与程序设计实例

求矩阵的主特征值及特征向量的幂法.

算法概要

幂法是求矩阵主特征值的一种迭代方法. 设 $A \in R^{n \times n}$ 有 n 个线性无关的特征向量 X_1, X_2, \dots, X_n , 而相应的特征值满足 $\lambda_1 > \lambda_2 > \dots > \lambda_n$, 则对任意非零初始向量 $V_0 = U_0 \neq 0$, 按下列公式构造向量序列:

$$\begin{cases} V_0 = U_0 \neq 0, \\ V_k = AU_{k-1}, \quad k = 0, 1, 2, \dots, \\ U_k = V_k / \max(V_k), \end{cases}$$

其中 $\max(V_k)$ 表示 V_k 中模最大的分量并有

$$\lim_k U_k = \frac{X_1}{\max(X_1)}, \quad \lim_k \max(V_k) = \lambda_1.$$

用幂法计算实对称矩阵的特征值时, 可用 Rayleigh 商作加速. 设 U_k 的 Rayleigh 商为 R_k , 则

$$R_k = \frac{(AU_k, U_k)}{(U_k, U_k)} = \frac{(V_{k+1}, U_k)}{(U_k, U_k)} = \frac{(A^{k+1}U_0, A^k U_0)}{(A^k U_0, A^k U_0)}$$

$$= \frac{\sum_{j=1}^n a_{jj}^{2k+1}}{\sum_{j=1}^n a_{jj}^{2k}} = \lambda_1 + O\left[\left(\frac{\lambda_2}{\lambda_1}\right)^{2k}\right].$$

当 $k \rightarrow \infty$ 时, R_k 将比 $\max(V_k)$ 更快地趋于 λ_1 .

实例

求矩阵的主特征值及特征向量:

$$(1) \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix} \quad \left[\begin{array}{l} \text{主特征值为 } 2 + \sqrt{2}; \text{ 相应的特征} \\ \text{向量为 } \left[-\frac{1}{\sqrt{2}}, 1, -\frac{1}{\sqrt{2}} \right]^T \end{array} \right].$$

程序和输出结果

```
# include <stdio.h>
# include <conio.h>
# include <math.h>
# define N 3
# define EPS 1e-6
# define KM 30

float PowerMethod(float * A)
{
    float MaxValue(float * , int);
    float U[N], V[N], r2, r1;
    float temp;
    int i, j, k = 0;
    for(i = 0; i < N; i++) U[i] = 1;
    while(k < KM)
```

```

{
    k+ + ;
    for(i= 0; i< N; i+ + )
    {
        temp= 0;
        for(j= 0; j< N; j+ + ) temp+ = * (A+ i* N+ j)* U[j];
        V[i]= temp;
    }
    for(i= 0; i< N; i+ + ) U[i]= V[i]/MaxValue(V, N);
    if(k== 1) r1= MaxValue(V, N);
    r2= Max Value(V, N);
    if(fabs(r2- r1)< EPS) break;
    r1= r2;
}
printf( \nr= % f , r2);
for(i= 0; i< N; i+ + ) printf( \nx[ % d]= % f , i+ 1, U[i]);
}

float MaxValue(float * x, int n)
{
    float Max= x[ 0];
    int i;
    for(i= 1; i< n; i+ + )
        if(fabs(x[ i])> fabs(Max)) Max= x[ i];
    return Max;
}

void main()
{
    float A[N][N]= {{2, - 1, 0}, {- 1, 2, - 1}, {0, - 1, 2}};
    PowerMethod(A[0]);
}

```

```

    getch();
}

```

输出结果如下:

```

    r= 3.414214
    x[ 1]= - 0.707107
    x[ 2]=  1.000000
    x[ 3]= - 0.707107
(2)  $\begin{bmatrix} 4 & -1 & 1 \\ -1 & 3 & -2 \\ 1 & -2 & 3 \end{bmatrix}$ 

```

(主特征值为 6; 相应的特征向量为 $(1, -1, 1)^T$).

输出结果如下:

```

    r= 6.000000
    x[ 1]=  1.000000
    x[ 2]= - 1.000000
    x[ 3]=  1.000000

```

思 考 题

1. 何谓幂法? 用幂法可求矩阵哪些特征值及特征向量? 写出迭代格式.
2. 幂法收敛速度取决于什么? 怎样加速收敛?
3. 反幂法的思想是什么? 可用它求哪些特征值? 步骤如何?
4. 雅可比方法可用于何处? 其基本思想是什么?
5. 旋转矩阵的参数 p, q , 怎样确定? 目的何在? 矩阵旋转相似变换有何特点?
6. 何谓雅可比过关法? 优点何在?

习 题 四

1. 用乘幂法求下列矩阵的主特征值 λ_1 及相应的特征向量, 要求 λ_1 的近似值 $\lambda_1^{(k)}$ 满足 $|\lambda_1^{(k)} - \lambda_1^{(k-1)}| < 10^{-1}$.

$$(1) A = \begin{bmatrix} 2 & 3 & 2 \\ 10 & 3 & 4 \\ 3 & 6 & 1 \end{bmatrix}, \quad \epsilon = 10^{-1};$$

$$(2) A = \begin{bmatrix} 7 & 3 & -2 \\ 3 & 4 & -1 \\ -2 & -1 & 3 \end{bmatrix}, \quad \epsilon = 10^{-2}.$$

2. 设

$$A = \begin{bmatrix} -12 & 3 & 3 \\ 3 & 1 & -2 \\ 3 & -2 & 7 \end{bmatrix},$$

用幂法、原点平移法(取 $p = 4.6$)求 A 的主特征值及相应的特征向量, 要求 $|\lambda_1^{(k+1)} - \lambda_1^{(k)}| < 10^{-6}$.

3. 用反幂法求矩阵

$$A = \begin{bmatrix} -12 & 3 & 3 \\ 3 & 1 & -2 \\ 3 & -2 & 7 \end{bmatrix}$$

的与 $p = -13$ 最接近的那个特征值及相应的特征向量. 要求运算过程小数点后至少保留 5 位, 特征值的迭代误差不超过 10^{-5} .

4. 用雅可比方法求矩阵

$$A = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}$$

的全部特征值和对应的一组特征向量, 要求运算过程至少保留 4

位小数, 迭代到 $\left| \sum_{i,j=1}^n (a_{ij}^{(k)})^2 \right| < 10^{-3}$ 为止.

5. 设方阵 A 的特征值是实数, 且满足

$$\lambda_1 > \lambda_2 > \dots > \lambda_n, \quad \lambda_1 > \lambda_n.$$

为求 λ_1 而作原点平移, 试证: 当平移量 $p = \frac{1}{2}(\lambda_2 + \lambda_n)$ 时, 幂法收敛最快.

6. 设 A 为实对称矩阵, $\{A_k\}$ 是按古典雅可比方法计算时产生的矩阵序列, $S(A_k) = \sum_{i,j=1}^n (a_{ij}^{(k)})^2$. 证明:

$$S(A_{k+1}) = \left[1 - \frac{2}{n(n-1)} \right] S(A_k).$$

第五章 插 值 法

在科学研究与工程技术中,常会遇到函数表达式过于复杂而不便于计算,且又需要计算众多点处的函数值;或只已知由实验或测量得到的某一函数 $y = f(x)$ 在区间 $[a, b]$ 中互异的 $n+1$ 个 x_0, x_1, \dots, x_n 处的值 y_0, y_1, \dots, y_n , 需要构造一个简单函数 $P(x)$ 作为函数 $y = f(x)$ 的近似表达式

$$y = f(x) \approx P(x),$$

使得

$$P(x_i) = f(x_i) = y_i \quad (i = 0, 1, \dots, n).$$

这类问题称为插值问题, $P(x)$ 即称插值函数. 由于代数多项式是最简单而又便于计算的函数, 所以经常采用多项式作为插值函数. 当然, 也可采用三角多项式或有理分式等作为插值函数. 若插值函数类 $\{P(x)\}$ 是代数多项式, 则相应的插值问题称为代数插值. 若 $\{P(x)\}$ 是三角多项式, 则相应的插值问题称为三角插值. 本章只讨论代数插值问题. 对于别的插值问题, 读者可参阅有关理科的计算方法书籍.

插值法是一种古老而实用的数值方法, 它来自生产实践. 早在一千多年前, 我国科学家在研究历法中就应用了线性插值与二次插值, 但它的基本理论和结果却是在微积分产生以后才逐步完善, 其应用也日益广泛. 时至今日, 随着电子计算机的普及, 插值法的应用范围已涉及到了生产、科研的各个领域. 特别是由于航空、造船、精密机械加工等实际问题的需要, 更使得插值法在实践与理论上显得尤为重要并得到了进一步发展, 尤其是近几十年发展起来的样条(Spline)插值, 更获得了广泛的应用.

§ 1 拉格朗日(Lagrange)插值

一、代数插值问题

先给出代数插值的定义.

设 $y = f(x)$ 在区间 $[a, b]$ 上有定义, 且在 $[a, b]$ 上的 $n+1$ 个不同点 $a = x_0 < x_1 < \dots < x_n = b$ 的函数值为 y_0, y_1, \dots, y_n , 若存在一个代数多项式

$$P_n(x) = a_0 + a_1x + a_2x^2 + \dots + a_nx^n, \quad (5.1.1)$$

其中 a_i 为实数, 使得

$$P_n(x_i) = y_i \quad (i = 0, 1, 2, \dots, n) \quad (5.1.2)$$

成立, 则称 $P_n(x)$ 为函数 $y = f(x)$ 的插值多项式, 点 x_0, x_1, \dots, x_n 称为插值节点, 包含插值节点的区间 $[a, b]$ 称为插值区间, 关系式 (5.1.2) 称为插值条件. 求插值多项式 $P_n(x)$ 的问题(方法)称为代数插值问题(方法).

代数插值的几何意义, 就是通过 $n+1$ 个点 (x_i, y_i) ($i = 0, 1, 2, \dots, n$) 做一条代数曲线 $y = P_n(x)$, 使其近似于曲线 $y = f(x)$, 如图 5-1 所示.




图 5-1

显然, 在 $[a, b]$ 上用 $P_n(x)$ 近似 $f(x)$, 除了在插值节点 x_i 处

$P_n(x_i) = f(x_i)$ 外, 在其余点 x 处都有误差.

令 $R_n(x) = f(x) - P_n(x)$, 则 $R_n(x)$ 称为插值多项式的余项, 它表示用 $P_n(x)$ 去近似 $f(x)$ 的截断误差. 一般地, $\max_{a \leq x \leq b} R_n(x)$ 越小, 其近似程序越好.

二、插值多项式的存在与唯一性

定理 1 在 $n+1$ 个互异节点 x_i 上满足插值条件

$$P_n(x_i) = y_i \quad (i = 0, 1, 2, \dots, n)$$

的次数不高于 n 次的插值多项式 $P_n(x)$ 存在且惟一.

证明 若(5.1.1)式的 $n+1$ 个系数可以被惟一确定, 则该多项式也就存在且惟一.

根据插值条件(5.1.2), (5.1.1)式中的系数 a_0, a_1, \dots, a_n 应满足以下 $n+1$ 阶线性方程组

$$\left\{ \begin{array}{l} \textbf{a}_0 + \textbf{a}_1\textbf{x}_0 + \textbf{a}_2\textbf{x}_0^2 + ... + \textbf{a}_n\textbf{x}_0^n = \textbf{y}_0, \\ \textbf{a}_0 + \textbf{a}_1\textbf{x}_1 + \textbf{a}_2\textbf{x}_1^2 + ... + \textbf{a}_n\textbf{x}_1^n = \textbf{y}_1, \\ \\ \textbf{a}_0 + \textbf{a}_1\textbf{x}_n + \textbf{a}_2\textbf{x}_n^2 + ... + \textbf{a}_n\textbf{x}_n^n = \textbf{y}_n, \end{array} \right. \quad (5.1.3)$$

其中未知量 a_0, a_1, \dots, a_n 的系数行列式为范德蒙 (Vandermonde) 行列式

$$V = \begin{vmatrix} 1 & x_0 & x_0^2 & \dots & x_0^n \\ 1 & x_1 & x_1^2 & \dots & x_1^n \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & x_n^2 & \dots & x_n^n \end{vmatrix} = \prod_{0 \leq i < j \leq n} (x_i - x_j). \quad (5.1.4)$$

由于节点互异, 即 $x_i \neq x_j (i \neq j)$, 所以 $V \neq 0$. 由克莱姆法则可知方程组(5.1.3)存在惟一的一组解 a_0, a_1, \dots, a_n , 即插值多项式(5.1.1)存在且惟一.

三、线性插值

线性插值是多项式插值的最简单情形.

设函数 $y = f(x)$ 在区间 $[x_0, x_1]$ 两端点的值为 $y_0 = f(x_0)$, $y_1 = f(x_1)$, 要求用线性函数 $y = L_1(x) = ax + b$ 近似代替 $f(x)$, 适当选择参数 a, b , 使

$$L_1(x_0) = f(x_0), \quad L_1(x_1) = f(x_1), \quad (5.1.5)$$

则称线性函数 $L_1(x)$ 为 $f(x)$ 的线性插值函数.




图 5-2

线性插值的几何意义是利用通过两点 $A(x_0, f(x_0))$ 和 $B(x_1, f(x_1))$ 的直线去近似代替曲线 $y = f(x)$, 如图 5-2 所示.

由直线方程的两点式可求得 $L_1(x)$ 的表达式为

$$L_1(x) = \frac{x - x_1}{x_0 - x_1} y_0 + \frac{x - x_0}{x_1 - x_0} y_1, \quad (5.1.6)$$

这就是所求的线性插值函数.

设

$$l_0(x) = \frac{x - x_1}{x_0 - x_1}, \quad l_1(x) = \frac{x - x_0}{x_1 - x_0},$$

则 $l_0(x), l_1(x)$ 均为 x 的一次函数, 且不难看出它们具有下列性质:

$$\begin{cases} l_0(x_0) = 1, & l_1(x_0) = 0, \\ l_0(x_1) = 0, & l_1(x_1) = 1, \end{cases}$$

或统一写为

$$l_k(x_i) = \begin{cases} 1, & \text{当 } i = k \text{ 时,} \\ 0, & \text{当 } i \neq k \text{ 时,} \end{cases} \quad (i, k = 0, 1)$$

具有这种性质的函数 $l_0(x), l_1(x)$ 称为线性插值基函数. 于是 (5.1.6) 式可用基函数表示为

$$L_1(x) = y_0 l_0(x) + y_1 l_1(x).$$

上式说明, 任何一个满足插值条件 (5.1.5) 式的线性插值函数都可

由线性插值基函数 $l_0(x), l_1(x)$ 的一个线性组合来表示.

下面继续讨论在 $[x_0, x_1]$ 上用函数 $y = L_1(x)$ 近似 $y = f(x)$ 所产生的截断误差 $R_1(x) = f(x) - L_1(x)$.

定理 2 设 $f(x)$ 在 $[x_0, x_1]$ 上连续, $f(x)$ 在 (x_0, x_1) 内存在, $L_1(x)$ 是满足插值条件 (5.1.5) 的插值多项式, 则对任何 $x \in [x_0, x_1]$, 插值余项(截断误差)为

$$R_1(x) = f(x) - L_1(x) = \frac{f(\xi)}{2!}(x - x_0)(x - x_1), \quad (5.1.7)$$

其中 $\xi \in (x_0, x_1)$, 且依赖于 x .

证明 当 $x = x_0$ 或 $x = x_1$ 时, 由 (5.1.5) 式知 (5.1.7) 式成立; 当 $x \in (x_0, x_1)$ 且 $x \neq x_0, x_1$ 时, 把 x 看成 $[x_0, x_1]$ 上的一个固定点, 作辅助函数

$$(t) = f(t) - L_1(t) - \frac{f(x) - L_1(x)}{(x - x_0)(x - x_1)}(t - x_0)(t - x_1),$$

容易证明

$$(x_0) = (x_1) = (x) = 0,$$

即 (t) 在 $[x_0, x_1]$ 上有三个零点. 由罗尔(Rolle)定理知, (t) 在 (x_0, x_1) 内至少有两个零点. 对 (t) 再应用罗尔定理, 则 (ξ) 在 (x_0, x_1) 内至少有一个零点, 记为 ξ , 使得

$$(\xi) = f(\xi) - L_1(\xi) - 2! \frac{f(x) - L_1(x)}{(x - x_0)(x - x_1)} = 0,$$

由此得

$$\begin{aligned} R_1(x) &= f(x) - L_1(x) \\ &= \frac{f(\xi)}{2!}(x - x_0)(x - x_1), \quad \xi \in (x_0, x_1). \end{aligned}$$

应当指出, 若 $f(x)$ 的解析表达式不知道, 或者 $f(x)$ 在 (x_0, x_1) 内不存在, 就不能用这个余项表达式去估计插值的截断误差. 即使 $f(x)$ 存在, 但由于 ξ 在 (x_0, x_1) 内的具体位置一般是不知

道的,这时若能求出 $\max_{a \leq x \leq b} f(x) = M_1$, 则其截断误差限是

$$R_1 = \frac{M_1}{2!} (x - x_0)(x - x_1) .$$

四、抛物线插值

设已知 $y = f(x)$ 在三个不同点 x_0, x_1, x_2 上的值分别为 y_0, y_1, y_2 . 要求作一个二次插值多项式 $L_2(x)$, 使它满足插值条件

$$L_2(x_i) = y_i \quad (i = 0, 1, 2). \tag{5.1.8}$$

由于通过不同在一直线上的三点 $A(x_0, f(x_0)), B(x_1, f(x_1)), C(x_2, f(x_2))$ 可以作一条抛物线, 故称二次插值多项式 $L_2(x)$ 为 $f(x)$ 的抛物线插值函数, 如图 5-3 所示.




图 5-3

下面采用类似线性插值基函数的求法去求 $L_2(x)$.

设二次插值多项式为

$$L_2(x) = y_0l_0(x) + y_1l_1(x) + y_2l_2(x), \quad x_0 \leq x \leq x_2, \tag{5.1.9}$$

其中 $l_k(x)$ ($k = 0, 1, 2$) 都是二次多项式, 且满足

$$l_k(x_i) = \begin{cases} 1, & \text{当 } i = k \text{ 时,} \\ 0, & \text{当 } i \neq k \text{ 时.} \end{cases} \quad (i, k = 0, 1, 2) \tag{5.1.10}$$

显然, $L_2(x)$ 满足插值条件 (5.1.8) 式, 余下的问题是如何求 $l_k(x)$. 以 $l_0(x)$ 为例, 由 (5.1.10) 式知, $l_0(x_1) = l_0(x_2) = 0$, 即 x_1, x_2 是 $l_0(x)$ 的两个零点, 故可设

$$l_0(x) = k(x - x_1)(x - x_2),$$

其中 k 为待定常数. 由 $l_0(x_0) = 1$, 得

$$k(x_0 - x_1)(x_0 - x_2) = 1,$$

所以

$$k = \frac{1}{(x_0 - x_1)(x_0 - x_2)},$$

于是

$$l_0(x) = \frac{(x - x_1)(x - x_2)}{(x_0 - x_1)(x_0 - x_2)}.$$

同理可得

$$l_1(x) = \frac{(x - x_0)(x - x_2)}{(x_1 - x_0)(x_1 - x_2)}, \quad l_2(x) = \frac{(x - x_0)(x - x_1)}{(x_2 - x_0)(x_2 - x_1)}.$$

代入(5.1.9)式得

$$\begin{aligned} L_2(x) = & y_0 \frac{(x - x_1)(x - x_2)}{(x_0 - x_1)(x_0 - x_2)} + y_1 \frac{(x - x_0)(x - x_2)}{(x_1 - x_0)(x_1 - x_2)} \\ & + y_2 \frac{(x - x_0)(x - x_1)}{(x_2 - x_0)(x_2 - x_1)} \quad (x_0 \quad x \quad x_2), \end{aligned} \quad (5.1.11)$$

其中

$$y_i = f(x_i) \quad (i = 0, 1, 2).$$

由(5.1.11)式所表示的函数又称为 $f(x)$ 的二次拉格朗日插值多项式.

如果 $f(x)$ 在 $[x_0, x_2]$ 上连续, $f(x)$ 在 (x_0, x_2) 内存在, 则类似于定理 2 的证明, 用 $L_2(x)$ 去近似 $f(x)$ 的截断误差为

$$R_2(x) = f(x) - L_2(x) = \frac{f^{(3)}(\xi)}{3!}(x - x_0)(x - x_1)(x - x_2),$$

其中 $\xi \in (x_0, x_2)$, 且依赖于 x_0 .

若 $\max_{x_0 \leq x \leq x_2} f^{(3)}(x) = M_2$, 则截断误差限为

$$|R_2(x)| \leq \frac{M_2}{3!} (x - x_0)(x - x_1)(x - x_2).$$

五、拉格朗日插值多项式

下面进一步研究 n 次插值多项式的问题.

设函数 $y = f(x)$ 在 $n+1$ 个节点

$$x_0 < x_1 < \dots < x_n$$

处的函数值为 $y_k = f(x_k)$ ($k = 0, 1, 2, \dots, n$), 现要作一个 n 次插值多项式 $L_n(x)$, 并使 $L_n(x)$ 在节点 x_i 处满足

$$L_n(x_i) = y_k \quad (k = 0, 1, 2, \dots, n). \quad (5.1.12)$$

我们仍用构造 n 次插值基函数的方法去求 $L_n(x)$. 所谓 n 次插值基函数 $l_k(x)$ ($k = 0, 1, 2, \dots, n$), 就是在 $n+1$ 个节点 $x_0 < x_1 < \dots < x_n$ 上满足条件

$$l_k(x_i) = \begin{cases} 1, & \text{当 } i = k \text{ 时,} \\ 0, & \text{当 } i \neq k \text{ 时} \end{cases} \quad (i, k = 0, 1, 2, \dots, n) \quad (5.1.13)$$

的 n 次多项式.

用前面二次插值的类似推导方法, 不难推得

$$l_k(x) = \frac{(x - x_0)(x - x_1) \dots (x - x_{k-1})(x - x_{k+1}) \dots (x - x_n)}{(x_k - x_0)(x_k - x_1) \dots (x_k - x_{k-1})(x_k - x_{k+1}) \dots (x_k - x_n)} \quad (k = 0, 1, 2, \dots, n). \quad (5.1.14)$$

显然, $l_k(x)$ 满足插值条件(5.1.12)式, 从而

$$L_n(x) = \sum_{k=0}^n y_k l_k(x). \quad (5.1.15)$$

以上插值多项式就称为 n 次拉格朗日插值多项式. 当 $n=1$ 和 $n=2$ 时, $L_1(x)$ 和 $L_2(x)$ 分别称为线性插值多项式和二次插值多项式.

若引入记号

$$\omega_{n+1}(x) = (x - x_0)(x - x_1) \dots (x - x_n), \quad (5.1.16)$$

则

$$\omega_{n+1}(x_k) = (x_k - x_0)(x_k - x_1) \dots (x_k - x_{k-1})(x_k - x_{k+1}) \dots (x_k - x_n).$$

于是(5.1.15)式可改写为

$$L_n(x) = \sum_{k=0}^n y_k \frac{\prod_{i=0, i \neq k}^n (x - x_i)}{(x - x_k) \prod_{i=0, i \neq k}^n (x_i - x_k)}. \quad (5.1.17)$$

注意, n 次插值多项式 $L_n(x)$ 通常是次数为 n 的多项式, 特殊情况下次数可能小于 n . 例如, 通过三点 $(x_0, y_0), (x_1, y_1), (x_2, y_2)$ 的二次插值多项式 $L_2(x)$, 如果三点共线, 则 $y = L_2(x)$ 就是一条直线, 而不是抛物线, 这时 $L_2(x)$ 是一次多项式.

为了在计算机上计算 $L_n(x)$ 的值, 通常采用如下紧凑表达式

$$L_n(x) = \sum_{k=0}^n \left[\prod_{i=0, i \neq k}^n \left(\frac{x - x_i}{x_k - x_i} \right) \right] y_k. \quad (5.1.18)$$

编排程序时为二重循环, 先固定 k , 令 i 从 0 到 n ($i \neq k$) 作乘积, 再对 k 求和, 即可求得 $L_n(x)$ 在某点 x 的值.

若 $f^{(n)}(x)$ 在 $[x_0, x_n]$ 上连续, $f^{(n+1)}(x)$ 在 (x_0, x_n) 内存在, $x_0 < x_1 < \dots < x_n$ 是 $n+1$ 个节点, 则用 $L_n(x)$ 去近似 $f(x)$ 所产生的截断误差为

$$R_n(x) = f(x) - L_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega_{n+1}(x), \quad (5.1.19)$$

其中 $\xi = \xi(x)$ 且依赖于 x .

必须指出, 通过 $n+1$ 个互异节点 $x_0, x_1, x_2, \dots, x_n$ 且满足插值条件(5.1.12)式的插值多项式是惟一的. 事实上, 若还有一个插值多项式 $P_n(x)$, 则 $L_n(x) - P_n(x)$ 是一个次数不超过 n 的多项式, 且在节点 x_i 处的值为零, 就是说 $L_n(x) - P_n(x)$ 有 $n+1$ 个零点 $x_0, x_1, x_2, \dots, x_n$. 但次数不超过 n 的多项式的零点个数不能超过 n , 故只有一个可能, 即 $L_n(x) - P_n(x) \equiv 0$, 所以 $L_n(x) \equiv P_n(x)$.

例 1 已知 e^{-x} 在 $x = 1, 2, 3$ 点的值由下表给出. 试分别用线性插值与二次插值计算 $e^{-2.1}$ 的近似值, 并进行误差估计.

x	1	2	3
e^{-x}	0.367879441	0.135335283	0.049787068

解 取 $x_0 = 2, x_1 = 3, x = 2.1$ 代入一次插值公式(5.1.6), 得

$$\begin{aligned} L_1(2.1) &= \frac{2.1-3}{2-3} \times 0.135335283 \\ &\quad + \frac{2.1-2}{3-2} \times 0.049787068 \\ &= 0.12678046. \end{aligned}$$

取 $x_0 = 1, x_1 = 2, x_2 = 3, x = 2.1$ 代入二次插值公式(5.1.11), 得

$$\begin{aligned} L_2(2.1) &= \frac{(2.1-2)(2.1-3)}{(1-2)(1-3)} \times 0.367879441 \\ &\quad + \frac{(2.1-1)(2.1-3)}{(2-1)(2-3)} \times 0.135335283 \\ &\quad + \frac{(2.1-1)(2.1-2)}{(3-1)(3-2)} \times 0.049787068 \\ &= 0.120165644. \end{aligned}$$

由(5.1.19)式与函数 e^{-x} 的递减性, 有

$$\begin{aligned} R_1(2.1) &= \frac{e^{-2}}{2!} (2.1-2)(2.1-3) = 0.00609009, \\ R_2(2.1) &= \frac{e^{-1}}{3!} (2.1-1)(2.1-2)(2.1-3) \\ &= 0.00607001. \end{aligned}$$

从计算结果和误差估计均可看出, 与精确值 $e^{-2.1} = 0.122456428$ 比较, $L_2(2.1)$ 比 $L_1(2.1)$ 近似程度要好一些.

§ 2 分段低次插值

前面我们根据区间 $[a, b]$ 上给出的节点可以得到函数 $f(x)$ 的插值多项式, 但并非插值多项式的次数越高, 逼近函数 $f(x)$ 的精度就越好. 其主要原因是, 由于高次插值多项式往往有数值不稳定的缺点, 即对任意的插值节点, 当 n 时, 插值多项式 $P_n(x)$ 不一定收敛到 $f(x)$. 对此, 本世纪初龙格(Runge)就给出了下述等

距节点插值多项式 $L_n(x)$ 不收敛到 $f(x)$ 的例子.

给定函数 $f(x) = \frac{1}{1+x^2}$, 它在 $[-5, 5]$ 上的各阶导数均存在, 但在 $[-5, 5]$ 上取 $n+1$ 个等距节点 $x_i = -5 + 10 \frac{i}{n}$ ($i = 0, 1, 2, \dots, n$) 所构造的拉格朗日插值多项式

$$L_n(x) = \sum_{k=0}^n \frac{1}{1+x_k^2} \frac{\prod_{j \neq k}^{n+1} (x - x_j)}{\prod_{j \neq k}^{n+1} (x_k - x_j)}$$

当 n 时, 只在 $x \in [-3.63, 3.63]$ 内收敛, 而在这区间外是发散的. 图 5-4 给出了 $n=10$ 时, $y = L_{10}(x)$ 与 $f(x) = \frac{1}{1+x^2}$ 的图形. 从图 5-4 可见, 在 $x = \pm 5$ 附近, $L_{10}(x)$ 与 $f(x)$ 偏离很远, 例如 $L_{10}(4.8) = 1.80438, f(4.8) = 0.4160$. 这种高次插值不准确的现象称为龙格现象.




图 5-4

为了避免高次插值的上述缺点, 我们常常采用分段插值的方法, 即将插值区间分为若干个小区间, 在每个小区间上运用前面介绍的插值方法构造低次插值多项式, 以达到适当缩小插值区间长度, 同样可以提高插值精度的目的. 事实上, 若在上例中将 $f(x) =$

$1/(1+x^2)$ 在节点 $x = 0, \pm 1, \pm 2, \pm 3, \pm 4, \pm 5$ 处用折线连起来, 并在每个小区间上应用线性插值计算所得的近似值显然比 $f_{10}(x)$ 更逼近 $f(x)$, 这正是分段低次插值的优越所在.

分段低次插值的优点是公式简单, 计算量小, 且有较好的收敛性和稳定性, 并且可避免计算机上作高次乘幂时常遇到的上溢和下溢的困难.

一、分段线性插值

从几何意义上看, 分段线性插值就是用折线近似代替曲线 $y = f(x)$.

设在区间 $[a, b]$ 上取 $n+1$ 个点

$$a = x_0 < x_1 < \dots < x_{n-1} < x_n = b. \quad (5.2.1)$$

函数 $f(x)$ 在上述节点处的函数值为

$$y_i = f(x_i) \quad (i = 0, 1, 2, \dots, n),$$

于是得到 $n+1$ 个点

$$(x_0, y_0), (x_1, y_1), \dots, (x_n, y_n).$$

连接相邻两点 (x_i, y_i) 和 (x_{i+1}, y_{i+1}) ($i = 0, 1, 2, \dots, n$), 得一折线函数 (x) , 若满足:

- (1) (x) 在 $[a, b]$ 上连续;
- (2) $(x_i) = y_i$ ($i = 0, 1, 2, \dots, n$);
- (3) (x) 在每个小区间 $[x_i, x_{i+1}]$ 上是线性函数,

则称折线函数 (x) 为分段线性插值函数.

由分段线性插值函数的定义知, (x) 在每个小区间 $[x_i, x_{i+1}]$ 上可表为

$$(x) = \frac{x - x_{i+1}}{x_i - x_{i+1}} y_i + \frac{x - x_i}{x_{i+1} - x_i} y_{i+1},$$

$$x_i \leq x \leq x_{i+1} \quad (i = 0, 1, 2, \dots, n-1).$$

(x) 是一分段函数, 若用基函数表示, 只需对 $i = 0, 1, 2, \dots, n$, 令

$$l_i(x) = \begin{cases} \frac{x - x_{i-1}}{x_i - x_{i-1}}, & x_{i-1} \leq x \leq x_i \quad (i = 0 \text{ 略去}), \\ \frac{x - x_{i+1}}{x_i - x_{i+1}}, & x_i \leq x \leq x_{i+1} \quad (i = n \text{ 略去}), \\ 0, & \text{其他.} \end{cases}$$

显然, $l_i(x)$ 是分段的线性连续函数, 且满足

$$l_i(x_k) = \begin{cases} 1, & i = k, \\ 0, & i \neq k, \end{cases}$$

于是

$$(x) = \sum_{i=0}^n y_i l_i(x), \quad a \leq x \leq b. \quad (5.2.2)$$

二、分段抛物线插值

分段抛物线插值是把区间 $[a, b]$ 分成若干个子区间, 在每个子区间

$$[x_{i-1}, x_{i+1}] \quad (i = 1, 2, \dots, n-1)$$

上用抛物线去近似曲线 $y = f(x)$. 若记子区间 $[x_{i-1}, x_{i+1}]$ 上的分段二次插值多项式为 $L_2(x)$, 则由上节(5.1.11)式可知, $L_2(x)$ 可表为

$$\begin{aligned} L_2(x) = & \frac{(x - x_i)(x - x_{i+1})}{(x_{i-1} - x_i)(x_{i-1} - x_{i+1})} y_{i-1} \\ & + \frac{(x - x_{i-1})(x - x_{i+1})}{(x_i - x_{i-1})(x_i - x_{i+1})} y_i \\ & + \frac{(x - x_{i-1})(x - x_i)}{(x_{i+1} - x_{i-1})(x_{i+1} - x_i)} y_{i+1}. \end{aligned} \quad (5.2.3)$$

今将 (x) 定义为按式(5.2.3)分段表示的区间 $[a, b]$ 上的函数, 则称 (x) 为 $f(x)$ 在区间 $[a, b]$ 上的分段二次插值函数, 它有下列性质:

- (1) (x) 在区间 $[a, b]$ 上是连续函数;
- (2) $(x_i) = y_i \quad (i = 0, 1, 2, \dots, n)$;

(3) 在每个子区间 $[x_i, x_{i+1}]$ 上, (x) 是次数不超过二次的多项式.

应用低次插值的关键是恰当地选择插值点, 而选择插值节点的原则是应尽可能地在插值点的邻近选取插值节点. 例如, 假设插值点 x 位于点 x_{k-1}, x_k 之间, 这时为了确定另一个插值节点, 需要进一步判定 x 究竟偏向区间 (x_{k-1}, x_k) 的哪一边. 当 x 靠近 x_{k-1} , 即 $x - x_{k-1} < x - x_k$ 时, 则取 x_{k-2} 为第三个插值节点, 这时令 (5.2.3) 式中的下标 $i = k-1$; 反之, 当 x 靠近 x_k , 即 $x - x_{k-1} > x - x_k$ 时, 则取 x_{k+1} 为第三个插值节点, 这时令 (5.2.3) 式中的下标 $i = k$; 当 x 靠近开始点, 即 $x < x_1$ 时, 自然取 x_0, x_1, x_2 为插值节点, 这时令公式 (5.2.3) 中的下标 $i = 1$; 当 x 靠近终点, 即 $x > x_{n-1}$ 时, 则取 $i = n-1$. 根据以上讨论, i 的取法可归结为

$$i = \begin{cases} 1, & \text{当 } x < x_1, \\ k-1, & \text{当 } x_{k-1} < x < x_k, \text{ 且 } x - x_{k-1} < x - x_k, \\ & k = 2, 3, \dots, n-1, \\ k, & \text{当 } x_{k-1} < x < x_k, \text{ 且 } x - x_{k-1} > x - x_k, \\ & k = 2, 3, \dots, n-1, \\ n-1, & \text{当 } x > x_{n-1}. \end{cases}$$

§ 3 差商与牛顿插值多项式

拉格朗日插值多项式具有含义直观, 形式对称, 结构紧凑, 便于记忆和编程计算等特点. 但这种插值多项式, 当精度不高而需要增加插值节点时, 插值多项式就得重新构造, 整个公式改变后以前的计算结果就不能在新的公式里发挥作用, 计算工作也就必须全部从头做起. 为了克服这一缺点, 本节将介绍另一种形式的插值多项式——牛顿插值多项式. 它的使用比较灵活, 当增加插值节点时, 只要原来的基础上增加部分计算工作量而使原来的计算结果仍可得到利用, 这样就节约了计算时间, 为实际计算带来了许多

方便. 此外, 它还可用于被插值函数由表格形式给出时的余项估计. 在讨论牛顿插值多项式之前, 先介绍差商的概念及性质.

一、差商的定义及性质

定义 1 已知函数 $f(x)$ 在 $n+1$ 个互异节点 $x_0 < x_1 < x_2 < \dots < x_n$ 处的函数值分别为 $f(x_0), f(x_1), \dots, f(x_n)$, 称

$$f[x_i, x_{i+1}] = \frac{f(x_{i+1}) - f(x_i)}{x_{i+1} - x_i}$$

为 $f(x)$ 关于节点 x_i, x_{i+1} 的一阶差商. 称

$$f[x_i, x_{i+1}, x_{i+2}] = \frac{f[x_{i+1}, x_{i+2}] - f[x_i, x_{i+1}]}{x_{i+2} - x_i}$$

为 $f(x)$ 关于节点 x_i, x_{i+1}, x_{i+2} 的二阶差商. 一般地, 称

$$\begin{aligned} & f[x_i, x_{i+1}, \dots, x_{i+k}] \\ &= \frac{f[x_{i+1}, x_{i+2}, \dots, x_{i+k}] - f[x_i, x_{i+1}, \dots, x_{i+k-1}]}{x_{i+k} - x_i} \end{aligned} \quad (5.3.1)$$

为 $f(x)$ 关于节点 $x_i, x_{i+1}, \dots, x_{i+k}$ 的 k 阶差商. 当 $k=0$ 时称 $f(x_i)$ 为 $f(x)$ 关于节点 x_i 的零阶差商, 记为 $f[x_i]$.

$$\begin{aligned} \text{因为 } f(x_i) &= \lim_{x_{i+1} \rightarrow x_i} \frac{f(x_{i+1}) - f(x_i)}{x_{i+1} - x_i}, \text{ 故} \\ f(x_i) &= \lim_{x_{i+1} \rightarrow x_i} f[x_i, x_{i+1}], \end{aligned}$$

即差商是微商的离散形式.

差商有如下性质:

性质 1 函数 $f(x)$ 关于节点 x_0, x_1, \dots, x_k 的 k 阶差商 $f[x_0, x_1, \dots, x_k]$ 可以表示为函数值 $f(x_0), f(x_1), \dots, f(x_k)$ 的线性组合, 即

$$f[x_0, x_1, \dots, x_k] = \sum_{j=0}^k \frac{f(x_j)}{k+1(x_j)}. \quad (5.3.2)$$

证明 用数学归纳法.

当 $k=1$ 时, 由定义

$$\begin{aligned} f[x_0, x_1] &= \frac{f(x_1) - f(x_0)}{x_1 - x_0} = \frac{f(x_0)}{x_0 - x_1} + \frac{f(x_1)}{x_1 - x_0} \\ &= \sum_{j=0}^1 \frac{f(x_j)}{1+1(x_j)}, \end{aligned}$$

对 $k=1$, (5.3.2) 成立.

设 $k=n-1$ 时亦成立, 即对 $n-1$ 阶差商 (5.3.2) 式成立, 于是有

$$\begin{aligned} f[x_0, x_1, \dots, x_{n-1}] &= \sum_{j=0}^{n-1} \frac{f(x_j)}{n(x_j)} \\ &= \sum_{j=0}^{n-1} \frac{f(x_j)}{(x_j - x_0)(x_j - x_1) \dots (x_j - x_{j-1})(x_j - x_{j+1}) \dots (x_j - x_{n-1})}, \\ f[x_1, x_2, \dots, x_n] &= \sum_{j=1}^n \frac{f(x_j)}{n(x_j)} \\ &= \sum_{j=1}^n \frac{f(x_j)}{(x_j - x_1)(x_j - x_2) \dots (x_j - x_{j-1})(x_j - x_{j+1}) \dots (x_j - x_n)}. \end{aligned}$$

由定义

$$\begin{aligned} f[x_0, x_1, \dots, x_n] &= \frac{f[x_1, x_2, \dots, x_n] - f[x_0, x_1, \dots, x_{n-1}]}{x_n - x_0} \\ &= \sum_{j=1}^n \frac{f(x_j)}{n(x_j)(x_n - x_0)} + \sum_{j=0}^{n-1} \frac{f(x_j)}{n(x_j)(x_0 - x_n)} \\ &= \frac{f(x_0)}{(x_0 - x_1) \dots (x_0 - x_n)} \\ &\quad + \sum_{j=1}^{n-1} \left[\frac{f(x_j)}{n(x_j)(x_n - x_0)} - \frac{f(x_j)}{n(x_j)(x_n - x_0)} \right] \\ &\quad + \frac{f(x_n)}{(x_n - x_0)(x_n - x_1) \dots (x_n - x_{n-1})} \\ &= \sum_{j=0}^n \frac{f(x_j)}{n+1(x_j)}, \end{aligned}$$

即推出 $k = n$ 时也成立, 故命题成立.

由性质 1 可直接推出以下性质.

性质 2 差商与其所含节点的排列次序无关, 即

$$f [X_i, X_{i+1}] = f [X_{i+1}, X_i],$$

$$f [X_i, X_{i+1}, X_{i+2}] = f [X_{i+1}, X_i, X_{i+2}] = f [X_{i+2}, X_{i+1}, X_i].$$

一般地, 在 k 阶差商 $f [X_0, X_1, \dots, X_k]$ 中, 任意调换节点的次序, 其值不变.

性质 3 设 $f (x)$ 在包含互异节点 X_0, X_1, \dots, X_n 的闭区间 $[a, b]$ 上有 n 阶导数, 则 n 阶差商与 n 阶导数之间有如下关系

$$f [X_0, X_1, \dots, X_n] = \frac{f^{(n)}(\xi)}{n!}, \quad (\xi \in (a, b)). \quad (5.3.3)$$

关于这一性质的证明将在后面给出.

利用差商的递推定义, 差商的计算可列差商表如表 5-1 所示:

表 5-1

X_i	$f (X_i)$	一阶差商	二阶差商	三阶差商
X_0	$f (X_0)$			
X_1	$f (X_1)$	$f [X_0, X_1]$		
X_2	$f (X_2)$	$f [X_1, X_2]$	$f [X_0, X_1, X_2]$	
X_3	$f (X_3)$	$f [X_2, X_3]$	$f [X_1, X_2, X_3]$	$f [X_0, X_1, X_2, X_3]$

若要计算四阶差商, 增加一个节点, 再计算一个斜行. 如此下去, 即可求出各阶差商的值.

二、牛顿插值多项式及其余项

根据差商的定义, 可以得出满足插值条件

$$N_n (X_i) = y_i \quad (i = 0, 1, 2, \dots, n) \quad (5.3.4)$$

的插值多项式 $N_n (x)$.

设 X_0, X_1, \dots, X_n 为 $n + 1$ 个插值节点, $x \in [a, b]$ 且 $x \neq X_i \ (i = 0, 1, 2, \dots, n)$, 则由差商定义有

将上组等式中第二式代入第一式得

式中 $N_1(x) = f(x_0) + f[x_0, x_1](x - x_0)$, 可验证 $N_1(x)$ 是满足插值条件(5.3.4)的一次插值多项式. 而

为一次插值的余项.

再将第三式代入 $f(x) = N_1(x) + R_1(x)$ 得

式中

由 $N_2(x)$ 的表达式, $N_2(x_0) = y_0$, $N_2(x_1) = y_1$ 显然成立. 当 $x = x_2$ 时,

154

$$\begin{aligned}
&= f(x_0) + x_2 f[x_0, x_1] - x_0 f[x_0, x_1] + x_2 f[x_1, x_2] \\
&\quad - x_2 f[x_0, x_1] - x_1 f[x_1, x_2] + x_1 f[x_0, x_1] \\
&= f(x_0) + f[x_0, x_1](x_1 - x_0) + f[x_1, x_2](x_2 - x_1) \\
&= f(x_0) + f(x_1) - f(x_0) + f(x_2) - f(x_1) \\
&= f(x_2).
\end{aligned}$$

所以 $N_2(x)$ 为满足插值条件 (5.3.4) 的二次插值多项式. 而

$$R_2(x) = f[x, x_0, x_1, x_2](x - x_0)(x - x_1)(x - x_2)$$

为二次插值的余项.

类似地, 将各式逐次代入前一公式, 可得

$$\begin{aligned}
f(x) &= f(x_0) + f[x_0, x_1](x - x_0) \\
&\quad + f[x_0, x_1, x_2](x - x_0)(x - x_1) + \dots \\
&\quad + f[x_0, x_1, \dots, x_n](x - x_0)(x - x_1) \dots (x - x_{n-1}) \\
&\quad + f[x, x_0, \dots, x_n](x - x_0)(x - x_1) \dots (x - x_n),
\end{aligned} \tag{5.3.5}$$

令

$$\begin{aligned}
N_n(x) &= f(x_0) + f[x_0, x_1](x - x_0) \\
&\quad + f[x_0, x_1, x_2](x - x_0)(x - x_1) + \dots \\
&\quad + f[x_0, x_1, \dots, x_n](x - x_0)(x - x_1) \dots (x - x_{n-1}),
\end{aligned} \tag{5.3.6}$$

$$R_n(x) = f[x, x_0, \dots, x_n](x - x_0)(x - x_1) \dots (x - x_n), \tag{5.3.7}$$

则 (5.3.5) 式可写为

$$f(x) = N_n(x) + R_n(x).$$

由 $R_n(x_i) = 0$ ($i = 0, 1, \dots, n$) 可知, $N_n(x)$ 为满足插值条件 (5.3.4) 的 n 次插值多项式. 通常称 $N_n(x)$ 为 n 次牛顿插值多项式, $R_n(x)$ 为牛顿型插值余项.

由 §1 定理 1, 满足插值条件的插值多项式存在且惟一, 于是

$$N_n(x) = L_n(x).$$

进而当 $f(x)$ 在 (a, b) 上有 $n+1$ 阶导数时, 有

$$R_n(x) = R_n(x),$$

即

$$R_n(x) = f[x, x_0, \dots, x_n]_{n+1}(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega_{n+1}(x). \quad (5.3.8)$$

所以, 对列表函数或高阶导数不存在的函数, 其余项可由牛顿型插值余项给出.

由(5.3.8)式还可得

$$f[x, x_0, x_1, \dots, x_n] = \frac{f^{(n+1)}(\xi)}{(n+1)!}, \quad (a, b),$$

这就证明了差商的性质 3.

记 $N_k(x)$ 为具有节点 x_0, x_1, \dots, x_k 的牛顿插值多项式, 则具有节点 x_0, x_1, \dots, x_{k+1} 的牛顿插值多项式 $N_{k+1}(x)$ 可表为

$$N_{k+1}(x) = N_k(x) + f[x_0, x_1, \dots, x_{k+1}] \cdot (x - x_0)(x - x_1) \dots (x - x_k).$$

上式说明增加一个新节点 x_{k+1} , 只要在 $N_k(x)$ 的基础上, 增加计算

$$f[x_0, x_1, \dots, x_{k+1}](x - x_0)(x - x_1) \dots (x - x_k)$$

即可. 牛顿插值多项式的递推性给实用带来了方便.

实际计算时, 可借助于差商表 5-1, 牛顿插值多项式的各项系数就是表 5-1 中第一条斜线上对应的数值.

例 1 已知一组观察数据为

i	0	1	2	3
x_i	1	2	3	4
y_i	0	-5	-6	3

试用此组数据构造 3 次牛顿插值多项式 $N_3(x)$, 并计算 $N_3(1.5)$ 的值.

解 先按表 5-1 作出如下差商表.

x_i	y_i	一阶差商	二阶差商	三阶差商
1	0			
2	- 5	<u>- 5</u>	2	
3	- 6	- 1	5	<u>1</u>
4	3	9		

相应的牛顿插值多项式只需将表中第一条斜线上对应的数值 (划了一横线) 代入公式 (5.3.6) 即得

$$N_3(x) = 0 - 5(x - 1) + 2(x - 1)(x - 2) + (x - 1)(x - 2)(x - 3),$$

整理得

$$N_3(x) = x^3 - 4x^2 + 3,$$

$$N_3(1.5) = 1.5^3 - 4 \times 1.5^2 + 3 = - 2.65.$$

§ 4 差分与等距节点插值公式

上面讨论了节点任意分布的插值公式, 但实际应用时, 常采用等距节点, 这时插值公式可以进一步简化, 计算也简单得多. 由于节点是等距的, 所以函数的平均变化率与自变量的区间无关. 此时, 差商可用“差分”代替.

一、差分的定义及性质

定义 1 设函数 $y = f(x)$ 在等距节点 $x_i = x_0 + ih$ ($i = 0, 1, 2, \dots, n$) 上的值 $y_i = f(x_i)$ 为已知, 这里 $h = x_i - x_{i-1}$ 为常数, 称为步长, 记作

$$y_i = y_{i+1} - y_i, \tag{5.4.1}$$

$$\nabla y_i = y_i - y_{i-1}, \tag{5.4.2}$$

分别称为函数 $y = f(x)$ 在 x_i 处以 h 为步长的向前差分 and 向后差

分, 符号 Δ , ∇ 分别称为向前差分算符(或算子)和向后差分算符(或算子). 所谓算符, 可以理解为某种运算的符号记法.

与高阶差商可以由低阶差商来定义相类似, 高阶差分也可以通过对低阶差分再求差分来定义. 例如二阶差分可用以下方法得到

$$\begin{aligned}\Delta^2 y_i &= (\Delta y_i) = (y_{i+1} - y_i) - (y_i - y_{i-1}) = y_{i+1} - 2y_i + y_{i-1}, \\ \nabla^2 y_i &= \nabla(\nabla y_i) = \nabla(y_i - y_{i-1}) = (y_i - y_{i-1}) - (y_{i-1} - y_{i-2}) \\ &= y_i - 2y_{i-1} + y_{i-2},\end{aligned}$$

更高阶的差分可用同样方法递推得到. 一般地, $n-1$ 阶差分的差分称为 n 阶差分, 记作

$$\Delta^n y_i = \Delta^{n-1} y_{i+1} - \Delta^{n-1} y_i, \quad (5.4.3)$$

称为 $f(x)$ 在 x_i 处以 h 为步长的 n 阶向前差分.

差分的性质:

性质 1 各阶差分可用函数值线性表示为

$$\begin{aligned}\Delta^n y_i &= y_{n+i} - C_n^1 y_{n+i-1} + C_n^2 y_{n+i-2} - \dots + (-1)^k C_n^k y_{n+i-k} \\ &\quad + \dots + (-1)^n y_i,\end{aligned} \quad (5.4.4)$$

其中

$$C_n^k = \frac{n!}{k!(n-k)!} = \frac{n(n-1)\dots(n-k+1)}{k!}.$$

该性质由差分定义, 读者不难自证(留作习题).

性质 2 差分与差商满足下述关系:

$$f[x_0, x_1, \dots, x_k] = \frac{\Delta^k y_0}{k! h^k}, \quad k = 1, 2, \dots, n, \quad (5.4.5)$$

$$f[x_n, x_{n-1}, \dots, x_{n-k}] = \frac{\nabla^k y_n}{k! h^k}, \quad k = 1, 2, \dots, n. \quad (5.4.6)$$

证明 利用归纳法证明(5.4.5)式.

当 $k=1$ 时, 有 $f[x_0, x_1] = \frac{y_1 - y_0}{h}$, 结论成立.

设 $k=n-1$ 时, 结论亦成立, 即有

$$f[x_0, x_1, \dots, x_{n-1}] = \frac{{}^{n-1}y_0}{(n-1)!h^{n-1}},$$

$$f[x_1, x_2, \dots, x_n] = \frac{{}^{n-1}y_1}{(n-1)!h^{n-1}}.$$

则当 $k=n$ 时

$$\begin{aligned} f[x_0, x_1, \dots, x_n] &= \frac{f[x_1, x_2, \dots, x_n] - f[x_0, x_1, \dots, x_{n-1}]}{x_n - x_0} \\ &= \frac{{}^{n-1}y_1 - {}^{n-1}y_0}{(n-1)!h^{n-1} \cdot nh} = \frac{{}^ny_0}{n!h^n}, \end{aligned}$$

故(5.4.5)式成立(同理可证(5.4.6)式成立).

性质3 差分与导数满足关系

$${}^ny_0 = h^n f^{(n)}(\xi) \quad (\xi \in (x_0, x_n)). \quad (5.4.7)$$

证明 将(5.3.3)式与(5.4.5)式联立, 即得

$$f^{(n)}(\xi) = \frac{{}^ny_0}{h^n} \quad (\xi \in (a, b)),$$

故(5.4.7)式成立.

由(5.4.7)式可看出, 若 $f(x)$ 是一个 n 次多项式, 则它的 n 阶差分为常数. 因此, 如果一个列表函数的 n 阶差分已接近常数, 则用一个 n 次多项式去逼近它是恰当的.

为了应用方便, 计算差分可列差分表(见表 5-2).

表 5-2

x_i	y_i	y_i	2y_i	3y_i	4y_i
x_0	y_0				
x_1	y_1	y_0	2y_0		
x_2	y_2	y_1	2y_1	3y_0	
x_3	y_3	y_2	2y_2	3y_1	4y_0
x_4	y_4	y_3			

二、等距节点插值多项式及其余项

将牛顿差商插值多项式(5.3.6)中各阶差商用相应差分代替,

就可得到各种形式的等距节点插值公式. 这里只推导常用的前插与后插公式.

设给定等距节点 $x_i = x_0 + ih (i = 0, 1, 2, \dots, n)$ 后, 将差分与差商的关系式(5.4.5)代入牛顿插值多项式 $N_n(x)$ 即可得到

$$N_n(x) = f(x_0) + \frac{y_0}{h}(x - x_0) + \frac{^2y_0}{2!h^2}(x - x_0)(x - x_1) \\ + \dots + \frac{^ny_0}{n!h^n}(x - x_0)(x - x_1)\dots(x - x_{n-1}).$$

令 $x = x_0 + th, t > 0$, 则有

$$N_n(x_0 + th) = f(x_0) + t y_0 + \frac{t(t-1)}{2!} ^2y_0 + \dots \\ + \frac{t(t-1)\dots(t-n+1)}{n!} ^ny_0. \quad (5.4.8)$$

将差分与差商的关系式(5.4.5)代入牛顿型插值余项式(5.3.7)又得到

$$R_n(x_0 + th) = \frac{t(t-1)\dots(t-n)}{(n+1)!} h^{n+1} f^{(n+1)}(\xi) \\ (\xi \in (x_0, x_n)). \quad (5.4.9)$$

(5.4.8)式与(5.4.9)式分别称为牛顿向前插值多项式与牛顿向前插值多项式的余项.

具体计算时, 首先应根据数据表计算差分表, 然后按公式 $x = x_0 + th$, 求出 $t = (x - x_0)/h$ 的值, 再代入公式(5.4.8)计算, 公式中用到的各阶差分就是向前差分表上边第一条斜线上的对应值. 牛顿向前插值公式适用于计算 x_0 附近的函数值.

在非等距节点情形如果要求出接近 x_n 处函数 $y = f(x)$ 的近似值, 可以将公式(5.4.8)改为按插值节点 x_n, x_{n-1}, \dots, x_0 的次序排列的牛顿插值公式, 即

$$N_n(x) = f(x_n) + f[x_n, x_{n-1}](x - x_n) + \dots \\ + f[x_n, x_{n-1}, \dots, x_0](x - x_n)(x - x_{n-1})\dots(x - x_1). \quad (5.4.10)$$

节点若为等距时, 设 $x = x_{n-t}h$. 其中 $0 < t < 1$, 即 x 为靠近节点 x_n 的点, 于是有

$$\begin{aligned} & (x - x_n)(x - x_{n-1}) \dots (x - x_{n-i}) \\ &= (-1)^{i+1} t(t-1) \dots (t-i) h^{i+1}. \end{aligned} \quad (5.4.11)$$

将(5.4.6)和(5.4.11)代入公式(5.4.10), 得

$$\begin{aligned} N_n(x) &= y_n - t \nabla y_n + (-1)^2 \frac{t(t-1)}{2!} \nabla^2 y_n + \dots \\ &+ (-1)^n \frac{t(t-1) \dots (t-n+1)}{n!} \nabla^n y_n \\ &= \sum_{j=0}^n (-1)^j \frac{t(t-1) \dots (t-j+1)}{j!} \nabla^j y_n, \end{aligned} \quad (5.4.12)$$

公式(5.4.12)称为牛顿后插公式. 其中 $\nabla^j y_n (j = 0, 1, \dots, n)$, 可以用构造向后差分表的方法得到. 其构造法与向前差分表类同, 只是节点及相应函数值的排列次序不同而已.

若实际问题既要求出函数 $y = f(x)$ 靠近节点 x_0 处的近似值, 又要求出它靠近节点 x_n 处的近似值, 这时分别利用公式(5.4.8)和(5.4.12)就需要构造向前差分表和向后差分表. 能否利用一个差分表来完成以上两项工作呢? 回答是肯定的. 我们可以利用向前差分与向后差分的关系: $\nabla^j y_n = \delta^j y_{n-j}$, 将公式(5.4.12)改写成

$$\begin{aligned} N_n(x) &= y_n - t \delta y_{n-1} + \frac{t(t-1)}{2!} \delta^2 y_{n-2} + \dots \\ &+ (-1)^n \frac{t(t-1) \dots (t-n+1)}{n!} \delta^n y_0 \\ &= \sum_{j=0}^n (-1)^j \frac{t(t-1) \dots (t-j+1)}{j!} \delta^j y_{n-j}. \end{aligned} \quad (5.4.13)$$

公式(5.4.8)和(5.4.13)都只用到向前差分, 所以只需构造向前差分表, 公式(5.4.8)用表前部分, 公式(5.4.13)用表后部分, 所以分别称它们为表前公式和表后公式.

牛顿向后插值公式的余项为

$$R_n(x) = (-1)^{n+1} \frac{f^{(n+1)}(\xi)}{(n+1)!} h^{n+1} t(t-1)(t-2)\dots(t-n),$$

$$(x_0, x_n), \quad (5.4.14)$$

牛顿向后插值公式适用于计算函数表末端附近的函数值. 公式 (5.4.13) 中用到的各阶差分, 就是向前差分表最小斜行上的各对应值.

例 1 已知等距节点及相应点上的函数值如下表所示, 试求 $N_3(0.5)$ 及 $N_3(0.9)$ 的值.

i	0	1	2	3
x_i	0.4	0.6	0.8	1.0
y_i	1.5	1.8	2.2	2.8

解 先造向前差分表

i	x_i	y_i	Δy_i	$\Delta^2 y_i$	$\Delta^3 y_i$
0	0.4	<u>1.5</u>	<u>0.3</u>		
1	0.6	1.8	0.4	<u>0.1</u>	
2	0.8	2.2	<u>0.6</u>	<u>0.2</u>	<u>0.1</u>
3	1.0	<u>2.8</u>			

由题意, $x_0 = 0.4$, $h = 0.2$. 当 $x = 0.5$ 时,

$$t = \frac{x - x_0}{h} = \frac{0.5 - 0.4}{0.2} = 0.5.$$

将差分表上部那些画横线的数及 $t = 0.5$ 代入公式 (5.4.8) 得

$$N_3(0.5) = 1.5 + 0.5 \times 0.3 + \frac{0.5(-0.5)}{2} \times (0.1)$$

$$+ \frac{0.5(-0.5)(-1.5)}{6} \times (0.1)$$

$$= 1.64375.$$

当 $x = 0.9$ 时, $t = \frac{1.0 - 0.9}{h} = 0.5$. 将差分表中下部那些画横

线的数及 $t = 0.5$ 代入公式(5.4.13), 得

$$\begin{aligned} N_3(0.9) &= 2.8 - 0.5 \times 0.6 + \frac{1}{2}(0.5)(-0.5)(0.2) \\ &\quad - \frac{1}{6}(0.5)(-0.5)(-1.5)(0.1) \\ &= 2.46875. \end{aligned}$$

§ 5 埃尔米特(Hermite)插值

前面讨论的插值条件不包含导数条件, 而实际问题中有时不但要求在节点上函数值相等, 而且还要求插值函数的导数值与被插值函数的导数值在节点上也相等. 这种包含导数条件的插值多项式称为埃尔米特插值多项式.

一、一般情形的埃尔米特插值问题

一般情形的埃尔米特插值问题是指所满足的插值条件中, 函数值的个数与导数值的个数相等. 即当函数 $f(x)$ 在区间 $[a, b]$ 上 $n+1$ 个节点 x_i ($i = 0, 1, \dots, n$) 处的函数值 $f(x_i) = y_i$ 及导数值 $f'(x_i) = m_i$ 给定时, 要求一个次数不超过 $2n+1$ 的多项式 $H_{2n+1}(x)$, 使之满足

$$\begin{cases} H_{2n+1}(x_i) = y_i, \\ H'_{2n+1}(x_i) = m_i. \end{cases} \quad (i = 0, 1, \dots, n) \quad (5.5.1)$$

这里给出了 $2n+2$ 个插值条件, 可惟一确定一个形式为

$$H_{2n+1}(x) = a_0 + a_1x + \dots + a_{2n+1}x^{2n+1}$$

的多项式, 但是, 如果直接由条件(5.5.1)来确定 $2n+2$ 个系数 $a_0, a_1, \dots, a_{2n+1}$, 显然非常复杂. 所以, 我们仍借用构造拉格朗日插值多项式的基函数的方法来讨论.

设 $l_j(x), l'_j(x)$ ($j = 0, 1, \dots, n$) 为次数不超过 $2n+1$ 的多项式, 且满足

$$\begin{cases} l_j(x_i) = \delta_{ij}, & l_j(x_i) = 0, \\ l_j(x_i) = 0, & l_j(x_i) = \delta_{ij}. \end{cases} \quad (i, j = 0, 1, \dots, n) \quad (5.5.2)$$

则满足插值条件(5.5.1)的埃尔米特插值多项式可写成用插值基函数表示的形式

$$H_{2n+1}(x) = \sum_{j=0}^n [l_j^2(x) y_j + 2l_j(x) l_j'(x) m_j]. \quad (5.5.3)$$

由条件(5.5.2), 显然有

$$H_{2n+1}(x_i) = y_i, \quad H'_{2n+1}(x_i) = m_i \quad (i = 0, 1, \dots, n).$$

下面的问题就是求满足条件(5.5.2)的基函数 $l_j(x)$, $l_j'(x)$ ($j = 0, 1, \dots, n$). 为此, 仍借用构造拉格朗日插值多项式的基函数 $l_j(x)$ ($j = 0, 1, \dots, n$) 的方法进行.

由 $l_j(x_i) = 0$, $l_j'(x_i) = 0$ ($i \neq j$), 令

$$l_j(x) = (a_j x + b_j) [l_j(x)]^2,$$

其中 a_j, b_j 为待定常数. 由条件(5.5.2)在 $x = x_j$ 处有

$$\begin{cases} a_j x_j + b_j = 1, \\ a_j + 2(a_j x_j + b_j) l_j'(x_j) = 0, \end{cases}$$

解之得

$$a_j = -2l_j'(x_j) = -2 \sum_{\substack{k=0 \\ k \neq j}}^n \frac{1}{x_j - x_k},$$

$$b_j = 1 + 2x_j l_j'(x_j) = 1 + 2x_j \sum_{\substack{k=0 \\ k \neq j}}^n \frac{1}{x_j - x_k},$$

于是

$$l_j(x) = \left[1 - 2(x - x_j) \sum_{\substack{k=0 \\ k \neq j}}^n \frac{1}{x_j - x_k} \right] l_j^2(x) \quad (j = 0, 1, \dots, n). \quad (5.5.4)$$

类似地, 由 $l_j(x_i) = 0$, $l_j'(x_i) = 0$ ($i \neq j$), 令

$$l_j(x) = (c_j x + d_j) [l_j(x)]^2,$$

其中 c_j, d_j 为待定常数. 由条件(5.5.2), 在 $x = x_j$ 处有

$$\begin{cases} c_j x_j + d_j = 0, \\ c_j + 2(c_j x_j + d_j) l_j(x_j) = 1, \end{cases}$$

解之得 $c_j = 1, d_j = -x_j$. 于是

$$j(x) = (x - x_j) l_j^2(x) \quad (j = 0, 1, \dots, n). \quad (5.5.5)$$

将 $j(x), j(x)$ 代入(5.5.3)式得

$$\begin{aligned} H_{2n+1}(x) = & \sum_{j=0}^n \left[1 - 2(x - x_j) \sum_{\substack{k=0 \\ k \neq j}}^n \frac{1}{x_j - x_k} \right] l_j^2(x) y_j \\ & + \sum_{j=0}^n (x - x_j) l_j^2(x) m_j. \end{aligned} \quad (5.5.6)$$

在给出了埃尔米特插值多项式(5.5.6)后, 下面讨论它的惟一性. 为此, 假设另有一次数不高于 $2n+1$ 的多项式 $P_{2n+1}(x)$ 满足条件(5.5.1), 则

$$(x) = H_{2n+1}(x) - P_{2n+1}(x)$$

是次数不高于 $2n+1$ 的多项式, 且以节点 x_i ($i = 0, 1, \dots, n$) 为二重零点, 即 (x) 至少有 $2n+2$ 个零点. 从而必有 $(x) \equiv 0$, 即

$$H_{2n+1}(x) = P_{2n+1}(x).$$

仿拉格朗日插值余项的讨论方法, 可得出埃尔米特插值多项式的插值余项.

定理 1 若 $f(x)$ 在 $[a, b]$ 上存在 $2n+2$ 阶导数, 则其插值余项

$$R_{2n+1}(x) = f(x) - H_{2n+1}(x) = \frac{f^{(2n+2)}(\xi)}{(2n+2)!} \omega_{n+1}^2(x), \quad (5.5.7)$$

式中 $\xi \in (a, b)$ 且与 x 有关.

埃尔米特插值的几何意义是, 曲线 $y = H_{2n+1}(x)$ 与曲线 $y = f(x)$ 在插值节点处有公共切线.

作为埃尔米特插值多项式(5.5.6)的重要特例是 $n=1$ 的情形. 这时次数不高于 3 的埃尔米特插值多项式 $H_3(x)$ 满足条件

$$H_3(x_0) = y_0, \quad H_3(x_1) = y_1;$$

$$H_3(x_0) = m_0, \quad H_3(x_1) = m_1.$$

由(5.5.4)式与(5.5.5)式可得

$$l_0(x) = \left[1 - 2 \frac{x - x_0}{x_0 - x_1} \right] \left[\frac{x - x_1}{x_0 - x_1} \right]^2,$$

$$l_1(x) = \left[1 - 2 \frac{x - x_1}{x_1 - x_0} \right] \left[\frac{x - x_0}{x_1 - x_0} \right]^2,$$

$$h_0(x) = (x - x_0) \left[\frac{x - x_1}{x_0 - x_1} \right]^2,$$

$$h_1(x) = (x - x_1) \left[\frac{x - x_0}{x_1 - x_0} \right]^2,$$

于是

$$\begin{aligned} H_3(x) &= \sum_{j=0}^1 l_j(x) y_j + \sum_{j=0}^1 l_j(x) m_j \\ &= y_0 \left[1 - 2 \frac{x - x_0}{x_0 - x_1} \right] l_0^2(x) + y_1 \left[1 - 2 \frac{x - x_1}{x_1 - x_0} \right] l_1^2(x) \\ &\quad + m_0 (x - x_0) l_0^2(x) + m_1 (x - x_1) l_1^2(x). \end{aligned} \quad (5.5.8)$$

二、特殊情形的埃尔米特插值问题

在带导数的插值问题中,有时插值条件中的函数值个数与导数值个数不等.这时可以牛顿插值多项式或一般情况的埃尔米特插值多项式为基础,运用待定系数法求出满足插值条件的多项式.以下举例说明这种方法的基本思路.

设给定函数表如下:

x	x_0	x_1	x_2
$f(x)$	y_0	y_1	y_2
$f'(x)$	m_0	m_1	

求次数不高于 4 的多项式 $H_4(x)$, 使之满足

$$\begin{cases} H_4(x_i) = y_i & (i = 0, 1, 2), \\ H_4'(x_i) = m_i & (i = 0, 1). \end{cases}$$

若以牛顿插值多项式为基础, 可设

$$\begin{aligned}H_4(x) = & y_0 + f[x_0, x_1](x - x_0) \\& + f[x_0, x_1, x_2](x - x_0)(x - x_1) \\& + (Ax + B)(x - x_0)(x - x_1)(x - x_2),\end{aligned}$$

其中 A, B 为待定常数. 显然

$$H_4(x_i) = y_i \quad (i = 0, 1, 2),$$

通过条件 $H_4(x_i) = m_i \quad (i = 0, 1)$, 求得常数 A, B 后, 即可得 $H_4(x)$.

若以埃尔米特插值多项式为基础, 可设

$$H_4(x) = H_3(x) + C(x - x_0)^2(x - x_1)^2,$$

其中 C 为待定常数, $H_3(x)$ 为满足条件 $H_3(x_i) = y_i$, $H_3'(x_i) = m_i$ ($i = 0, 1$) 的次数不高于 3 的埃尔米特插值多项式, 其具体表达式见(5.5.8)式. 显然

$$H_4(x_i) = y_i, \quad H_4'(x_i) = m_i \quad (i = 0, 1),$$

通过条件 $H_4(x_2) = y_2$ 求得 C 后, 即可得 $H_4(x)$.

对于函数值个数与导数值个数不等的带导数插值问题, 可以类似于一般的埃尔米特插值问题得到其插值多项式的惟一性及插值余项的表达式.

§ 6 三次样条插值

在工程技术问题中, 如飞机机翼设计和船体放样, 常要求插值曲线不仅连续而且处处光滑. 而在整个插值区间上作高次插值多项式, 虽然可以保证曲线光滑, 但却存在计算量大、误差积累严重、计算稳定性差等缺点. 分段线性插值与分段二次插值可以避免上述缺点, 但在各段连接点处只能保证曲线连续而不能保证光滑性要求, 埃尔米特插值虽能保持各节点处都是光滑衔接的, 但它要以已知节点导数值为条件, 这在实际中一般是很难满足的. 为了克服

尖角问题, 需要采用一种新的方法——样条插值法.

样条这一名词来源于工程中的样条曲线. 在工程中绘图员为了将一些指定点(称为样点)联结成一条光滑曲线, 往往用富有弹性的细长木条(样条)把相邻的几点连接起来, 再逐步延伸连接起全部节点, 使之形成一条光滑曲线, 称为样条曲线. 它实际上是由分段三次多项式曲线连接而成, 在连接点即样点上有直到二阶连续导数, 即它在连接点处具有连续曲率. 从数学上加以概括就得到所谓样条插值问题. 下面首先介绍样条函数的定义.

一、三次样条插值函数的定义

定义 1 在区间 $[a, b]$ 上取 $n+1$ 个节点

$$a = x_0 < x_1 < x_2 < \dots < x_{n-1} < x_n = b,$$

若函数 $S(x)$ 满足条件:

- (1) $S(x)$ 在整个区间 $[a, b]$ 上具有二阶连续导数;
- (2) 在每个小区间 $[x_{i-1}, x_i]$ ($i = 1, 2, \dots, n$) 上是 x 的三次多项式;
- (3) 在节点 x_i 处给定函数值 $y_i = f(x_i)$ 且

$$S(x_i) = y_i, \quad i = 0, 1, 2, \dots, n, \quad (5.6.1)$$

则称 $S(x)$ 为 $f(x)$ 的三次样条插值函数.

要确定 $S(x)$, 在每个小区间上要确定 4 个待定系数, 一共有 n 个小区间, 故应确定 $4n$ 个系数. 由于 $S(x)$ 在 $[a, b]$ 上具有二阶导数, 在内节点 x_1, x_2, \dots, x_{n-1} 处应满足 $3n-3$ 个连续性条件

$$\begin{cases} S(x_i - 0) = S(x_i + 0), \\ S'(x_i - 0) = S'(x_i + 0), \quad (i = 1, 2, \dots, n-1) \\ S''(x_i - 0) = S''(x_i + 0). \end{cases}$$

再加上 $S(x)$ 满足的插值条件(5.6.1), 共有 $4n-2$ 个条件, 因此还需要 2 个条件才能确定 $S(x)$. 通常可在区间 $[a, b]$ 端点上补充两个边界条件. 常见的边界条件如下:

- (1) 给定两端点处的一阶导数值, 记为

$$S(x_0) = m_0, \quad S(x_n) = m_n. \quad (5.6.2)$$

(2) 给定两端点处的二阶导数值, 记为

$$S(x_0) = M_0, \quad S(x_n) = M_n. \quad (5.6.3)$$

对于

$$S(x_0) = S(x_n) = 0 \quad (5.6.4)$$

的边界条件特别称之为自然边界条件.

二、三次样条插值函数的构造

构造三次样条插值函数, 就是要写出它在子区间 $[x_{i-1}, x_i]$ ($i=1, 2, \dots, n$) 上的表达式, 记为 $S_i(x)$ ($i=1, 2, \dots, n$).

(1) 用节点处一阶导数表示的三次样条插值函数

记节点处的一阶导数值为 $S'(x_i) = m_i$ ($i=0, 1, \dots, n$), 若已知 m_i 后, 则 $S(x)$ 在 $[x_{i-1}, x_i]$ ($i=1, 2, \dots, n$) 上就是满足条件

$$S(x_{i-1}) = y_{i-1}, \quad S(x_i) = y_i,$$

$$S'(x_{i-1}) = m_{i-1}, \quad S'(x_i) = m_i \quad (i=1, 2, \dots, n)$$

的三次埃尔米特插值多项式. 所以构造以节点处一阶导数表示的三次样条函数可分为以下三步:

第一步 根据 $S(x)$, $S'(x)$ 在内节点的连续性及插值条件, 运用 $[x_{i-1}, x_i]$ 上的二点三次埃尔米特插值多项式, 写出 $S(x)$ 用 m_i ($i=0, 1, \dots, n$) 表示的形式;

第二步 利用 $S(x)$ 在内节点 x_i ($i=1, 2, \dots, n-1$) 的连续性 & 边界条件, 导出含 m_i ($i=0, 1, \dots, n$) 的 $n+1$ 阶线性方程组;

第三步 求解含 m_i ($i=0, 1, \dots, n$) 的线性方程组, 将得到的 m_i 代入 $[x_{i-1}, x_i]$ 上的二点三次埃尔米特插值多项式, 即得到以节点处一阶导数表示的三次样条插值函数.

下面建立具体公式. 由(5.5.8)式可知,

$$S_i(x) = \left[1 + 2 \frac{x - x_{i-1}}{x_i - x_{i-1}} \right] \left[\frac{x - x_i}{x_i - x_{i-1}} \right]^2 y_{i-1}$$

$$\begin{aligned}
& + \left[1 + 2 \frac{x - x_i}{x_{i-1} - x_i} \right] \left(\frac{x - x_{i-1}}{x_i - x_{i-1}} \right)^2 y_i \\
& + (x - x_i) \left(\frac{x - x_i}{x_{i-1} - x_i} \right)^2 m_{i-1} \\
& + (x - x_i) \left(\frac{x - x_{i-1}}{x_i - x_{i-1}} \right)^2 m_i.
\end{aligned} \tag{5.6.5}$$

记 $h_i = x_i - x_{i-1}$, (5.6.5) 式可写为

$$\begin{aligned}
S_i(x) = & \frac{(x - x_i)^2 [h_i + 2(x - x_{i-1})]}{h_i^3} y_{i-1} \\
& + \frac{(x - x_{i-1})^2 [h_i + 2(x_i - x)]}{h_i^3} y_i \\
& + \frac{(x - x_i)^2 (x - x_{i-1})}{h_i^2} m_{i-1} \\
& + \frac{(x - x_{i-1})^2 (x - x_i)}{h_i^2} m_i,
\end{aligned} \tag{5.6.6}$$

式中 $x \in [x_{i-1}, x_i]$ ($i = 1, 2, \dots, n$).

为了确定 m_i , 需要用到 $S(x)$ 的二阶导数在内节点连续的条件, 由(5.6.6)式可得 $S(x)$ 在 $[x_{i-1}, x_i]$ 上的二阶导数

$$\begin{aligned}
S_i(x) = & \frac{6x - 2x_{i-1} - 4x_i}{h_i^2} m_{i-1} + \frac{6x - 4x_{i-1} - 2x_i}{h_i^2} m_i \\
& + \frac{6(x_{i-1} + x_i - 2x)}{h_i^3} (y_i - y_{i-1}) \quad (x \in [x_{i-1}, x_i]).
\end{aligned} \tag{5.6.7}$$

同理可得 $S(x)$ 在 $[x_i, x_{i+1}]$ 上的二阶导数

$$\begin{aligned}
S_{i+1}(x) = & \frac{6x - 2x_i - 4x_{i+1}}{h_{i+1}^2} m_i + \frac{6x - 4x_i - 2x_{i+1}}{h_{i+1}^2} m_{i+1} \\
& + \frac{6(x_i + x_{i+1} - 2x)}{h_{i+1}^3} (y_{i+1} - y_i) \quad (x \in [x_i, x_{i+1}]),
\end{aligned} \tag{5.6.8}$$

从而

$$S(x_{i-0}) = \frac{2}{h_i}m_{i-1} + \frac{4}{h_i}m_i - \frac{6}{h_i^2}(y_i - y_{i-1}),$$

$$S(x_{i+0}) = \frac{4}{h_{i+1}}m_i - \frac{2}{h_{i+1}}m_{i+1} + \frac{6}{h_{i+1}^2}(y_{i+1} - y_i).$$

由 $S(x)$ 在 x_i 处连续的条件 $S(x_{i-0}) = S(x_{i+0})$ 可得

$$\begin{aligned} \frac{1}{h_i}m_{i-1} + 2\left[\frac{1}{h_i} + \frac{1}{h_{i+1}}\right]m_i + \frac{1}{h_{i+1}}m_{i+1} \\ = 3\left[\frac{y_{i+1} - y_i}{h_{i+1}^2} + \frac{y_i - y_{i-1}}{h_i^2}\right]. \end{aligned}$$

上式两端同除以 $\frac{1}{h_i} + \frac{1}{h_{i+1}}$, 得

$$\begin{aligned} \frac{h_{i+1}}{h_i + h_{i+1}}m_{i-1} + 2m_i + \frac{h_i}{h_i + h_{i+1}}m_{i+1} \\ = 3\left[\frac{h_i}{h_i + h_{i+1}} \cdot \frac{y_{i+1} - y_i}{h_{i+1}^2} + \frac{h_{i+1}}{h_i + h_{i+1}} \cdot \frac{y_i - y_{i-1}}{h_i^2}\right]. \end{aligned} \quad (5.6.9)$$

引入记号

$$\left. \begin{aligned} \alpha_i &= \frac{h_{i+1}}{h_i + h_{i+1}}, \\ M_i &= 1 - \alpha_i = \frac{h_i}{h_i + h_{i+1}}, \\ f_i &= 3\left[M_i \frac{y_{i+1} - y_i}{h_{i+1}^2} + \alpha_i \frac{y_i - y_{i-1}}{h_i^2}\right], \end{aligned} \right\} \quad (i = 1, 2, \dots, n-1)$$

(5.6.10)

则(5.6.9)式可写成

$$\alpha_i m_{i-1} + 2m_i + M_i m_{i+1} = f_i \quad (i = 1, 2, \dots, n-1). \quad (5.6.11)$$

(5.6.11) 式是含有 $n+1$ 个未知数 m_i ($i=0, 1, \dots, n$) 的 $n-1$ 阶线性方程组. 要完全确定 $n+1$ 个未知数的值, 还需用到两个边界条件.

1) 对第一种边界条件

$$S(x_0) = m_0, \quad S(x_n) = m_n.$$

在方程组(5.6.11)中将已知边界条件代入, 则其可改写为只含 $n-1$ 个未知数的线性方程组

$$\begin{bmatrix} 2 & M_1 & & & \\ & 2 & M_2 & & \\ & & W & W & W \\ & & & n-2 & 2 & M_{n-2} \\ & & & & n-1 & 2 \end{bmatrix} \begin{bmatrix} m_1 \\ m_2 \\ \\ m_{n-2} \\ m_{n-1} \end{bmatrix} = \begin{bmatrix} f_1 - m_0 \\ f_2 \\ \\ f_{n-2} \\ f_{n-1} - M_{n-1}m_n \end{bmatrix}. \quad (5.6.12)$$

2) 对第二种边界条件

$$S(x_0) = M_0, \quad S(x_n) = M_n.$$

根据(5.6.8)式得

$$S_1(x) = \frac{6x - 2x_0 - 4x_1}{h_1^2}m_0 + \frac{6x - 4x_0 - 2x_1}{h_1^2}m_1 \\ + \frac{6(x_0 + x_1 - 2x)}{h_1^3}(y_1 - y_0) \quad (x \in [x_0, x_1]),$$

由 $S(x_0) = M_0$ 得

$$2m_0 + m_1 = \frac{3}{h_1}(y_1 - y_0) - \frac{h_1}{2}M_0.$$

同理, 由 $S(x_n) = M_n$ 得

$$m_{n-1} + 2m_n = \frac{3}{h_n}(y_n - y_{n-1}) + \frac{h_n}{2}M_n.$$

将上述边界点的方程与内节点的方程组(5.6.11)联立, 即可得到关于 m_0, m_1, \dots, m_n 的 $n+1$ 阶线性方程组

$$\begin{bmatrix} 2 & 1 & & & \\ & 1 & 2 & M_1 & \\ & & 2 & 2 & M_2 \\ & & & W & W & W \\ & & & & n-1 & 2 & M_{n-1} \\ & & & & & 1 & 2 \end{bmatrix} \begin{bmatrix} m_0 \\ m_1 \\ m_2 \\ \\ m_{n-1} \\ m_n \end{bmatrix} = \begin{bmatrix} f_0 \\ f_1 \\ f_2 \\ \\ f_{n-1} \\ f_n \end{bmatrix}, \quad (5.6.13)$$

$$\begin{cases} f_0 = 3 \frac{y_1 - y_0}{h_1} - \frac{h_1}{2} M_0, \\ f_n = 3 \frac{y_n - y_{n-1}}{h_n} + \frac{h_n}{2} M_n. \end{cases} \quad (5.6.14)$$

方程组(5.6.12)、(5.6.13)均为三对角方程组,其系数矩阵为严格对角占优阵(系数矩阵的对角元素按模严格大于同一行非对角元素的模之和).对于这种三对角方程组可证明其行列式不等于零,因此方程组有惟一确定的解,其求解方法通常采用第二章的追赶法.

例 1 给出函数表:

x_i	0	1	2	3
$f(x_i)$	0	3	4	6
$f'(x_i)$	1			0

试求 $f(x)$ 在区间 $[0, 3]$ 上的三次样条插值函数.

解 令 $m_0 = f'(0) = 1, m_3 = f'(3) = 0$. 在(5.6.10)式中取 $h_i = 1 (i = 1, 2, 3)$, 有

$$i = M_i = \frac{1}{2} \quad (i = 1, 2),$$

$$f_1 = 3 \left[\frac{1}{2}(f(1) - f(0)) + \frac{1}{2}(f(2) - f(1)) \right] = 6,$$

$$f_2 = 3 \left[\frac{1}{2}(f(2) - f(1)) + \frac{1}{2}(f(3) - f(2)) \right] = \frac{9}{2}.$$

由(5.6.12)得

$$\begin{bmatrix} 2 & \frac{1}{2} \\ \frac{1}{2} & 2 \end{bmatrix} \begin{bmatrix} m_1 \\ m_2 \end{bmatrix} = \begin{bmatrix} 6 - \frac{1}{2} \\ \frac{9}{2} \end{bmatrix},$$

解之得 $m_1 = \frac{7}{3}, m_2 = \frac{5}{3}$.

从而由 $S_i(x)$ 的表达式(5.6.6), 三次样条插值函数为

$$S_1(x) = 3[1 + 2(1 - x)]x^2 + x(x - 1)^2 + \frac{7}{3}x^2(x - 1) \quad (x \in [0, 1]),$$

$$S_2(x) = 3(2x - 1)(x - 2)^2 + 4(5 - 2x)(x - 1)^2 + \frac{7}{3}(x - 1)(x - 2)^2 + \frac{5}{3}(x - 2)(x - 1)^2 \quad (x \in [1, 2]),$$

$$S_3(x) = 4(2x - 3)(x - 3)^2 + 6(7 - 2x)(x - 2)^2 + \frac{5}{3}(x - 3)(x - 2)^2 \quad (x \in [2, 3]).$$

(2) 用节点处二阶导数表示的三次样条插值函数

记节点处的二阶导数值为

$$S''(x_i) = M_i \quad (i = 0, 1, \dots, n).$$

由于 $S''(x)$ 在 $[x_{i-1}, x_i]$ ($i = 1, 2, \dots, n$) 上是 x 的线性函数, 因此构造以节点处二阶导数表示的三次样条插值函数可分为以下三步:

第一步 根据 $S''(x)$ 在内节点的连续性及为线性函数的特点, 将 $S''(x)$ 表示为线性函数. 再根据 $S''(x)$ 在内节点的连续性及插值条件, 写出 $S''(x)$ 用 M_i ($i = 0, 1, \dots, n$) 表示的形式.

第二步 利用 $S''(x)$ 在内节点 x_i ($i = 1, 2, \dots, n-1$) 的连续性 & 边界条件, 导出含 M_i ($i = 0, 1, \dots, n$) 的 $n+1$ 阶线性方程组.

第三步 求解含 M_i ($i = 0, 1, \dots, n$) 的线性方程组, 将得到的 M_i 代入 $[x_{i-1}, x_i]$ 上 $S''(x)$ 的表达式, 即得到以节点处二阶导数表示的三次样条插值函数.

下面建立具体公式. 由定义可知, $S''(x)$ 在子区间 $[x_{i-1}, x_i]$ ($i = 1, 2, \dots, n$) 上是三次多项式, 因此 $S''(x)$ 在 $[x_{i-1}, x_i]$ 上是 x 的线性函数. 假定 $S''(x_{i-1}) = M_{i-1}$, $S''(x_i) = M_i$, 则由线性插值有

$$S''_i(x) = \frac{x - x_i}{x_{i-1} - x_i} M_{i-1} + \frac{x - x_{i-1}}{x_i - x_{i-1}} M_i \quad (x \in [x_{i-1}, x_i]).$$

对上式积分两次, 且用插值条件

$$S_i(x_{i-1}) = y_{i-1}, \quad S_i(x_i) = y_i$$

确定其中的两个积分常数, 即可得出用 M_i 表示的三次样条插值函数

$$S_i(x) = \frac{(x_i - x)^3}{6h_i} M_{i-1} + \frac{(x - x_{i-1})^3}{6h_i} M_i + \left[y_{i-1} - \frac{M_{i-1}}{6} h_i^2 \right] \frac{x_i - x}{h_i} + \left[y_i - \frac{M_i}{6} h_i^2 \right] \frac{x - x_{i-1}}{h_i}, \quad (5.6.15)$$

式中 $x \in [x_{i-1}, x_i]$, $h_i = x_i - x_{i-1}$ ($i = 1, 2, \dots, n$).

由 (5.6.15) 式可求得 $S_i(x)$ 在 $[x_{i-1}, x_i]$ 上的表达式, 且类似可得 $S_{i+1}(x)$ 在 $[x_i, x_{i+1}]$ 上的表达式. 利用 $S(x)$ 在内节点 x_i ($i = 1, 2, \dots, n-1$) 处连续的条件, 即

$$S_i(x_i - 0) = S_{i+1}(x_i + 0),$$

则可得线性方程组

$$M_i M_{i-1} + 2M_i + M_{i+1} = f_i \quad (i = 1, 2, \dots, n-1). \quad (5.6.16)$$

式中

$$\left. \begin{aligned} M_i &= \frac{h_i}{h_i + h_{i+1}}, \\ 1 - M_i &= \frac{h_{i+1}}{h_i + h_{i+1}}, \\ f_i &= \frac{6}{h_i + h_{i+1}} \left[\frac{y_{i+1} - y_i}{h_{i+1}} - \frac{y_i - y_{i-1}}{h_i} \right], \end{aligned} \right\} \quad (i = 1, 2, \dots, n-1) \quad (5.6.17)$$

(5.6.17) 式是含有 $n+1$ 个未知数 M_0, M_1, \dots, M_n 的 $n-1$ 阶线性方程组. 要确定 $n+1$ 个未知数的值, 还须用到两个边界条件.

1) 对第一种边界条件

$$S(x_0) = m_0, \quad S(x_n) = m_n.$$

由 $S(x_0) = m_0$ 与 $S(x_n) = m_n$ 可得

$$2M_0 + M_1 = \frac{6}{h_1} \left[\frac{y_1 - y_0}{h_1} - m_0 \right],$$

$$M_{n-1} + 2M_n = \frac{6}{h_n} \left[m_n - \frac{y_n - y_{n-1}}{h_n} \right].$$

将上述边界点的方程与内节点的方程(5.6.16)联立,即可得关于 M_0, M_1, \dots, M_n 的线性方程组

$$\begin{bmatrix} 2 & 1 & & & \\ M_1 & 2 & & & \\ & W & W & W & \\ & & M_{n-1} & 2 & \\ & & & 1 & 2 \end{bmatrix} \begin{bmatrix} M_0 \\ M_1 \\ \\ M_{n-1} \\ M_n \end{bmatrix} = \begin{bmatrix} f_0 \\ f_1 \\ \\ f_{n-1} \\ f_n \end{bmatrix}, \quad (5.6.18)$$

式中

$$\begin{cases} f_0 = \frac{6}{h_1} \left[\frac{y_1 - y_0}{h_1} - m_0 \right], \\ f_n = \frac{6}{h_n} \left[m_n - \frac{y_n - y_{n-1}}{h_n} \right]. \end{cases} \quad (5.6.19)$$

2) 对第二种边界条件

$$S(x_0) = M_0, \quad S(x_n) = M_n.$$

在方程组(5.6.16)中将已知边界条件代入,则方程组(5.6.16)可改写为只含 $n-1$ 个未知数 M_1, M_2, \dots, M_{n-1} 的 $n-1$ 阶线性方程组

$$\begin{bmatrix} 2 & 1 & & & \\ M_2 & 2 & & & \\ & W & W & W & \\ & & M_{n-2} & 2 & \\ & & & M_{n-1} & 2 \end{bmatrix} \begin{bmatrix} M_1 \\ M_2 \\ \\ M_{n-2} \\ M_{n-1} \end{bmatrix} = \begin{bmatrix} f_1 - M_1 M_0 \\ f_2 \\ \\ f_{n-2} \\ f_{n-1} - M_{n-1} M_n \end{bmatrix}. \quad (5.6.20)$$

方程组(5.6.18), (5.6.20)均为三对角方程组,可用追赶法求其惟一解.

对于三次样条插值函数来说,当插值节点逐渐加密时,可以证

明:不但样条插值函数收敛于函数本身,而且其导数也收敛于函数的导数.正因如此,三次样条插值函数在实际中得到了广泛的应用.

本章小结

插值法是函数逼近的一种重要方法,它是数值微积分、微分方程数值解等数值计算的基础与工具.由于多项式具有形式简单,计算方便等许多优点,故本章主要介绍多项式插值,它是插值法中最常用和最基本的方法.

拉格朗日插值多项式的优点是表达式简单明确,形式对称,便于记忆.它的缺点是如果要想增加插值节点,公式必须整个改变,这就增加了计算工作量.而牛顿插值多项式对此作了改进,当增加一个节点时只需在原牛顿插值多项式基础上增加一项,此时原有的项无需改变,从而达到节省计算次数、节约存储单元、应用较少节点达到应有精度的目的.在等距节点条件下,利用差分型的牛顿前插或后插公式可以简化计算.

由于高次插值多项式具有数值不稳定的缺点(如龙格现象),高次插值多项式的效果并非一定比低次插值好,所以当区间较大、节点较多时,常用分段低次插值,如分段线性插值和分段二次插值.由于分段插值是局部化的,即每个节点只影响附近少数几个间距,从而带来了计算上的方便,可以步进地进行插值计算.同时也带来了内在的高度稳定性和较好的收敛性,因此它是计算机上常用的一种算法.分段插值的缺点是不能保证曲线在连接点处的光滑性.

为了保证插值曲线在节点处不仅连续而且光滑,可用样条插值方法.三次样条插值法是最常用的方法,它在整个插值区间上可保证具有直到二阶导数的连续性.用它来求数值微分、微分方程数值解等,都能起到良好效果.

算法与程序设计实例

用拉格朗日插值多项式求函数近似值.

算法

(1) 输入 x_i, y_i ($i=0, 1, 2, \dots, n$), 令 $L_n(x)=0$;

(2) 对 $i=0, 1, 2, \dots, n$, 计算

$$l_i(x) = \prod_{\substack{j=0 \\ j \neq i}}^n \frac{x - x_j}{x_i - x_j},$$
$$L_n(x) = L_n(x) + l_i(x)y_i.$$

实例

例 1 已知函数表

x_i	0.56160	0.56280	0.56401	0.56521
y_i	0.82741	0.82659	0.82577	0.82495

用三次拉格朗日插值多项式求 $x=0.5635$ 时的函数近似值.

程序和输出结果

```
# include <stdio.h>
# include <conio.h>
# include <alloc.h>

float Lagrange(float * x, float * y, float xx, int n)
{
    int i, j;
    float * a, yy= 0.0
    a= (float * ) malloc(n* sizeof(float))
    for(i= 0; i<= n- 1; i++ )
    {
        a[i]= y[i];
```

```

        for(j= 0;j< = n- 1;j+ + )
            if(j!= i) a[i]* = (xx- x[j])/(x[i]- x[j]);
        yy+ = a[i];
    }
    free(a);
    return yy;
}

void main()
{
    float x[ 4]= {0. 56160, 0. 56280, 0. 56401, 0. 56521};
    float y[ 4]= {0. 82741, 0. 82659, 0. 82577, 0. 82495};
    float xx= 0. 5635, yy;
    float Lagrange(float * , float * , float, int);
    yy= Lagrange(x, y, xx, 4);
    clrscr();
    printf( x= %f, y= %f\n , xx, yy)
    getch();
}

```

输出结果如下:

$x = 0.563500, \quad y = 0.826116$

用牛顿插值多项式求函数近似值.

算法

(1) 输入 $n, x_i, y_i \ (i= 0, 1, 2, \dots, n)$;

(2) 对 $k= 1, 2, 3, \dots, n, \ i= 1, 2, \dots, k$ 计算函数 $f(x)$ 的各阶差商 $f[x_0, x_1, \dots, x_k]$;

(3) 计算函数值

$$N_n(x) = f(x_0) + f[x_0, x_1](x - x_0) + \dots$$

$$+ f[x_0, x_1, \dots, x_n](x - x_0)(x - x_1) \dots (x - x_{n-1}).$$

实例

例 2 已知函数表

x_i	0.4	0.55	0.65	0.8	0.9
y_i	0.41075	0.57815	0.69675	0.88811	1.02652

用牛顿插值多项式求 $N_n(0.596)$ 和 $N_n(0.895)$.

程序和输出结果

```
# include <stdio.h>
# include <conio.h>
# include <alloc.h>
# define N 4

void Difference(float * x, float * y, int n)
{
    float * f;
    int k, i;
    f = (float *) malloc(n * sizeof(float));
    for(k = 1; k <= n; k++)
    {
        f[0] = y[k];
        for(i = 0; i < k; i++)
            f[i+1] = (f[i] - y[i]) / (x[k] - x[i]);
        y[k] = f[k];
    }
    return;
}

main()
{
```

```

int i;
float varx= 0. 895, b;
float x[N+ 1]= {0. 4, 0. 55, 0. 65, 0. 8, 0. 9};
float y[N+ 1]= {0. 41075, 0. 57815, 0. 69675, 0. 88811,
                1. 02652};
Difference(x, (float *)y, N);
clrscr();
b= y[ N];
for(i= N- 1; i> = 0; i- - )b= b* (varx- x[i])+ y[i];
printf( "NInterp(% f)= % f , varx, b);
getch();
}

```

输出结果如下:

$$N_n(0.596) = 0.631918 \quad N_n(0.895) = 1.019368$$

思 考 题

1. 何谓插值函数、插值多项式、插值余项?
2. 插值多项式系数 a_0, a_1, \dots, a_n 满足的线性方程组, 其系数矩阵的行列式为什么不为零?
3. 插值多项式的存在惟一性有何意义?
4. 拉格朗日插值多项式是怎样构造的? 截断误差如何表示? 如何估计?
5. 何谓拉格朗日插值基函数? 为什么说它也是插值多项式? 怎样表示?
6. 分段插值主要有哪几种常用公式? 它的优点如何?
7. 何谓差商? 怎样构造差商表? 牛顿插值多项式形式如何? 系数怎样确定? 误差怎样表示?

8. 差分和差商有何关系? 在什么情况下可以构造差分型牛顿插值多项式?

9. 在插值区间上, 随着节点的增多, 插值多项式是否越来越接近被插函数? 在插值节点及其附近, 插值多项式的导数是否接近被插函数?

10. 何谓样条插值函数? 样条插值比之于前面几种插值公式有何优点? 怎样构造三次样条插值函数?

习 题 五

1. 当 $x = 1, -1, 2$ 时, $f(x) = 0, -3, 4$, 求 $f(x)$ 的二次插值多项式.

2. 已知函数 $y = f(x)$ 的观察值如下:

i	0	1	2	3
x_i	0	1	2	3
y_i	2	3	0	-1

试求其拉格朗日插值多项式.

3. 已知函数表:

x	1.1275	1.1503	1.1735	1.1972
$y = f(x)$	0.1191	0.13954	0.15932	0.17903

应用拉格朗日插值公式计算 $f(1.1300)$ 的近似值(计算取 4 位小数).

4. 设 $x_i (i = 0, 1, 2, \dots, n)$ 为互异节点, 试证明拉格朗日插值基函数 $l_i(x)$ 具有以下性质:

$$(1) \sum_{i=0}^n l_i(x) = 1;$$

$$(2) \sum_{i=0}^n x_i^k l_i(x) = x^k, \quad k=0, 1, 2, \dots, n.$$

5. 设 $f(x)$ 在 $[a, b]$ 上具有二阶连续导数, 且 $f(a) = f(b) = 0$, 证明

$$\max_{a \leq x \leq b} f(x) \leq \frac{1}{8}(b-a)^2 \max_{a \leq x \leq b} f''(x).$$

6. 已知函数表

x	1.2	1.3	1.4	1.5	1.6	1.7
y = f(x)	1.244	1.406	1.602	1.837	2.121	2.465

用二次插值求 $f(1.54)$ 的近似值(计算取 5 位小数).

7. 用拉格朗日插值和牛顿插值找经过点 $(-3, -1), (0, 2), (3, -2), (6, 10)$ 的三次插值多项式, 并验证插值多项式的惟一性.

8. 利用函数表

x	1.615	1.634	1.702	1.828	1.921
y = f(x)	2.41450	2.46459	2.65271	3.03035	3.34066

造出差商表, 并利用牛顿插值公式计算 $f(x)$ 在 $x = 1.682, 1.813$ 处的近似值(计算取 5 位小数).

9. 证明 n 阶差商有下列性质:

(1) 若 $F(x) = Cf(x)$, 则

$$F[x_0, x_1, \dots, x_n] = Cf[x_0, x_1, \dots, x_n];$$

(2) 若 $F(x) = f(x) + g(x)$, 则

$$F[x_0, x_1, \dots, x_n] = f[x_0, x_1, \dots, x_n] + g[x_0, x_1, \dots, x_n].$$

10. 证明:

$$f[x_0, x_1, \dots, x_n] = \sum_{j=0}^n \frac{f(x_j)}{(x_j - x_0) \dots (x_j - x_{j-1})(x_j - x_{j+1}) \dots (x_j - x_n)}.$$

11. 已知数表

x_i	0	1	2	3
y_i	1	2	17	64

试分别作出三次牛顿前插和牛顿后插公式并分别计算 $x = 0.5$ 及 $x = 2.5$ 时函数的近似值(计算取 3 位小数).

12. 已知连续函数 $P(x)$ 的函数值如下表:

x	- 1	0	1	2
$P(x)$	- 2	- 1	1	2

求方程 $P(x) = 0$ 在 $[-1, 2]$ 内的根的近似值, 要求误差尽量小.

13. 证明

$${}^n y_i = y_{n+i} - C_n^1 y_{n+i-1} + C_n^2 y_{n+i-2} - \dots + (-1)^k C_n^k y_{n+i-k} + \dots + (-1)^n y_i,$$

式中

$$C_n^k = \frac{n(n-1)\dots(n-k+1)}{k!}.$$

14. 已知 $y = \ln x$ 的函数表

x_i	0.4	0.5	0.6	0.7	0.8
y_i	- 0.916291	- 0.693147	- 0.510826	- 0.356675	- 0.223144

分别用牛顿前插和牛顿后插公式计算 $x = 0.45$ 和 $x = 0.82$ 时函数的近似值, 并估计误差.

15. 在 $[-4, 4]$ 上给出 $f(x) = e^x$ 的等距节点函数表, 若用二次插值求 e^x 的近似值, 要使截断误差不超过 10^{-5} , 问使用函数表其步长应取多少(计算取 5 位小数)?

16. 求满足函数表

(1)

x	1	2
f (x)	2	3
f' (x)	0	- 1

(2)

x	1	2	3
f (x)	1	0	2
f' (x)		- 1/2	

的插值多项式及余项.

17. 给定插值条件

x	0	1	2	3
f (x)	0	0	0	0

端点条件为

(1) $m_0= 1, m_3= 0;$

(2) $M_0= 1, M_3= 0.$

分别求出满足上述条件的三次样条插值函数的分段表达式.

第六章 最小二乘法与曲线拟合

在科学研究与工程技术中,常常需要从一组测量数据 (x_i, y_i) ($i=1, 2, \dots, n$)出发,寻找变量 x 与 y 的函数关系的近似表达式. 上章所述的插值法虽是函数逼近的一种重要方法,但它还存在以下缺陷:一是由于测量数据往往不可避免地带有测试误差,而插值多项式又通过所有的点 (x_i, y_i) ,这样就使插值多项式保留了这些误差,从而影响了逼近精度. 此时显然插值效果是不理想的. 二是如果由实验提供的数据较多,则必然得到次数较高的插值多项式,这样近似程度往往既不稳定又明显缺乏实用价值. 因此,怎样从给定的一组实验数据出发,寻求已知函数的一个逼近函数 $y = f(x)$,使得逼近函数从总体上来说与已知函数的偏差按某种方法度量能达到最小而又不一定过全部的点 (x_i, y_i) ,这就是本章所要介绍的最小二乘曲线拟合法.

§ 1 用最小二乘法求解矛盾方程组

一、最小二乘原理

如前所述,用近似曲线 $y = f(x)$ 拟合数据 (x_i, y_i) ($i=1, 2, \dots, n$),自然希望要“拟合得最好”,其标准是什么呢?显然,希望择选 $f(x)$,使得它在 x_i 处的函数值 $f(x_i)$ ($i=1, 2, \dots, n$)与测量数据 y_i ($i=1, 2, \dots, n$)相差都很小,即要使偏差(也称残差)

$$f(x_i) - y_i \quad (i=1, 2, \dots, n)$$

都很小. 那么如何达到这一要求呢?一种方法是使偏差之和

$$\sum_{i=1}^n [f(x_i) - y_i]$$

很小来保证每个偏差都很小. 但由于偏差有正有负, 在求和时可能互相抵消. 为了避免上述情况发生, 还可使偏差的绝对值之和

$$\sum_{i=1}^n |(x_i) - y_i|$$

为最小. 但这个式子中有绝对值符号, 不便于分析讨论. 由于任何实数的平方都是正数或零, 因而我们可选择使“偏差平方和

$$\sum_{i=1}^n [(x_i) - y_i]^2$$

最小”的原则来保证每个偏差的绝对值都很小, 从而得到最佳拟合曲线 $y = f(x)$. 这种“偏差平方和最小”的原则称为最小二乘原则, 而按最小二乘原则拟合曲线的方法称为最小二乘法或称最小二乘曲线拟合法(二乘的意思就是方).

那么, 用什么样的函数去拟合数据 (x_i, y_i) ($i = 1, 2, \dots, m$) 呢? 一般而言, 所求得的拟合函数可以是不同的函数类, 拟合曲线 $f(x)$ 都是由 m 个线性无关函数 $\phi_1(x), \phi_2(x), \dots, \phi_m(x)$ 的线性组合而成, 即

$$f(x) = a_1 \phi_1(x) + a_2 \phi_2(x) + \dots + a_m \phi_m(x) \quad (m < n - 1),$$

其中 a_1, a_2, \dots, a_m 为待定常数.

线性无关函数组 $\phi_1(x), \phi_2(x), \dots, \phi_m(x)$ 称为基函数. 常用的基函数有

多项式: $1, x, x^2, \dots, x^m$;

三角函数: $\sin x, \sin 2x, \dots, \sin mx$;

指数函数: $e^{1^x}, e^{2^x}, \dots, e^{m^x}$.

其中最简单的是多项式, 至于函数类, 一般可取比较低的多项式或其他较简单的函数集合.

二、用最小二乘法求解矛盾方程组

由线性代数理论知, 求解线性方程组时, 当方程式的个数多于未知数的个数时, 方程组往往无解, 此类方程组称为矛盾方程组

(或称超定方程组). 而最小二乘法就是用来解矛盾方程组的一个常用方法.

设有矛盾方程组

[illegible]

即

$$\sum_{j=1}^m a_{ij}x_j = b_i \quad (i = 1, 2, \dots, n; m < n).$$

由于(6.1.1)式为矛盾方程组,故找不到能同时满足这 n 个方程的解,因此我们转而寻求在某种意义下的近似解.这种近似解当然不是指对精确解的近似(因为精确解并不存在),而是指寻求各未知数的一组值,使方程组(6.1.1)中各式能近似相等.这就是用最小二乘法解矛盾方程组的基本思想.把近似解代入方程组(6.1.1)后,只能使各方程式两端近似相等,我们将各方程两端之差

$$x_i = \sum_{j=1}^m a_{ij}x_j - b_i \quad (i = 1, 2, \dots, n)$$

称为偏差.按最小二乘原则,常采用使偏差的平方和

$$Q = \sum_{i=1}^n \left[\sum_{j=1}^m a_{ij} X_j - b_i \right]^2 \quad (6.1.2)$$

达到最小值来作为衡量一个近似解的近似程度的标志. 如果 x_j ($j = 1, 2, \dots, m$) 的取值, 使偏差平方和 (6.1.2) 式达到最小, 则称这组值是矛盾方程组 (6.1.1) 的最优近似解.

偏差平方和 Q 可看成是 m 个自变量 x_j 的二次函数, 因此, 求解矛盾方程组 (6.1.1) 的问题归结为求二次函数 Q 的最小值问题. 应该指出, 因为二次函数 Q 是 x_1, x_2, \dots, x_m 的连续函数, 且

$$Q = \sum_{i=1}^n \left[\sum_{j=1}^m a_{ij} x_j - b_j \right]^2 \quad 0,$$

故一定存在一组数 x_1, x_2, \dots, x_m , 使 Q 达到最小值. 由高等数学可

知,二次函数 Q 取极值的必要条件为

$$\frac{\partial Q}{\partial x_k} = 0 \quad (k = 1, 2, \dots, m),$$

而

$$\begin{aligned} \frac{\partial Q}{\partial x_k} &= \sum_{i=1}^n 2 \left[\sum_{j=1}^m a_{ij} x_j - b_i \right] a_{ik} \\ &= 2 \sum_{i=1}^n \left[\sum_{j=1}^m a_{ij} a_{ik} x_j - a_{ik} b_i \right] \\ &= 2 \sum_{j=1}^m \left[\sum_{i=1}^n a_{ij} a_{ik} \right] x_j - 2 \sum_{i=1}^n a_{ik} b_i. \end{aligned}$$

从而极值条件变为

$$\sum_{j=1}^m \left[\sum_{i=1}^n a_{ij} a_{ik} \right] x_j = \sum_{i=1}^n a_{ik} b_i \quad (k = 1, 2, \dots, m). \quad (6.1.3)$$

具有 m 个未知量 m 个方程式的线性方程组(6.1.3)称为对应于矛盾方程组(6.1.1)的法方程组(也叫正规方程组). 由上述推导可以看出, 法方程组(6.1.3)的解是矛盾方程组(6.1.1)的最优近似解.

记

$$A = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1m} \\ a_{21} & a_{22} & \dots & a_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nm} \end{bmatrix},$$

$$X = (x_1, x_2, \dots, x_m)^T, \quad b = (b_1, b_2, \dots, b_n)^T,$$

则方程组(6.1.1)可表示为

$$AX = b. \quad (6.1.4)$$

若用 c_{kj} 表示法方程组第 k 个方程中 x_j 的系数, 用 d_k 表示法方程组第 k 个方程的右端项, 则法方程组(6.1.3)可记为

$$\sum_{j=1}^m c_{kj} x_j = d_k \quad (k = 1, 2, \dots, m),$$

其中

$$\begin{cases} c_{kj} = \sum_{i=1}^n a_{ik} a_{ij} & (k, j = 1, 2, \dots, m), \\ d_k = \sum_{i=1}^n a_{ik} b_i & (k = 1, 2, \dots, m). \end{cases} \quad (6.1.5)$$

记

$$C = \begin{bmatrix} c_{11} & c_{12} & \dots & c_{1m} \\ c_{21} & c_{22} & \dots & c_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ c_{m1} & c_{m2} & \dots & c_{mm} \end{bmatrix}, \quad d = (d_1, d_2, \dots, d_m)^T,$$

则由(6.1.5)式可知,

$$C = A^T A, \quad d = A^T b.$$

于是法方程组(6.1.3)可用矩阵表示为

$$CX = d$$

或

$$A^T A X = A^T b. \quad (6.1.6)$$

显然, $C = A^T A$ 为对称矩阵, 故 $c_{kj} = c_{jk}$.

用最小二乘法解矛盾方程组 $AX = b$ 的步骤可归纳如下:

- (1) 计算 $A^T A$ 和 $A^T b$, 得法方程组 $A^T A X = A^T b$;
- (2) 求解法方程组, 得出矛盾方程组的最优近似解.

§ 2 用多项式作最小二乘曲线拟合

若取基函数为

$$\varphi_0(x) = 1, \quad \varphi_1(x) = x, \quad \varphi_2(x) = x^2, \quad \dots, \quad \varphi_m(x) = x^m,$$

则它们的线性组合

$$P(x) = a_0 + a_1 x + a_2 x^2 + \dots + a_m x^m \quad (m < n - 1) \quad (6.2.1)$$

是关于 x 的 m 次多项式. 依最小二乘原理, 即是要通过给定的数据 $(x_i, y_i) \ (i = 1, 2, \dots, n)$, 确定系数 a_j , 使得在各个点上的偏差平

方和达到最小. 为此, 将 n 对数据 (x_i, y_i) 代入 (6.2.1) 式, 就得到一个具有 $m+1$ 个未知数 a_j 的 n 个方程的矛盾方程组:

$$\left\{ \begin{array}{l} \mathbf{a}_0 + \mathbf{a}_1 \mathbf{x}_1 + \mathbf{a}_2 \mathbf{x}_1^2 + \dots + \mathbf{a}_m \mathbf{x}_1^m = \mathbf{y}_1, \\ \mathbf{a}_0 + \mathbf{a}_1 \mathbf{x}_2 + \mathbf{a}_2 \mathbf{x}_2^2 + \dots + \mathbf{a}_m \mathbf{x}_2^m = \mathbf{y}_2, \\ \dots\dots\dots \\ \mathbf{a}_0 + \mathbf{a}_1 \mathbf{x}_n + \mathbf{a}_2 \mathbf{x}_n^2 + \dots + \mathbf{a}_m \mathbf{x}_n^m = \mathbf{y}_n. \end{array} \right. \quad (6.2.2)$$

其矩阵形式为

$$A = Y,$$

式中

$$A = \begin{bmatrix} 1 & x_1 & x_1^2 & \dots & x_1^m \\ 1 & x_2 & x_2^2 & \dots & x_2^m \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & x_n^2 & \dots & x_n^m \end{bmatrix}, \quad = \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_m \end{bmatrix}, \quad Y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix},$$

它对应的正规方程组为

$$\mathbf{A}^T \mathbf{A} = \mathbf{A}^T \mathbf{Y}. \quad (6.2.3)$$

这是关于 $m+1$ 个未知量 a_j ($j = 0, 1, 2, \dots, m$) 的线性方程组, 只要它的系数行列式不等于零, 就可求得方程组 (6.2.2) 的惟一的一组最优近似解, 使得

$$Q = \sum_{i=1}^n \left[\sum_{j=0}^m a_j x_i^j - y_i \right]^2$$

取得极小,从而求得所给数据的最小二乘拟合多项式.

由于 x_1, x_2, \dots, x_n 互异, 故矩阵 A 的 $m+1$ 个列向量线性无关, 从而 A 的秩 $r(A) = m+1$. 于是对任给的 $m+1$ 维非零列向量 X , 都有 $AX \neq 0$, 由

$$\mathbf{X}^T \mathbf{A}^T \mathbf{A} \mathbf{X} = (\mathbf{A} \mathbf{X})^T (\mathbf{A} \mathbf{X}) \geq 0$$

知 $A^T A$ 为对称正定矩阵, 从而 $A^T A$ 非奇异. 因此方程组 (6.2.3) 的解存在且惟一.

由于

$$A^T A = \begin{bmatrix} 1 & 1 & \dots & 1 \\ X_1 & X_2 & \dots & X_n \\ X_1^2 & X_2^2 & \dots & X_n^2 \\ \vdots & \vdots & \ddots & \vdots \\ X_1^m & X_2^m & \dots & X_n^m \end{bmatrix} \begin{bmatrix} 1 & X_1 & X_1^2 & \dots & X_1^m \\ 1 & X_2 & X_2^2 & \dots & X_2^m \\ 1 & X_3 & X_3^2 & \dots & X_3^m \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & X_n & X_n^2 & \dots & X_n^m \end{bmatrix}$$

$$= \begin{bmatrix} n & \sum_{i=1}^n X_i & \sum_{i=1}^n X_i^2 & \dots & \sum_{i=1}^n X_i^m \\ \sum_{i=1}^n X_i & \sum_{i=1}^n X_i^2 & \sum_{i=1}^n X_i^3 & \dots & \sum_{i=1}^n X_i^{m+1} \\ \sum_{i=1}^n X_i^2 & \sum_{i=1}^n X_i^3 & \sum_{i=1}^n X_i^4 & \dots & \sum_{i=1}^n X_i^{m+2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \sum_{i=1}^n X_i^m & \sum_{i=1}^n X_i^{m+1} & \sum_{i=1}^n X_i^{m+2} & \dots & \sum_{i=1}^n X_i^{2m} \end{bmatrix},$$

所以在计算法方程组的系数矩阵时, 只需计算 $n, \sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2, \dots,$

$\sum_{i=1}^n X_i^m, \sum_{i=1}^n X_i^{m+1}, \dots, \sum_{i=1}^n X_i^{2m}$, 然后按上述顺序排列即可. 这样可大大节约计算量.

最后, 给出利用多项式作最小二乘数据拟合的具体步骤如下:

(1) 计算法方程组的系数矩阵和常数项的各元素:

$$\sum_{i=1}^n X_i^0 = n, \quad \sum_{i=1}^n X_i, \quad \sum_{i=1}^n X_i^2, \quad \dots, \quad \sum_{i=1}^n X_i^{2m};$$

$$\sum_{i=1}^n y_i, \quad \sum_{i=1}^n y_i X_i, \quad \sum_{i=1}^n y_i X_i^2, \quad \dots, \quad \sum_{i=1}^n y_i X_i^m;$$

(2) 利用改进的平方根法或迭代法求法方程组的解 $a_0^*, a_1^*, \dots, a_m^*$, 则最小二乘数据拟合多项式为

$$P(x) = a_0^* + a_1^* x + a_2^* x^2 + \dots + a_m^* x^m.$$

例 1 通过实验获得数据如下:

x_i	1	2	3	4	6	7	8
y_i	2	3	6	7	5	3	2

试用最小二乘法求多项式曲线, 使与此数据组相拟合(计算取 4 位小数).

解 (1) 作散点分布图

将数据 (x_i, y_i) 描在坐标纸上, 如图 6-1 所示.




图 6-1

从图可以看出, 点的分布近似为抛物线.

(2) 确定近似表达式

设拟合曲线为二次多项式

$$y = (x) = a_0 + a_1x + a_2x^2.$$

(3) 建立法方程组

$$\begin{aligned} h=7, \quad \sum_{i=1}^7 x_i=31, \quad \sum_{i=1}^7 x_i^2=179, \quad \sum_{i=1}^7 x_i^3=1171, \quad \sum_{i=1}^7 x_i^4=8147; \\ \sum_{i=1}^7 y_i=28, \quad \sum_{i=1}^7 y_i x_i=121, \quad \sum_{i=1}^7 y_i x_i^2=635, \end{aligned}$$

故法方程组为

$$\begin{bmatrix} 7 & 31 & 179 \\ 31 & 179 & 1171 \\ 179 & 1171 & 8147 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} 28 \\ 121 \\ 635 \end{bmatrix}.$$

(4) 求解法方程组得

$$a_0 = -1.3185, \quad a_1 = 3.4321, \quad a_2 = -0.3864,$$

故所求拟合曲线为

$$y = (x) = -1.3185 + 3.4321x - 0.3864x^2.$$

例 2 在一物理实验中,测得电压 V 与电流 I 的一组数据如下:

V_i/V	1	2	3	4	5	6	7	8
I_i/mA	15.3	20.5	27.4	36.6	49.1	65.6	87.8	117.6

试用最小二乘法求最佳数据拟合函数.

解 将数据描在坐标纸上,如图 6-2 所示.




图 6-2

从图看出,点的分布近似为指数曲线.故可取指数函数 $I = ae^{bV}$ (a, b 为常数) 作为拟合函数比较合适.此时只要求出常数 a, b ,就可找到最佳拟合函数.但是,这是一个关于 a, b 的非线性模型,故应首先通过适当变换,将其化为线性模型,然后再利用最小二乘法去求解.为此,我们对函数 $I = ae^{bV}$ 两边取常用对数有

$$\lg I = \lg a + bV \lg e.$$

令 $u = \lg I$, 并记 $A = \lg a, B = b \lg e$, 则得线性模型

$$u = A + BV.$$

以下计算步骤类似于例 1.

由表 6-1 可计算法方程组的各系数和右端项.

表 6-1

V_i	I_i	u_i	V_i^2	$V_i u_i$
1	15.3	1.1847	1	1.1847
2	20.5	1.3118	4	2.6236
3	27.4	1.4378	9	4.3134
4	36.6	1.5635	16	6.2540
5	49.1	1.6911	25	8.4555
6	65.6	1.8169	36	10.9014
7	87.8	1.9435	49	13.6045
8	117.6	2.0704	64	16.5632

$$\begin{aligned}n &= 8, \quad \sum_{i=1}^8 V_i = 36, \quad \sum_{i=1}^8 V_i^2 = 204, \\ \sum_{i=1}^8 u_i &= 13.0197, \quad \sum_{i=1}^8 V_i u_i = 63.9003,\end{aligned}$$

于是法方程组为

$$\begin{bmatrix} 8 & 36 \\ 36 & 204 \end{bmatrix} \begin{bmatrix} A \\ B \end{bmatrix} = \begin{bmatrix} 13.0197 \\ 63.9003 \end{bmatrix},$$

解得 $A = 1.0584$, $B = 0.1265$. 进而可得 $a = 11.4393$, $b = 0.2912$.

故最佳拟合函数为

$$I = 11.4393e^{0.2912V}$$

本章小结

曲线拟合的最小二乘法是计算机数据处理的重要内容,也是函数逼近的另一重要方法,它在工程技术中有着广泛的应用.本章用多元二次多项式求极值的方法导出了一般线性最小二乘问题的法方程组,并讨论了其解的存在惟一性.某些非线性问题可以转化

为线性问题得以解决. 对实际问题而言, 拟合曲线的选型是一个极其重要而又比较困难的问题, 必要时可由草图观察选取几种不同类型的拟合曲线, 再以其偏差小者为优, 经检验后再决定最后的取舍.

算法与程序设计实例

曲线拟合的最小二乘法.

算法

已知数据对 (x_j, y_j) ($j= 1, 2, \dots, n$). 求多项式

$$P(x) = \sum_{i=0}^m a_i x^i \quad (m < n),$$

使得

$$(a_0, a_1, \dots, a_m) = \min_{j=1}^n \left[\sum_{i=0}^m a_i x_j^i - y_j \right]^2$$

为最小. 注意到此时 $k(x) = x^k$, 多项式系数 a_0, a_1, \dots, a_m 满足下面的线性方程组:

$$\begin{bmatrix} S_0 & S_1 & \dots & S_m \\ S_1 & S_2 & \dots & S_{m+1} \\ \vdots & \vdots & \ddots & \vdots \\ S_m & S_{m+1} & \dots & S_{2m} \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_m \end{bmatrix} = \begin{bmatrix} T_0 \\ T_1 \\ \vdots \\ T_m \end{bmatrix},$$

其中

$$S_k = \sum_{j=1}^n x_j^k \quad (k= 0, 1, 2, \dots, 2m),$$

$$T_k = \sum_{j=1}^n y_j x_j^k \quad (k= 0, 1, 2, \dots, m),$$

然后只要调用解线性方程组的函数程序即可.

实例

由化学实验得到某物质浓度与时间的关系如下:

时间 t	1	2	3	4	5	6	7	8
浓度 y	4.00	6.40	8.00	8.80	9.22	9.50	9.70	9.86

时间 t	9	10	11	12	13	14	15	16
浓度 y	10.00	10.20	10.32	10.42	10.50	10.55	10.58	10.60

求浓度与时间的二次拟合曲线.

程序和输出结果

```
# include <stdio.h>
# include <alloc.h>
# include <math.h>
void main()
{
    int i;
    float * a;
    float x[ 16]= { 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14,
                    15, 16};
    float y[ 16]= {4.00, 6.40, 8.00, 8.80, 9.22, 9.50, 9.70,
                    9.86, 10.00, 10.20, 10.32, 10.42, 10.50,
                    10.55, 10.58, 10.60};
    float * Approx(float * , float * , int, int);
    a= Approx(x, y, 16, 2);
    clrscr();
    for(i= 0; i<= 2; i++ )
        printf( a[ % d]= % f\n , i, a[i] );
    getch();
}

float * Approx(float * x, float * y, int m, int n)
{
    float * c, * a;
    int i, j, t;
    float power(int, float);
```

```

float * ColPivot( float * , int);
c= (float * )malloc((n+ 1)* (n+ 2)* sizeof(float));
for( i= 0; i< = n; i+ + )
{
    for(j= 0; j< = n; j+ + )
    {
        * (c+ i* (n+ 2)+ j)= 0. 0;
        for(t= 0; t< = m- 1; t+ + )
            * (c+ i* (n+ 2)+ j)+ = power(i+ j, x[ t] );
    }
    * (c+ i* (n+ 2)+ n+ 1)= 0. 0;
    for(j= 0; j< = m- 1; j+ + )
        * (c+ i* (n+ 2)+ n+ 1)+ = y[j]* power(i, x[ j] );
}
a= ColPivot(( float * )c, n+ 1);
return a;
}

float * ColPivot( float * a, int n)
{
    int i, j, t, k;
    float * x, * c, p;
    x= (float * )malloc(n* sizeof( float));
    c= (float * )malloc(n* (n+ 1)* sizeof(float));
    for( i= 0; i< = n- 1; i+ + )
    for(j= 0; j< = n; j+ + )
        * (c+ i* (n+ 1)+ j)= (* ( a+ i* (n+ 1)+ j));
    for( i= 0; i< = n- 2; i+ + )
    {
        k= i;

```

```

for(j= i+ 1;j< = n- 1;j+ + )
    if(fabs(* (c+ j* (n+ 1)+ i))
        > (fabs(* (c+ k* (n+ 1)+ i)))) k= j;
if(k!= i)
    for(j= i;j< = n;j+ + )
    {
        p= * (c+ i* (n+ 1)+ j);
        * (c+ i* (n+ 1)+ j)= * (c+ k* (n+ 1)+ j);
        * (c+ k* (n+ 1)+ j)= p;
    }
for(j= i+ 1;j< = n- 1;j+ + )
{
    p= (* (c+ j* (n+ 1)+ i))
        /(* (c+ i* (n+ 1)+ i));
    for(t= i;t< = n- 1;t+ + )
        * (c+ j* (n+ 1)+ t)
            = * (c+ j* (n+ 1)+ t)
              - p* (* (c+ i* (n+ 1)+ t));
    * (c+ j* (n+ 1)+ n)-
        = * (c+ i* (n+ 1)+ n)* p;
}
}
for(i= n- 1;i> = 0;i- - )
{
    for(j= n- 1;j> = i+ 1;j- - )
        (* (c+ i* (n+ 1)+ n))-
            = x[j]* (* (c+ i* (n+ 1)+ j));
    x[i]= * (c+ i* (n+ 1)+ n)
        /(* (c+ i* (n+ 1)+ i));
}

```



```

    }
    free(c);
    return x;
}

float power(int i, float v)
{
    float a= 1.0;
    while(i-- ) a*= v;
    return a;
}

```

输出结果如下:

$a[0] = 4.387500,$ $a[1] = 1.065962,$
 $a[2] = -0.044466.$

因此二次拟合多项式为

$$y(t) = 4.3875 + 1.065962t - 0.044466t^2.$$

思 考 题

1. 何谓最小二乘原理? 为什么要研究最小二乘原理? 用最小二乘法求函数近似表达式的一般步骤如何? 它与插值函数求近似式有何区别?
2. 最小二乘问题的法方程组是如何构造出来的? 它是否存在惟一解?
3. 何谓矛盾方程组? 如何求解?

习 题 六

1. 求线性方程组

$$\begin{cases} 2x_1 + 4x_2 = 1, \\ 3x_1 - 5x_2 = 3, \\ x_1 + 2x_2 = 6, \\ 4x_1 + 2x_2 = 14 \end{cases}$$

的最小二乘解(计算取 4 位小数).

2. 试用最小二乘法分别求一次和二次多项式, 使与下列数据相拟合(计算取 3 位小数), 并比较两条拟合曲线的优劣.

x_i	1.36	1.49	1.73	1.81	1.95	2.16	2.28	2.48
y_i	14.094	15.069	16.844	17.378	18.435	19.949	20.963	22.495

3. 试用最小二乘法求形如 $y = a + bx^2$ 的多项式, 使与下列数据相拟合(计算取 3 位小数).

x_i	19	25	31	28	44
y_i	19.0	32.3	49.0	73.3	97.8

4. 观测一个物体的直线运动, 测得数据为

时间 t_i/s	0	0.9	1.9	3.0	3.9	5.0
距离 s_i/m	0	10	30	50	80	110

求该物体的初速度及加速度(假定为常数)(计算取 3 位小数).

5. 某种铝合金的含铝量为 $x\%$, 其熔解温度为 y , 由实验测得 x 与 y 的数据为

x_i	36.9	46.7	63.7	77.8	84.0	87.5
y_i	181	197	235	270	283	292

试用最小二乘法建立 x 与 y 之间的经验公式(计算取 4 位小数).

6. 设一发射源的发射强度公式为 $I = I_0 e^{-at}$, 测得 I 与 t 的数据为

t_i	0.2	0.3	0.4	0.5	0.6	0.7	0.8
I_i	3.16	2.38	1.75	1.34	1.00	0.74	0.56

试用最小二乘法确定 I_0 与 a (计算取 3 位小数) .

7. 求形如 $y=ae^{bx}$ (a, b 为常数且 $a>0$) 的经验公式, 使它能和下表数据拟合(计算取 4 位小数) .

x_i	1.00	1.25	1.50	1.75	2.00
y_i	5.10	5.79	6.53	7.45	8.46

8. 用最小二乘法求一个形如

$$y = (x) = a + b\ln x$$

的经验公式, 使其与数据

x_i	1	2	3	4
y_i	2.5	3.4	4.1	4.4

相拟合(计算取 4 位小数) .

第七章 数值微积分

实际问题中常常需要计算定积分. 在微积分中, 我们熟知, 牛顿-莱布尼兹公式是计算定积分的一种有效工具, 在理论和实际计算上有很大作用. 对定积分 $I = \int_a^b f(x) dx$, 若 $f(x)$ 在区间 $[a, b]$ 上连续, 且 $f(x)$ 的原函数为 $F(x)$, 则可计算定积分

$$I = \int_a^b f(x) dx = F(b) - F(a).$$

但在工程计算和科学研究中, 经常会遇到被积函数 $f(x)$ 的下列一些情况:

(1) $f(x)$ 本身形式复杂, 求原函数更为困难. 例如

$$f(x) = \sqrt{ax^2 + bx + c}.$$

(2) $f(x)$ 的原函数不能用初等函数形式表示. 例如

$$f(x) = \frac{1}{\ln x}, \quad e^{-x^2}, \quad \sin x^2, \quad \frac{\sin x}{x}.$$

(3) $f(x)$ 虽有初等函数形式表示的原函数, 但其原函数表示形式相当复杂. 例如 $f(x) = \frac{1}{1+x^4}$.

(4) $f(x)$ 本身没有解析表达式, 其函数关系由表格或图形给出. 例如为实验或测量数据.

以上情况都不能利用牛顿-莱布尼兹公式方便地计算该函数的定积分, 满足不了实际需求. 因此, 有必要研究定积分的数值计算问题; 另外, 对一些函数的求导问题, 其求导、微分也相当复杂, 也有必要研究求导、微分的数值计算问题. 本章主要介绍数值求积分和数值求微分的方法.

§ 1 牛顿-柯特斯(Newton-Cotes) 公式

一、数值求积的基本思想

当函数 $f(x)$ 为已知时, 我们讨论如何计算定积分

$$I = \int_a^b f(x) dx.$$

为了避开求原函数的困难, 我们通过被积函数 $f(x)$ 的值来求出定积分的值. 由积分中值定理: 对于连续函数 $f(x)$, 在 $[a, b]$ 内存在点 ξ , 有

$$I = \int_a^b f(x) dx = (b - a)f(\xi) \quad (a < \xi < b).$$

但 ξ 的值一般是不知道的, 因而难以准确计算 $f(\xi)$ 的值. 我们称 $f(\xi)$ 为 $f(x)$ 在区间 $[a, b]$ 上的平均高度. 若能对 $f(\xi)$ 提供一种近似算法, 就可得到一种数值积分公式. 如最简单的形式

$$I = \int_a^b f(x) dx \approx (b - a)f(a), \quad (7.1.1)$$

$$I = \int_a^b f(x) dx \approx (b - a)f(b), \quad (7.1.2)$$

$$I = \int_a^b f(x) dx \approx (b - a)f\left[\frac{a+b}{2}\right]. \quad (7.1.3)$$

以上三个公式分别称为左矩形、右矩形及中矩形公式, 其几何意义是明显的.

更一般地, $f(x)$ 在 $[a, b]$ 内 $n+1$ 个节点 x_i 处的高度为 $f(x_i)$ ($i=0, 1, \dots, n$), 通过加权平均的方法近似地得出平均高度 $f(\xi)$, 这类公式一般形式为

$$I = \int_a^b f(x) dx \approx \sum_{i=0}^n A_i f(x_i). \quad (7.1.4)$$

我们称 x_i 为求积节点, 称 A_i 为求积系数(或节点 x_i 的权).

记

$$R_n[f] = \int_a^b f(x) dx - \sum_{i=0}^n A_i f(x_i), \quad (7.1.5)$$

称 $R_n[f]$ 为求积公式(7.1.4)的截断误差.

这类求积方法通常称为机械求积方法,其特点是直接利用某些节点上的函数值计算积分值,从而将积分求值问题归结为函数值的计算,这就避开了牛顿-莱布尼兹公式需要寻求原函数的困难.

二、插值型求积公式

用拉格朗日多项式 $L_n(x)$ 作为 $f(x)$ 的近似函数, 设 $[a, b]$ 上的节点为

$$a = x_0 < x_1 < x_2 < \dots < x_n = b,$$

则有
$$L_n(x) = \sum_{i=0}^n l_i(x) f(x_i),$$

其中
$$l_i(x) = \prod_{\substack{j=0 \\ j \neq i}}^n \frac{x - x_j}{x_i - x_j}.$$

则计算定积分时, $f(x)$ 可由 $L_n(x)$ 代替, 有

$$\begin{aligned} I &= \int_a^b f(x) dx \approx \int_a^b L_n(x) dx \\ &= \sum_{i=0}^n \int_a^b l_i(x) f(x_i) dx \\ &= \sum_{i=0}^n \left\{ \int_a^b l_i(x) dx \right\} f(x_i). \end{aligned}$$

记

$$A_i = \int_a^b l_i(x) dx, \quad (7.1.6)$$

则有公式

$$I \approx \int_a^b f(x) dx \approx \sum_{i=0}^n A_i f(x_i), \quad (7.1.7)$$

其中 A_i 只与插值节点 x_i 有关, 而与被积函数 $f(x)$ 无关. 公式

(7.1.7)称为插值型求积公式.

由拉格朗日插值余项可知, 公式(7.1.7)的截断误差

$$\begin{aligned} R_n[f] &= \int_a^b [f(x) - L_n(x)] dx \\ &= \frac{1}{(n+1)!} \int_a^b f^{(n+1)}(x) \omega_{n+1}(x) dx, \end{aligned} \quad (7.1.8)$$

其中 $\omega_{n+1}(x) = \prod_{i=0}^n (x - x_i), \quad x \in (a, b).$

三、牛顿-柯特斯公式

在插值型求积公式中, 若取等距节点, 将区间 $[a, b]$ n 等分, 记节点 $x_i = a + ih \ (i = 0, 1, \dots, n), h = \frac{b-a}{n}$. 这样, 计算 A_i 的公式(7.1.6)在作变量替换 $x = a + th$ 后可简化为

$$\begin{aligned} A_i &= \int_a^b \frac{x - x_j}{x_i - x_j} dx = h \int_0^n \frac{(t - j)}{(i - j)} dt \\ &= \frac{b-a}{n} \cdot \frac{(-1)^{n-i}}{i!(n-i)!} \int_0^n (t - j) dt. \end{aligned}$$

记

$$C_i^{(n)} = \frac{1}{n} \frac{(-1)^{n-i}}{i!(n-i)!} \int_0^n (t - j) dt, \quad (7.1.9)$$

则有 $A_i = (b-a)C_i^{(n)}, \quad (7.1.10)$

且 $I = \int_a^b f(x) dx = (b-a) \sum_{i=0}^n C_i^{(n)} f(x_i), \quad (7.1.11)$

其中 $C_i^{(n)}$ 是不依赖于 $f(x)$ 和区间 $[a, b]$ 的常数. 称公式(7.1.11)为牛顿-柯特斯求积公式, $C_i^{(n)}$ 称为柯特斯系数.

由式(7.1.9)可得柯特斯系数具有以下性质:

(1) $C_i^{(n)} = C_{n-i}^{(n)}$ (对称性);

(2) $\sum_{i=0}^n C_i^{(n)} = 1$ (权性).

特别地, 当 $n=1$ 时

$$C_0^{(1)} = C_1^{(1)} = \int_0^1 t dt = \frac{1}{2},$$

$$I = \int_a^b f(x) dx = \frac{b-a}{2} [f(a) + f(b)], \quad (7.1.12)$$

公式(7.1.12)称为梯形公式.

当 $n=2$ 时

$$C_0^{(2)} = C_2^{(2)} = \frac{1}{4} \int_0^2 t(t-1) dt = \frac{1}{6},$$

$$C_1^{(2)} = \frac{1}{4} \int_0^2 t(t-2) dt = \frac{4}{6},$$

$$I = \int_a^b f(x) dx = \frac{b-a}{6} \left[f(a) + 4f\left[\frac{a+b}{2}\right] + f(b) \right], \quad (7.1.13)$$

公式(7.1.13)称为辛普森(Simpson)或抛物公式.

当 $n=4$ 时, 类似地

$$I = \int_a^b f(x) dx = \frac{(b-a)}{90} [7f(x_0) + 32f(x_1) + 12f(x_2) + 32f(x_3) + 7f(x_4)],$$

$$x_i = a + i \cdot \frac{b-a}{4} \quad (i = 0, 1, \dots, 4), \quad (7.1.14)$$

公式(7.1.14)称为柯特斯公式.

为了便于应用, 将部分柯特斯系数列表如下:

n	$C_i^{(n)}$
1	$\frac{1}{2} \quad \frac{1}{2}$
2	$\frac{1}{6} \quad \frac{4}{6} \quad \frac{1}{6}$
3	$\frac{1}{8} \quad \frac{3}{8} \quad \frac{3}{8} \quad \frac{1}{8}$
4	$\frac{7}{90} \quad \frac{32}{90} \quad \frac{12}{90} \quad \frac{32}{90} \quad \frac{7}{90}$

n	$C_i^{(n)}$
5	$\frac{19}{288} \frac{75}{288} \frac{50}{288} \frac{50}{288} \frac{75}{288} \frac{19}{288}$
6	$\frac{41}{840} \frac{216}{840} \frac{27}{840} \frac{272}{840} \frac{27}{840} \frac{216}{840} \frac{41}{840}$
7	$\frac{751}{17280} \frac{3577}{17280} \frac{1323}{17280} \frac{2989}{17280} \frac{2989}{17280} \frac{1323}{17280} \frac{3577}{17280} \frac{751}{17280}$
8	$\frac{989}{28350} \frac{5888}{28350} \frac{-928}{28350} \frac{10496}{28350} \frac{-4540}{28350} \frac{10496}{28350} \frac{-928}{28350} \frac{5888}{28350} \frac{989}{28350}$

从表可看出, 当 n 较大时, 柯特斯系数较复杂, 且出现负项, 计算过程的稳定性没有保证, 一般较少使用. 梯形公式、辛普森公式和柯特斯公式是最基本、最常用的求积公式, 其截断误差可由下述定理给出.

定理 1 若 $f(x)$ 在 $[a, b]$ 上连续, 则梯形公式(7.1.12)的截断误差

$$R_1[f] = -\frac{(b-a)^3}{12} f''(\xi), \quad [a, b]. \quad (7.1.15)$$

若 $f^{(4)}(x)$ 在 $[a, b]$ 上连续, 则辛普森公式(7.1.13)的截断误差

$$\begin{aligned} R_2[f] &= -\frac{(b-a)^5}{2880} f^{(4)}(\xi) \\ &= -\frac{1}{90} \left[\frac{b-a}{2} \right]^5 f^{(4)}(\xi), \quad [a, b]. \quad (7.1.16) \end{aligned}$$

若 $f^{(6)}(x)$ 在 $[a, b]$ 上连续, 则柯特斯公式(7.1.14)的截断误差

$$\begin{aligned} R_4[f] &= -\frac{(b-a)^7}{1013760} f^{(6)}(\xi) \\ &= -\frac{8}{495} \left[\frac{b-a}{4} \right]^7 f^{(6)}(\xi), \quad [a, b]. \quad (7.1.17) \end{aligned}$$

例 1 分别利用梯形公式、辛普森公式和柯特斯公式计算

$I = \int_{0.5}^1 \sqrt{x} dx$, 并与精确值进行比较.

解 (1) 用梯形公式

$$I \approx \frac{0.5}{2}(\sqrt{0.5} + 1) = 0.4267767.$$

(2) 用辛普森公式

$$I \approx \frac{0.5}{6}(\sqrt{0.5} + 4\sqrt{0.75} + 1) = 0.43093403.$$

(3) 用柯特斯公式

$$\begin{aligned} I &\approx \frac{0.5}{90}(7\sqrt{0.5} + 32\sqrt{0.625} + 12\sqrt{0.75} \\ &\quad + 32\sqrt{0.875} + 7) \\ &= 0.43096407. \end{aligned}$$

精确值

$$I = \int_{0.5}^1 \sqrt{x} dx = \left. \frac{2}{3} \sqrt{x^3} \right|_{0.5}^1 = 0.43096441,$$

由此知三种计算方法计算的结果分别具有 2 位、3 位、6 位有效数字.

§ 2 龙贝格(Romberg)求积公式

一、复化求积公式

为了提高数值积分的精确度, 将区间 $[a, b]$ 等分为 n 个子区间, 在每个子区间上用基本求积公式, 然后再累加得出新的求积公式. 这样既可提高结果的精度, 又可使算法简便易于实现. 这种求积公式称为复化求积公式.

将区间 $[a, b]$ 分为 n 等分, 记分点 $x_i = a + ih$ ($i = 0, 1, \dots, n$), $h = \frac{b-a}{n}$ 称为步长. 子区间为 $[x_{i-1}, x_i]$ ($i = 1, 2, \dots, n$).

若在每个小区间 $[x_{i-1}, x_i]$ 上应用梯形公式(7.1.12), 即

$$\int_{x_{i-1}}^{x_i} f(x) dx = \frac{h}{2} [f(x_{i-1}) + f(x_i)] \quad (i = 1, 2, \dots, n),$$

则有

$$I = \int_a^b f(x) dx = \sum_{i=1}^n \int_{x_{i-1}}^{x_i} f(x) dx$$

$$= \frac{h}{2} \sum_{i=1}^n [f(x_{i-1}) + f(x_i)]$$

$$= \frac{h}{2} \left[f(a) + 2 \sum_{i=1}^{n-1} f(x_i) + f(b) \right] \text{记为 } T_n, \quad (7.2.1)$$

(7.2.1)式称为复化梯形公式.

类似地, 也有复化的辛普森公式

$$S_n = \frac{h}{6} \left[f(a) + 4 \sum_{i=0}^{n-1} f(x_{i+\frac{1}{2}}) + 2 \sum_{i=1}^{n-1} f(x_i) + f(b) \right],$$

其中

$$x_{i+\frac{1}{2}} = x_i + \frac{1}{2}h; \quad (7.2.2)$$

以及复化的柯特斯公式

$$C_n = \frac{h}{90} \left[7f(a) + 32 \sum_{i=0}^{n-1} f(x_{i+\frac{1}{4}}) + 12 \sum_{i=0}^{n-1} f(x_{i+\frac{1}{2}}) \right. \\ \left. + 32 \sum_{i=0}^{n-1} f(x_{i+\frac{3}{4}}) + 14 \sum_{i=1}^{n-1} f(x_i) + 7f(b) \right], \quad (7.2.3)$$

其中

$$x_{i+\frac{1}{4}} = x_i + \frac{1}{4}h, \quad x_{i+\frac{1}{2}} = x_i + \frac{1}{2}h, \quad x_{i+\frac{3}{4}} = x_i + \frac{3}{4}h.$$

定理 1 设 $f(x)$ 在区间 $[a, b]$ 上具有连续的二阶导数, 则复化梯形公式的截断误差为

$$R_T[f] = -\frac{b-a}{12} h^2 f''(\xi) \quad (\xi \in (a, b)). \quad (7.2.4)$$

证明 由本章§1定理1, 在区间 $[x_i, x_{i+1}]$ 上梯形公式的截断误差为

$$= -\frac{h^3}{12} f''(\xi_i), \quad \xi_i \in (x_i, x_{i+1}) \quad i = 0, 1, \dots, n-1,$$

误差相加

$$R_T[f] = \int_a^b f(x) dx - T_n = -\frac{h^3}{12} \sum_{i=0}^{n-1} f''(\xi_i).$$

由于 $f(x)$ 在 $[a, b]$ 上连续, 所以在 $[a, b]$ 内必存在一点 ξ , 使得

$$f(\xi) = \frac{1}{n} \sum_{i=0}^{n-1} f(x_i),$$

于是有 $R_T[f] = -\frac{b-a}{12} h^2 f''(\xi), \quad (a, b).$

类似地, 可推出复化辛普森公式的截断误差为

$$R_S[f] = -\frac{b-a}{2880} h^4 f^{(4)}(\xi), \quad (a, b), \quad (7.2.5)$$

以及复化柯特斯公式的截断误差为

$$R_C[f] = -\frac{2(b-a)}{945} \left[\frac{h}{4} \right]^6 f^{(6)}(\xi), \quad (a, b). \quad (7.2.6)$$

例 1 计算积分 $I = \int_0^1 e^x dx$, 若要求误差不超过 $\frac{1}{2} \times 10^{-4}$, 分别用复化梯形公式和复化辛普森公式计算, 问至少需各取多少个节点?

解 由 $f(x) = e^x, f'(x) = f^{(4)}(x) = e^x$, 得

$$\max_{x \in [0, 1]} f(x) = \max_{x \in [0, 1]} f^{(4)}(x) = e.$$

由式(7.2.4)有

$$R_T[f] \leq \frac{e}{12n^2} \leq \frac{1}{2} \times 10^{-4},$$

解出 $n > 67.3$, 故用复化梯形公式 n 至少取 68, 即需 69 个节点.

由式(7.2.5)有

$$R_S[f] \leq \frac{e}{2880n^4} \leq \frac{1}{2} \times 10^{-4},$$

解出 $n > 2.1$, 故用复化辛普森公式 n 至少取 3, 即需 7 个节点.

二、变步长求积公式

复化求积公式在使用时, 必须事先给出合适的步长. 在实际问题中, 有时导数绝对值上界很难估计, 从而误差也不好估计. 所以, 在实际计算中, 常采用变步长的计算方案, 即步长逐次分半, 反复利用复化求积公式进行计算, 并同时查看相继两次计算结果的误

差是否达到要求,直到所求得的积分近似值满足精度要求为止.下面以复化梯形公式为例,介绍变步长的求积公式.

设求积区间 $[a, b]$ 分为 n 等分,共有 $n+1$ 个节点,由复化梯形公式得

$$T_n = \frac{h}{2} \left[f(a) + 2 \sum_{i=1}^{n-1} f(x_i) + f(b) \right], \quad h = \frac{b-a}{n}.$$

若将求积区间再二分一次,分为 $2n$ 个子区间, $2n+1$ 个节点.为了讨论二分前后的两个积分值的关系,考察一个子区间 $[x_i, x_{i+1}]$,其中点为 $x_{i+\frac{1}{2}}$,该子区间上二分前后的两个积分值分别为

$$T_1 = \frac{h}{2} [f(x_i) + f(x_{i+1})]$$

及
$$T_2 = \frac{h}{4} [f(x_i) + 2f(x_{i+\frac{1}{2}}) + f(x_{i+1})],$$

显然有关系

$$T_2 = \frac{1}{2}T_1 + \frac{h}{2}f(x_{i+\frac{1}{2}}).$$

将这一关系式两边关于 i 由 0 到 $n-1$ 累加求和,则有下列关系式

$$T_{2n} = \frac{1}{2}T_n + \frac{h}{2} \sum_{i=0}^{n-1} f(x_{i+\frac{1}{2}}). \quad (7.2.7)$$

上式即为二分前后区间 $[a, b]$ 上积分值 T_n 与 T_{2n} 的递推公式,在计算 T_{2n} 时, T_n 为已知数据,只需累加新增的分点 $x_{i+\frac{1}{2}}$ 的函数值 $f(x_{i+\frac{1}{2}})$,使计算量节约一半.计算过程中,常用 $|T_{2n} - T_n| < \epsilon$ 是否满足作为控制计算精度的条件.若满足,则取 T_{2n} 为 I 的近似值;若不满足,则再将区间分半,直到满足要求为止.

三、龙贝格求积公式

我们对递推化的梯形公式进行修正,希望提高该公式的收敛速度.由复化梯形公式的误差(7.2.4)式,有

$$\frac{I - T_{2n}}{I - T_n} = \frac{1}{4} \frac{f^{(4)}(\xi_1)}{f^{(4)}(\xi_2)}.$$

若 $f(x)$ 在 $[a, b]$ 上变化不大, 即有 $f(x_1) \approx f(x_2)$. 则在二分之后误差是原先误差的 $\frac{1}{4}$ 倍, 即 $\frac{I - T_{2n}}{I - T_n} = \frac{1}{4}$, 可得

$$I = \frac{4}{3}T_{2n} - \frac{1}{3}T_n \quad \text{记为} \quad T, \quad (7.2.8)$$

T 应当比 T_{2n} 更接近于积分值 I .

事实上, 容易验证 $S_n = T$, 这说明用二分前后的两个梯形公式值 T_n 和 T_{2n} 按(7.2.8)式组合, 结果得出的是辛普森公式 S_n .

类似地, 由辛普森公式逐次分半, 有

$$\frac{I - S_{2n}}{I - S_n} = \frac{1}{16},$$

可得

$$I = \frac{16}{15}S_{2n} - \frac{1}{15}S_n.$$

也可验证右端即为柯特斯公式的值 C_n , 即

$$C_n = \frac{16}{15}S_{2n} - \frac{1}{15}S_n. \quad (7.2.9)$$

同样, 由柯特斯公式逐次分半, 有

$$\frac{I - C_{2n}}{I - C_n} = \frac{1}{64},$$

可得

$$I = \frac{64}{63}C_{2n} - \frac{1}{63}C_n.$$

将该式右端记为

$$R_n = \frac{64}{63}C_{2n} - \frac{1}{63}C_n, \quad (7.2.10)$$

式(7.2.10)称为龙贝格公式.

我们在步长二分的过程中运用公式(7.2.8), (7.2.9), (7.2.10)修正三次, 便将粗糙的梯形公式积分值 T_n 逐步加工成精度较高的龙贝格公式积分值 R_n , 这种加速方法称为龙贝格算法. 其计算流程图如下所示:

梯形序列	辛普森	柯特斯	龙贝格
T_1	序列	序列	序列
T_2	S_1		
T_4	S_2	C_1	
T_8	S_4	C_2	R_1
T_{16}	S_8	C_4	R_2

例 2 用龙贝格算法计算积分 $I = \int_0^1 \frac{4}{1+x^2} dx$, 要求误差不超过 $\frac{1}{2} \times 10^{-5}$ (其精确值为).

解 计算结果见下表.

k	区间等分数 $n=2^k$	梯形序列 T_{2^k}	辛普森序列 $S_{2^{k-1}}$	柯特斯序列 $C_{2^{k-2}}$	龙贝格序列 $R_{2^{k-2}}$
0	1	3			
1	2	3.1	3.133333		
2	4	3.131177	3.141569	3.142118	
3	8	3.138989	3.141593	3.141595	3.141586
4	16	3.140942	3.141593	3.141593	3.141593
5	32	3.141430	3.141593	3.141593	3.141593

故 $I \approx 3.141593$.

§ 3 高斯型求积公式

一、代数精确度

定义 1 若求积公式

$$\int_a^b f(x) dx = \sum_{k=0}^n A_k f(x_k),$$

对于任意不高于 m 次的代数多项式都准确地成立, 而对于 $m+1$ 次多项式却不能准确成立, 则称该求积公式具有 m 次代数精确度.

由上述定义和积分性质易知: 求积公式

$$\int_a^b f(x) dx = \sum_{k=0}^n A_k f(x_k)$$

具有 m 次代数精确度的充要条件是该公式对 $f(x) = 1, x, \dots, x^m$ 能准确成立, 而对 $f(x) = x^{m+1}$ 不能准确成立.

例如梯形公式

$$\int_a^b f(x) dx = \frac{b-a}{2} [f(a) + f(b)],$$

可以验证, 对于 $f(x) = 1, x$ 准确成立, 但对 $f(x) = x^2$ 却不准确成立, 所以梯形公式的代数精确度 $m=1$.

由插值型求积公式的余项(7.1.8)易得

定理 1 含有 $n+1$ 个节点 x_i ($i=0, 1, \dots, n$) 的插值型求积公式(7.1.7)的代数精确度至少为 n .

定理 2 牛顿-柯特斯公式(7.1.11)的代数精确度至少是 n . 特别地, 当 n 为偶数时, 牛顿-柯特斯求积公式的代数精确度可以达到 $n+1$.

证明 (主要证明定理后半部分内容)

验证当 $n=2k$ 时, 公式对 $f(x) = x^{n+1}$ 精确成立, 由误差

$$\begin{aligned} R &= \int_a^b \frac{f^{(n+1)}(\xi)}{(n+1)!} (x) dx = \int_a^b \frac{f^{(n+1)}(\xi)}{(n+1)!} (x) dx \\ &= \int_{x=a}^{x=b} \frac{h^{n+2}}{(n+1)!} t(t-1)\dots(t-n) dt \\ &= \frac{h^{n+2}}{(n+1)!} \int_0^{2k} t(t-1)\dots(t-k)(t-k-1) \\ &\quad \dots(t-2k-1)(t-2k) dt \end{aligned}$$

$$u = t - k \quad h^{n+2} \int_{-k}^k (u+k)(u+k-1)\dots u(u-1)\dots(u-k+1)(u-k)du,$$

令

$$H(u) = (u+k)(u+k-1)\dots u(u-1)\dots(u-k+1)(u-k),$$

则

$$H(-u) = (-1)^{2k+1} H(u) = -H(u).$$

即 $H(u)$ 是奇函数, 故 $R = 0$. 这说明, 当 n 为偶数时, 牛顿-柯特斯求积公式的代数精确度可达 $n+1$.

辛普森求积公式, 即 $n=2$ 时的牛顿-柯特斯公式, 其代数精确度为 3.

二、高斯型求积公式

当节点等距时, 插值型求积公式的代数精确度是 n 或 $n+1$. 若对节点适当选择, 可提高插值型求积公式的代数精确度. 对具有 $n+1$ 个节点的插值型求积公式, 其代数精确最高可达 $2n+1$.

定义 2 将 $n+1$ 个节点的具有 $2n+1$ 次代数精确度的插值型求积公式

$$\int_a^b f(x) dx \approx \sum_{k=0}^n A_k f(x_k)$$

称为高斯型求积公式, 节点 x_k 称为高斯点, A_k 称为高斯系数.

对于高斯型求积公式, 下面主要讨论如何确定高斯点 x_k 及高斯系数 A_k .

我们以 $\int_{-1}^1 f(x) dx$ 为例, 一点高斯公式是中矩形公式

$$\int_{-1}^1 f(x) dx \approx 2f(0),$$

其高斯点为 $x_0 = 0$, 系数 $A_0 = 2$.

现推导两点高斯公式

$$\int_{-1}^1 f(x) dx = A_0 f(x_0) + A_1 f(x_1)$$

具有三次代数精确度,即要求对 $f(x) = 1, x, x^2, x^3$ 准确成立,有

$$\begin{cases} A_0 + A_1 = 2, \\ A_0 x_0 + A_1 x_1 = 0, \\ A_0 x_0^2 + A_1 x_1^2 = \frac{2}{3}, \\ A_0 x_0^3 + A_1 x_1^3 = 0, \end{cases}$$

解之得 $x_0 = -\frac{1}{\sqrt{3}}, x_1 = \frac{1}{\sqrt{3}}, A_0 = A_1 = 1$. 公式为

$$\int_{-1}^1 f(x) dx = f\left[-\frac{1}{\sqrt{3}}\right] + f\left[\frac{1}{\sqrt{3}}\right]. \quad (7.3.1)$$

对任意求积区间 $[a, b]$, 可通过变换 $x = \frac{b-a}{2}t + \frac{a+b}{2}$ 变到区间 $[-1, 1]$ 上, 这时

$$\int_a^b f(x) dx = \frac{b-a}{2} \int_{-1}^1 f\left[\frac{b-a}{2}t + \frac{a+b}{2}\right] dt.$$

相应的两点高斯型求积公式为

$$\int_a^b f(x) dx = \frac{b-a}{2} \left[f\left[\frac{a-b}{2\sqrt{3}} + \frac{a+b}{2}\right] + f\left[\frac{b-a}{2\sqrt{3}} + \frac{a+b}{2}\right] \right]. \quad (7.3.2)$$

更一般的高斯型求积公式虽可化为代数方程问题, 但求解困难. 我们给出高斯点的基本特性定理.

定理 3 节点 x_k ($k = 0, 1, \dots, n$) 为高斯点的充要条件是以这

些点为零点的多项式 $\pi_{n+1}(x) = \prod_{i=0}^n (x - x_i)$ 与任意的次数 n 的多项式 $P(x)$ 在 $[a, b]$ 上正交, 即

$$\int_a^b P(x) \pi_{n+1}(x) dx = 0.$$

证明 必要性 设 x_k ($k = 0, 1, \dots, n$) 是插值型求积公式的高斯点, $P(x)$ 是次数不超过 n 的多项式, 则 $P(x) \pi_{n+1}(x)$ 是次数

不超过 $2n+1$ 的多项式, 由高斯点定义及

$$\omega_{n+1}(x_k) = 0, \quad (k = 0, 1, \dots, n),$$

有
$$\int_a^b P(x) \omega_{n+1}(x) dx = \sum_{k=0}^n A_k P(x_k) \omega_{n+1}(x_k) = 0.$$

充分性 设 $\omega_{n+1}(x)$ 与任意的次数不超过 n 的多项式正交, 设 $f(x)$ 是任一次数不超过 $2n+1$ 的多项式, 则必存在次数不超过 n 的多项式 $P(x), Q(x)$, 使

$$f(x) = P(x) \omega_{n+1}(x) + Q(x).$$

由插值型求积公式至少具有 n 次代数精度, 且

$$\omega_{n+1}(x_k) = 0, \quad k = 0, 1, \dots, n,$$

故有

$$\begin{aligned} \int_a^b f(x) dx &= \int_a^b P(x) \omega_{n+1}(x) dx + \int_a^b Q(x) dx \\ &= 0 + \int_a^b Q(x) dx = \sum_{k=0}^n A_k Q(x_k) \\ &= \sum_{k=0}^n A_k [P(x_k) \omega_{n+1}(x_k) + Q(x_k)] \\ &= \sum_{k=0}^n A_k f(x_k). \end{aligned}$$

可见, 求积公式至少具有 $2n+1$ 次代数精确度. 而对于 $2n+2$ 次多项式

$$f(x) = \omega_{n+1}^2(x),$$

有
$$\int_a^b \omega_{n+1}^2(x) dx > 0.$$

所以, 求积公式的代数精确度是 $2n+1$, x_k ($k = 0, 1, \dots, n$) 是高斯点.

由定理 3 可知:

(1) 具有 $n+1$ 个节点的插值型求积公式的代数精确度最高是 $2n+1$, 因此, 高斯型求积公式是代数精确度最高的求积公式.

(2) 定理给出了求高斯点的方法. 找与任意的次数不超过 n

的多项式 $P(x)$ 在 $[a, b]$ 上正交的多项式

$$P_{n+1}(x) = \prod_{k=0}^n (x - x_k),$$

其零点 x_k ($k=0, 1, \dots, n$) 即为高斯点.

三、勒让德(Legendre) 多项式

以高斯点 x_k ($k=1, 2, \dots, n$) 为零点的 n 次多项式

$$P_n(x) = P_n(x) = \prod_{k=1}^n (x - x_k), \quad (7.3.3)$$

式(7.3.3)称为勒让德多项式.

在 $[-1, 1]$ 上, 可以证明勒让德多项式为

$$P_n(x) = \frac{1}{2^n n!} \frac{d^n}{dx^n} [(x^2 - 1)^n]. \quad (7.3.4)$$

由此即可得出勒让德多项式, 例如

$$P_1(x) = x, \quad P_2(x) = x^2 - \frac{1}{2},$$

$$P_3(x) = x^3 - \frac{3}{2}x, \quad P_4(x) = x^4 - \frac{30}{35}x^2 + \frac{3}{35}, \quad \dots$$

这样, 求勒让德多项式的零点即可得到高斯点 x_k , 进而求出求积系数 A_k , 如三点高斯型求积公式为

$$\int_{-1}^1 f(x) dx \approx \frac{5}{9} f\left[-\sqrt{\frac{3}{5}}\right] + \frac{8}{9} f(0) + \frac{5}{9} f\left[\sqrt{\frac{3}{5}}\right]. \quad (7.3.5)$$

高斯型求积公式代数精确度高, 但节点较多时, 求节点和系数复杂, 可用复化方法处理.

§ 4 数值微分

一、差商型求导公式

对于函数的表达式复杂, 或函数以表格形式给出, 可利用数值

方法求其导数, 这类问题称为数值微分. 统一可表述为: 给定函数表 $(x_i, f(x_i))$ 或 (x_i, y_i) ($i = 0, 1, \dots, n$), 求函数 $f(x)$ 在节点 x_i 处的导数值.

最简单的数值微分公式建立是用节点 x_k 处的差商代替微商. 若为等距节点, 设 $h = x_{k+1} - x_k$, 则有

$$f'(x_k) = \frac{f(x_k + h) - f(x_k)}{h} + O(h) = \frac{f(x_{k+1}) - f(x_k)}{h}, \quad (7.4.1)$$

$$f'(x_k) = \frac{f(x_k) - f(x_k - h)}{h} + O(h) = \frac{f(x_k) - f(x_{k-1})}{h}, \quad (7.4.2)$$

$$f'(x_k) = \frac{f(x_k + h) - f(x_k - h)}{2h} + O(h^2) = \frac{f(x_{k+1}) - f(x_{k-1}))}{2h}. \quad (7.4.3)$$

公式(7.4.1), (7.4.2), (7.4.3)分别称为数值微分的向前差商, 向后差商及中心差商公式.

类似地, 可得到

$$f'(x_k) = \frac{f(x_{k+1}) - 2f(x_k) + f(x_{k-1}))}{h^2} + O(h^2). \quad (7.4.4)$$

以上数值微分公式简洁, 可利用节点值快速计算节点的导数, 但精度较低, 在实际计算中, 步长 h 应较小.

二、插值型求导公式

利用数据表构造函数 $f(x)$ 的插值多项式 $P_n(x)$, 并取 $P_n(x)$ 的值作为 $f(x)$ 的近似值, 这样建立的数值公式 $f'(x) \approx P_n'(x)$ 称为插值型求导公式.

设 $P_n(x)$ 是满足插值条件

$$P_n(x_i) = f(x_i) \quad (i = 0, 1, \dots, n)$$

的插值多项式, 则余项

$$f(x) - P_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega_{n+1}(x),$$

式中 ξ 是 x 的函数, 求导

$$f'(x) - P'_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega_{n+1}(x) + \frac{\omega_{n+1}(x)}{(n+1)!} \frac{d}{dx} f^{(n+1)}(\xi). \quad (7.4.5)$$

由于 ξ 与 x 的具体关系无法知道, (7.4.5) 中第二项 $\frac{d}{dx} f^{(n+1)}(\xi)$ 无法求得. 因此, 对任意给定的点 x , 误差 $f(x) - P_n(x)$ 可能很大. 为此, 我们限定求节点 x_i ($i = 0, 1, \dots, n$) 处的导数值, 于是 $\omega_{n+1}(x_i) = 0$, 数值微分公式为

$$f'(x_i) = P'_n(x_i) + \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega'_{n+1}(x_i) \quad (i = 0, 1, \dots, n). \quad (7.4.6)$$

下面是节点等距分布时, 常用的数值微分公式.

(1) 一阶两点公式

$$f'(x_i) = \frac{1}{h}(y_{i+1} - y_i) - \frac{h}{2}f^{(3)}(\xi_1), \quad \xi_1 \in (x_i, x_{i+1}),$$

$$(i = 0, 1, \dots, n-1),$$

$$f'(x_i) = \frac{1}{h}(y_i - y_{i-1}) - \frac{h}{2}f^{(3)}(\xi_2), \quad \xi_2 \in (x_{i-1}, x_i),$$

$$(i = 1, \dots, n). \quad (7.4.7)$$

(2) 一阶三点公式

$$f'(x_i) = \frac{1}{2h}(-3y_i + 4y_{i+1} - y_{i+2}) + \frac{h^2}{3}f^{(3)}(\xi_1), \quad \xi_1 \in (x_i, x_{i+2}),$$

$$f'(x_i) = \frac{1}{2h}(-y_{i-1} + y_{i+1}) - \frac{h^2}{6}f^{(3)}(\xi_2), \quad \xi_2 \in (x_{i-1}, x_{i+1}),$$

$$f'(x_i) = \frac{1}{2h}(y_{i-2} - 4y_{i-1} + 3y_i) + \frac{h^2}{3}f^{(3)}(\xi_3), \quad \xi_3 \in (x_{i-2}, x_i).$$

(7.4.8)

用插值多项式 $P_n(x)$ 作为 $f(x)$ 的近似函数, 还可以建立高阶数值微分公式

$$f^{(k)}(x_i) = P_n^{(k)}(x_i).$$

(3) 二阶三点公式

$$f'(x_i) = \frac{1}{h^2}(y_{i-1} - 2y_i + y_{i+1}) - \frac{h^2}{12}f^{(4)}(\xi), \quad \xi \in (x_{i-1}, x_{i+1}).$$

在实际计算数值微分时, 要特别注意误差分析. 由于数值微分对舍入误差较敏感, 往往计算不稳定. 还需指出, 当插值多项式 $P_n(x)$ 收敛到 $f(x)$ 时, $P_n(x)$ 不一定收敛到 $f'(x)$. 为避免这方面的问题, 可用样条插值函数的导函数代替函数 $f(x)$ 的导函数.

本章小结

本章主要介绍了数值积分和微分的一些常用方法.

牛顿-柯特斯公式是在等距节点情形下的插值型求积公式, 其简单情形如梯形公式, 辛普森公式等.

复化求积公式是改善求积公式精度的一种行之有效的方法, 特别是复化梯形公式、复化辛普森公式, 使用方便, 在实际计算中常常使用.

龙贝格求积公式是在区间逐次分半过程中, 对用梯形法所得的近似值进行多级“修正”, 而获得的准确程度较高的求积分近似值的一种方法.

高斯型求积公式是一种高精度的求积公式. 在求积节点数相同, 即计算量相近的情况下, 利用高斯型求积公式往往可以获得准确度较高的积分近似值, 但需确定高斯点, 且当节点数据改变时, 所有数据都要重新查表计算.

数值微分仅介绍了简单形式的差商型和插值型求导公式, 在精度要求不高时可采用.

对具体实际问题而言, 一个公式使用的效果如何, 与被积分、

被微分的函数性态及计算结果的精度要求等有关. 我们要根据具体问题, 选择合适的公式进行计算.

算法与程序设计实例

用辛普森公式计算积分.

算法

复化辛普森公式为

$$S_n = \frac{h}{6} \sum_{k=0}^{n-1} \left[f(x_k) + 4f\left(x_k + \frac{h}{2}\right) + f(x_{k+1}) \right],$$

计算过程为:

(1) 令 $h = (b - a)/n$, $s_1 = f(a + h/2)$, $s_2 = 0$;

(2) 对 $k = 1, 2, \dots, n-1$, 计算

$$s_1 = s_1 + f(a + kh + h/2), \quad s_2 = s_2 + f(a + kh);$$

(3) $s = \frac{h}{6}(f(a) + 4s_1 + 2s_2 + f(b))$.

实例

例 1 用复化辛普森公式计算积分 $I = \int_0^1 \frac{1}{1+x^2} dx$.

程序和输出结果

```
# include <stdio.h>
# include <conio.h>
void main()
{
    int i, n = 2;
    float s;
    float f(float);
    float Simpson(float (*)(float), float, float, int);
    for(i = 0; i <= 2; i++)
    {
```



```

        s= Simpson( f, 0, 1, n);
        printf( s( %d)= %f\n , n, s);
        n*= 2;
    }
    getch();
}

float Simpson( float (* f)( float), float a, float b, int n)
{
    int k;
    float s, s1, s2= 0.0;
    float h= ( b- a)/ n;
    s1= f(a+ h/ 2);
    for(k= 1; k<= n- 1; k++ )
    {
        s1+= f(a+ k* h+ h/ 2);
        s2+= f(a+ k* h);
    }
    s= h/ 6* ( f(a)+ 4* s1+ 2* s2+ f(b));
    return s;
}

float f( float x)
{
    return 1/ ( 1+ x* x);
}

```

输出结果为:

```

s( 2)= 0. 785392,
s( 4)= 0. 785398,
s( 8)= 0. 785398.

```

说明: 本例运行了三次, 当 $n = 2^3 = 8$ 时, 就与 $n = 2^2 = 4$ 时有 6 位数字相同, 若用复化梯形法计算, 当 $n = 512$ 时有此结果.

例 2 用复化辛普森公式计算积分 $I = \int_0^1 \frac{\sin x}{x} dx$.

只要将函数定义为

```
float f(float x)
{
    if(x == 0) return 1;
    else return sin(x)/x;
}
```

输出结果为:

$$s(2) = 0.946087,$$

$$s(4) = 0.946083,$$

$$s(8) = 0.946083.$$

思考题

1. 叙述数值求积的基本思想方法.
2. 何谓插值型求积公式? 它的截断误差如何表示?
3. “复化求积”与分段插值的思想方法有何联系? 梯形公式、辛普森公式、柯特斯公式及其复化公式都具有什么形式? 这 3 个复化公式的截断误差各是步长 h 的几阶无穷小量?
4. 龙贝格求积公式是怎样形成的? 怎样用龙贝格方法求积分的近似值? 给定允许误差范围, 怎样检查所求结果是在允许误差范围内?
5. 何谓代数精确度? 说高斯型求积公式具有最高代数精确度的含义是什么?
6. 高斯积分和高斯点是如何定义的? 何谓两点高斯公式? 已

知区间 $[-1, 1]$ 上的高斯公式, 如何构造一般区间 $[a, b]$ 上的高斯公式?

7. 插值型求导公式怎样形成? 误差怎样估计?

习 题 七

1. 分别用梯形公式和辛普森公式计算积分

$$I = \int_0^1 e^{-x} dx,$$

并估计误差(计算取 5 位小数).

2. 证明柯特斯系数 $C_i^{(n)}$ 具有性质 $\sum_{i=0}^n C_i^{(n)} = 1$.

3. 推导出中矩形公式及其截断误差:

$$\int_a^b f(x) dx - (b-a)f\left[\frac{a+b}{2}\right],$$

$$R[f] = \frac{f''(\xi)}{24}(b-a)^3, \quad (a, b),$$

并说明该公式的几何意义.

4. 已知连续函数 $f(x)$ 的下列数据:

x_k	1.8	2.0	2.2	2.4	2.6
$f(x_k)$	3.12014	4.42659	6.04241	8.03014	10.46675

用柯特斯公式计算积分 $\int_{1.8}^{2.6} f(x) dx$ (计算取 5 位小数).

5. 分别用复化梯形和复化辛普森公式计算积分 $I = \int_0^{10} e^{-x^2} dx$ (取 11 个节点, 6 位小数计算).

6. 用积分 $\int_2^8 \frac{1}{x} dx = 2\ln 2$ 计算 $\ln 2$, 要使计算误差不超过 $\frac{1}{2} \times 10^{-5}$, 问用复化梯形公式时至少取多少个节点?

7. 用龙贝格公式计算积分 $I = \int_0^1 \frac{2}{\sqrt{x}} e^{-x} dx$, 要求误差不超过 10^{-5} .

8. 证明求积公式

$$\int_{-1}^1 f(x) dx \approx \frac{1}{9} [5f(-\sqrt{0.6}) + 8f(0) + 5f(\sqrt{0.6})]$$

对于不高于 5 次的多项式准确成立, 并计算 $I = \int_0^1 \frac{\sin x}{1+x} dx$ (取 5 位小数).

9. 证明高斯求积公式系数

$$A_k = \int_{-1}^1 l_k^2(x) dx,$$

其中
$$l_k = \frac{\prod_{n+1}^{n+1}(x)}{(x - x_k) \prod_{n+1}^{n+1}(x_k)}, \quad k = 0, 1, \dots, n.$$

10. 设

$$f(x) \in C^4[x_0 - 2h, x_0 + 2h], \quad h > 0, \\ x_k = x_0 + kh, \quad f(x_k) = f_k \quad (k = \pm 2, \pm 1, 0).$$

求证:

$$(1) \quad f(x_0) = \frac{1}{12h} [f_{-2} - 8f_{-1} + 8f_1 - f_2] + O(h^4);$$

$$(2) \quad f(x_0) = \frac{1}{h^2} [f_1 + f_{-1} - 2f_0] + O(h^2).$$

第八章 常微分方程的数值解法

常微分方程的求解问题在实践中经常遇到,但我们只知道一些特殊类型的常微分方程的解析解.在科学和工程问题中遇到的常微分方程往往很复杂,在许多情况下都不可能求出解的表达式.另一方面,在许多实际问题中,并不需要方程解的表达式,而仅仅需要获得解在若干点上的近似值即可.因此,研究常微分方程的数值解法就很有必要.

本章着重讨论一阶常微分方程初值问题

$$\begin{cases} \frac{dy}{dx} = f(x, y), & (x_0 \leq x) \\ y(x_0) = y_0 \end{cases} \quad (8.0.1)$$

的数值解法.理论上,函数 $f(x, y)$ 对于 y 满足李普希兹 (Lipschitz) 条件:

$$f(x, y_1) - f(x, y_2) \leq L |y_1 - y_2|,$$

则初值问题(8.0.1)存在惟一解.因此,在本章讨论中,我们总假定 $f(x, y)$ 满足李普希兹条件.

所谓数值解法,就是寻求解 $y(x)$ 在一系列离散节点

$$a \leq x_0 < x_1 < x_2 < \dots < x_n < x_{n+1} < \dots \leq b$$

上的近似值 $y_0, y_1, y_2, \dots, y_n, y_{n+1}, \dots$, 其相邻两个节点的距离 $h_n = x_{n+1} - x_n$ 称为步长,我们总假设节点是等距离的,即 h_n 为常数 h , 这时

$$x_n = x_0 + nh, \quad n = 0, 1, 2, \dots,$$

此时节点 x_n 所对应的函数值为

$$y_n = y(x_0 + nh), \quad n = 0, 1, 2, \dots$$

§ 1 欧拉(Euler)方法

一、欧拉公式

在方程(8.0.1)中,由差商替代导数,即

$$y'(x_n) \approx \frac{y(x_{n+1}) - y(x_n)}{h},$$

结果有

$$y(x_{n+1}) \approx y(x_n) + hf(x_n, y(x_n)).$$

再用 y_n 近似代替 $y(x_n)$, 便导出计算公式

$$\begin{cases} y_{n+1} = y_n + hf(x_n, y_n), \\ y_0 = y(x_0), \end{cases} \quad n = 0, 1, 2, \dots, \quad (8.1.1)$$

公式(8.1.1)称为显式欧拉公式. 由初值 y_0 , 就可逐步算出 y_1, y_2, \dots

若用向后差商替代导数, 即

$$y'(x_{n+1}) \approx \frac{1}{h}[y(x_{n+1}) - y(x_n)],$$

便可导出计算公式

$$y_{n+1} = y_n + hf(x_{n+1}, y_{n+1}). \quad (8.1.2)$$

公式(8.1.2)称为隐式欧拉公式. 这类隐式格式的计算远比显式格式困难.

类似地, 利用中心差商替代导数, 即

$$y'(x_n) \approx \frac{1}{2h}[y(x_{n+1}) - y(x_{n-1})],$$

便可导出公式

$$y_{n+1} = y_{n-1} + 2hf(x_n, y_n). \quad (8.1.3)$$

公式(8.1.3)称为两步欧拉公式. 在计算 y_{n+1} 时, 需利用前两步的信息 y_n, y_{n-1} .

二、欧拉预估-校正方法

对方程 $y' = f(x, y)$ 的两端从 x_n 到 x_{n+1} 积分, 得

$$y(x_{n+1}) = y(x_n) + \int_{x_n}^{x_{n+1}} f(x, y(x)) dx. \quad (8.1.4)$$

在上式中, 利用梯形公式计算积分项, 便有

$$y(x_{n+1}) = y(x_n) + \frac{h}{2} [f(x_n, y(x_n)) + f(x_{n+1}, y(x_{n+1}))].$$

再用 y_n 代替 $y(x_n)$ 的近似值, 便可导出计算公式

$$y_{n+1} = y_n + \frac{h}{2} [f(x_n, y_n) + f(x_{n+1}, y_{n+1})], \quad (8.1.5)$$

公式(8.1.5)称为梯形公式. 可视为显式欧拉格式(8.1.1)与隐式欧拉格式(8.1.2)的算术平均. 它仍是隐式, 不便于直接计算.

在实际计算中, 可将欧拉公式与梯形公式结合使用. 先由显式欧拉公式求得一个初步的近似值, 记为 y_{n+1} , 称之为预报值. 再将预报值代入梯形公式, 即由 y_{n+1} 代替 y_{n+1} , 直接计算, 这一步骤称为校正. 这样, 建立的预估-校正系统

$$\begin{cases} \text{预估} & y_{n+1} = y_n + hf(x_n, y_n), \\ \text{校正} & y_{n+1} = y_n + \frac{h}{2} [f(x_n, y_n) + f(x_{n+1}, y_{n+1})]. \end{cases} \quad (8.1.6)$$

公式(8.1.6)称为欧拉预估-校正公式, 或改进的欧拉公式. 这是一种显式公式, 是对隐式梯形公式的改进, 可以直接计算.

为便于上机编程计算, (8.1.6)可改写为

$$\begin{cases} y_p = y_n + hf(x_n, y_n), \\ y_c = y_n + hf(x_{n+1}, y_p), \\ y_{n+1} = \frac{1}{2}(y_p + y_c). \end{cases} \quad (8.1.7)$$

例1 利用欧拉公式和预估-校正公式求初值问题

$$\begin{cases} y' = y - \frac{2x}{y}, \\ y(0) = 1 \end{cases}$$

在区间[0, 1]上的数值解(取 $h=0.1$), 并与精确解 $y=\sqrt{2x+1}$ 进行比较.

解 将 $f(x,y)=y-\frac{2x}{y}$ 代入有关公式.

(1) 欧拉公式计算

$$\begin{cases} y_{n+1}=y_n+h\left[y_n-\frac{2x_n}{y_n}\right] & (n=0,1,2,\dots,9), \\ y_0=1, \quad h=0.1. \end{cases}$$

(2) 预估-校正公式计算

$$\begin{cases} y_{n+1}=y_n+h\left[y_n-\frac{2x_n}{y_n}\right], \\ y_{n+1}=y_n+\frac{h}{2}\left[y_n-\frac{2x_n}{y_n}+y_{n+1}-\frac{2x_{n+1}}{y_{n+1}}\right], \\ y_0=1, \quad h=0.1 \quad (n=0,1,2,\dots,9). \end{cases}$$

分别计算, 其结果为下表.

x_n	欧拉公式 y_n	预估-校正公式 y_n	精确值 $y_n=\sqrt{2x_n+1}$
0.0	1	1	1
0.1	1.1	1.095909	1.095445
0.2	1.191818	1.184097	1.183216
0.3	1.277438	1.266201	1.264911
0.4	1.358213	1.343360	1.341641
0.5	1.435133	1.416402	1.414214
0.6	1.508966	1.485956	1.483240
0.7	1.580338	1.552514	1.549193
0.8	1.649783	1.616475	1.612452
0.9	1.717779	1.678166	1.673320
1.0	1.784771	1.737867	1.732051

从上表可看出, 用欧拉公式计算的数值解有两位有效数字, 而用预估-校正公式计算的数值解有 3 位有效数字.

三、欧拉方法的误差估计

定义 1 假定 y_n 为准确值, 即 $y_n = y(x_n)$, 在此前提下, 用某种数值方法计算 y_{n+1} 的误差 $R_n = y(x_{n+1}) - y_{n+1}$ 称为该数值方法计算 y_{n+1} 的局部截断误差.

定义 2 若某一数值方法的局部截断误差为 $R_n = O(h^{p+1})$, p 为正整数, 则称这种数值方法为 p 阶方法, 或说该方法具有 p 阶精度.

下面我们着重讨论欧拉方法的局部截断误差及其阶.

由泰勒公式

$$\begin{aligned} y(x_{n+1}) &= y(x_n + h) \\ &= y(x_n) + hy'(x_n) + \frac{h^2}{2!}y''(x_n) + \frac{1}{3!}h^3y'''(x_n) + \dots \end{aligned}$$

对于显式欧拉公式(8.1.1)

$$\begin{aligned} y_{n+1} &= y_n + hf(x_n, y_n) = y(x_n) + hf(x_n, y_n) \\ &= y(x_n) + hy'(x_n), \end{aligned}$$

则其局部截断误差为

$$y(x_{n+1}) - y_{n+1} = \frac{h^2}{2!}y''(x_n) + \dots = O(h^2). \quad (8.1.8)$$

因此, 显式欧拉公式的局部截断误差为 $O(h^2)$, 该方法是一阶方法.

对于梯形公式(8.1.5), 由梯形求积公式(7.1.15)的误差

$$R_T(f) = \frac{h^3}{12} \max_{a \leq x \leq b} |y''(x)|,$$

则其局部截断误差为 $O(h^3)$. 因此, 梯形公式是二阶方法.

对于欧拉预估-校正方法(8.1.6), 将公式改写为

$$\begin{cases} y_{n+1} = y_n + \frac{1}{2}(k_1 + k_2), \\ k_1 = hf(x_n, y_n), \\ k_2 = hf(x_n + h, y_n + k_1). \end{cases} \quad (8.1.9)$$

在 $y_n = y(x_n)$ 前提下,

$$k_1 = hf(x_n, y_n) = hy(x_n),$$

$$k_2 = hf(x_n + h, y_n + k_1) = hf(x_n + h, y(x_n) + k_1)$$

$$= h \left[f(x_n, y(x_n)) + h \frac{\partial f}{\partial x}(x_n, y(x_n)) \right. \\ \left. + k_1 \frac{\partial f}{\partial y}(x_n, y(x_n)) + O(h^2) \right]$$

$$= hf(x_n, y(x_n)) + h^2 \left[\frac{\partial f}{\partial x}(x_n, y(x_n)) \right. \\ \left. + f(x_n, y(x_n)) \frac{\partial f}{\partial y}(x_n, y(x_n)) + O(h) \right]$$

$$= hy(x_n) + h^2 y'(x_n) + O(h^3).$$

将 k_1, k_2 代入式(8.1.9)有

$$y_{n+1} = y_n + hy(x_n) + \frac{1}{2}h^2 y'(x_n) + O(h^3).$$

与泰勒公式比较, 则其局部截断误差为

$$y(x_{n+1}) - y_{n+1} = \frac{h^3}{3!} y''(x_n) + \dots = O(h^3) = O(h^3).$$

因此, 欧拉预估-校正公式是二阶方法.

§ 2 龙格-库塔(Runge-Kutta)方法

一、龙格-库塔方法的基本思想

在上一节, 我们得到了一些基本的求微分方程的数值方法, 从误差估计知道, 这些方法的局部截断误差较大, 精度较低. 我们希望得到更高阶的方法.

考察差商 $\frac{y(x_{n+1}) - y(x_n)}{h}$. 由微分中值定理, 存在点 ξ , 使得

$$\frac{y(x_{n+1}) - y(x_n)}{h} = y'(\xi), \quad (\xi, x_{n+1}).$$

便由方程 $y' = f(x, y(x))$ 得

$$y(x_{n+1}) = y(x_n) + hf(\xi, y(\xi)),$$

其中 $k^* = f(\xi, y(\xi))$ 称为 $[x_n, x_{n+1}]$ 上的平均斜率. 这样, 只要对平均斜率提供一种近似算法, 便相应导出一种计算格式. 显然, 显式欧拉公式(8.1.1)就是以 $k_1 = f(x_n, y_n)$ 作为平均斜率 k^* 的近似. 欧拉预估-校正公式(8.1.9)就是以 x_n 与 x_{n+1} 两个点的斜率值 k_1 与 k_2 取算术平均作为平均斜率 k^* 的近似.

这个处理过程启示我们, 若设法在 $[x_n, x_{n+1}]$ 内多预报几个点的斜率值, 然后将它们加权平均作为平均斜率 k^* , 则有可能构造出具有更高精度的计算格式. 这就是龙格-库塔方法的基本思想.

二、二阶龙格-库塔公式

我们推广欧拉预估-校正方法, 考察区间 $[x_n, x_{n+1}]$ 内任一点

$$x_{n+p} = x_n + ph, \quad 0 < p < 1.$$

用 x_n 和 x_{n+p} 两个点的斜率值 k_1 与 k_2 加权平均得到平均斜率 k^* . 即令

$$y_{n+1} = y_n + h[(1-\alpha)k_1 + \alpha k_2],$$

其中 α 为待定系数. 类似于欧拉预估-校正方法, 取

$$k_1 = f(x_n, y_n), \quad y_{n+p} = y_n + phk_1, \quad k_2 = f(x_{n+p}, y_{n+p}),$$

这样便有如下计算格式

$$\begin{cases} y_{n+1} = y_n + h[(1-\alpha)k_1 + \alpha k_2], \\ k_1 = f(x_n, y_n), \\ k_2 = f(x_n + ph, y_n + phk_1). \end{cases} \quad (8.2.1)$$

我们希望适当选取参数 α, p , 使得计算格式(8.2.1)具有较高精度.

现仍假定 $y_n = y(x_n)$, 分别将 k_1 和 k_2 泰勒展开,

$$k_1 = f(x_n, y_n) = y'(x_n),$$

$$k_2 = f(x_{n+p}, y_{n+p})$$

$$= f(x_n, y_n) + ph[f_x(x_n, y_n) + f(x_n, y_n)f_y(x_n, y_n)] + O(h^2)$$

$$= y'(x_n) + phy''(x_n) + O(h^2).$$

代入(8.2.1)式

$$y_{n+1} = y(x_n) + hy'(x_n) + \frac{1}{2}h^2 y''(x_n) + O(h^3),$$

与泰勒展开式

$$y(x_{n+1}) = y(x_n) + hy'(x_n) + \frac{h^2}{2}y''(x_n) + O(h^3)$$

相比较系数,要使(8.2.1)具有二阶精度,须使 $p = \frac{1}{2}$. 因此,我们

把满足 $p = \frac{1}{2}$ 的公式(8.2.1)统称为二阶龙格-库塔格式.

特别地,当 $p = 1, \alpha = \frac{1}{2}$ 时, (8.2.1)就是欧拉预估-校正公式.

若取 $p = \frac{1}{2}, \alpha = 1$, 则公式(8.2.1)形式为

$$\begin{cases} y_{n+1} = y_n + hk_2, \\ k_1 = f(x_n, y_n), \\ k_2 = f\left[x_n + \frac{h}{2}, y_n + \frac{h}{2}k_1\right]. \end{cases} \quad (8.2.2)$$

该公式可看作用中点斜率值 k_2 取代平均斜率 k^* , 公式(8.2.2)也可称为中点格式,它具有二阶精度.

三、高阶龙格-库塔公式

为了进一步提高精度,在 $[x_n, x_{n+1}]$ 上可取多个点,预报相应点的斜率值,对这些斜率值加权平均作为平均斜率值. 利用泰勒展开,比较相应系数,从而确定在尽可能高的精度下有关参数应满足的条件.

其中较常用的三阶龙格-库塔公式有

$$\begin{cases} y_{n+1} = y_n + \frac{h}{6}[k_1 + 4k_2 + k_3], \\ k_1 = f(x_n, y_n), \\ k_2 = f\left[x_n + \frac{h}{2}, y_n + \frac{h}{2}k_1\right], \\ k_3 = f(x_n + h, y_n + h(-k_1 + 2k_2)). \end{cases} \quad (8.2.3)$$

经典的四阶龙格-库塔公式为

$$\begin{cases} y_{n+1} = y_n + \frac{h}{6}[k_1 + 2k_2 + 2k_3 + k_4], \\ k_1 = f(x_n, y_n), \\ k_2 = f\left(x_n + \frac{h}{2}, y_n + \frac{h}{2}k_1\right), \\ k_3 = f\left(x_n + \frac{h}{2}, y_n + \frac{h}{2}k_2\right), \\ k_4 = f(x_n + h, y_n + hk_3). \end{cases} \quad (8.2.4)$$

从理论上讲,可以构造任意高阶的龙格-库塔公式.但实践证明,高于四阶的龙格-库塔公式,不但计算量大,而且精确度并不一定提高.在实际计算中,四阶龙格-库塔公式是精度及计算量较理想的公式.

例 1 用经典四阶龙格-库塔方法求解初值问题

$$\begin{cases} y' = y - \frac{2x}{y}, \\ y(0) = 1 \end{cases}$$

在 $[0, 1]$ 上的数值解(取 $h = 0.2$).

解 利用经典四阶龙格-库塔公式有

$$\begin{cases} k_1 = y_n - \frac{2x_n}{y_n}, \\ k_2 = y_n + 0.1k_1 - \frac{2(x_n + 0.1)}{y_n + 0.1k_1}, \\ k_3 = y_n + 0.1k_2 - \frac{2(x_n + 0.1)}{y_n + 0.1k_2}, \\ k_4 = y_n + 0.2k_3 - \frac{2(x_n + 0.2)}{y_n + 0.2k_3}, \\ y_{n+1} = y_n + \frac{0.1}{3}(k_1 + 2k_2 + 2k_3 + k_4). \end{cases} \quad n = 0, 1, 2, \dots$$

计算结果见下表.

x_n	0	0.2	0.4	0.6	0.8	1.0
y_n	1	1.18323	1.34167	1.48324	1.61251	1.73214
$y(x_n)$	1	1.18322	1.34164	1.48328	1.61245	1.73205

该结果有四位有效数字,和本章§ 1 例 1 相比,可见四阶龙格-库塔方法的精确度高于欧拉公式和预估-校正公式.

§ 3 线性多步方法

一、线性多步方法的基本思想

在微分方程求解的递推公式中,计算 y_{n+1} 之前,事实上,近似值 y_0, y_1, \dots, y_n 已经求出,若能充分利用第 $n+1$ 步前面的多步信息来计算 y_{n+1} ,就可希望获得较高的精度.这就是构造线性多步方法的基本思想.

我们已经知道,微分方程初值问题(8.0.1)等价于积分方程

$$y(x_{n+1}) = y(x_n) + \int_{x_n}^{x_{n+1}} f(x, y(x)) dx.$$

用 k 次插值多项式 $P_k(x)$ 来代替 $f(x, y(x))$,即令 $f(x, y(x)) = P_k(x) + R_k(x)$,则有

$$y(x_{n+1}) = y(x_n) + \int_{x_n}^{x_{n+1}} P_k(x) dx + \int_{x_n}^{x_{n+1}} R_k(x) dx.$$

舍去余项

$$R_n = \int_{x_n}^{x_{n+1}} R_k(x) dx,$$

设 $y_n = y(x_n)$,而 y_{n+1} 为 $y(x_{n+1})$ 的近似值,便可得到一类线性多步方法的计算公式

$$y_{n+1} = y_n + \int_{x_n}^{x_{n+1}} P_k(x) dx. \tag{8.3.1}$$

$P_k(x)$ 分别取 0 次和 1 次多项式,就是我们已知的显式、隐式

欧拉公式和梯形公式. 若需要提高计算精度, 就要用更高次的插值多项式 $P_k(x)$ 来代替 $f(x, y(x))$.

二、阿达姆斯(Adams) 外插公式及其误差

在公式(8.3.1)中, 作三次插值多项式 $P_3(x)$, 选取 $x_n, x_{n-1}, x_{n-2}, x_{n-3}$ 作为插值节点, 记 $F(x) = f(x, y(x))$, 则 $F(x)$ 的三次插值多项式

$$P_3(x) = \sum_{i=0}^3 \left[\sum_{j=i}^3 \frac{x - x_{n-j}}{x_{n-i} - x_{n-j}} F(x_{n-i}) \right].$$

其插值余项为

$$R_3(x) = \frac{1}{4!} F^{(4)}(\xi) (x - x_n)(x - x_{n-1})(x - x_{n-2})(x - x_{n-3}),$$

$\xi \in [x_{n-3}, x_n]$

由公式(8.3.1), 令 $x = x_n + th$ (h 为步长), 则

$$\begin{aligned} \int_{x_n}^{x_{n+1}} P_3(x) dx &= \int_0^1 \left[\frac{1}{3!} F(x_n) (t+1)(t+2)(t+3) \right. \\ &\quad + \frac{1}{2} F(x_{n-1}) t(t+2)(t+3) \\ &\quad + \frac{1}{2} F(x_{n-2}) t(t+1)(t+3) \\ &\quad \left. + \frac{1}{3!} F(x_{n-3}) t(t+1)(t+2) \right] h dt \\ &= \frac{h}{24} [55F(x_n) - 59F(x_{n-1}) + 37F(x_{n-2}) \\ &\quad - 9F(x_{n-3})]. \end{aligned}$$

这样, 便有公式

$$\begin{aligned} y_{n+1} &= y_n + \frac{h}{24} [55f(x_n, y_n) - 59f(x_{n-1}, y_{n-1}) \\ &\quad + 37f(x_{n-2}, y_{n-2}) - 9f(x_{n-3}, y_{n-3})], \\ n &= 3, 4, 5, \dots \end{aligned} \quad (8.3.2)$$

公式(8.3.2)称为线性四步阿达姆斯显式公式. 由于插值多项式 $P_3(x)$ 是在 $[x_{n-3}, x_n]$ 上作出的, 而积分区间为 $[x_n, x_{n+1}]$, 所以(8.3.2)也称为阿达姆斯外插公式.

其局部截断误差就是数值积分的误差.

$$\begin{aligned} R_n &= \int_{x_n}^{x_{n+1}} R_3(x) dx \\ &= \int_{x_n}^{x_{n+1}} \frac{1}{4!} F^{(4)}(\xi)(x - x_n) \\ &\quad \cdot (x - x_{n-1})(x - x_{n-2})(x - x_{n-3}) dx, \end{aligned}$$

由于 $(x - x_n)(x - x_{n-1})(x - x_{n-2})(x - x_{n-3})$ 在 $[x_n, x_{n+1}]$ 上不变号, 并设 $F^{(4)}(x)$ 在 $[x_n, x_{n+1}]$ 上连续, 利用积分第二中值定理, 存在 $\xi \in [x_n, x_{n+1}]$ 使得

$$\begin{aligned} R_n &= \frac{1}{4!} F^{(4)}(\xi) \int_{x_n}^{x_{n+1}} (x - x_n)(x - x_{n-1}) \\ &\quad \cdot (x - x_{n-2})(x - x_{n-3}) dx \\ &= \frac{251}{720} h^5 F^{(4)}(\xi) = \frac{251}{720} h^5 y^{(5)}(\xi) = O(h^5). \end{aligned} \tag{8.3.3}$$

因此, 公式(8.3.2)是一个四阶公式.

注意到阿达姆斯外插公式要进行计算, 必须提供初值 y_0, y_1, y_2, y_3 . 实际计算中, 常用四阶龙格-库塔方法计算出这些初值. 然后再由阿达姆斯外插公式计算.

例 1 用阿达姆斯外插公式求解初值问题

$$\begin{cases} \frac{dy}{dx} = y - \frac{2x}{y}, \\ y(0) = 1 \end{cases}$$

在 $[0, 1]$ 上的数值解(取 $h = 0.1$).

解 先由四阶龙格-库塔方法求出初值, 结果为:

x_n	0	0.1	0.2	0.3
y_n	1	1.095446	1.183217	1.264916

然后由公式(8.3.2)计算其他点处的值, 结果为下表:

x_n	0.4	0.5	0.6	0.7	0.8	0.9	1.0
y_n	1.341551	1.414045	1.483017	1.548917	1.612114	1.672914	1.731566
$y(x_n)$	1.341641	1.414214	1.483240	1.549193	1.612452	1.673320	1.732051

三、阿达姆斯内插公式

在公式(8.3.1)中, 若以 $x_{n+1}, x_n, x_{n-1}, x_{n-2}$ 为插值节点作 $f(x, y(x))$ 的三次插值多项式, 类似于上段做法, 可得计算公式及截断误差

$$y_{n+1} = y_n + \frac{h}{24}[9f_{n+1} + 19f_n - 5f_{n-1} + f_{n-2}], \quad (8.3.4)$$

$$R_n = -\frac{19}{720}h^5 y^{(5)}(x_n) = O(h^5). \quad (8.3.5)$$

公式(8.3.4)称为线性三步阿达姆斯公式, 或称为阿达姆斯内插公式, 也是四阶方法.

公式(8.3.4)是隐式公式, 不便于直接使用. 仿照改进欧拉公式的构造方法, 将显式(8.3.2)与隐式(8.3.4)结合, 则有以下预估-校正公式

$$\left\{ \begin{array}{l} \text{预估} \quad y_{n+1} = y_n + \frac{h}{24}[55f_n - 59f_{n-1} + 37f_{n-2} - 9f_{n-3}], \\ \quad \quad f_{n+1} = f(x_{n+1}, y_{n+1}), \\ \text{校正} \quad y_{n+1} = y_n + \frac{h}{24}[9f_{n+1} + 19f_n - 5f_{n-1} + f_{n-2}], \\ \quad \quad n = 3, 4, 5, \dots \end{array} \right. \quad (8.3.6)$$

上面我们建立了两个四阶的线性多步公式, 在实际计算中经常使用. 从理论上, 还可以建立更高阶的线性多步公式, 但由于高阶拉格朗日插值多项式不一定一致地收敛于被插值函数(甚至出现龙格现象). 特别地, 它的导数更不一定能很好地近似被插值函数的导数, 所以建立更高阶的多步公式没有太大的实际意义.

§ 4 一阶微分方程组和高阶微分方程的数值解法

一、一阶微分方程组的数值解法

前面介绍了一阶常微分方程的各种解法,对微分方程组同样适用.其计算公式,截断误差推导与一阶方程类似,下面以两个未知函数的方程组为例,并直接给出计算公式.

设讨论的微分方程组初值问题为

$$\begin{cases} \frac{dy}{dt} = f(t, y, z), & y(t_0) = y_0, \\ \frac{dz}{dt} = g(t, y, z), & z(t_0) = z_0, \end{cases} \quad t_0 \leq t \leq T. \quad (8.4.1)$$

(1) 欧拉计算公式为

$$\begin{cases} y_{n+1} = y_n + hf(t_n, y_n, z_n), \\ z_{n+1} = z_n + hg(t_n, y_n, z_n). \end{cases} \quad (8.4.2)$$

(2) 标准四阶龙格-库塔计算公式为

$$\begin{cases} y_{n+1} = y_n + \frac{1}{6}(k_1 + 2k_2 + 2k_3 + k_4), \\ z_{n+1} = z_n + \frac{1}{6}(m_1 + 2m_2 + 2m_3 + m_4), \end{cases} \quad (8.4.3)$$

其中

$$\begin{cases} k_1 = hf(t_n, y_n, z_n), \\ m_1 = hg(t_n, y_n, z_n), \\ k_2 = hf(t_n + h/2, y_n + k_1/2, z_n + m_1/2), \\ m_2 = hg(t_n + h/2, y_n + k_1/2, z_n + m_1/2), \\ k_3 = hf(t_n + h/2, y_n + k_2/2, z_n + m_2/2), \\ m_3 = hg(t_n + h/2, y_n + k_2/2, z_n + m_2/2), \\ k_4 = hf(t_n + h, y_n + k_3, z_n + m_3), \\ m_4 = hg(t_n + h, y_n + k_3, z_n + m_3). \end{cases}$$

(3) 四阶阿达姆斯外插计算公式为

$$y_{n+1} = y_n + \frac{h}{24} [55f_n - 59f_{n-1} + 37f_{n-2} - 9f_{n-3}],$$

$$z_{n+1} = z_n + \frac{h}{24} [55g_n - 59g_{n-1} + 37g_{n-2} - 9g_{n-3}].$$

(8.4.4)

二、高阶微分方程的数值解法

对于高阶常微分方程初值问题, 可先化为含多个未知函数的一阶微分方程组的形式, 然后按方程组的方法求解. 下面以二阶常微分方程初值问题为例.

$$\begin{cases} \frac{d^2 y}{dx^2} = f\left(x, y, \frac{dy}{dx}\right), \\ y(x_0) = y_0, \quad \frac{dy}{dx}\bigg|_{x=x_0} = z_0, \end{cases} \quad x_0 \leq x \leq b. \quad (8.4.5)$$

令 $z = \frac{dy}{dx}$, 则方程(8.4.5)可化为方程组

$$\begin{cases} \frac{dy}{dx} = z, & y(x_0) = y_0, \quad x_0 \leq x \leq b, \\ \frac{dz}{dx} = f(x, y, z), & z(x_0) = z_0. \end{cases} \quad (8.4.6)$$

若用欧拉预估-校正公式求解, 则有计算公式

$$\begin{cases} y_{n+1} = y_n + \frac{1}{2}(k_1 + k_2), \\ z_{n+1} = z_n + \frac{1}{2}(m_1 + m_2), \end{cases} \quad (8.4.7)$$

其中

$$\begin{cases} k_1 = h z_n, \\ m_1 = h f(x_n, y_n, z_n), \\ k_2 = h(z_n + m_1), \\ m_2 = h f(x_n + h, y_n + k_1, z_n + m_1). \end{cases}$$

对于高于二阶的高阶微分方程, 可引入多个变量, 化为多个方

程的一阶微分方程组, 类似于上面的方法处理.

本章小结

本章着重介绍了常微分方程初值问题的数值解法, 主要有欧拉方法, 龙格-库塔方法及线性多步方法等.

欧拉方法是最简单、最基本的方法, 利用差商代替微商, 就可得到一系列欧拉公式. 这些公式形式简洁, 易于编程计算, 但精度较低, 可方便用于精度要求不高的近似计算.

龙格-库塔方法是利用区间上多个点的斜率值的加权平均的思想, 得出的高精度的计算公式. 特别是四阶龙格-库塔公式, 易于编程计算, 精度较高, 是常用的工程计算方法.

线性多步方法是在用插值多项式代替被积函数的基础上构造的, 它可利用前面若干步计算结果的信息, 使计算结果提高精度. 其中较常用的四阶阿达姆斯公式, 易于估计误差, 计算精度较高, 适用于 $f(x, y)$ 较复杂的情形. 但需利用其他方法提供初值.

本章最后, 简单介绍了一阶微分方程组和可化为一阶微分方程组的高阶微分方程的一些计算公式.

算法与程序设计实例

用改进欧拉方法求解一阶常微分方程初值问题.

算法概要

解一阶常微分方程初值问题

$$\begin{cases} y' = f(x, y), & a \leq x \leq b, \\ y(x_0) = y_0, \end{cases}$$

将区间 $[a, b]$ 作 n 等分, 取步长 $h = \frac{b-a}{n}$.

欧拉公式为

$$y_{i+1} = y_i + hf(x_i, y_i).$$

梯形公式为

$$y_{i+1} = y_i + \frac{h}{2}[f(x_i, y_i) + f(x_{i+1}, y_{i+1})].$$

改进欧拉方法,采用公式

$$\begin{cases} y_{i+1} = y_i + hf(x_i, y_i), \\ y_{i+1} = y_i + \frac{h}{2}[f(x_i, y_i) + f(x_{i+1}, y_{i+1})], \end{cases}$$

或表示为

$$\begin{cases} y_p = y_i + hf(x_i, y_i), \\ y_c = y_i + hf(x_{i+1}, y_p), \\ y_{i+1} = \frac{1}{2}(y_p + y_c). \end{cases}$$

实例

用改进欧拉方法解

$$\begin{cases} y' = -xy^2, & 0 \leq x \leq 5, \\ y(0) = 2. \end{cases}$$

程序和输出结果

```
# include <stdio.h>
# define N 20
void ModEuler(float (* f1)(float, float), float x0, float y0,
               float xn, int n)
{
    int i;
    float yp, yc, x = x0, y = y0, h = (xn - x0)/n;
    printf("x[0]= %f\ty[0]= %f\n", x, y);
    for(i= 1; i<= n; i++)
    {
        yp= y+ h* f1(x, y);
```

```

        x= x0+ i* h;
        yc= y+ h* f1(x, yp);
        y= ( yp+ yc)/ 2. 0;
        printf( x[ % d]= % f\ ty[ % d]= % f\n , i, x, i, y);
    }
}

void main()
{
    int i;
    float xn= 5. 0, x0= 0. 0, y0= 2. 0;
    void ModEuler(float (* )(float, float), float, float, float,
                    int);
    float f1(float, float);
    ModEuler(f1, x0, y0, xn, N);
    getch();
}

float f1(float x, float y)
{
    return - x* y* y;
}

```

输出结果为:

```

x[ 0]= 0. 000000,   y[ 0]= 2. 000000
x[ 1]= 0. 250000,   y[ 1]= 1. 875000
x[ 2]= 0. 500000,   y[ 2]= 1. 593891
x[ 3]= 0. 750000,   y[ 3]= 1. 282390
x[ 4]= 1. 000000,   y[ 4]= 1. 009621
x[ 5]= 1. 250000,   y[ 5]= 0. 793188
x[ 6]= 1. 500000,   y[ 6]= 0. 628151

```

$x[7] = 1.750000,$	$y[7] = 0.503730$
$x[8] = 2.000000,$	$y[8] = 0.409667$
$x[9] = 2.250000,$	$y[9] = 0.337865$
$x[10] = 2.500000,$	$y[10] = 0.282357$
$x[11] = 2.750000,$	$y[11] = 0.238857$
$x[12] = 3.000000,$	$y[12] = 0.204300$
$x[13] = 3.250000,$	$y[13] = 0.176490$
$x[14] = 3.500000,$	$y[14] = 0.153836$
$x[15] = 3.750000,$	$y[15] = 0.135175$
$x[16] = 4.000000,$	$y[16] = 0.119642$
$x[17] = 4.250000,$	$y[17] = 0.106592$
$x[18] = 4.500000,$	$y[18] = 0.095530$
$x[19] = 4.750000,$	$y[19] = 0.086080$
$x[20] = 5.000000,$	$y[20] = 0.077948$

思 考 题

1. 何谓常微分方程的数值解法？一阶微分方程初值问题有哪些数值解法？比较各种方法的优缺点并举具体例子说明之。
2. 何谓数值方法的局部截断误差？ p 阶精度的定义是什么？泰勒展开式在研究局部截断误差中起何作用？
3. 何谓显式、隐式、单步、多步方法？如何使用隐式方法？
4. 阿达姆斯公式是怎样导出的？有何优缺点？
5. 如何求解一阶微分方程组的初值问题？
6. 高阶微分方程的初值问题怎样求解？

习 题 八

1. 分别用显式欧拉公式和欧拉预估-校正公式求解初值问题

$$\begin{cases} y = x^2 - y^2, \\ y(0) = 1 \end{cases} \text{ 在 } x \in [0, 0.5] \text{ 上的数值解 (取 } h = 0.1 \text{).}$$

2. 证明欧拉预估-校正公式可精确求解初值问题 $y' = ax + b$, $y(0) = 0$.

3. 用标准四阶龙格-库塔方法求解初值问题 (取 $h = 0.2$)

$$\begin{cases} y' = \frac{3y}{1+x}, & 0 \leq x \leq 1, \\ y(0) = 1. \end{cases}$$

4. 用阿达姆斯外插公式求初值问题 $\begin{cases} y' = x + y, \\ y(0) = 0 \end{cases}$ 在 $[0, 1]$ 上的数值解 (取 $h = 0.1$).

5. 证明对任何参数 t , 下列是二阶龙格-库塔公式

$$\begin{cases} y_{n+1} = y_n + \frac{1}{2}(k_2 + k_3), \\ k_1 = hf(x_n, y_n), \\ k_2 = hf(x_n + th, y_n + tk_1), \\ k_3 = hf(x_n + (1-t)h, y_n + (1-t)k_2). \end{cases}$$

6. 对初值问题 $y' = f(x, y)$, $y(x_0) = y_0$ 的计算公式

$y_{n+1} = y_n + h[af(x_n, y_n) + bf(x_{n-1}, y_{n-1}) + cf(x_{n-2}, y_{n-2})]$,
假设 $y_{n-2} = y(x_{n-2})$, $y_{n-1} = y(x_{n-1})$, $y_n = y(x_n)$, 试确定参数 a, b, c , 使该公式的局部截断误差为 $O(h^4)$.

7. 利用标准四阶龙格-库塔公式求解微分方程组

$$\begin{cases} y' = \frac{1}{z-x}, & y(0) = 1, \\ z' = -\frac{1}{y} + 1, & z(0) = 1 \end{cases}$$

在 $x \in [0, 1]$ 上的数值解 (取 $h = 0.2$).

8. 构造形如

$$y_{n+1} = a_0 y_n + a_1 y_{n-1} + a_2 y_{n-2} + h[b_0 f(x_n, y_n) + b_1 f(x_{n-1}, y_{n-1}) + b_2 f(x_{n-2}, y_{n-2})]$$

的三阶线性三步公式.

习题答案与提示

习 题 一

1. 49×10^2 : $E = 0.005$, $E_r = 0.0102$, 2 位有效数字;
 0.0490 : $E = 0.00005$, $E_r = 0.00102$, 3 位有效数字;
 490.00 : $E = 0.005$, $E_r = 0.0000102$, 5 位有效数字.
2. $E = 0.0013$, $E_r = 0.00041$, 3 位有效数字.
3. 6 位有效数字.
5. (1) 4.472; (2) 4.47.
6. 0.005 cm.
7. $n \times 1\%$.
8. 2 位有效数字.
10. 第(3)个公式绝对误差最小.
11. $\frac{2x^2}{(1+2x)(1+x)}$, $x \rightarrow 1$;
 $\frac{2}{\sqrt{-x}(\sqrt{x^2+1}+\sqrt{x^2-1})}$, $x \rightarrow 1$;
 $\frac{\left[2\sin^2 \frac{x}{2}\right]}{x}$, $x \rightarrow 1$, $x \rightarrow 0$.
12. 不稳定. 从 x_0 计算到 x_{10} 时误差约为 $\frac{1}{2} \times 10^8$.

习 题 二

1. (1) 精确解为 $x_1 = 3$, $x_2 = x_3 = 1$;
(2) 精确解为 $x_1 = 2$, $x_2 = 1$, $x_3 = \frac{1}{2}$;

- (3) $x_1 = 1.040, x_2 = 0.9870, x_3 = 0.9351, x_4 = 0.8813$.
2. 精确解 $x_1 = x_3 = 1, x_2 = x_4 = -1$.
3. (1) $x_1 = 0, x_2 = 2, x_3 = 1$;
 (2) $x_1 = 1, x_2 = \frac{1}{2}, x_3 = \frac{1}{3}$.
4. $X = (1.11111, 0.77778, 2.55556)^T$.
5. (1) $X = \left[\frac{1507}{665}, -\frac{1145}{665}, \frac{703}{665}, -\frac{395}{665}, \frac{212}{665} \right]^T$;
 (2) $X = (3, 2, 1)^T$.
7. (2) $(-3.999, 2.999, 1.999)^T$.
8. $X^{(10)} = (0.49996, 0.99997, -0.50001)^T$.
12. $\|A\| = 1.1, \|A\|_1 = 0.8, \|A\|_2 = 0.825, \|A\|_F = 0.8426$.
13. (2) 对 $A^T A$ 使用迹定理: 对角元之和等于特征值之和.

习 题 三

1. 0.35.
2. 15 次.
3. (1) 一个根, $\left[0, \frac{1}{4}\right], x_{n+1} = \frac{\sin x_n + \cos x_n}{4}$;
 (2) 一个根, $[1, 2], x_{n+1} = \log_2(4 - x_n)$.
4. (1)、(2) 收敛, (3)、(4) 发散, $= 1.466$.
5. 1.04476.
6. 0.0905.
7. 0.5671.
8. 0.6104.
9. $-(n-1)/2\sqrt[n]{a}, (n+1)/2\sqrt[n]{a}; 15. 1/4a$;
10. 1.879.
11. 1.442250.
12. 0.51098.

习 题 四

1. (1) 11, $(0.6667, 1.3333, 1)^T$;
 (2) 9.005, $(1, 0.6056, -0.3945)^T$.
2. - 13.220180293, $(1, -0.235105504, -0.171621092)^T$;
 - 13.2201809, $(1, -0.2351055, -0.1716216)^T$.
3. - 13.22018, $(1, -0.23510, -0.17162)^T$.
4. $x_1 = 3.4142$, $x_2 = 1.9998$, $x_3 = 0.5959$.
 $X^{(1)} = (0.9926, -0.1207, 0)^T$,
 $X^{(2)} = (0.1207, 0.9926, 0)^T$, $X^{(3)} = (0, 0, 0)^T$.

习 题 五

1. $\frac{5}{6}x^2 + \frac{3}{2}x - \frac{7}{3}$.
2. $-\frac{1}{3}(x-1)(x-2)(x-3) + \frac{3}{2}x(x-2)(x-3)$
 $-\frac{1}{6}x(x-1)(x-2)$.
3. 0.1214.
6. 1.94472.
7. $\frac{1}{162}(23x^3 - 63x^2 - 234x + 324)$.
8. $f(1.682) = 2.5957$, $f(1.813) = 2.9833$.
11. 0.875, 35.375.
12. 0.5.
14. $f(0.45) = 0.798626$, $R < \frac{1}{2} \times 10^{-2}$;
 $f(0.82) = 0.198607$, $R < \frac{1}{2} \times 10^{-2}$.
15. 2.498×10^{-2} .
16. (1) $-3x^2 + 13x^2 - 17x + 9$, $\frac{1}{4!}f^{(4)}(\xi)(x-1)^2(x-2)^2$,

(1, 2);

$$(2) \quad x^3 - \frac{9}{2}x^2 + \frac{11}{2}x - 1, \quad \frac{1}{4}f^{(4)}(\quad)(x-1)(x-2)^2(x-3),$$

(1, 3).

$$17. \quad (1) \quad \begin{cases} S_1(x) = \frac{1}{15}x(1-x)(15-11x), & x \in [0, 1], \\ S_2(x) = \frac{1}{15}(x-1)(x-2)(7-3x), & x \in [1, 2], \\ S_3(x) = \frac{1}{15}(x-3)^2(x-2), & x \in [2, 3]; \end{cases}$$

$$(2) \quad \begin{cases} S_1(x) = \frac{1}{90}x(1-x)(19x-26), & x \in [0, 1], \\ S_2(x) = \frac{1}{90}(x-1)(x-2)(5x-12), & x \in [1, 2], \\ S_3(x) = \frac{1}{90}(3-x)(x-2)(x-4), & x \in [2, 3]. \end{cases}$$

习 题 六

1. $x_1 = 2.9794, \quad x_2 = 1.2259.$
2. $\quad_1(x) = 7.464x + 3.916;$
 $\quad_2(x) = 0.301x^2 + 6.312x + 4.978.$
3. $y = 0.973 + 0.050x^2.$
4. $v_0 = 10.658, \quad a = 4.627.$
5. $y = 95.3524 + 2.2337x.$
6. $I = 5.635e^{-2.889t}.$
7. $y = 3.072e^{0.5057x}.$
8. $y = 2.40 + 1.601 \ln x.$

习 题 七

1. $0.68394, \quad 0.63233, \quad R_1 = 0.08333, \quad R_2 = 0.00035.$
3. 提示 用 $f(x)$ 的泰勒展开式.

4. 5. 03292.
5. 0. 886319.
6. 0. 836214.
7. 0. 71327.
8. 0. 28425.

习 题 八

1. x_n 0 0. 1 0. 2 0. 3 0. 4 0. 5
 欧拉法 y_n 1 0. 9 0. 82 0. 75676 0. 70849 0. 67430
 预估校正 y_n 1 0. 91 0. 83680 0. 77858 0. 73435 0. 70364
3. x_n 0 0. 2 0. 4 0. 6 0. 8 1. 0
 y_n 1 1. 72755 2. 74295 4. 09204 5. 82617 7. 99184
4. x_n 0 0. 2 0. 4 0. 6 0. 8 1. 0
 y_n 0 0. 0214 0. 0918 0. 2221 0. 4255 0. 7182
6. $a = \frac{23}{12}$, $b = -\frac{16}{12}$, $c = \frac{5}{12}$.
7. x_n 0 0. 2 0. 4 0. 6 0. 8 1. 0
 y_n 1 1. 222 1. 493 1. 823 2. 226 2. 718
 z_n 1 1. 019 1. 071 1. 150 1. 250 1. 370

参 考 书 目

- [1] 李庆扬, 王能超, 易大义. 数值分析(第四版). 北京: 清华大学出版社, 施普林格出版社, 2001.
- [2] 封建湖, 车刚明, 聂玉峰. 数值分析原理. 北京: 科学出版社, 2001.
- [3] 邓建中, 刘之行. 计算方法(第二版). 西安: 西安交通大学出版社, 2001.
- [4] 黄友谦, 李岳生. 数值逼近(第二版). 北京: 高等教育出版社, 1987.
- [5] 李信真, 车刚明, 欧阳洁, 封建湖. 计算方法. 西安: 西北工业大学出版社, 2000.
- [6] 徐树方, 高立, 张平文. 数值线性代数. 北京: 北京大学出版社, 2000.
- [7] 梁家荣, 尹琦. 计算方法. 重庆: 重庆大学出版社, 2001.
- [8] 王世儒, 王金金, 冯有前, 李彦民. 计算方法. 西安: 西安电子科技大学出版社, 1996.
- [9] 贺俐, 陈桂兴. 计算方法. 武汉: 武汉大学出版社, 1998.
- [10] 曹志浩. 矩阵特征值问题. 上海: 上海科学技术出版社, 1980.
- [11] 袁慰平, 孙志忠, 吴宏伟, 闻震初. 计算方法与实习(第3版). 南京: 东南大学出版社, 2000.
- [12] 陈宏盛, 刘雨. 计算方法. 长沙: 国防科技大学出版社, 2001.
- [13] 聂铁军, 侯谊, 郑介庸. 数值计算方法. 西安: 西北工业大学出版社, 1990.
- [14] 胡健伟, 汤怀民. 微分方程数值解法. 北京: 科学出版社, 2000.
- [15] 李德志, 刘启海. 计算机数值方法引论. 西安: 西北大学出版社, 1993.
- [16] 王能超. 数值分析简明教程. 北京: 高等教育出版社, 1995.